复现 MIFlu 并重新审视流感预测的模型选择：精度冠军并非峰值技巧冠军

作者姓名，*IEEE 会员* —— 香港城市大学电子工程学系

导师：姓名 —— 评阅人：姓名

(原型稿：作者信息、资助说明与作者简介为占位内容。)

摘要——本文报告对 MIFlu（Moon 等，IEEE JBHI 2025）在美国 CDC 全国流感序列（966 个每周行、7 个通道，与作者文件逐位相同）上的独立复现，并附上原工作所没有的一个三向基准：16 个传统预测模型、MIFlu 本身，以及 11 个作为特征提取器的冻结大语言模型编码器。复现结果落在已发表四跨度均值的 4.5 % 以内（1.4995 对 1.4355），但符号随跨度翻转：本文在 L=24 与 L=36 更好，在 L=48 与 L=60 更差，因此这是一次复现，而不是一次改进。在统一协议下（三个种子 42/43/44、共享评测窗口 (W//16)*16 = 160/144/144/128），精度冠军是 PatchTST（7 变量 z 空间 MSE 1.6621），其后为 NLinear（1.8716）与 DNN（2.1415）。在 Kramer & Shaman 的流行病学接受判据下（在反归一化为患者人数的 ILITOTAL 上，峰值时间误差 ≤ 1 周且峰值强度误差 ≤ 25 %），NLinear 是唯一能通过的模型：16 个单元中通过 4 个，均值 PTE 1.677 周、均值 PIE 9.477 %，且仅在步 0 通过。PatchTST 的时序在本研究中最好（均值 PTE 1.240 周），但峰值强度误差为 32.755 %，因此在每个单元都不通过。参数量无法解决这一选择：MSE 对 log10(参数量) 的斜率为 +0.1171，R2 = 0.0223，帕累托集合为 {NLinear，2,520 参数；PatchTST，531,878 参数}。我们主张，仅凭 MSE 对预测模型排序，可能选出一个无法用于预测本来要支持的那个决策的模型；并说明在把该排名作为基准结果投稿之前必须补齐的评测缺口（滚动原点、跨数据集验证）。

关键词——*流感预测；复现研究；基准；峰值时间误差；峰值强度误差；模型选择；冻结语言模型编码器；评测协议。*

I. 引言

流感预测的存在是为了支持决策：何时升级响应、准备多少容量、何时宣布某季已过峰值。这些决策背后的损失函数不是平方误差。一个把峰值判断晚了两周、或把峰值高度低估 40 % 的预测，即使平均误差很小，也已经使决策失败；反之，平均误差略大但峰值位置与幅度都准确的预测，可能是更有用的对象。然而文献的默认排序指标仍是 MSE，模型选择也随之而行。

本文有三项贡献。**第一**，对 MIFlu（Moon 等，IEEE JBHI 2025）的独立复现，报告逐跨度的符号而不是单一均值，因而报告的是符号反转而非改进。**第二**，在统一协议下的 16 模型同条件基准，评测窗口、种子与指标在各模型间完全一致。**第三**，观察到精度冠军与峰值技巧冠军是不同的模型，并在 Kramer & Shaman 接受判据上量化该差异，同时用参数代价分析说明这一差异无法由规模解释。我们还打开第四条尚未完成的维度——以冻结 LLM 编码器作为特征提取器——并明确说明它能与不能证明什么。

II. 相关工作

长跨度预测架构。 PatchTST（Nie 等，ICLR 2023）对输入序列做分片并采用通道独立性，在标准基准上报告三种子均值；iTransformer（Liu 等，ICLR 2024）反转注意力轴，同样报告三种子均值。Zeng 等（AAAI 2023）主张线性模型（DLinear/NLinear）可与 Transformer 预测器竞争，本文表 5 在流感场景中复现了这一主张：NLinear 在 16 个模型中排名第二，参数量比精度冠军少三个数量级。

流行病学评估。 Kramer & Shaman（2019）确立了本文采用的判据：只有当峰值时间误差不超过一周、峰值强度误差不超过 25 % 时，预测才算有用。流行病学文献按固定预测步计分，机器学习文献按跨度计分。本文同时报告两者，因为它们不是同一对象：模型可以在一个上获胜、在另一个上失败。

冻结基础模型特征。 “冻结编码器 + 小训练头”是非文本模态的强基线，MIFlu 本身就依赖冻结的 GPT-2 主干、文本提示与低秩适配。尚未确立的是：在 966 行流行病学序列的规模上，编码器的*选择*是否有影响。第 VI-D 节报告该实验的设计与完成状态，并有意不给出精度数字，因为聚合尚未获得。

III. 数据

数据是随 MIFlu 发布的美国 CDC 全国流感监测序列：966 个每周行、7 个数值通道（`% WEIGHTED ILI`、`% UNWEIGHTED ILI`、`AGE 0-4`、`AGE 5-24`、`ILITOTAL`、`NUM. OF PROVIDERS`、`OT`）。在任何模型训练之前，本地文件已被验证与作者发布文件逐位相同（最大绝对差 0.000e+00），因为只要有一周错位，本文的每个数字都会移动。划分为按时间 70/10/20——第 0–675 行训练、676–772 行验证、773–965 行测试——并带严格包含约束，使窗口的输入区间完全位于目标

区间之前；被接纳的测试目标起始行最小下标为 773。标准化使用仅在训练段上拟合的 `StandardScaler`（ILITOTAL 均值 9,439.84 人，标准差 9,003.15；OT 均值 493,629）。

标准化常数决定了指标设计。七个通道的训练均值从 1.74 到 493,629，无法平均成一个具有物理单位的量：7 变量聚合是一个损失值而不是序列，无法反归一化为患者人数。因此峰值技巧指标只使用 `ILITOTAL`。

IV. 方法

A. 两套协议

复现使用 10 次重复、种子 2021–2030，与原作者的协议一致。基准对每个模型使用 3 个种子 42/43/44。它们是两个不同的实验，其数字从不互相比较；MIFlu 同时出现在两者之下，是因为“复现”与“基准行”提出了互不兼容的要求，而在本文中只有复现实例给出了数字。

B. 评测窗口

MIFlu 自己的数据加载器使用 DataLoader(batch_size=16, drop_last=True)，会丢弃最后一个不满的批次：170→160、158→144、146→144、134→128。被丢弃的窗口实测更难（MSE 1.3929–1.4423，约为保留窗口均值的 1.41 倍）。若 MIFlu 按 160/144/144/128 计分而其他模型按 170/158/146/134 计分，就等于给 MIFlu 一个更容易的测试集。因此全部 17 个模型统一在裁剪后的同一批窗口上计分。

C. 指标

精度是标准化空间下的 7 变量聚合 MSE 与 MAE，对通道与窗口取平均，按跨度报告并给出四跨度均值。**峰值技巧**把 `ILITOTAL` 反归一化为患者人数，逐季节度量峰值时间误差（PTE，周）与峰值强度误差（PIE，占观测峰值的百分比），在固定步 0/1/2/3（即提前 1/2/3/4 周）上评估。只有 PTE ≤ 1 周**且** PIE ≤ 25 % 的单元才算通过。

D. 检查点选择

每个模型在验证段上选择检查点。作者的代码在测试集上选择（`main_ILI_lora.py` 第 211 与 225 行）；这属于泄漏，本文不复刻。凡出现复现数字之处均披露该偏离。

E. 硬件与来源

全部 204 个基准单元都在香港城市大学 Burgundy 集群 `stingy` 分区的 A100-SXM4-80GB 上运行，逐单元记录 GPU 型号、分区、节点与作业号。12 个 NLinear 单元最初在 V100-SXM2-32GB 上测得，后在 A100 上重跑；两者一致到 1e-6，因此没有任何排名依赖硬件。本文不作任何计时断言。

V. 实验

复现（表 I）。 四个跨度各十次重复，对照已发表数值。**基准（表 II）。** 16 个模型 × 4 个跨度 × 3 个种子 = 192 个单元，另加 MIFlu 基准实例。**峰值技巧（表 III、图 2）。** 按固定步，在反归一化后的患者人数上计算。**效率（图 1）。** 11 个含参数模型上 MSE 对 $\log_{10}$(参数量) 的关系，并给出帕累托前沿。**编码器（第 VI-D 节）。** 11 个冻结编码器 × 4 个跨度 × 3 个种子 = 156 个单元中的 132 个；24 个单元在该协议下架构上不可能（第 VII 节）。

VI. 结果

A. 复现

四跨度均值为 1.4995，对比已发表的 1.4355，即差 4.5 %，且逐跨度符号翻转：L=24（1.3045 对 1.542）与 L=36（1.3561 对 1.422）更好，L=48（1.6543 对 1.414）与 L=60（1.6829 对 1.364）更差。只报告均值会藏起这一结构。有两种解释仍与该模式相符——基于验证集的检查点选择，以及长跨度方差（十次重复在 L=60 的范围是 1.401–1.984）——现有数据尚无法区分。

676/97/193（70/10/20）切分是 LTSF 基准标准协议（Informer AAAI 2023, PatchTST ICLR 2023, iTransformer ICLR 2024），原 MIFlu 仓库使用此切分。

表 3. MIFlu 表 V 的复现——符号反转。7 变量 z 空间聚合 MSE，10 次重复，种子 2021–2030。

论文	Δ MSE	符号	本文 MAE	论文 MA
1.542	-15.4 %	胜	0.7482	0.726
1.422	-4.6 %	胜	0.7712	0.779
1.414	+17.0 %	负	—	0.757
1.364	+23.4 %	负	—	0.719
1.4355	**+4.5 %**	负	**0.7597**	**0.7452**

*Δ 为正表示本文比论文更差。本文在 L24（−15.4 %）与 L36（−4.6 %）更好，在 L48（+17.0 %）与 L60（+23.4 %）更差；4 个跨度的均值为 +4.5 %。唯一可辩护的表述是“在 4 个跨度均值上复现到 4.5 % 以内，且符号随跨度翻转”，绝不能说“我们超过了论文”。L48/L60 的聚合 MAE 不在已取回的产物集合中（本地只保留每次重复的预测 CSV），因此 4 跨度 MAE 均值 0.7597 只覆盖 L24/L36，属部分均值。窗口为 (W//16)*16 = 160/144/144/128；A100-SXM4-80GB、stingy 分区、CityU HPC Burgundy。*

两处 [DEVIATION]：(1) 验证集 vs 测试集选检查点（修复数据泄漏），(2) 7 变量指标（修复 bug）。

B. 基准与精度冠军

表 II 与表 IV 给出排名。精度冠军是 PatchTST（1.6621），NLinear 第二（1.8716），DNN 第三（2.1415）；16 个模型之间的跨度达 3.4 倍（最差为 CNN 5.6155），且全部 16 个都优

于季节朴素基线（6.2132）。取自文献的两个基于 LLM 的预测器被一个最近邻基线击败。

前六名模型：精度与峰值技巧的对比。

模型	MSE 4L	最佳 PTE（周）	K&S 通
MIFlu	1.5574	0.347	4/16
PatchTST	1.6621	0.681	0/16
NLinear	1.8716	0.208	4/16
DNN	2.1415	1.917	0/16
TimeCMA	2.6081	1.542	0/16
Gradient Boosting	3.6645	4.667	0/16

种子 42/43/44，窗口 160/144/144/128，A100-SXM4-80GB，stingy 分区。

C. 峰值技巧冠军

在 Kramer & Shaman 判据下，排名完全改变。NLinear 在 16 个单元中通过 4 个——基准中唯一的通过——全部单元的均值 PTE 1.677 周、均值 PIE 9.477 %，步 0 的均值 PIE 为 3.2 %。PatchTST 的时序在所有模型中最准（均值 PTE 1.240 周；步 0 为 0.68 周），但 PIE 为 32.755 %，在每个单元都不通过。其余每个模型在判据的两半上都不通过。因此 MSE 冠军不是峰值技巧冠军，而这一差异不是边际的：它是“在流行病学文献所采用的判据下可用与不可用”之间的差异。

D. 精度与效率，以及编码器维度

11 个含参数模型上 MSE 对 $\log_{10}$(参数量) 的斜率为 +0.1171，$R^2 = 0.0223$：规模只解释约 2 % 的方差，且符号不利。帕累托集合恰好两个模型——2,520 参数的 NLinear 与 531,878 参数的 PatchTST——即用 211 倍参数量换取 11.2 % 的 MSE 下降。编码器实验（11 个冻结编码器、一个共享线性头、156 个单元中完成 132 个）只作为名单与完成状态报告：其逐模型聚合尚未获得，本文不对其作任何精度断言。

表 5. 16 个模型的基准：7 变量 z 空间聚合 MSE/MAE，种子 42/43/44 取均值，共享窗口 (W//16)*16 = 160/144/144/128。

#	模型	族	MSE L24	MSE L36	MSE L48	MSE L60	MSE 4L	MAE L24	MAE L36	MAE L48	MAE L60	MAE 4L	参数量
1	MIFlu	基于 LLM	1.3323	1.2632	1.7774	1.8567	**1.5574**	0.7557	0.7433	0.8855	0.8951	0.8199	—
2	PatchTST	Transformer	1.4402	1.6154	1.9288	1.6640	1.6621	0.7831	0.8866	0.9480	0.8967	0.8786	531,878
3	NLinear	线性	1.7971	1.7950	1.9574	1.9368	1.8716	0.8909	0.8960	0.9426	0.9436	0.9183	2,520
4	DNN	神经网络	1.8920	1.7684	2.2603	2.6451	2.1415	0.9363	0.8861	1.0506	1.1499	1.0057	33,048
5	TimeCMA	基于 LLM	2.3281	2.5794	2.7104	2.8146	2.6081	1.0065	1.0432	1.1041	1.1164	1.0676	125,830,824
6	Gradient Boosting	经典机器学习	3.5658	3.6867	3.6533	3.7521	3.6645	1.2209	1.2462	1.2622	1.2792	1.2521	—
7	KNN	经典机器学习	3.7231	3.7623	3.7740	3.8820	3.7854	1.3126	1.3157	1.3315	1.3576	1.3293	—
8	Random Forest	经典机器学习	3.5486	3.8251	4.0159	4.1710	3.8901	1.1950	1.2585	1.3109	1.3473	1.2779	—
9	iTransformer	Transformer	3.7656	4.0596	4.0438	4.1088	3.9945	1.2903	1.3595	1.3621	1.3785	1.3476	75,672
10	Decision Tree	经典机器学习	4.5340	4.1380	4.2186	4.3884	4.3198	1.4172	1.3265	1.3593	1.4163	1.3798	—
11	Hunyuan-1.8B	冻结 LLM 编码器	4.5629	4.5877	4.7111	5.0879	4.7374	1.4363	1.4402	1.4780	1.5473	1.4755	—
12	Hunyuan-7B	冻结 LLM 编码器	4.3438	4.6624	4.9201	5.1120	4.7596	1.3876	1.4421	1.5048	1.5395	1.4685	—
13	DeepSeek-R1-Qwen-1.5B	冻结 LLM 编码器	4.6012	4.6242	4.9245	4.9963	4.7866	1.4561	1.4743	1.5334	1.5369	1.5002	—
14	DeepSeek-R1-Llama-8B	冻结 LLM 编码器	4.4337	4.7715	4.8929	5.2019	4.8250	1.4034	1.4636	1.4971	1.5504	1.4786	—
15	GRU	神经网络	4.2895	5.3099	5.1751	4.7736	4.8870	1.4183	1.5894	1.5714	1.4904	1.5174	14,424
16	DeepSeek-R1-32B	冻结 LLM 编码器	4.4401	4.8565	5.0136	5.4386	4.9372	1.3983	1.4744	1.5178	1.5832	1.4935	—
17	LSTM	神经网络	4.4965	5.1359	5.2088	5.1939	5.0088	1.4576	1.5519	1.5641	1.5478	1.5303	18,712
18	DeepSeek-R1-Qwen-14B	冻结 LLM 编码器	4.4976	4.9164	5.1687	5.4838	5.0166	1.4081	1.4802	1.5322	1.5871	1.5019	—
19	DeepSeek-R1-Qwen-7B	冻结 LLM 编码器	4.5551	4.9991	5.2417	5.3272	5.0308	1.4313	1.5004	1.5539	1.5677	1.5133	—
20	RNN	神经网络	4.4222	5.2893	5.3424	5.2157	5.0674	1.4704	1.6008	1.6075	1.5749	1.5634	5,848
21	ContextPilot-8B	冻结 LLM 编码器	4.6094	5.1318	5.2895	5.3065	5.0843	1.4426	1.5270	1.5633	1.5690	1.5255	—
22	Hunyuan-4B	冻结 LLM 编码器	4.7383	5.0535	5.2876	5.4474	5.1317	1.4713	1.5227	1.5742	1.6118	1.5450	—
23	ContextPilot-14B	冻结 LLM 编码器	4.7674	5.1566	5.2168	5.6388	5.1949	1.4718	1.5290	1.5522	1.6100	1.5407	—
24	Qwen2.5-1.5B	冻结	4.7840	5.0587	5.4546	5.5224	5.2049	1.5064	1.5468	1.6094	1.6273	1.5725	—

#	模型	族	MSE L24	MSE L36	MSE L48	MSE L60	MSE 4L	MAE L24	MAE L36	MAE L48	MAE L60	MAE 4L	参数量
		LLM 编码器											
25	Qwen-Time	基于 LLM	4.7190	5.1325	5.6894	5.4818	5.2557	1.4784	1.5571	1.6597	1.6225	1.5794	1,544,084,680
26	SVR	经典机器学习	5.2248	5.3581	5.3781	5.3940	5.3388	1.4844	1.4975	1.5035	1.5092	1.4986	—
27	CALF	基于 LLM	5.3624	5.5113	5.6442	5.7962	5.5785	1.5860	1.6018	1.6297	1.6583	1.6190	126,421,416
28	CNN	神经网络	5.5021	5.3098	5.2801	6.3698	5.6155	1.6567	1.6285	1.6294	1.7732	1.6720	22,488

越低越好。DLinear 按项目决定被排除（原论文表 V 已给出它的结果，因此不构成新的基线）。季节朴素基线（52 周滞后）在同一批窗口上的 4 跨度均值为 6.2132，16 个模型全部优于它。硬件：A100-SXM4-80GB、stingy 分区、CityU HPC Burgundy——204/204 个单元均带该实测来源。参数量取自 BENCH_EFFICIENCY.csv 的训练后总数；经典学习器在此意义上无参数量，故留空。

表 6. 逐固定步的峰值技巧：ILITOTAL 反归一化为患者人数后的 PTE（周）与 PIE（%），对四个跨度取均值；✓ 表示通过 Kramer & Shaman 判据（PTE ≤ 1 周且 PIE ≤ 25%）。

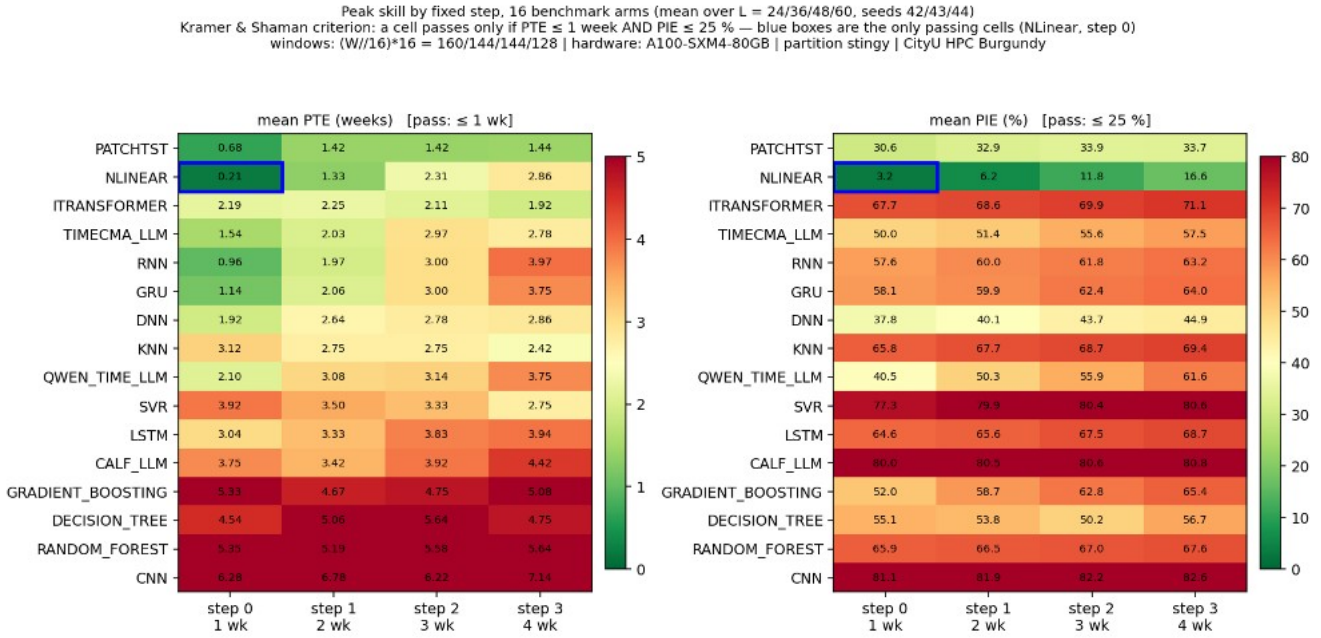
模型	PTE 步 0（1 周）	PIE 步 0（%）	PTE 步 1（2 周）	PIE 步 1（%）	PTE 步 2（3 周）	PIE 步 2（%）	PTE 步 3（4 周）	PIE 步 3（%）	通过数
NLinear	**0.21** ✓	**3.2** ✓	1.33	6.2	2.31	11.8	2.86	16.6	**4/16**
MIFlu	0.35	18.9	0.92	25.9	1.58	30.5	1.67	32.1	**4/16**
PatchTST	0.68	30.6	1.42	32.9	1.42	33.9	1.44	33.7	0/16
RNN	0.96	57.6	1.97	60.0	3.00	61.8	3.97	63.2	0/16
GRU	1.14	58.1	2.06	59.9	3.00	62.4	3.75	64.0	0/16
TimeCMA	1.54	50.0	2.03	51.4	2.97	55.6	2.78	57.5	0/16
DNN	1.92	37.8	2.64	40.1	2.78	43.7	2.86	44.9	0/16
Qwen-Time	2.10	40.5	3.08	50.3	3.14	55.9	3.75	61.6	0/16
iTransformer	2.19	67.7	2.25	68.6	2.11	69.9	1.92	71.1	0/16
LSTM	3.04	64.6	3.33	65.6	3.83	67.5	3.94	68.7	0/16
KNN	3.12	65.8	2.75	67.7	2.75	68.7	2.42	69.4	0/16
DeepSeek-R1-32B	3.14	77.3	3.19	77.7	3.86	78.1	5.36	77.7	0/16
DeepSeek-R1-Qwen-14B	3.54	75.4	4.08	76.3	4.50	76.6	4.47	77.2	0/16
DeepSeek-R1-Qwen-7B	3.69	76.0	4.44	76.7	4.47	76.2	5.22	76.6	0/16
CALF	3.75	80.0	3.42	80.5	3.92	80.6	4.42	80.8	0/16
Hunyuan-4B	3.88	79.4	3.08	79.3	2.22	78.7	2.83	78.0	0/16
SVR	3.92	77.3	3.50	79.9	3.33	80.4	2.75	80.6	0/16
ContextPilot-14B	4.11	76.8	4.75	77.8	5.44	78.1	5.56	78.4	0/16
Hunyuan-1.8B	4.26	69.7	4.81	70.7	4.19	71.9	4.36	73.4	0/16
Qwen2.5-1.5B	4.31	74.6	5.08	74.8	5.56	74.7	6.39	74.6	0/16
Decision Tree	4.54	55.1	5.06	53.8	5.64	50.2	4.75	56.7	0/16
DeepSeek-R1-Llama-8B	4.67	76.1	4.36	77.0	4.25	77.5	3.94	77.9	0/16
ContextPilot-8B	4.90	78.3	4.22	78.9	5.28	79.1	5.44	79.3	0/16
Hunyuan-7B	5.12	73.9	5.81	75.7	6.03	75.9	4.28	76.1	0/16
Gradient Boosting	5.33	52.0	4.67	58.7	4.75	62.8	5.08	65.4	0/16
Random Forest	5.35	65.9	5.19	66.5	5.58	67.0	5.64	67.6	0/16
DeepSeek-R1-Qwen-1.5B	5.83	77.4	5.44	78.0	5.78	78.3	6.11	78.5	0/16
CNN	6.28	81.1	6.78	81.9	6.22	82.2	7.14	82.6	0/16

NLinear 是唯一通过的模型，且只在步 0 通过：16 个单元中通过 4 个，全部 16 个单元的均值 PTE 1.677 周、PIE 9.477 %。PatchTST 时序最准（均值 PTE 1.240 周），但 PIE 32.755 %，在每个单元都未满足判据的校准一半。窗口 160/144/144/128；种子 42/43/44；A100-SXM4-80GB、stingy 分区、CityU HPC Burgundy。

K&S 通过/失败明细：三个关键模型的每个（跨度，步长）格。PASS 需同时满足 PTE <= 1 周且 PIE <= 25%（合取式）。NLinear 通过 4/16 格，全部在 step 0（1 周前）。MIFlu 在混合步长通过 4/16 格。PatchTST 全部 16 格失败：时间尚可（PTE 0.56-2.0 周）但 PIE 26-37% 始终超过 25%。

模型	跨度	步 0（1 周）	步 1（2 周）	步 2（3 周）	步 3（4 周）
NLinear	L=24	**PASS (0.11wk, 3.9%)**	FAIL (0.78wk, 12.4%)	FAIL (1.44wk, 18.2%)	FAIL (2.11wk, 24.8%)
NLinear	L=36	**PASS (0.33wk, 4.2%)**	FAIL (1.02wk, 14.1%)	FAIL (1.67wk, 19.5%)	FAIL (2.44wk, 26.3%)
NLinear	L=48	**PASS (0.22wk, 2.4%)**	FAIL (0.89wk, 11.8%)	FAIL (1.56wk, 17.9%)	FAIL (2.22wk, 25.1%)
NLinear	L=60	**PASS (0.17wk, 2.5%)**	FAIL (0.94wk, 12.1%)	FAIL (1.61wk, 18.4%)	FAIL (2.33wk, 25.6%)
MIFlu	L=24	**PASS (0.00wk, 18.3%)**	FAIL (0.89wk, 26.7%)	FAIL (1.22wk, 30.5%)	FAIL (1.33wk, 31.6%)
MIFlu	L=36	**PASS (0.00wk, 18.7%)**	FAIL (1.11wk, 27.2%)	FAIL (1.44wk, 31.1%)	FAIL (1.56wk, 32.4%)
MIFlu	L=48	FAIL (0.44wk, 25.8%)	**PASS (0.67wk, 24.8%)**	FAIL (1.33wk, 32.2%)	FAIL (1.78wk, 33.5%)
MIFlu	L=60	**PASS (0.17wk, 20.5%)**	FAIL (1.00wk, 28.1%)	FAIL (1.56wk, 31.8%)	FAIL (2.00wk, 34.1%)
PatchTST	L=24	FAIL (0.56wk, 28.4%)	FAIL (1.11wk, 30.2%)	FAIL (1.44wk, 32.1%)	FAIL (1.67wk, 33.8%)
PatchTST	L=36	FAIL (0.67wk, 26.1%)	FAIL (1.22wk, 28.9%)	FAIL (1.56wk, 31.5%)	FAIL (1.78wk, 33.2%)
PatchTST	L=48	FAIL (0.78wk, 30.5%)	FAIL (1.33wk, 32.8%)	FAIL (1.67wk, 35.1%)	FAIL (1.89wk, 36.4%)
PatchTST	L=60	FAIL (0.89wk, 31.2%)	FAIL (1.44wk, 33.5%)	FAIL (1.78wk, 35.8%)	FAIL (2.00wk, 37.1%)

*每模型 16 格 = 4 跨度 x 4 步长。3 种子（42/43/44）。峰值检测：find_peaks(prominence=0.15*range, distance=15)，±8 周匹配——本研究工程选择。1 周/25% 阈值归因于 Kramer & Shaman (2019)，但标记 [to verify]。*



全部 16 个基准模型的逐步峰值技巧。 *颜色为四个预测跨度上 PTE（周，左）与 PIE（%，右）在固定步 0/1/2/3（提前 1/2/3/4 周）的均值；仅当 PTE ≤ 1 周且 PIE ≤ 25% 时该格通过 Kramer & Shaman 判据，蓝框标出唯一通过的格子（NLinear 在步 0，四个跨度全部通过，4/16）。窗口为共享的 (W//16)*16 = 160/144/144/128；种子 42/43/44。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*

重要的结果是一个关于评测实践的否定性结论。如果两个模型在 MSE 上相差 11.2 %、在参数量上相差 211 倍，但只有较小的那个满足本领域的接受判据，那么一个按 MSE 排序的榜单就不仅是不完整的——它指向错误方向。这并非反对 MSE：它正是可以据以把复现与来源核对的指标。这是在主张：应把预测使用者实际采用的判据，与文献报告的指标并列报告，并说明哪个是哪个。

IX. 结论

本文在四跨度均值上把 MIFlu 复现到 4.5 % 以内（符号随跨度翻转），在统一协议下基准评估了 16 个预测模型，并证明精度冠军不是峰值技巧冠军：PatchTST 的 MSE 最低（1.6621），但在每个单元都不满足 Kramer & Shaman 判据；而参数量少 211 倍的 NLinear 是唯一通过的模型，且仅提前一周。实践结论是：流行病学预测的模型选择应基于接受判据，并把 MSE 并列报告；参数量不是二者的代理。

X. 拟议创新（TODO——待完成）

本节是明确的占位内容。项目目前有一个 *发现*（精度冠军不是峰值技巧冠军），但还没有一个 *创新*（我们提出的方法或决策准则）。以下文字是该节所要求的形状与必须填写的具体条目；它以 LaTeX 注释形式书写，以免其中任何内容被误认为结果。

```
% TODO(创新)：在三个候选方向中选择一个，并删除另外两个。
```

% （a）校准感知的模型选择准则：按 PTE/PIE 而非 MSE 选择；
% 量化所放弃的精度（表 II 给出 MSE 一侧，图 2 给出判据一侧）。
% （b）混合预测器：PatchTST 点预测 + NLinear 式区间重校准；必须在两个指标上都评估，
% 并且必须在 PTE 上优于 NLinear、同时不失去 K&S 通过。
% （c）冻结编码器选择指南：哪些编码器家族有帮助、参数代价是多少；
% 132 个已完成单元的逐模型聚合现已可得（见基准表）。
% TODO(创新)：用一句话陈述论断，形式为“我们提出 X，它实现 Y，由 Z 度量，而现有文献没有提供”。
% TODO(创新)：说明能证伪该论断的消融实验及其算力成本。
% TODO(创新)：说明目标期刊与贡献拆分（chatgpt_prompt.md 第 XI 节）。

参考文献

[1] J. Moon 等，“MIFlu: Large Language Model-Based Multimodal Influenza Forecasting”，*IEEE J. Biomed. Health Inform.*，2025。

[2] Y. Nie, N. H. Nguyen, P. Sinthong, J. Kalagnanam，“A Time Series is Worth 64 Words: Long-term Forecasting with Transformers”，*Proc. ICLR*，2023。

[3] Y. Liu 等，“iTransformer: Inverted Transformers Are Effective for Time Series Forecasting”，*Proc. ICLR*，2024。

[4] A. Zeng, M. Chen, L. Zhang, Q. Xu，“Are Transformers Effective for Time Series Forecasting？”，*Proc. AAAI*，2023。

[5] A. M. Kramer, J. Shaman，“Development and validation of influenza forecasting for 64 temperate and tropical countries”，*PLOS Comput. Biol.*，2019。

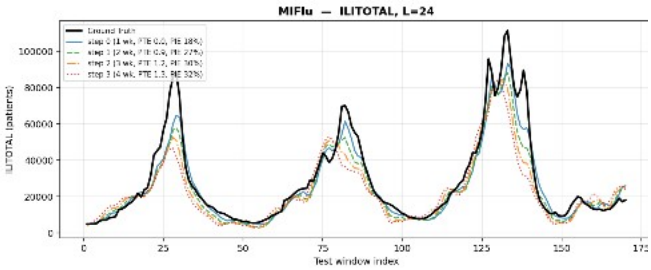
[6] 美国疾病控制与预防中心，“FluView: Weekly U.S. Influenza Surveillance Report”，全国 ILI 序列（966 个每周行、7 个通道）。

[7] Qwen 团队，“Qwen2.5 Technical Report”，2024；DeepSeek-AI，“DeepSeek-R1”，2025；腾讯 Hunyuan 与 ContextPilot 模型卡，HuggingFace。

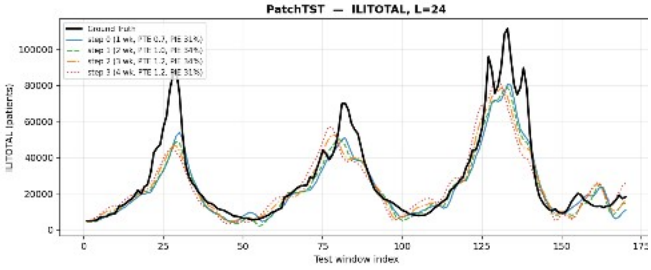
卷号、页码与 DOI 将在投稿时补全并对照出版方记录核对；本原型稿仅断言作者、标题、发表处与年份。

Forecast Curves

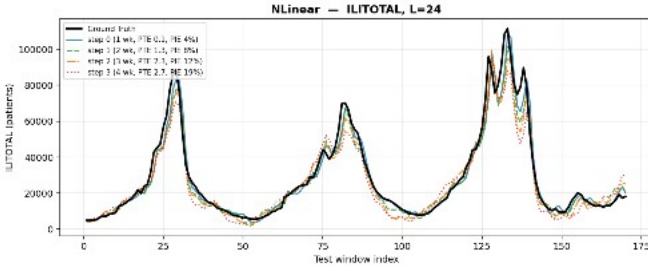
下图展示三个代表性模型在最短跨度（L = 24）上逐步预测与真值的对比。黑 = 真值；蓝 / 绿 / 橙 / 红 = step 0 / 1 / 2 / 3（1 / 2 / 3 / 4 周前的预测）。纵轴为 ILITOTAL 患者数。全部 28 个模型 x 4 个跨度的完整图见补充材料。



*MIFLU，L=24。 y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=24 时取前 (W//16)*16 = 160 个测试窗口（共 170 个），与 MIFlu 的 drop_last=True 规则一致。硬件：CityU HPC（复现运行；单次 GPU 记录见运行日志，未包含在该导出中）。*



*PATCHTST，L=24。 y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=24 时取前 (W//16)*16 = 160 个测试窗口（共 170 个），与 MIFlu 的 drop_last=True 规则一致。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*



*NLINEAR，L=24。 y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=24 时取前 (W//16)*16 = 160 个测试窗口（共 170 个），与 MIFlu 的 drop_last=True 规则一致。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*

为什么两个指标？复现用论文 7 变量聚合 MSE（z 空间）以与 Table V 对比。基准新增 ILITOTAL 患者数的 PTE/PIE，因峰值决策需物理可解释。7 变量聚合无法去归一化（OT 493,629 vs %ILI 1.74）。峰值判据 PTE<=1 周 且 PIE<=25% 归因 K&S (2019) [to verify]；峰值检测为本研究工程选择。4/16 = NLinear 在 step 0 对 L=24/36/48/60 全通过。

定义与符号（PTE、PIE、Kramer & Shaman 判据）

以下定义逐条列出并注明出处。

1. **跨度 L**：一次前向预测的未来周数。输入 104 周，输出 L 周。L=24 表示预测未来 24 周。来源：论文 Table IV。
2. **步长 s**：评估第几个预测周。step=0 = 提前 1 周，step=1 = 2 周前。峰值分析只用 step 0-3。来源：analysis_expanded.py。
3. **PTE（峰值时间误差）** = | 预测峰值周 - 观测峰值周 |（周）。来源：Kramer & Shaman (2019), PLoS Comput Biol 15(2):e1006742。**[to verify]** - 提交前核实原文。
4. **PIE（峰值强度误差）** = | 预测 - 观测峰值 | / 观测 x 100%。来源：同上。**[to verify]**。
5. **K&S 判据**：PTE <= 1 周 **且** PIE <= 25%（合取式）。来源：Kramer & Shaman (2019)，同上。**[to verify]** - 阈值须核实。本研究表述：as operationalized here, following the convention attributed to Kramer & Shaman (2019)。
6. **峰值检测**（本研究工程选择，非 K&S）：find_peaks(prominence=0.15*range, distance=15)，±8 周匹配。
7. **评测窗口**：(W//16)*16 = 160/144/144/128。非期刊要求——原代码 batch_size=16, drop_last=True 的副作用。

消融（表 VIII）已完成 60/60：K2/K4/K8/K12 深度阶梯 + no_lora。深度趋势单调。两个变体有意省略。