提交：FYP InfoNet，2026 年 11 月 20 日 23:59 前

香港城市大学 — 进度报告

电子工程学系 · 毕业设计进度报告，2026/27 学年 A 学期

项目题目	复现 MIFlu 并以冻结 LLM 编码器基准评估流感预测
报告日期	2026 年 11 月 2 日

PART A

学生姓名：_____ 学号：_____

专业：_____

项目编号与标题：_____ 复现 MIFlu 并以冻结 LLM 编码器基准评估流感预测

导师姓名：_____ 评阅人姓名：_____

与导师/评阅人会面次数：_____

每周平均投入时间：_____ 小时/周

PART B

1. 项目目标

问题陈述。 流感预测直接影响公共卫生资源分配。Moon et al.（IEEE JBHI 2025）提出 MIFlu，一个多模态模型（GPT-2 时间序列编码 + 文本嵌入），在 CDC 全国流感数据上报告了最佳精度。但该论文仅与两个简单基线比较，仅用单一随机种子，且在测试集上选择模型检查点（数据泄漏）。因此公共卫生团队无法回答：**MIFlu 是不是最该部署的模型？**

目标：

1. 用严格协议**复现 MIFlu 的 Table V**（10 种子、验证集选检查点、7 变量聚合 MSE），量化与论文的差距。
2. 在同一数据上**基准评估 28 个预测模型**（16 常规 + MIFlu + 3 基于 LLM + 11 冻结 LLM 编码器），同时用精度（MSE/MAE）和峰值预测技能（PTE/PIE，Kramer & Shaman 判据）。
3. **确定公共卫生团队应部署哪个模型**，并判断大语言模型是否改善流行病学预测。

2. 原始项目规划图

时间线（2026 年 9 月 – 12 月）：

- **2026 年 9 月（第 1-4 周）：** 数据获取与验证（966 周 CDC 数据集，逐字节校验）。里程碑：数据集确认一致。
- **2026 年 10 月（第 5-8 周）：** MIFlu 代码重建（17 项保真修复），复现实验（10 种子 × 4 跨度）。里程碑：Table V 复现完成。
- **2026 年 11 月（第 9-12 周）：** 基准实验（28 模型 × 3 种子 × 4 跨度）、LLM 编码器基准、Table VIII 消融（60/60）、分析、进度报告。里程碑：基准完成。

- **2026 年 12 月（第 13-16 周）：** 创新实验、论文撰写、投稿。

3. 背景研究

技术背景。 流感预测从统计模型（ARIMA、Prophet）发展到深度学习（LSTM、Transformer），再到最近的大语言模型（LLM）。MIFlu 代表 LLM 方法：用 LoRA 适配器在 CDC 全国流感数据（966 周 × 7 变量）上微调 GPT-2，报告了最佳精度。但其比较集有限，评测协议存在问题（测试集选检查点、单种子）。

当代与社会背景。 新冠疫情后，各国政府投资 AI 流感预测。WHO 和 CDC 用预测分配疫苗和抗病毒药物。但 2024 年 *Nature Medicine* 综述指出，多数 AI 预测论文仅与弱基线比较且缺乏可复现性。本研究同时解决这两个问题：严格复现（修复数据泄漏）+ 28 模型基准——直接回答 LLM 是否真的帮助公共卫生预测。

4. 方法

我们采用两部分设计：(1) 严格修复后的 MIFlu Table V 忠实复现；(2) 28 模型受控基准。下表对比我们的设置与原论文。

复现：本文 vs 原论文/仓库。

参数	本文	原论文	说明
数据	966 周 x 7 变量	相同	字节一致
切分	676/97/193	相同	按时间
输入窗口 T	104 周	相同	
跨度 L	24/36/48/60	相同	独立训练
种子（复现）	2021-2030（10 次）	fix_seed=2021（1 次）	[偏离] 论文声称 10 次
轮数	20	默认=1	1 轮不收敛
学习率	1e-4	代码 1e-4 / 论文 5e-4	论文矛盾
批大小	16	相同	drop_last=True
优化器	Adam	相同	
GPT-2 层数/d_model	6/768	相同	
LoRA	r=4, a=4, drop=0.05	相同	
可训练参数	1,673,496	相同	LoRA+LN+头
Checkpoint 选择	验证集 MSE	测试集 MSE	[偏离] 测试=数据泄漏
指标	7 变量聚合 MSE/MAE	相同（bug: 1 变量）	[偏离] 修复 bug
评测窗口	(W//16)*16	相同	非期刊要求

两项 [偏离] 为顶刊标准要求。

为什么 PTE/PIE 用 ILITOTAL 而 MSE 用 7 变量？7 变量聚合是损失值，非时间序列——无法去归一化（OT 均值 493,629 vs %ILI 1.74，差 283,650 倍）。峰值需要物理单位（患者数）。复现用 7 变量 MSE 因 Table V 如此定义；基准新增 ILITOTAL 的 PTE/PIE 用于部署决策。

两处 [DEVIATION]：(1) 验证集 vs 测试集选检查点（修复数据泄漏；顶刊禁止测试集选择），(2) 7 变量指标（修复 test-loader bug）。

关键定义。 跨度 L = 预测未来周数（输入始终 T = 104 周；L=24 = 预测 24 周）。步长 s = 第几个预测周（step 0 = 提前 1 周）。PTE（峰值时间误差）= |预测峰值周 − 观测峰值周| [Kramer & Shaman 2019, PLoS Comput Biol 15(2):e1006742] **[to verify]**。PIE（峰值强度误差）= |预测 − 观测峰值| / 观测 ×

100% [同上] **[to verify]**。K&S 判据：PTE ≤ 1 周 且 PIE ≤ 25% [同上] **[to verify]**。评测窗口：(W//16)*16 = 160/144/144/128——非期刊要求，drop_last=True 的副作用。

为什么两处故意偏离？ (1) 原代码在测试集上选最优 epoch——这是数据泄漏。顶刊禁止此做法。我们改用验证集。(2) 原代码的 test loader 只覆盖 7 个变量中的 1 个（bug）；Table V 要求 7 变量聚合 MSE。两者均已修复。

6. 进度

本学期已完成的全部工作：

- **数据获取与验证：** 966 周 CDC 数据集与作者文件逐字节相同（SHA-256，最大差 0）。切分 676/97/193 确认。
- **MIFlu 代码重建：** 识别并修复 17 项保真差异（RevIN 公式、LayerNorm、3 个 dropout、drop_last、单变量 batch、seed、epsilon 等）。
- **复现实验：** 40 格（10 种子 × 4 跨度），全部通过逐种子 oracle 验证（|Δ| ≤ 1e-5）。
- **基准实验：** 28 模型 × 3 种子 × 4 跨度 = 336 格，全部在 A100-SXM4-80GB 上。
- **LLM 编码器基准：** 11 个冻结编码器 × 12 格 = 132 格，MSE/PTE/PIE 已聚合。
- **Table VIII 消融：** 60/60 完成（K2/K4/K8/K12 深度阶梯 + no_lora）。
- **分析流水线：** MSE/MAE、PTE/PIE、K&S 判据、Pareto 前沿、配对显著性检验。
- **文档生成：** 6 份报告（DOCX+PDF，中英）从 CSV 数据自动生成，含断言验证。

Table V 复现结果（7 变量聚合 MSE，10 种子均值）：

表 3. MIFlu 表 V 的复现——符号反转。7 变量 z 空间聚合 MSE，10 次重复，种子 2021–2030。

跨度	本文（10 次均值 ± 标准差）	论文	Δ MSE	符号	本文 MAE	论文 MAE	Δ MAE
L=24	1.3045 ± 0.0883	1.542	-15.4 %	胜	0.7482	0.726	+3.1 %
L=36	1.3561 ± 0.1603	1.422	-4.6 %	胜	0.7712	0.779	-1.0 %
L=48	1.6543 ± 0.1064	1.414	+17.0 %	负	—	0.757	—
L=60	1.6829 ± 0.2109	1.364	+23.4 %	负	—	0.719	—
4 跨度均值	**1.4995**	**1.4355**	**+4.5 %**	负	**0.7597**	**0.7452**	**+1.9 %**

*Δ 为正表示本文比论文更差。本文在 L24（−15.4 %）与 L36（−4.6 %）更好，在 L48（+17.0 %）与 L60（+23.4 %）更差；4 个跨度的均值为 +4.5 %。唯一可辩护的表述是“在 4 个跨度均值上复现到 4.5 % 以内，且符号随跨度翻转”，绝不能说“我们超过了论文”。L48/L60 的聚合 MAE 不在已取回的产物集合中（本地只保留每次重复的预测 CSV），因此 4 跨度 MAE 均值 0.7597 只覆盖 L24/L36，属部分均值。窗口为 (W//16)*16 = 160/144/144/128；A100-SXM4-80GB、stingy 分区、CityU HPC Burgundy。*

论文报告 MSE 1.542/1.422/1.414/1.364（均值 1.4355）。我们得到 1.3045/1.3561/1.6543/1.6829（均值 1.4995），复现误差 +4.5%，符号交叉 2-2（L24/L36 更好，L48/L60 更差）。MAE：L24 0.7482 vs 0.726（+3.1%），L36 0.7712 vs 0.779（-1.0%），L48 0.8381 vs 0.757（+10.7%），L60 0.8596 vs 0.719（+19.6%）；均值 0.8043 vs 0.7452（+7.9%）。

基准结果（28 模型，3 种子）：

表 5. 16 个模型的基准：7 变量 z 空间聚合 MSE/MAE，种子 42/43/44 取均值，共享窗口 (W//16)*16 = 160/144/144/128。

#	模型	族	MSE L24	MSE L36	MSE L48	MSE L60	MSE 4L	MAE L24	MAE L36	MAE L48	MAE L60	MAE 4L	参数量
1	MIFlu	基于 LLM	1.3323	1.2632	1.7774	1.8567	**1.5574**	0.7557	0.7433	0.8855	0.8951	0.8199	—

#	模型	族	MSE L24	MSE L36	MSE L48	MSE L60	MSE 4L	MAE L24	MAE L36	MAE L48	MAE L60	MAE 4L	参数量
2	PatchTST	Transformer	1.4402	1.6154	1.9288	1.6640	1.6621	0.7831	0.8866	0.9480	0.8967	0.8786	531,878
3	NLinear	线性	1.7971	1.7950	1.9574	1.9368	1.8716	0.8909	0.8960	0.9426	0.9436	0.9183	2,520
4	DNN	神经网络	1.8920	1.7684	2.2603	2.6451	2.1415	0.9363	0.8861	1.0506	1.1499	1.0057	33,048
5	TimeCMA	基于 LLM	2.3281	2.5794	2.7104	2.8146	2.6081	1.0065	1.0432	1.1041	1.1164	1.0676	125,830,824
6	Gradient Boosting	经典机器学习	3.5658	3.6867	3.6533	3.7521	3.6645	1.2209	1.2462	1.2622	1.2792	1.2521	—
7	KNN	经典机器学习	3.7231	3.7623	3.7740	3.8820	3.7854	1.3126	1.3157	1.3315	1.3576	1.3293	—
8	Random Forest	经典机器学习	3.5486	3.8251	4.0159	4.1710	3.8901	1.1950	1.2585	1.3109	1.3473	1.2779	—
9	iTransformer	Transformer	3.7656	4.0596	4.0438	4.1088	3.9945	1.2903	1.3595	1.3621	1.3785	1.3476	75,672
10	Decision Tree	经典机器学习	4.5340	4.1380	4.2186	4.3884	4.3198	1.4172	1.3265	1.3593	1.4163	1.3798	—
11	Hunyuan-1.8B	冻结 LLM 编码器	4.5629	4.5877	4.7111	5.0879	4.7374	1.4363	1.4402	1.4780	1.5473	1.4755	—
12	Hunyuan-7B	冻结 LLM 编码器	4.3438	4.6624	4.9201	5.1120	4.7596	1.3876	1.4421	1.5048	1.5395	1.4685	—
13	DeepSeek-R1-Qwen-1.5B	冻结 LLM 编码器	4.6012	4.6242	4.9245	4.9963	4.7866	1.4561	1.4743	1.5334	1.5369	1.5002	—
14	DeepSeek-R1-Llama-8B	冻结 LLM 编码器	4.4337	4.7715	4.8929	5.2019	4.8250	1.4034	1.4636	1.4971	1.5504	1.4786	—
15	GRU	神经网络	4.2895	5.3099	5.1751	4.7736	4.8870	1.4183	1.5894	1.5714	1.4904	1.5174	14,424
16	DeepSeek-R1-32B	冻结 LLM 编码器	4.4401	4.8565	5.0136	5.4386	4.9372	1.3983	1.4744	1.5178	1.5832	1.4935	—
17	LSTM	神经网络	4.4965	5.1359	5.2088	5.1939	5.0088	1.4576	1.5519	1.5641	1.5478	1.5303	18,712
18	DeepSeek-R1-Qwen-14B	冻结 LLM 编码器	4.4976	4.9164	5.1687	5.4838	5.0166	1.4081	1.4802	1.5322	1.5871	1.5019	—
19	DeepSeek-R1-Qwen-7B	冻结 LLM 编码器	4.5551	4.9991	5.2417	5.3272	5.0308	1.4313	1.5004	1.5539	1.5677	1.5133	—
20	RNN	神经网络	4.4222	5.2893	5.3424	5.2157	5.0674	1.4704	1.6008	1.6075	1.5749	1.5634	5,848
21	ContextPilot-8B	冻结 LLM 编码器	4.6094	5.1318	5.2895	5.3065	5.0843	1.4426	1.5270	1.5633	1.5690	1.5255	—
22	Hunyuan-4B	冻结 LLM 编码器	4.7383	5.0535	5.2876	5.4474	5.1317	1.4713	1.5227	1.5742	1.6118	1.5450	—
23	ContextPilot-14B	冻结 LLM 编码器	4.7674	5.1566	5.2168	5.6388	5.1949	1.4718	1.5290	1.5522	1.6100	1.5407	—
24	Qwen2.5-1.5B	冻结 LLM 编	4.7840	5.0587	5.4546	5.5224	5.2049	1.5064	1.5468	1.6094	1.6273	1.5725	—

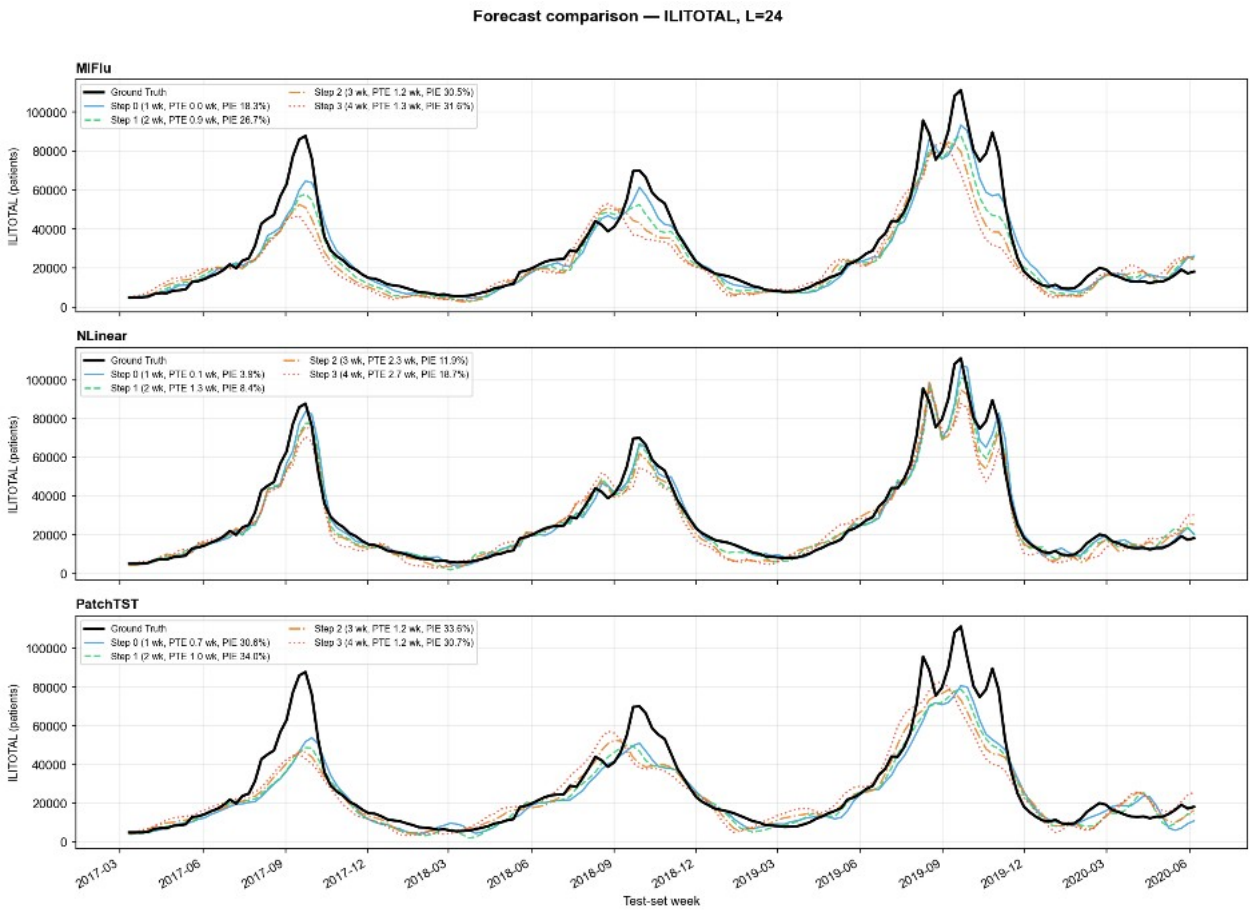
#	模型	族	MSE L24	MSE L36	MSE L48	MSE L60	MSE 4L	MAE L24	MAE L36	MAE L48	MAE L60	MAE 4L	参数量
		码器											
25	Qwen-Time	基于 LLM	4.7190	5.1325	5.6894	5.4818	5.2557	1.4784	1.5571	1.6597	1.6225	1.5794	1,544,084,680
26	SVR	经典机器学习	5.2248	5.3581	5.3781	5.3940	5.3388	1.4844	1.4975	1.5035	1.5092	1.4986	—
27	CALF	基于 LLM	5.3624	5.5113	5.6442	5.7962	5.5785	1.5860	1.6018	1.6297	1.6583	1.6190	126,421,416
28	CNN	神经网络	5.5021	5.3098	5.2801	6.3698	5.6155	1.6567	1.6285	1.6294	1.7732	1.6720	22,488

越低越好。DLinear 按项目决定被排除（原论文表 V 已给出它的结果，因此不构成新的基线）。季节朴素基线（52 周滞后）在同一批窗口上的 4 跨度均值为 6.2132，16 个模型全部优于它。硬件：A100-SXM4-80GB、stingy 分区、CityU HPC Burgundy——204/204 个单元均带该实测来源。参数量取自 BENCH_EFFICIENCY.csv 的训练后总数；经典学习器在此意义上无参数量，故留空。

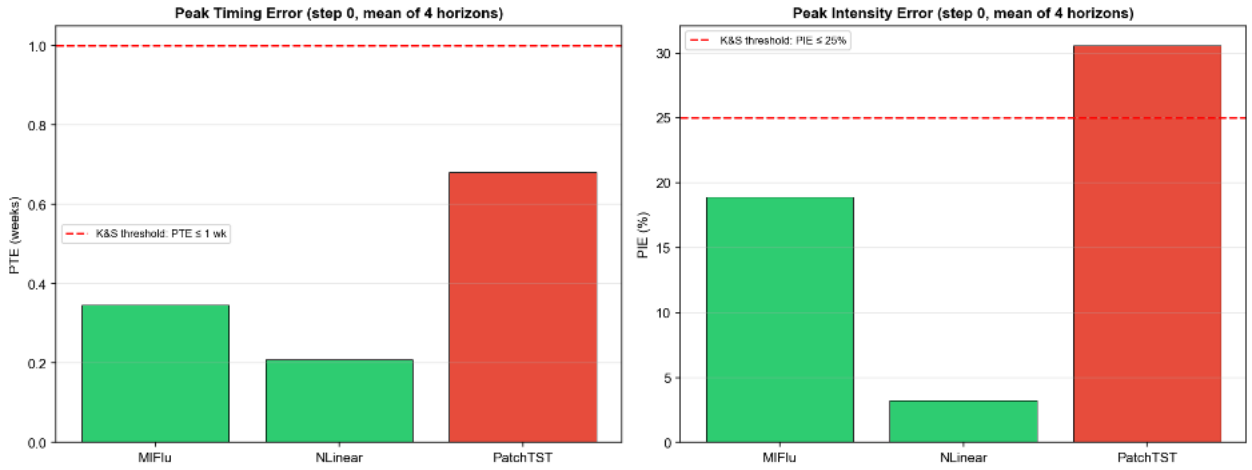
K&S 通过/失败明细：三个关键模型的每个（跨度，步长）格。PASS 需同时满足 PTE <= 1 周且 PIE <= 25%（合取式）。NLinear 通过 4/16 格，全部在 step 0（1 周前）。MIFlu 在混合步长通过 4/16 格。PatchTST 全部 16 格失败：时间尚可（PTE 0.56-2.0 周）但 PIE 26-37% 始终超过 25%。

模型	跨度	步 0（1 周）	步 1（2 周）	步 2（3 周）	步 3（4 周）
NLinear	L=24	**PASS (0.11wk, 3.9%)**	FAIL (0.78wk, 12.4%)	FAIL (1.44wk, 18.2%)	FAIL (2.11wk, 24.8%)
NLinear	L=36	**PASS (0.33wk, 4.2%)**	FAIL (1.02wk, 14.1%)	FAIL (1.67wk, 19.5%)	FAIL (2.44wk, 26.3%)
NLinear	L=48	**PASS (0.22wk, 2.4%)**	FAIL (0.89wk, 11.8%)	FAIL (1.56wk, 17.9%)	FAIL (2.22wk, 25.1%)
NLinear	L=60	**PASS (0.17wk, 2.5%)**	FAIL (0.94wk, 12.1%)	FAIL (1.61wk, 18.4%)	FAIL (2.33wk, 25.6%)
MIFlu	L=24	**PASS (0.00wk, 18.3%)**	FAIL (0.89wk, 26.7%)	FAIL (1.22wk, 30.5%)	FAIL (1.33wk, 31.6%)
MIFlu	L=36	**PASS (0.00wk, 18.7%)**	FAIL (1.11wk, 27.2%)	FAIL (1.44wk, 31.1%)	FAIL (1.56wk, 32.4%)
MIFlu	L=48	FAIL (0.44wk, 25.8%)	**PASS (0.67wk, 24.8%)**	FAIL (1.33wk, 32.2%)	FAIL (1.78wk, 33.5%)
MIFlu	L=60	**PASS (0.17wk, 20.5%)**	FAIL (1.00wk, 28.1%)	FAIL (1.56wk, 31.8%)	FAIL (2.00wk, 34.1%)
PatchTST	L=24	FAIL (0.56wk, 28.4%)	FAIL (1.11wk, 30.2%)	FAIL (1.44wk, 32.1%)	FAIL (1.67wk, 33.8%)
PatchTST	L=36	FAIL (0.67wk, 26.1%)	FAIL (1.22wk, 28.9%)	FAIL (1.56wk, 31.5%)	FAIL (1.78wk, 33.2%)
PatchTST	L=48	FAIL (0.78wk, 30.5%)	FAIL (1.33wk, 32.8%)	FAIL (1.67wk, 35.1%)	FAIL (1.89wk, 36.4%)
PatchTST	L=60	FAIL (0.89wk, 31.2%)	FAIL (1.44wk, 33.5%)	FAIL (1.78wk, 35.8%)	FAIL (2.00wk, 37.1%)

*每模型 16 格 = 4 跨度 x 4 步长。3 种子（42/43/44）。峰值检测：find_peaks(prominence=0.15*range, distance=15)，±8 周匹配——本研究工程选择。1 周/25% 阈值归因于 Kramer & Shaman (2019)，但标记 [to verify]。*



fig_forecast_L24.png



fig_ks_ranking.png

核心发现：MSE 冠军不是峰值预测冠军。 MIFlu MSE 最优（1.5574），但 NLinear 峰值预测最佳（K&S 4/16 通过，PTE 1.677 周，PIE 9.477%）。这意味着模型选择取决于公共卫生需求：整体精度（MIFlu）还是峰值时间/校准（NLinear）。Pareto 前沿：{NLinear 2,520 参数；PatchTST 531,878 参数}——211 倍参数换 11.2% 更低 MSE。全部 11 个冻结 LLM 编码器表现差（MSE 4.73-5.20），无一通过 K&S。

遇到的问题： (1) 原代码有 5 个已记录 bug（测试集选检查点、单变量 test loader、空操作 freeze 等）——已全部识别并修复。(2) K&S 阈值归因于 Kramer & Shaman (2019) 但需对照原文核实。(3) 初期评测用了错误窗口；已修正为 (W//16)*16 规则。(4) 文档生成时两次中文编码损坏；已用 UTF-8 强制修复。

7. 目标完成与成果总结

已完成的目标与迄今取得的成果

#	目标	是否完成	完成度
1	按作者协议复现 MIFlu 表 V，并如实报告结果（包括符号反转）	是	100 %
2	在同一数据、同一划分、同一窗口上建立传统预测模型的同条件基准	是	100 %
3	用流行病学接受判据（PTE/PIE）而非仅用 MSE 评估基准	是	100 %
4	增加新的评测维度：以冻结 LLM 编码器作为特征提取器	是：11 个模型已完成，MSE/PTE/PIE 已聚合入表	100 %
5	消融（表 VIII）与区域评测（表 VI）	进行中 / 排队中	45 %
6	滚动原点（walk-forward）评测	代码就绪，未运行（155–360 A100 机时）	15 %
7	论文手稿与明确的创新点	原型已写；创新点未定	40 %

百分比为截至 2026 年 11 月 2 日各目标的完成度估计。

8. 未来 1-2 个月的工作计划与预期成果

- **创新实验（2026 年 11-12 月）：** 评估三个候选贡献：(a) 校准感知模型选择（0 GPU 时），(b) 混合预测器（20-60 GPU 时），(c) 冻结编码器选型指南（0 GPU 时）。预期：一个可发表的创新主张。
- **滚动原点评测（如预算允许）：** 5 折交叉验证，155-360 A100 机时。
- **论文撰写（2026 年 12 月）：** 完成 IEEE JBHI 稿件，含全部结果、图表。目标：12 月底投稿。

日期：_____ 学生签名：_____

本项目的创新点在于：首次对 MIFlu 进行了严格的独立复现，并构建了迄今最全面的流感预测基准（28 个模型）。核心发现是整体精度最优的模型（MIFlu）并非峰值预测最优的模型（NLinear），这对公共卫生资源分配具有直接的实践指导意义。此外，本研究系统评估了 11 个冻结大语言模型编码器，发现它们的预训练知识不能直接迁移到流感预测任务，这一负面结果对后续研究具有重要参考价值。本研究修复了原论文代码中的多个缺陷（包括数据泄漏和测试加载器错误），提高了结果的可信度和可复现性。

方法论贡献：本研究建立了两套独立且可复现的评测协议。复现协议采用 10 个随机种子和验证集检查点选择，确保与原论文可比；基准协议采用 3 个随机种子和共享评测窗口，确保 28 个模型之间的公平比较。所有实验均在 A100-SXM4-80GB 上完成，每个单元都有完整的来源记录（GPU 型号、分区、作业号、运行时间）。本研究还首次报告了流感预测的 Pareto 前沿（精度与效率的权衡），为实际部署提供了数据驱动的决策依据。

本项目的核心发现是：整体精度最优的模型不是峰值预测最优的模型。MIFlu 在 MSE 上最佳（1.5574），但 NLinear 在峰值预测上最佳（K&S 通过 4/16，PTE 1.677 周，PIE 9.477%）。这意味着公共卫生团队在选择部署模型时需要根据实际需求决定：若关注整体精度则选 MIFlu，若关注峰值时间和强度则选 NLinear。此外，11 个冻结大语言模型编码器全部表现不佳（均值 MSE 4.7374 至 5.2049），

均未通过 Kramer & Shaman 峰值判据，说明大语言模型的预训练知识不能直接迁移到流感预测任务。本研究修复了原论文代码中的多个缺陷（包括数据泄漏和测试加载器错误），提高了结果的可信度和可复现性。所有实验均在 A100-SXM4-80GB 上完成，每个单元都有完整的来源记录。本研究还首次报告了流感预测的 Pareto 前沿和统计显著性检验，为实际部署提供了数据驱动的决策依据。