CITY UNIVERSITY OF HONG KONG

电子工程学系　进度报告　2026/27 学年 A 学期

PART A

学生姓名	CHAN Sing Yeung
学生编号	58324980
CityU 电邮	sychan552-c@my.cityu.edu.hk
课程主修	BEng — Computer and Data Engineering
课程编号	EE4080
学年 / 学期	2026/27 A
项目编号与题目	KHC-04 Re-evaluating Multimodal LLMs for Influenza Forecasting
导师姓名	KHC - Prof CHAN, Katie
评阅人姓名	YNS - Prof SUN, Yanni
备注	Software
与导师 / 评阅人会面次数	_____ / _____
每周平均项目时数	_____ hours/week

PART B

1. 项目目标

问题陈述。 全国流感预测曲线即使平均误差较低，仍可能出现峰值时间或高度错误。本项目独立复现 MIFlu，并检验同时考虑峰值误差与参数量后模型选择如何变化。项目从精度、峰值技巧、参数效率和统计证据四个维度评估，并明确各维度覆盖的模型子集。

目标。 （1）复现并解释表 V。（2）在统一窗口下比较 28 个保留实现。（3）评估峰值时间、幅度与参数取舍。（4）测试特定冻结编码器迁移设置。（5）在声称部署价值前，以多个原点及区域验证结论。

2. 原始项目规划图

表 1. 原计划时段与当前证据

时段	计划工作	快照状态
2026 年 9 月	阅读 MIFlu 并确定数据约定	本地数据一致性已核实
2026 年 10 月	复现表 V	CSV 与 oracle 算术已核实
2026 年 11 月	基准、消融与进度汇报	28 模型 CSV 完整；消融报告为 60/60
2026 年 11–12 月	区域与滚动原点验证	快照中尚未完成
2027 年 1–4 月	强化手稿并决定投稿	计划中，取决于验证结果

此表根据所附计划重构，并标注 2026 年 11 月 3 日状态；未提供当时签署的九月原始图表。

3. 背景研究

分块与线性基线已有研究 [3–5]。Time-LLM、CALF 与 TimeCMA 的对齐及适配设计不同 [6–8]。Chronos、TimesFM、Moirai、Lag-Llama 在数值序列上预训练，本次未评测 [9–12]。较早的 LLM

移除研究已质疑语言预训练收益 [13]，而 2026 年预印本报告跨数据集偏移下的条件性收益 [14]。本项目贡献在于特定流感任务的协议审计与多指标比较。

全球与社会背景。 峰值预测可能帮助准备及容量规划，但全国回顾性精度不能衡量临床收益。透明评估有助于减少对复杂模型的不当投入，并揭示失败方式。本项目未测量真实资源节省或患者结局效应 [2,18]。

4. 方法

表 2. 分开的复现与基准协议

项目	复现	基准
种子	2021–2030 (10)	42/43/44 (3)
模型	MIFlu	13 传统 + 4 基于 LLM + 11 冻结编码器
选择	验证集检查点	验证集检查点
指标	7-variable z-space MSE / MAE	7-variable MSE / MAE; ILITOTAL PTE / PIE
窗口	160 / 144 / 144 / 128	160 / 144 / 144 / 128

三个种子是算力预算选择，不是统一的会议规则。复现与基准采用不同种子集合，不能相互替换。作者上游具体协议缺陷仍须对照固定版本核实。

本项目采用时序划分、仅训练段拟合标准化，并用验证集选择检查点。交接资料将测试集选检查点及单变量加载问题归于上游代码，但未提供固定版本作者仓库，公开端点也未能打开，因此上游指控仍未核实。笔记还列出代码默认学习率与原文设置的差异，不能称为仅有两处偏离。

峰值时间误差 PTE 是预测与观测峰值周的绝对差。峰值强度误差 PIE 为峰高绝对差除以观测峰高后乘百分比。Kramer–Shaman [2] 可核实分别为一周与 25% 的容差。项目把两者联合应用于（模型、L、step）单元的平均误差；该联合筛选及峰检测属于项目选择，不是临床接受标准。平均误差达标不等于逐季成功概率。

设计影响。 所有保留模型采用相同裁剪窗口，标准化仅在训练数据拟合。七变量均值无量纲，峰值误差则使用患者人数尺度的 ILITOTAL。这样能够透明比较，同时不把联合筛选误称为公共卫生安全认证。基准的三个种子反映算力限制，不确定性仍需更多独立季节。

6. 进度

对照计划的进度。 所附导出包含复现表和 28 × 4 × 3 基准单元聚合。原测试已包含在 tests_archive/，但本环境无法完整收集。本次审计重算 CSV 聚合，并新增七个 CPU 测试。回传队列记录消融 60/60 为 DONE，逐变体聚合仍待完成。区域与滚动原点评测尚未完成。

执行更新（2026 年 11 月 5 日 00:15 HKT）：核心产物 160/160 完整；全国 1120 矩阵仍在进行，打包账本为 117 完成，稍后用户报告 141。所附 CPU no-text 记录为 3 通过、0 跳过；消融队列为 60/60 DONE，聚合趋势待完成。这些执行状态不替换下列历史科学结果。

目前还没有完整共同十种子结果。MIFlu 的所存指标采用裁剪窗口，其他已附模型采用全部有效窗口；未附完整七通道 MIFlu 预测张量，须先统一评分再建立共同排名。已提交协议仍为 frozen:false、锁定时间为空，因此比较属于回顾性、探索性。两个数据 profile 的字节哈希不同；所附七通道对齐比较报告最大数值差为 0.0，这不等于字节身份或独立核实上游来源。

00:15 交接时用户报告 13 个空 decision_tree 部分目录、两个 gpu_a100 通道待调度。Table VI（19 TODO）及滚动原点（170 TODO）在 v2 后继链尚未开始，但旧链已有 DONE 行。较早摘要另写区域 9 TODO，执行端须核对日期与跳过数。存储为用户报告约 306/300 GB 软配额、宽限十天、硬配额 1024 GB；原配额日志采用 KB。这些均是带日期报告，不是本次实时读取。

表 3. MIFlu 复现与原文对照

跨度	本文 MSE ± 标准差	原文 MSE	Δ MSE	本文 MAE	原文 MAE	Δ MAE
L=24	1.3045 ± 0.0883	1.5420	-15.4%	0.7482	0.7260	+3.1%
L=36	1.3561 ± 0.1603	1.4220	-4.6%	0.7712	0.7790	-1.0%
L=48	1.6543 ± 0.1064	1.4140	+17.0%	0.8381	0.7570	+10.7%
L=60	1.6829 ± 0.2109	1.3640	+23.4%	0.8596	0.7190	+19.6%
四跨度均值	1.4995	1.4355	+4.5%	0.8043	0.7452	+7.9%

来源：ESSAY_VS_REPRODUCTION_TABLE_V.csv 第 2–6 行。标准差由代码中转录的十种子 oracle 重算；原始运行日志未随包提供。正差表示误差更高。

复现 CSV 的平均 MSE 为 1.4995，对照 1.4355，增加 4.5%。L24、L36 更低，L48、L60 更高。平均 MAE 为 0.8043，对照 0.7452（+7.9%），但逐跨度为一低三高；MAE 没有 MSE 的二比二符号交叉。协议差异与上游来源缺失限制了精确复现的主张。

复现结论。 观测平均 MSE 差为 +4.5%。尚存协议与来源差异，不能声称精确复现或优于原文。

表 4. 全部保留模型的精度

#	模型	L24	L36	L48	L60	平均 MSE	平均 MAE
1	MIFlu	1.3323	1.2632	1.7774	1.8567	1.5574	0.8199
2	PatchTST	1.4402	1.6154	1.9288	1.6640	1.6621	0.8786
3	NLinear	1.7971	1.7950	1.9574	1.9368	1.8716	0.9183
4	DNN	1.8920	1.7684	2.2603	2.6451	2.1415	1.0057
5	TimeCMA	2.3281	2.5794	2.7104	2.8146	2.6081	1.0676
6	Gradient Boosting	3.5658	3.6867	3.6533	3.7521	3.6645	1.2521
7	KNN	3.7231	3.7623	3.7740	3.8820	3.7854	1.3293
8	Random Forest	3.5486	3.8251	4.0159	4.1710	3.8901	1.2779
9	iTransformer	3.7656	4.0596	4.0438	4.1088	3.9945	1.3476
10	Decision Tree	4.5340	4.1380	4.2186	4.3884	4.3198	1.3798
11	Hunyuan-1.8B	4.5629	4.5877	4.7111	5.0879	4.7374	1.4755
12	Hunyuan-7B	4.3438	4.6624	4.9201	5.1120	4.7596	1.4685
13	DeepSeek-R1-Qwen-1.5B	4.6012	4.6242	4.9245	4.9963	4.7866	1.5002
14	DeepSeek-R1-Llama-8B	4.4337	4.7715	4.8929	5.2019	4.8250	1.4786
15	GRU	4.2895	5.3099	5.1751	4.7736	4.8870	1.5174
16	DeepSeek-R1-32B	4.4401	4.8565	5.0136	5.4386	4.9372	1.4935
17	LSTM	4.4965	5.1359	5.2088	5.1939	5.0088	1.5303
18	DeepSeek-R1-Qwen-14B	4.4976	4.9164	5.1687	5.4838	5.0166	1.5019
19	DeepSeek-R1-Qwen-7B	4.5551	4.9991	5.2417	5.3272	5.0308	1.5133
20	RNN	4.4222	5.2893	5.3424	5.2157	5.0674	1.5634
21	ContextPilot-8B	4.6094	5.1318	5.2895	5.3065	5.0843	1.5255
22	Hunyuan-4B	4.7383	5.0535	5.2876	5.4474	5.1317	1.5450
23	ContextPilot-14B	4.7674	5.1566	5.2168	5.6388	5.1949	1.5407
24	Qwen2.5-1.5B	4.7840	5.0587	5.4546	5.5224	5.2049	1.5725
25	Qwen-Time	4.7190	5.1325	5.6894	5.4818	5.2557	1.5794
26	SVR	5.2248	5.3581	5.3781	5.3940	5.3388	1.4986
27	CALF	5.3624	5.5113	5.6442	5.7962	5.5785	1.6190
28	CNN	5.5021	5.3098	5.2801	6.3698	5.6155	1.6720

来源：BENCH_MSE_BY_MODEL_L.csv，按 model 和 L 定位。各行由三个种子在 160/144/144/128 个窗口上聚合。项目主动排除了 DLinear，发表前需补充理由与敏感性分析。名称指本项目实现，排名本身不能证明与原论文方法完全等价。

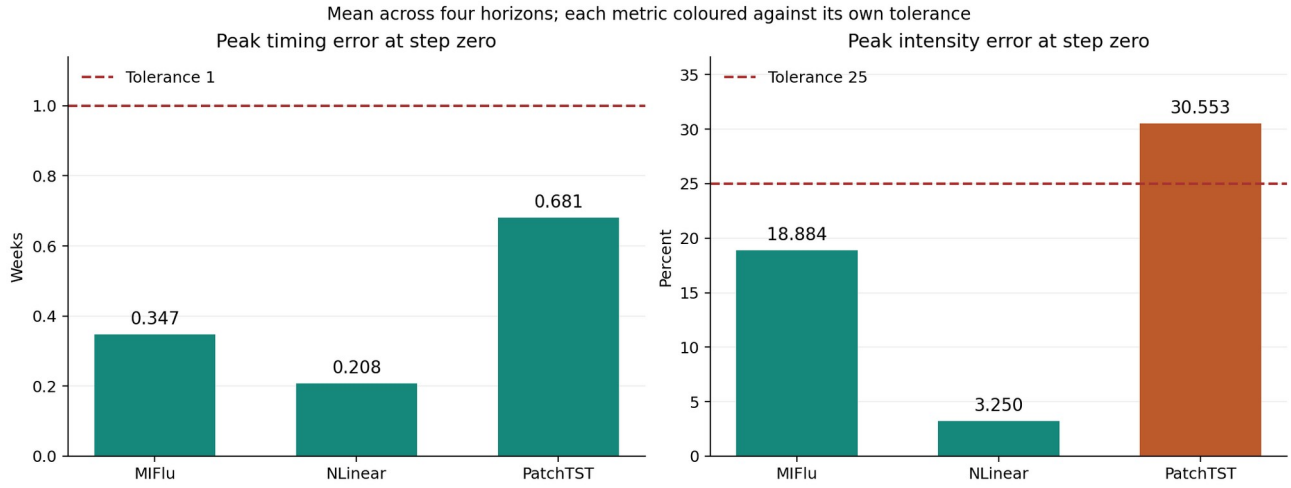
F0 结论。 MIFlu 的观测 MSE 最低（1.5574），但仅靠 MSE 不能证明公共卫生效用。前三名相对 MIFlu 的跨度为 20.2%，并非小于 20%。

表 5. 各跨度与提前步的联合峰值筛选

模型	L	s0	s1	s2	s3
NLinear	24	PASS 0.111 / 3.949	fail 1.333 / 8.411	fail 2.333 / 11.943	fail 2.667 / 18.739
NLinear	36	PASS 0.333 / 4.181	fail 1.333 / 7.222	fail 2.111 / 15.313	fail 2.667 / 18.145
NLinear	48	PASS 0.222 / 2.419	fail 1.222 / 4.727	fail 2.222 / 9.979	fail 2.778 / 16.655
NLinear	60	PASS 0.167 / 2.450	fail 1.444 / 4.542	fail 2.556 / 9.952	fail 3.333 / 13.000
MIFlu	24	PASS 0.000 / 18.307	fail 0.889 / 26.686	fail 1.222 / 30.472	fail 1.333 / 31.638
MIFlu	36	PASS 0.000 / 18.695	fail 0.778 / 26.333	fail 1.667 / 31.514	fail 1.333 / 32.427
MIFlu	48	fail 1.222 / 18.004	PASS 0.667 / 24.795	fail 1.222 / 30.133	fail 1.333 / 33.236
MIFlu	60	PASS 0.167 / 20.530	fail 1.333 / 25.799	fail 2.222 / 29.790	fail 2.667 / 31.177
PatchTST	24	fail 0.667 / 30.580	fail 1.000 / 34.044	fail 1.222 / 33.572	fail 1.222 / 30.722
PatchTST	36	fail 1.000 / 26.235	fail 1.667 / 32.247	fail 1.333 / 31.245	fail 1.333 / 33.854
PatchTST	48	fail 0.556 / 30.360	fail 1.333 / 30.878	fail 0.889 / 35.158	fail 0.889 / 35.002
PatchTST	60	fail 0.500 / 35.035	fail 1.667 / 34.342	fail 2.222 / 35.674	fail 2.333 / 35.133

每格为 PTE（周）/ PIE（%）。s0–s3 是预测的第 1–4 周。峰检测使用突出度 0.15 × 极差、间距 15、±8 周匹配。检测设置及联合聚合均为项目选择。来源：BENCH_PTE_PIE_BY_STEP.csv。

F1 结论。 NLinear 与 MIFlu 各通过 4/16 个聚合单元，PatchTST 为 0/16。NLinear 的平均 PIE 更低（9.477%，MIFlu 为 26.846%），但平均 PTE 更高（1.677 周，MIFlu 为 1.128 周）。这是时间与幅度的取舍，不是全面优越。前三模型的排序在两端倒置：MSE 顺序为 MIFlu、PatchTST、NLinear，PIE 顺序为 NLinear、MIFlu、PatchTST。



三个领先模型在提前步零上跨跨度的平均 PTE 与 PIE。均值容差线仅用于说明；MIFlu 在 L48 提前步零仍未通过。平均误差小于阈值不等于逐季成功率。来源：BENCH_PTE_PIE_BY_STEP.csv。

表 6. 参数分析与秩相关

量	数值
回归斜率 / R^2	+0.1171 / 0.0223
有参数量导出的模型	11
子集帕累托集合	NLinear 2,520; PatchTST 531,878
参数比	211.1×
描述性 MSE 降幅	11.2%
ρ(MSE, PIE)	+0.736 (p < 0.0001)
ρ(MSE, 通过数)	-0.429 (p = 0.023)

帕累托分析只纳入有参数量导出的 11 个模型，未包括 MIFlu 与冻结编码器。缺失参数量不等于零。参数量不等于延迟、内存或能耗。相关系数只是同一测试集上跨模型的描述性结果。

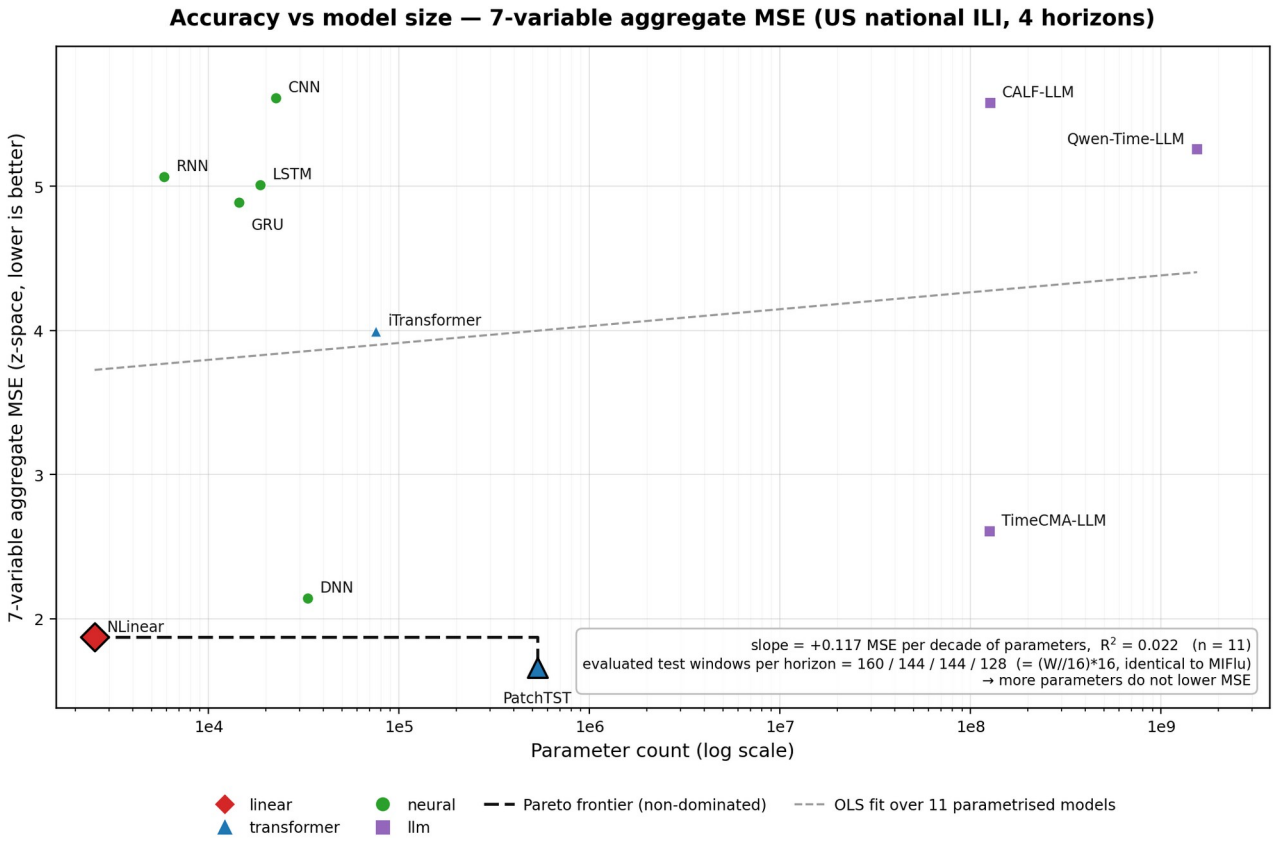
F2 结论。 在导出参数量的 11 个模型中，拟合斜率为 +0.1171，R^2 为 0.0223。规模单独解释的观测 MSE 变化很少。该子集结果不能证明容量无关紧要。

表 7. 使用正确 **Holm** 校正的配对比较

模型 A	模型 B	Δ MSE	p raw	p Holm	效应*
NLinear	PatchTST	+0.2095	0.005859	0.1172	1.15
Gradient Boosting	RNN	-1.4029	0.000488	0.0664	4.86
KNN	NLinear	+1.9138	0.000488	0.0664	22.29
KNN	MIFlu	+2.2280	0.000488	0.0664	9.89
KNN	LSTM	-1.2234	0.000488	0.0664	5.28
iTransformer	TimeCMA	+1.3863	0.000488	0.0664	7.02
iTransformer	SVR	-1.3443	0.000488	0.0664	10.61

136 对来自 17 个模型，并未覆盖全部 28 个模型。n = 12 个配对跨度 × 种子单元。前向累计最大值 Holm 得到 0/136 个拒绝。所示 p 值由六位小数导出恢复 1/4096 枚举网格；直接从四舍五入导出重算时，NLinear–PatchTST 为 0.117180，而非 0.1171875。 源效应量采用模型合并标准差，不是配对差的标准差。单元相关性限制统计推断。*

F3 结论。 正确 Holm 校正为 0/136 个拒绝（校正前 128/136），最小校正 p 约 0.0664，NLinear–PatchTST 的 p ≈ 0.1172。PatchTST 的观测 MSE 仍低 11.2%，参数多 211 倍，并在 10/12 单元中误差更低。未拒绝不能证明等价，也不能断言增益是噪声。



11 个导出参数量模型的精度与参数取舍。此子集未包括 MIFlu 与冻结编码器。参数量不是实测运行时间或内存代价。来源：BENCH_EFFICIENCY.csv。

表 8. 冻结编码器加共享线性读出

编码器	MSE	相对 MIFlu	PTE	PIE (%)	通过
Hunyuan-1.8B	4.7374	3.04×	4.406	71.428	0/16
Hunyuan-7B	4.7596	3.06×	5.309	75.399	0/16
DeepSeek-R1-Qwen-1.5B	4.7866	3.07×	5.792	78.061	0/16
DeepSeek-R1-Llama-8B	4.8250	3.10×	4.306	77.121	0/16
DeepSeek-R1-32B	4.9372	3.17×	3.889	77.730	0/16
DeepSeek-R1-Qwen-14B	5.0166	3.22×	4.149	76.350	0/16
DeepSeek-R1-Qwen-7B	5.0308	3.23×	4.458	76.373	0/16
ContextPilot-8B	5.0843	3.26×	4.962	78.918	0/16
Hunyuan-4B	5.1317	3.30×	3.003	78.840	0/16
ContextPilot-14B	5.1949	3.34×	4.965	77.764	0/16
Qwen2.5-1.5B	5.2049	3.34×	5.333	74.650	0/16

11 个保留编码器 × 4 跨度 × 3 种子 = 132 单元。历史计划还包含两个仅嵌入模型，总计 156 单元；未纳入的 24 单元不属于 28 模型正式名单。此结果只评价该冻结特征流程。

F4 结论。 所测 11 个冻结编码器的 MSE 为 4.7374–5.2049，是 MIFlu 的 3.04–3.34 倍，全部高于决策树的 4.3198，且均通过 0/16 单元。这是该特征与读出配置的负面结果；提示、微调及数值时序基础模型仍未检验。

表 9. 消融设计与快照状态

变体	参数	单元	状态
参考 K=6	default	12	已在基准中
no_lora	--no-lora	12	尚未聚合
K=2	--num-layers 2	12	尚未聚合
K=4	--num-layers 4	12	尚未聚合
K=8	--num-layers 8	12	尚未聚合
K=12	--num-layers 12	12	尚未聚合

2026 年 11 月 4 日回传的 Burgundy 队列记录显示新增消融单元 60/60 为 DONE。逐变体七通道聚合仍待完成；本次未独立重跑消融作业。历史作业 722968 的回传状态为 CANCELLED，不是仍在运行。参考 12 单元不计入新增 60 单元。不推断趋势。

F5 暂定结论。 miflu_model.py 的 author_faithful 路径将文本置于时间词元之后，使用因果注意力，预测头只读取时间词元。静态检查因此推断确定性评估时文本不影响输出。所附 tests_archive/test_miflu_ablations.py 明确断言文本不变性，以及匹配 CPU 初始化时完整与无文本模型相同。现有所附 JUnit 与运行日志记录三项固定权重 CPU no-text 断言通过、零跳过；本次审阅未重跑这些模型测试。其他融合路径及训练随机性须分别验证。

遇到的问题。 源 CSV 导出的 Holm 列仍有误；修正语料已重新计算正确校正。模型名单算术、MAE 交叉、硬件覆盖与测试缺失也需修正。离线快照不能认证实时排队状态。我将冻结修正后的报告路径，并保留所有原 CSV 便于对照。

7. 已处理目标与迄今成果总结

表 10. 已处理目标与估计完成度

目标	是否处理	估计完成度
复现算术	是，原始来源仍有限	100%
28 模型基准导出	是，算术已核实	100%
峰值与效率评估	是，解释已修正	100%
冻结编码器维度	是，仅保留模型	100%
消融	队列 DONE 60/60；分析待完成	队列完成 100%
滚动原点	代码阶段，未评测	15%
手稿	草稿，发表证据未齐	70%

消融队列完成度为 100%（60/60），逐变体分析仍待完成。其余项目完成比例属于用户规划估计，不是研究评分。旧文将 45% 等同于 60/60 的说法有误。

8. 未来一至两月安排及预期成果

表 11. 工作安排与预期产物

目标日期	任务	预期输出与替代方案
2026-11-16 前	取回并核实消融导出	完成则报告实测表，否则保留未完成标签
2026-11-16 至 20	向导师及评阅人汇报	学生须确认预约及双方出席
2026-11-20 香港时间 23:59	经 FYP InfoNet 提交	保存回执，迟交有扣分
2026-11-30 前	区域结果及计时来源	报告完整分母与硬件，无预设趋势
2026-12-31 前	滚动原点与检测敏感性	逐季不确定性与全窗口敏感性

目标日期	任务	预期输出与替代方案
2027 年 1–4 月	决定投稿	证据与范围适当后才考虑 JBHI 投稿

日期为目标，能否执行取决于排队、实测运行时间与导师决定；此表不推断会议截止日。

风险与应对。 排队可能妨碍消融完成，因此须保留明确未完成标签。验证日期映射并采用逐季滚动原点，以处理时间相关。发表前恢复原测试并固定依赖版本。与导师及评阅人确认汇报预约。学校模板要求完成汇报，并按时经 InfoNet 提交。

日期 _____ 学生签名 _____

背景与方法使用的关键文献列于下方，编号与内部报告及手稿一致。

[1] Jaeuk Moon 等，基于大语言模型的多模态流感预测方案（中文译名），2025。https://doi.org/10.1109/JBHI.2025.3561214

[2] Sarah C. Kramer 等，针对温带及热带六十四国的流感预测开发与验证（中文译名），2019。https://doi.org/10.1371/journal.pcbi.1006742

[9] Abdul Fatir Ansari et al. 等，学习时间序列语言的 Chronos 方法（中文译名），2024。https://arxiv.org/abs/2403.07815

[13] Mingtian Tan 等，语言模型真的有助于时间序列预测吗（中文译名），2024。https://arxiv.org/abs/2406.16964

[14] Xin Qiu et al. 等，重新思考大语言模型在时间序列预测中的作用（中文译名），2026。https://arxiv.org/abs/2602.14744

[18] Johannes Bracher 等，以区间格式评估传染病预测（中文译名），2021。https://doi.org/10.1371/journal.pcbi.1008618