MIFlu 研究问答与文献依据

导师讨论与答辩准备手册

CHAN Sing Yeung　58324980　配套文件修订 9.2

本册集中收录原中文内部报告的 Q01–Q25。每题保留直接回答、具名论文依据、导师简答、论文阅读位置与本地证据，供汇报准备和深入讨论使用。实验结果与执行状态沿用有日期的历史快照，不表示已取得新的运行结果。

配套正文为 report_internal_zh.docx / .pdf。问答中的表号、F0–F5 结论及章节说明指向该报告；其科学表格和图形仍保留在正文中。参考文献编号与原报告一致，不能直接套用英文期刊稿按首次引用重新编排的编号。

问答目录

1 数据与来源　Q01–Q03

2 方法与文献　Q04–Q06

3 MIFlu 复现　Q07–Q09

4 基准精度　Q10–Q11

5 峰值时间与幅度　Q12–Q14

6 精度与参数量　Q15–Q17

7 统计审计　Q18–Q20

8 冻结语言编码器　Q21

9 消融设计与状态　Q22–Q23

10 解释与发表计划　Q24

11 可复现性与待核实项　Q25

1 数据与来源

Q01 为什么采用 676 行训练、97 行验证、193 行测试?

直接回答与本地证据。 所附 966 行协议把 floor(966 × 0.7) = 676 行分给训练，floor(966 × 0.2) = 193 行分给测试，其余 97 行用于验证。训练段拟合权重和标准化参数，验证段选择检查点，最终测试段评价选择后的表现。按时间先后划分，可以避免用后来的观测训练较早的预测。这是本项目采用的协议，并非所有期刊统一要求；固定版本上游协议仍待独立核实。

文献依据与选择理由。 Tan 等明确对 Illness 使用 70/10/20 [13，第 3.3 节]，iTransformer 则保持按时间分离 [5，附录 A.1]。这是具体的预测研究先例：保留较多训练数据，以验证集选模，再用较晚观测做最终测试。676/97/193 的精确整数来自本项目 966 行及取整规则。文献支持设计理由，但不证明该比例对所有流感季最优，也不能证明本地文件与上游身份一致。

向导师简答。 这个划分有 Tan 等 Illness 实验的先例，时间分离用于保护最终评价 [13, 5]。

论文位置。 Tan et al. [13], §3.3 Datasets and Evaluation Metrics; iTransformer [5], Appendix A.1.

证据。 configs.py DATA_PROFILES[author_repo_966]; BENCH_MSE_BY_MODEL_L.csv; eval_windows.py

Q02 L24 明明有 170 个窗口，为什么只评 160 个?

直接回答与本地证据。 本地评测约定只保留完整的 16 个窗口一批，即 (W//16)×16。因此 L24/36/48/60 的 170/158/146/134 个可用窗口变成 160/144/144/128 个计分窗口。所有模型使用相同窗口，可避免拿不同测试样本比较。但裁剪会删去某一段时间尾部，仍可能改变分数。这是本快照为保持可比性采用的选择，不证明裁剪在科学上最优；仍需完整窗口敏感性分析。本次没有独立复核某个被删尾部的具体难度倍数。

文献依据与选择理由。 Tan 等复核时保留原数据加载器与训练条件 [13，第 3.1 节]，说明必须交代哪些样本进入计分，却不表示论文要求裁剪。本地完整批量规则改变了计分样本。各模型采用相同保留窗口，可消除比较不公平，但删去尾部仍可能改变结果。必要的敏感性分析是让所有模型在完整窗口重评分，再比较排名。文献不能代替被删尾部难度的原始计算。

向导师简答。 裁剪用于统一计分样本，完整窗口重评分用于检验裁剪影响 [13]。

论文位置。 Tan et al. [13], §3.1 Reproducibility Note; local eval_windows.py.

证据。 BENCH_MSE_BY_MODEL_L.csv; eval_windows.py; scripts/verify_snapshot.py --raw-smoke

Q03 为什么标准化参数只能从训练段计算?

直接回答与本地证据。 如果用完整序列计算均值或标准差，就会把未来测试段的信息带入模型准备过程。只在训练段拟合，可避免这类信息泄漏。七个通道分别标准化。本次一致性检查比较所附两个文件的七个对应数值列，最大绝对差为零。这只能核实本地副本数值一致，不能代替重新下载作者文件后核实字节一致。

文献依据与选择理由。 Kapoor 与 Narayanan 把跨越训练/测试边界的预处理列为泄漏路径 [22，L1.2]。用于这里，就是只在训练段拟合各通道均值和标准差，再原样复用。如果未来观测决定这些常数，预处理已适应留出分布，即使梯度更新没有使用测试标签。因此训练段标准化属于实验设计。本地文件相等检查则只证明输入一致，不能证明所有泄漏路径均不存在。

向导师简答。 依照 Kapoor 与 Narayanan 对泄漏的区分，预处理只在训练段拟合 [22]。

论文位置。 Kapoor and Narayanan [22], Results, leakage taxonomy L1 and L1.2.

证据。 06_原始数据集/scaler_miflu_author966.json; scripts/verify_snapshot.py

2 方法与文献

Q04 为什么复现用十个种子，基准却用三个种子?

直接回答与本地证据。 两者回答不同问题。所附复现以 2021–2030 十个种子对照转录的原文表格；更广的基准以 42/43/44 三个种子在统一协议下比较各实现。正式矩阵为 28 模型 × 4 跨度 × 3 种子 = 336 单元；十个种子则需要 1,120 单元。采用三个种子反映项目算力预算，不证明检验功效已经足够，更多种子也可能改善不确定性估计。本次没有证据支持所有场合均要求三个种子，或增加种子毫无收益。

文献依据与选择理由。 原来的三种子引用不正确。PatchTST 的主结果采用固定种子，另做五种子监督稳健性检查 [3，附录 A.6.1]；iTransformer 报告五次运行的标准差 [5，附录 A.2 表 5]。这些段落不能证明三种子是两文共同惯例。我们的选择属于算力折衷。 Bouthillier 等区分重复运行精度和更广的基准变异 [19]：增加种子可改善前者，增加季节/原点处理另一类不确定性。十次复现不会让独立的三种子基准同样精确。

向导师简答。 三种子是算力折衷；两篇所引论文实际提供五种子稳健性证据，提示仍需加强检查 [3, 5]。

论文位置。 PatchTST [3], Appendix A.6.1; iTransformer [5], Appendix A.2 and Table 5; Bouthillier et al. [19], Appendix C.3.

证据。 ESSAY_VS_REPRODUCTION_TABLE_V.csv; BENCH_MSE_BY_MODEL_L.csv; dlv/data.py ORACLE

Q05 哪些实现差异已经核实，哪些仍只是待核实的说法?

直接回答与本地证据。 已检查的本地代码在验证段选择检查点，并对七个标准化通道计分。交接笔记把测试集选检查点和单通道加载问题归于上游代码，但本次没有独立检查到固定版本作者仓库来支持该归因。笔记还提到学习率和训练轮数设置差异。因此应披露本地流程与未核实的参考设置，不能声称只有两处修复就解释全部分数差异。若要确认因果，应固定数据、种子及其他设置，每次只改变一个因素。

文献依据与选择理由。 检查点属于选模选择；按测试误差挑选，就是用最终评价拟合该选择，不符合干净分离 [22，L1]。不论上游缺陷是否能证实，这个原则都支持本地验证集选检查点。按声明的七通道计分则是另一项指标一致性问题。这些原则不能证明 Moon 等犯了所指缺陷，也不能证明差距仅由两项改变造成。因果归因需要配对运行，每次只改变检查点、加载器或另一项因素。

向导师简答。 验证集选模保护留出测试；上游是否有缺陷，须另有证据 [22]。

论文位置。 Kapoor and Narayanan [22], taxonomy L1, clean separation through modelling and evaluation.

证据。 train_miflu.py; audit/REPO_AUDIT.md; audit/UNVERIFIED_ITEMS.md

Q06 为什么 MSE 用七变量，而峰值误差只用 ILITOTAL?

直接回答与本地证据。 七变量 MSE 先逐通道标准化，再平均平方误差，衡量整体无量纲预测误差。这个平均损失不是患者人数时间序列，也没有一个统一的反标准化器。峰值时间与高度则必须针对一条真实序列。因此本项目对 ILITOTAL 使用其训练段标准化参数反变换，均值为 9,439.84、标准差为 9,003.15 人。一个模型可以在七通道总体误差上较好，但在 ILITOTAL 峰值上较差。评价对象与损失函数不同，是排名变化的一个解释。

文献依据与选择理由。 Hyndman 与 Koehler 解释尺度为何重要 [21，第 2.1 节]；Kramer 与 Shaman 在观测疾病序列上定义峰值 [2]。本项目标准化总体损失将各通道原单位平方误差除以训练方差，所得是无量纲损失，而非可用一组参数反变换的患者人数曲线。峰值评测应先反变换 ILITOTAL 预测和观测，再找峰；对七通道损失找峰会回答另一个问题。文献支持可解释端点，ILITOTAL 是明确的项目选择。

向导师简答。 标准化整体误差与可解释疾病峰值，是不同端点 [21, 2]。

论文位置。 Hyndman and Koehler [21], §2.1; Kramer and Shaman [2], Forecast accuracy and comparison.

证据。 BENCH_MSE_BY_MODEL_L.csv; BENCH_PTE_PIE_BY_STEP.csv; scaler_miflu_author966.json

3 MIFlu 复现

Q07 为什么这里的 MIFlu 是 1.4995，基准表却是 1.5574?

直接回答与本地证据。 前者来自十种子复现表的四跨度均值，后者来自三个基准种子的四跨度均值，它们汇总的是不同运行集合。讨论复现时，应把 1.4995 与原文转录均值 1.4355 比较；讨论选模时，应把 1.5574 与同一基准中的其他模型比较。两数之差并不能证明在其他条件完全一致时模型进步、退步或抄错；归因还需要完整运行配置与原始来源。

文献依据与选择理由。 Bouthillier 等说明基准估计取决于被抽样的学习流程 [19]。均值是指定运行集合的估计，不是模型名称自带的不变属性。两项 MIFlu 估计汇总不同种子集合，服务不同对照。差值可能同时包含种子波动与配置差异，不能分离某一原因。应先解释两表运行定义；若关心成因，再取回匹配的逐运行配置。

向导师简答。 两数估计不同运行集合，不能把差值视为一项改变的受控效果 [19]。

论文位置。 Bouthillier et al. [19], §§2–3, benchmark estimators and sources of variation.

证据。 ESSAY_VS_REPRODUCTION_TABLE_V.csv lines 2–6; BENCH_MSE_BY_MODEL_L.csv model=miflu

Q08 为什么 MSE 与 MAE 的逐跨度方向不完全一致?

直接回答与本地证据。 MSE 对误差平方，因此更重视大误差；MAE 平均绝对误差。因此，少数大误差的变化可能对两者产生不同影响。相对原文转录值，MSE 在 L24/L36 较低、L48/L60 较高；MAE 只有 L36 较低，其他三个跨度较高。平均差为 MSE +4.5%、MAE +7.9%。不能把两者都说成两低两高。

文献依据与选择理由。 该文区分平方与绝对误差，以及两者对大残差的敏感性 [21]。作代数示例而非实测：残差翻倍，绝对贡献变两倍，平方贡献变四倍。因此残差分布改变时，MSE 与 MAE 可以不同向。CSV 确定实际逐跨度符号，文献解释为何可能不同。若要确定哪些误差造成差距，仍需逐通道、逐窗口残差，不能只靠一般原理。

向导师简答。 MSE 更重视大残差，逐跨度方向必须与 MAE 分开读取 [21]。

论文位置。 Hyndman and Koehler [21], §2.1, MSE/MAE and sensitivity to large residuals.

证据。 ESSAY_VS_REPRODUCTION_TABLE_V.csv lines 2–6

Q09 种子 oracle 和预测曲线能证明已完整复现吗?

直接回答与本地证据。 oracle 是代码中转录的十种子分数记录，可以核算均值和标准差，但没有提供对应十种子的原始日志与预测供独立重评分。沿用曲线展示基准序列，不是这些十种子复现运行的独立轨迹。检查点选择、种子波动和配置差异都可能解释逐跨度表现，但尚未分离其因果作用。可辩护的结果是在明确限制下，平均 MSE 差为 +4.5%。

文献依据与选择理由。 重复运行估计与可追溯评测处理不同缺口 [19, 22]。oracle 核对转录记录的算术，保存预测才可核对流程是否产生该记录。实际链条是运行配置 → 预测 → 计分代码 → 单元 → 聚合。基准图是另一种摘要，不能建立十种子复现轨迹。即使均值接近，链条缺项仍限制主张；只要说明真实来源，沿用曲线仍可作示例。

向导师简答。 oracle 建立算术证据，原始输出建立来源证据，两者都重要 [19, 22]。

论文位置。 Bouthillier et al. [19], variance analysis; Kapoor and Narayanan [22], model info sheets.

证据。 dlv/data.py ORACLE; ESSAY_VS_REPRODUCTION_TABLE_V.csv; figure_captions.json

4 基准精度

Q10 28 个模型与不同分析子集各指什么?

直接回答与本地证据。 正式名单为 13 个传统模型 + 4 个基于 LLM 的模型 + 11 个冻结编码器。精度和峰值分析覆盖全部 28 个；参数导出支持其中 11 个；配对检验覆盖包括 MIFlu 的 17 个非编码器模型。项目主动把 DLinear 排除于正式名单及配对表。它在历史硬件来源表中出现，不代表属于正式保留模型。补充含 DLinear 的敏感性分析可加强基线覆盖；它曾出现在原文，本身不足以构成科学排除理由。

文献依据与选择理由。 各家族检验不同解释：简单时间映射 [4]、patch 与反转变量词元 [3, 5]，以及明确的跨模态对齐 [7, 8]。这支持采用多样对照，不证明 28 是最优数量，也使实现忠实度很重要：同名适配可能省略原文关键对齐或训练组件。DLinear 是这条文献中的相关简单对照；它曾出现在原论文，本身不是在敏感性分析中省略它的科学理由。

向导师简答。 论文支持选择不同对照；导出文件决定每项分析实际覆盖哪些模型 [3–5, 7, 8]。

论文位置。 Zeng et al. [4], §4; PatchTST [3], §3.1; iTransformer [5], §3; CALF [7] and TimeCMA [8], author abstracts.

证据。 BENCH_MSE_BY_MODEL_L.csv; BENCH_EFFICIENCY.csv; BENCH_PAIRED_TESTS.csv; BENCH_GPU_PROVENANCE.csv

Q11 MIFlu 的 MSE 最低，是否就应直接选它部署?

直接回答与本地证据。 MIFlu 的观测基准 MSE 最低，为 1.5574。这是在单一全国划分下的描述性精度结果，没有直接测量漏峰、误报、运行时间、区域稳健性或前瞻效益。MSE 差距较大，也不能证明调参不重要，因为本实验没有把调参作为另一因素进行对照。后面的评价维度回答精度表单独无法回答的问题。

文献依据与选择理由。 峰值时间/强度是疾病领域端点 [2]，区间评分考查预测不确定性 [18]；七通道点误差排名不会自动提供这些证据。应分别看观测精度、峰值取舍与操作代价。NLinear 峰高误差低不能抹去平均时间误差更大；MIFlu 的 MSE 最低也不证明区间校准或前瞻效益。我们因此可先论证选模证据，再谈公共卫生部署赢家。

向导师简答。 MIFlu 赢的是观测点误差排名，峰值端点与不确定性须有各自证据 [2, 18]。

论文位置。 Kramer and Shaman [2], Forecast accuracy and comparison; Bracher et al. [18], §§3–4.

证据。 BENCH_MSE_BY_MODEL_L.csv; audit/GRADE_READINESS.md

5 峰值时间与幅度

Q12 为什么 MIFlu 和 NLinear 都通过 4/16，却仍有不同结论?

直接回答与本地证据。 一次通过要求同一个（L，step）单元的平均 PTE ≤ 1 周且平均 PIE ≤ 25%。NLinear 在四个跨度的 step 0 均通过；MIFlu 在 L24/L36/L60 的 step 0，以及 L48 的 step 1 通过。因此，相同通过数会隐藏达标位置及误差大小的差异。跨全部 16 单元，NLinear 的 PIE 更低，为 9.477% 对 26.846%；MIFlu 的 PTE 更低，为 1.128 对 1.677 周。结论是时间与峰高之间存在取舍，任何一个都不是全面占优。

文献依据与选择理由。 文献分开评价时间与强度，支持先看两项误差，再压缩为通过数 [2]。相同四次通过隐藏不同步长/跨度位置，以及距阈值多远的差别。优先重视提前一周峰高的应用，可能与重视时间的

应用选择不同取舍。这是对本地表格的条件式解释，不是文献推荐 NLinear。二元通过标签只是连续误差的粗略摘要。

向导师简答。 相同通过数隐藏不同位置与时间—峰高取舍 [2]。

论文位置。 Kramer and Shaman [2], Forecast accuracy and comparison, separate timing/intensity tolerances.

证据。 BENCH_PTE_PIE_BY_STEP.csv model in {miflu,nlinear}

Q13 4/16 是否表示预测流行季成功的概率为 25%?

直接回答与本地证据。 不是。分母是四个跨度乘四个固定预测步，不是 16 个独立流行季。每个单元本身已经聚合可用运行或事件的误差。先平均再应用阈值，与先判断每个事件成功再计数，可能得到不同结果。Kramer–Shaman [2] 支持分别采用时间和强度容差；把两者联合用于聚合单元，以及具体峰检测设置，属于本项目选择，不是临床接受检验或经校准的概率。

文献依据与选择理由。 Kramer 与 Shaman 按提前时间评价逐预测峰值准确性 [2]，我们的十六个配置单元是另一种分母。对均值应用阈值，与对逐事件通过指示值取平均，在数学上不同，所以 4/16 不能改名为流行季成功概率。Bracher 等讨论预测分布校准 [18，第 4.2 节]，峰高误差小不等于已校准。估计事件成功率需保留逐事件结果、定义事件分母并处理依赖。

向导师简答。 这里数的是平均后的配置，而非成功流行季或经校准概率 [2, 18]。

论文位置。 Kramer and Shaman [2], Forecast accuracy and comparison / Fig. 2; Bracher et al. [18], §4.2.

证据。 BENCH_PTE_PIE_BY_STEP.csv; Kramer–Shaman [2]; analysis peak detector settings

Q14 为什么峰值排名会改变，却不能说已经证明脱钩?

直接回答与本地证据。 前三模型的 MSE 顺序为 MIFlu < PatchTST < NLinear，PIE 顺序为 NLinear < MIFlu < PatchTST。排序在两端倒置，中间位置也不同。跨全部模型， MSE–PIE 为正相关（+0.736），MSE–通过数为负相关（−0.429），都符合整体误差越低通常峰值表现越好的方向。局部排名不一致可以与整体相关同时存在。因此可主张评价目标改变排序，不能主张统计独立或所有模型都无法预测峰值。

文献依据与选择理由。 Zeng 等说明 NLinear 先减最后一个值，经过线性映射，再加回该值 [4]。这提供水平处理的可检验假设，却非本地峰值成因的证明。排名差别有更直接的区别：MSE 聚合许多点和七通道，PIE 聚焦 ILITOTAL 检测峰高 [21 提供误差指标背景]。模型可能改善非峰点却使该端点较差。若要归因于架构，须有受控变体和峰值/残差诊断。

向导师简答。 两种目标聚合不同误差，NLinear 水平校正是待检验的假设 [4, 21]。

论文位置。 Zeng et al. [4], §4 NLinear; Hyndman and Koehler [21], §2.1.

证据。 BENCH_MSE_BY_MODEL_L.csv joined to BENCH_PTE_PIE_BY_STEP.csv; audit/verified_facts.json

6 精度与参数量

Q15 我该怎样向导师解释 Pareto 图?

直接回答与本地证据。 横轴是参数量，纵轴是 MSE，两者均偏向越小越好。如果子集中另一个模型的参数不更多、MSE 不更高，且至少一项严格更好，前者就受到支配。导出的前沿包含 NLinear 和 PatchTST：NLinear 更小，PatchTST 的 MSE 更低，因此互不支配。这个前沿只覆盖有参数导出的 11 个模型，MIFlu 与冻结编码器不在其中，不能称为全部模型的全局前沿。

文献依据与选择理由。 iTransformer 同时评价误差、速度和内存 [5，附录 D]，是把表现与代价并列考虑的先例。我们的代价轴更窄，只用导出参数。两个前沿成员来自十一模型子集的两两支配关系，并非论

文推荐的通用赢家。Pareto 图排除被支配选择；余下选择仍需预算或可接受误差偏好。MIFlu 代价缺失，使它不能称为全部 28 模型前沿。

向导师简答。 前沿排除所测子集内的被支配选择，仍需决策偏好从中选模 [5]。

论文位置。 iTransformer [5], Appendix D Model Efficiency; local BENCH_EFFICIENCY.csv.

证据。 BENCH_EFFICIENCY.csv; fig_pareto_frontier.png

Q16 参数多 211 倍，是否就慢 211 倍?

直接回答与本地证据。 不是。531,878 / 2,520 = 211.1 比较的是导出的 PatchTST 与 NLinear 参数量。其观测 MSE 降幅为 (1.871583 − 1.662078) / 1.871583 ≈ 11.2%。参数存储、运算、硬件利用率及批量大小对运行时间有不同影响。延迟、峰值内存与能耗需要直接且可比的测量。因此使用“参数效率”这个表述；缺失参数继续记为缺失，不能当成零，更不能把 MIFlu 描述成无参数模型。

文献依据与选择理由。 iTransformer 在声明的输入/预测长度和统一批量下实测速度、内存 [5，附录 D]，我们的参数导出没有这些测量。参数影响存储，运算、词元数量与硬件利用率对耗时影响不同。因此参数多 211×，不能推出延迟、内存或能耗也多 211×。后续效率表应记录硬件、精度、批量，以及计时针对训练还是推理，不能用参数比猜这些字段。

向导师简答。 我报告的是参数比；文献展示了速度主张所需的匹配运行测量 [5]。

论文位置。 iTransformer [5], Appendix D, Fig. 10, matched speed/memory measurements.

证据。 BENCH_EFFICIENCY.csv; BENCH_MSE_BY_MODEL_L.csv model in {nlinear,patchtst}

Q17 R^2 = 0.0223 实际说明什么?

直接回答与本地证据。 在有参数导出的 11 个模型中，以 MSE 对 log10(参数量) 拟合，参数规模单独解释的观测变化很少。这种描述性关联没有隔离容量作用，因为架构、优化与训练设置也同时不同。较低 R^2 不能证明容量不重要，更不能证明观测精度增益只是随机噪声。若要研究容量因果作用，需要在受控模型家族及训练协议内改变规模。

文献依据与选择理由。 PatchTST 改变层数和隐藏维度，并特别指出 ILI 对这些设置敏感 [3，附录 A.6.2]，这反对轻率否定小流感序列上的调参。我们的跨模型 R^2 混合架构、优化和规模，不是受控容量作用。更强的后续是在一个家族内改变深度/宽度，固定训练协议并重复运行。MIFlu 深度阶梯开始提出这个问题，但未聚合状态不能提供科学趋势。

向导师简答。 跨模型 R^2 低不能否定调参；PatchTST 明确报告 ILI 敏感性 [3]。

论文位置。 PatchTST [3], Appendix A.6.2, Fig. 5, layers/width and ILI sensitivity.

证据。 BENCH_EFFICIENCY.csv; scripts/verify_snapshot.py linregress

7 统计审计

Q18 为什么配对检验表里会出现看起来不相关的模型对?

直接回答与本地证据。 报告有意把 NLinear–PatchTST 这对前沿比较放在第一行，再列原始 p 最小的六行，这样既展示核心问题，也展示更大检验族中的例子。该前沿对在导出表按原始 p 升序排列时位于第 117，因此自动只取最小六项会漏掉它。但完整检验族仍含全部 136 对；选择展示哪几行，不能改变 Holm 校正的检验族，更不能让选中比较变显著。

文献依据与选择理由。 Demšar 说明考查特定差异时须控制比较族 [20]。这里首行保留前沿核心问题，后六行展示原始 p 更小的对照，校正仍纳入全部 136 对。第 117 指原始 p 升序位置，不是模型精度排名。

选择展示行不能改变检验族。该文主要讨论多数据集，也不许可把本地重叠跨度和共享测试序列当成独立数据集。

向导师简答。 首行服务研究问题，校正仍由完整检验族决定 [20]。

论文位置。 Demšar [20], §3.2.2 Post-hoc tests; local raw-p rank.

证据。 BENCH_PAIRED_TESTS.csv model_a=nlinear/model_b=patchtst; audit/verified_facts.json pair_raw_rank

Q19 为什么未校正有 128 对显著，Holm 后却是零？

直接回答与本地证据。 同时检验很多模型对会增加误报机会。正确 Holm 先排列原始 p，再按递减多重比较因子计算并取前向累计最大值。原导出列方向错误，因此保留作来源记录但不使用。重算全部 136 对后为 0/136 个拒绝，最小校正 p 约 0.0664，NLinear–PatchTST 为 0.1172。在已记录的双侧精确 n=12 分辨率下，原始 p 最低为 2/4096，已高于 Holm 第一步的 0.05/136 阈值。跨度–种子单元之间的依赖还带来另一层限制。

文献依据与选择理由。 Demšar 说明 Holm 从最小 p 开始，在首次未通过阈值处停止 [20]。本项目第一阈值为 0.05/136；按已记录的十二贡献双侧符号翻转下限 2/2^12，乘 136 得 0.06640625，所以无法启动拒绝序列。这是本地数学推导，不是 Demšar 报告的流感结果。Holm 可处理有效 p 值之间的依赖，却不能修复因配对内部交换性不合理而无效的原始 p；两者是不同限制。

向导师简答。 精确检验下限超过 Holm 第一步阈值，这是设计分辨率限制 [20]。

论文位置。 Demšar [20], §3.2.2 Holm step-down; local exact-enumeration derivation.

证据。 BENCH_PAIRED_TESTS.csv p_raw; analysis_postprocess.py; audit/HOLM_RECOMPUTATION.csv

Q20 p = 0.1172 是否说明 NLinear 与 PatchTST 等价？

直接回答与本地证据。 不是。PatchTST 的观测平均 MSE 仍低 11.2%，且在 10/12 个配对单元中误差更低。未拒绝只表示该检验族校正流程没有在选定阈值下确立差异，不表示差异已小到可视为实际等价。等价判断需要预先规定可接受差异界值，并采用适合的不确定性与检验设计。表中源效应量还使用模型合并标准差，而非配对差标准差，因此只能标成源标准化效应。

文献依据与选择理由。 Lakens 区分不显著差异检验与预先规定有意义界限的等价检验 [25]。因此 p = 0.1172 没回答 NLinear 额外观测误差是否可接受。应先定义可接受差异，再采用尊重时间/季节依赖的不确定性设计。看表后才挑宽松界限，不能构成有说服力的确认。在此之前应并列报告观测降幅、参数比和推断不确定性，不能说额外参数只换来噪声。

向导师简答。 未拒绝不等于等价，观测取舍与尚未解决的推断并存 [25]。

论文位置。 Lakens [25], Introduction and Testing for Equivalence.

证据。 BENCH_EFFICIENCY.csv; BENCH_PAIRED_TESTS.csv; audit/CLAIM_AUDIT.md C3

8 冻结语言编码器

Q21 冻结编码器的负面结果能解释到哪一步？

直接回答与本地证据。 所测流程冻结语言编码器，再训练线性读出。11 个编码器的 MSE 为 4.7374–5.2049，均高于决策树的 4.3198，各自通过 0/16 联合单元。这说明这些特征与读出配置在当前协议中表现较差。分布不匹配、冻结特征和读出能力都可能解释结果，但实验没有分离其作用。生成、提示、微调及数值预训练时序基础模型均不属于这项测试。

文献依据与选择理由。 Time-LLM 也冻结 LLM，却加入可学习重编程和提示前缀 [6]，所以“冻结”不等同于本项目特征/线性读出流程。Chronos 则从数值序列学习预测 [9]。这些方法差异支持缩小负面结论。要分离读出瓶颈，应固定编码器后改变读出/对齐；要分离预训练作用，应比较匹配的预训练和随机骨干。十一模型结果没有完成这些受控分离。

向导师简答。 失败限定本地特征/读出流程，Time-LLM 与 Chronos 检验其他机制 [6, 9]。

论文位置。 Time-LLM [6], author abstract; Chronos [9], §3.

证据。 BENCH_MSE_BY_MODEL_L.csv family=llm_encoder; BENCH_PTE_PIE_BY_STEP.csv

9 消融设计与状态

Q22 为什么默认路径下去掉文本可能得到完全相同的输出?

直接回答与本地证据。 已检查的 author_faithful 路径把时间词元放在文本词元前。因果注意力只允许每个位置读取自身或更早位置，预测头又只读取时间词元位置。因此在确定性评估前向过程中，这些位置无法利用后面的文本。所附归档明确断言文本不变性，以及匹配初始化的完整/无文本 CPU 输出相同，所附 JUnit 现记录三项固定权重 CPU 模型断言通过、零跳过；本次审阅未重跑它们。其他融合路径、dropout 和独立训练轨迹仍需分别检查。精确文件与命令见 audit/NO_TEXT_VERIFICATION.md。

文献依据与选择理由。 Transformer 原文说明遮罩如何阻止关注后续位置 [24，第 3.1 节]。按已检查顺序，时间位置不能通过这些层取得后方文本，预测头又只读时间位置。这是固定前向路径的结构论证，不是仓库运行或逐位相等认证。三项归档断言须控制权重、输入和评估随机性，再比较更换文本及匹配完整/无文本输出，所附 JUnit 现记录三项 CPU 断言通过且零跳过；本次未重跑模型测试。独立训练可能不同地消耗随机数，须另测。

向导师简答。 因果遮罩支持结构论证，本地逐位相等须由受控运行测试建立 [24]。

论文位置。 Vaswani et al. [24], §3.1 Decoder; local ForecastingLLM.forward and archived assertions.

证据。 miflu_model.py ForecastingLLM; tests_archive/test_miflu_ablations.py; audit/NO_TEXT_VERIFICATION.md

Q23 消融完成 60/60，究竟可以说什么?

直接回答与本地证据。 这是 11 月 4 日回传记录中的队列完成证据，不是已聚合的模型比较，也不是本次独立重跑的消融研究。新增设计有五个变体，每个四跨度、三种子，合计 60 单元；参考模型另有 12 单元。没有逐变体结果导出，就不能从完成数量推断深度趋势或 LoRA 收益。存在 no-text 测试断言，也不代表已完成相应消融实验。报告科学结果前，需要逐运行输出、状态及来源。

文献依据与选择理由。 Tan 等保留周边可训练预测器，移除或替换 LLM [13，第 3.2 节]，以检验骨干是否额外贡献信息。本地 no-LoRA/深度变体只回答较窄的适配/容量问题，不会自动回答同样的移除/替换问题，也不能分离文本使用。部分完成是操作状态；解释科学趋势需各报告变体分数、重复运行波动及匹配协议。文献提供实验问题，不提供本地未完成阶梯的结果。

向导师简答。 文献支持移除/替换对照，未完成阶梯尚未回答这些因果问题 [13]。

论文位置。 Tan et al. [13], §3.2 Proposed Ablations, w/o LLM / LLM2Attn / LLM2Trsf.

证据。 Owner snapshot; ablation design table; tests_archive/test_miflu_ablations.py

10 解释与发表计划

Q24 除了复现，本项目增加了什么，为什么默认仍选 O1?

直接回答与本地证据。 本项目在明确不同子集的前提下，从精度、峰值技巧、参数效率和统计证据四个维度比较实现。本次没有核实参考论文是否只有前两项，因此不能断言原文缺失某项或声称首次发现。O1 通过补齐来源、恢复测试、滚动原点、区域和更强对照来发展实证贡献。可选 O2 是只在验证数据拟合的峰高再校准：若已有可审计的验证/测试预测，可不新增 GPU 训练。但本快照尚未确立这些验证导出；CPU 时间和费用未测量，几个工作日也仅为规划估计。

文献依据与选择理由。 简单线性及移除 LLM 的批评早已存在 [4, 13]，Qiu 等预印本又在更大跨数据集设置报告条件式收益 [14]。本地较窄贡献连接经审计流感精度、峰值端点、代价子集和正确推断。 O1 检查跨原点/区域是否保持，Tashman 支持滚动原点评测 [23]。O2 仅在预测导出合适时加入验证集拟合峰高调整；新增机制不能替代检查，也不能确立对所有 LLM 的判决。

向导师简答。 O1 检验流感特定发现；已有负面和条件式正面证据，不支持通用结论 [4, 13, 14]。

论文位置。 Zeng et al. [4], §4; Tan et al. [13], §3.2; Qiu et al. [14], abstract and §§3–5 (preprint); Tashman [23], publisher-indexed abstract.

证据。 audit/INNOVATION_DECISION.md; audit/LITERATURE_REVIEW.md; sources.json [1]

11 可复现性与待核实项

Q25 导师现在能复核什么，还有什么未执行?

直接回答与本地证据。 文档中的 CPU 命令可以重算 CSV 主要聚合、正确 Holm 和一个原始预测单元的 MSE；七个新增 CPU 审计检查已通过。整个历史归档的收集仍失败。所附 JUnit 记录三项固定权重 CPU no-text 断言通过且零跳过，核心产物满足 160/160 完整性检查；全国 1120 矩阵仍在进行。完整共同面板评分及固定上游身份仍待核实，本次未重跑 GPU 训练或连接实时 HPC，硬件来源也未完整覆盖正式单元。文档排版完善不能补足这些证据。精确后续命令见 audit/EXECUTION_STATUS.md 与 audit/NO_TEXT_VERIFICATION.md。

文献依据与选择理由。 Kapoor 与 Narayanan 要求明确报告论证，而非把代码可用等同于结果有效 [22]。这里应分开文档重建、CSV 算术、原始预测重评分与模型重训。导师可先运行 CSV 审计；完整包还支持一个原始单元 smoke 检查。模型文本不变性需在固定环境实际执行三项指定断言，且不能跳过。有用的交付是可追溯证据链、精确命令与状态，某一层通过不能认证其他所有层。

向导师简答。 我区分重算结果与静态检查，并为每层提供命令和状态 [22]。

论文位置。 Kapoor and Narayanan [22], model info sheets; EXECUTION_STATUS.md and NO_TEXT_VERIFICATION.md.

证据。 audit/EXECUTION_STATUS.md; audit/NO_TEXT_VERIFICATION.md; audit/REPO_AUDIT.md

参考文献

以下 25 项文献沿用原报告编号，方便对应每题的论文依据与阅读位置。

[1] Jaeuk Moon 等，基于大语言模型的多模态流感预测方案（中文译名），2025。https://doi.org/10.1109/JBHI.2025.3561214

[2] Sarah C. Kramer 等，针对温带及热带六十四国的流感预测开发与验证（中文译名），2019。https://doi.org/10.1371/journal.pcbi.1006742

[3] Yuqi Nie 等，一个时间序列相当于六十四个词的长期预测方法（中文译名），2023。https://arxiv.org/abs/2211.14730

[4] Ailing Zeng 等，Transformer 是否适用于时间序列预测（中文译名），2023。https://arxiv.org/abs/2205.13504

[5] Yong Liu et al. 等，反转维度的 Transformer 时间序列预测（中文译名），2024。https://arxiv.org/abs/2310.06625

[6] Ming Jin et al. 等，通过重编程大语言模型进行时间序列预测（中文译名），2024。https://arxiv.org/abs/2310.01728

[7] Peiyuan Liu et al. 等，通过跨模态微调对齐语言模型与时间序列（中文译名），2024。https://arxiv.org/abs/2403.07300

[8] Chenxi Liu et al. 等，通过跨模态对齐增强多变量时间序列预测（中文译名），2025。https://arxiv.org/abs/2406.01638

[9] Abdul Fatir Ansari et al. 等，学习时间序列语言的 Chronos 方法（中文译名），2024。https://arxiv.org/abs/2403.07815

[10] Abhimanyu Das 等，仅解码器时间序列预测基础模型（中文译名），2024。https://proceedings.mlr.press/v235/das24c.html

[11] Gerald Woo et al. 等，通用时间序列预测 Transformer 的统一训练（中文译名），2024。https://proceedings.mlr.press/v235/woo24a.html

[12] Kashif Rasul et al. 等，面向概率时间序列预测基础模型的 Lag Llama（中文译名），2024。https://arxiv.org/abs/2310.08278

[13] Mingtian Tan 等，语言模型真的有助于时间序列预测吗（中文译名），2024。https://arxiv.org/abs/2406.16964

[14] Xin Qiu et al. 等，重新思考大语言模型在时间序列预测中的作用（中文译名），2026。https://arxiv.org/abs/2602.14744

[15] Chen Xu 等，动态时间序列的共形预测区间（中文译名），2021。https://proceedings.mlr.press/v139/xu21h.html

[16] Chen Xu 等，时间序列的顺序预测共形推断（中文译名），2023。https://proceedings.mlr.press/v202/xu23r.html

[17] Isaac Gibbs 等，分布偏移下的自适应共形推断（中文译名），2021。https://arxiv.org/abs/2106.00170

[18] Johannes Bracher 等，以区间格式评估传染病预测（中文译名），2021。https://doi.org/10.1371/journal.pcbi.1008618

[19] Xavier Bouthillier et al. 等，Accounting for Variance in Machine Learning Benchmarks（英文原题），2021。https://proceedings.mlsys.org/paper_files/paper/2021/file/0184b0cd3cfb185989f858a1d9f5c1eb-Paper.pdf

[20] Janez Demšar 等，Statistical Comparisons of Classifiers over Multiple Data Sets（英文原题），2006。https://jmlr.org/papers/volume7/demsar06a/demsar06a.pdf

[21] Rob J. Hyndman 等，Another look at measures of forecast accuracy（英文原题），2006。https://doi.org/10.1016/j.ijforecast.2006.03.001

[22] Sayash Kapoor 等，Leakage and the reproducibility crisis in machine-learning-based science（英文原题），2023。https://doi.org/10.1016/j.patter.2023.100804

[23] Leonard J. Tashman 等，Out-of-sample tests of forecasting accuracy: an analysis and review（英文原题），2000。https://doi.org/10.1016/S0169-2070(00)00065-0

[24] Ashish Vaswani et al. 等，Attention Is All You Need（英文原题），2017。https://papers.neurips.cc/paper/7181-attention-is-all-you-need.pdf

[25] Daniël Lakens 等，Equivalence Tests: A Practical Primer for t Tests, Correlations, and Meta-Analyses（英文原题），2017。https://doi.org/10.1177/1948550617697177