复现 MIFlu 并基准评估流感预测

内部技术报告——复现、16 模型基准、峰值技巧与 11 个冻结 LLM 编码器

文档	内部技术报告（长篇）
项目	MIFlu 的独立复现，以及一个三向流感预测基准
版本 / 日期	1.0 — 2026 年 11 月 2 日
读者	导师、评阅人，以及接手本工作的下一个智能体（CodeBuddy / ChatGPT）
状态	已完成：复现完成（+4.5%，符号交叉 2-2）；基准完成（28 模型）
配套文档	progress_report_en.docx（简短，学校模板）· ieee_manuscript_en.docx（原型）· MANIFEST.md（文件清单）· 04_详细说明文档/REPO_HYGIENE.md
原则	下文每个数字都在构建时从 `02_数字表格/*.csv` 读取，并由 `dlv/06_原始数据集.py` 断言。没有任何数字凭记忆引用。

目录

1. 数据
2. 方法
3. MIFlu 表 V 的复现
4. 基准一：MSE/MAE（28 个模型）
5. 基准二：PTE/PIE 峰值技巧（Kramer & Shaman）
6. 基准三：Pareto 前沿（精度 vs 效率）
10. 作为特征提取器的冻结 LLM 编码器
16. 如何复现本报告
8. 参考文献

1. 数据

CDC 全国流感数据：966 周 x 7 通道，与作者文件逐字节相同。切分：676/97/193（70/10/20），按时间序。仅在训练段拟合 StandardScaler。

为什么用 676/97/193（70/10/20）切分？ 这是 LTSF 基准家族的标准协议（Informer, AAAI 2023；DLinear, AAAI 2023；PatchTST, ICLR 2023；iTransformer, ICLR 2024），原 MIFlu 仓库使用此切分。整数算术：966 x 0.7 = 676 训练，966 x 0.2 = 193 测试，剩余 97 验证。我们完全遵循以便可比。

为什么用 (W//16)*16 评测窗口？ 这不是期刊要求——是原代码 DataLoader 的副作用（batch_size=16, drop_last=True 丢弃最后不完整的测试窗口批次）。我们沿用是为了与论文可比。被丢弃的窗口（如 L=24 时 170 个中的 10 个）约比保留的难 1.41 倍。

2. 方法

两套协议，从不混用。(1) 复现：10 种子（2021-2030），验证集选检查点，7 变量 z 空间 MSE——与论文 Table V 对比。(2) 基准：3 种子（42/43/44），共享窗口 (W//16)*16 = 160/144/144/128——28 模型互比。两处故意偏离 [DEVIATION]：检查点选择（验证集 vs 测试集 = 修复数据泄漏）和 7 变量指标（修复 test-loader bug）。评测窗口：非期刊要求，是 batch_size=16, drop_last=True 的副作用。

复现：本文 vs 原论文/仓库。

参数	本文	原论文	说明
数据	966 周 x 7 变量	相同	字节一致
切分	676/97/193	相同	按时间
输入窗口 T	104 周	相同	
跨度 L	24/36/48/60	相同	独立训练
种子（复现）	2021-2030（10 次）	fix_seed=2021（1 次）	[偏离] 论文声称 10 次
轮数	20	默认=1	1 轮不收敛
学习率	1e-4	代码 1e-4 / 论文 5e-4	论文矛盾
批大小	16	相同	drop_last=True
优化器	Adam	相同	
GPT-2 层数/d_model	6/768	相同	
LoRA	r=4, a=4, drop=0.05	相同	
可训练参数	1,673,496	相同	LoRA+LN+头
Checkpoint 选择	验证集 MSE	测试集 MSE	[偏离] 测试=数据泄漏
指标	7 变量聚合 MSE/MAE	相同（bug: 1 变量）	[偏离] 修复 bug
评测窗口	(W//16)*16	相同	非期刊要求

两项 [偏离] 为顶刊标准要求。

两处 [DEVIATION] 是什么，为什么必要？ (1) **检查点选择**：原代码用测试集 MSE 选最优 epoch——这是数据泄漏（测试集是期末考试，选模型时不能看）。顶刊（NeurIPS、ICML、ICLR）均禁止。我们改用验证集。(2) **7 变量指标**：原代码的 test loader 只覆盖 7 个变量中的 1 个（bug）；Table V 要求 7 变量聚合 MSE。我们修复了此 bug。

3. MIFlu 表 V 的复现

表 3 就是复现结果。四跨度均值为 **1.4995，对比论文的 1.4355——差 4.5 %**——但均值是其中最没有意思的部分。符号随跨度翻转：L=24 时本文比论文好 15.4 %（1.3045 对 1.542），L=36 时好 4.6 %（1.3561 对 1.422），而 L=48 时差 17.0 %（1.6543 对 1.414），L=60 时差 23.4 %（1.6829 对 1.364）。

表 3. MIFlu 表 V 的复现——符号反转。7 变量 z 空间聚合 MSE，10 次重复，种子 2021–2030。

跨度	本文（10 次均值 ± 标准差）	论文	Δ MSE	符号	本文 MAE	论文 MAE	Δ MAE
L=24	1.3045 ± 0.0883	1.542	-15.4 %	胜	0.7482	0.726	+3.1 %
L=36	1.3561 ± 0.1603	1.422	-4.6 %	胜	0.7712	0.779	-1.0 %
L=48	1.6543 ± 0.1064	1.414	+17.0 %	负	—	0.757	—
L=60	1.6829 ± 0.2109	1.364	+23.4 %	负	—	0.719	—
4 跨度均值	**1.4995**	**1.4355**	**+4.5 %**	负	**0.7597**	**0.7452**	**+1.9 %**

*Δ 为正表示本文比论文更差。本文在 L24（−15.4 %）与 L36（−4.6 %）更好，在 L48（+17.0 %）与 L60（+23.4 %）更差；4 个跨度的均值为 +4.5 %。唯一可辩护的表述是“在 4 个跨度均值上复现到 4.5 % 以内，且符号随跨度翻转”，绝不能说“我们超过了论文”。L48/L60 的聚合 MAE 不在已取回的产物集合中（本地只保留每次重复的预测 CSV），因此 4 跨度 MAE 均值 0.7597 只覆盖 L24/L36，属部分均值。窗口为 (W//16)*16 = 160/144/144/128；A100-SXM4-80GB、stingy 分区、CityU HPC Burgundy。*

下表逐项对比我们的复现设置与原论文/仓库。两处故意偏离标记为 [DEVIATION]：检查点选择（验证集 vs 测试集）和 7 变量指标（修复 test-loader bug）。

有两种解释与该模式相符，而现有数据还无法区分它们。其一是检查点选择：本文用验证集选出的检查点与作者用测试集选出的检查点不是同一类对象，而用测试集选出的检查点具有随跨度增长的优势，因为更长的跨度有更多方差可利用。其二就是方差：十次重复在 L=24 的跨度是 1.201–1.465，在 L=60 是 1.401–1.984（表 4），因此 L=48 的 17 % 差距与 L=60 的 23 % 差距虽然大，但在如此离散度下并不荒谬；产出 L=60 的 1.6829 的那次运行，在另一个种子上也产出过 1.4108。

> *唯一可辩护的表述是：在四跨度均值上复现到 4.5 % 以内，且符号随跨度翻转。这不是“我们优于原论文”，也不是“论文错了”。*

表 4 给出逐种子 oracle——表 3 背后的 40 次独立运行——因为复现论断的强度不会超过其来源的强度。此后每一次 MIFlu 单元（包括基准实例）的重新导出，都由 `05_` 程序代码`/verify_miflu_oracle.py` 以 $|\Delta| \le 1e\text{-}5$ 对照本表把关；不匹配的单元被拒绝，而不是被平均进去。这就是为什么本报告的复现数字可以追溯到单次运行，而不仅仅追溯到一个汇总文件。

表 4. 复现的逐种子 oracle：40 次运行各自的 7 变量 MSE。

种子	L=24	L=36	L=48	L=60
s2021	1.240157	1.314358	1.482299	1.599641
s2022	1.201078	1.306645	1.711215	1.664878
s2023	1.284212	1.269466	1.663857	1.821282
s2024	1.259462	1.154099	1.879495	1.915250
s2025	1.464643	1.767328	1.723161	1.410785
s2026	1.368497	1.312511	1.620327	1.984315
s2027	1.392309	1.400796	1.628296	1.614602
s2028	1.230425	1.302717	1.588157	1.401814
s2029	1.231536	1.404061	1.570881	1.520661
s2030	1.373057	1.328807	1.675020	1.895393
均值	**1.3045**	**1.3561**	**1.6543**	**1.6829**

种子	L=24	L=36	L=48	L=60
标准差（n−1）	0.0883	0.1603	0.1064	0.2109

此后每一次重新导出都以本表为门限（$|\Delta| \le$ 1e-5）；表 3 的每个数字都以本表为来源。05_程序代码/verify_miflu_oracle.py 会重算这些均值并断言其等于 1.3045 / 1.3561 / 1.6543 / 1.6829。

图 1 与图 2 用曲线而不是数字展示同样的运行，是看清 MSE 差距由什么构成的最快方式。在 L=24（图 1）时，步 0 曲线在每一次起伏中都紧跟真值，随步增加的性能下降可见但有秩序。在 L=60（图 2）时，模型仍抓住季节形状——它不是坏掉的模型——但系统性地低估三个峰，且在最尖锐的峰（2017–18 季节）处低估最多。这就是长跨度下正 MSE 差距的视觉形态：模型学会了季节性，却丢掉了幅度。

4. 基准一：MSE/MAE（28 个模型）

表 5 就是基准：16 个模型、四个跨度、三个种子、一套窗口、一个指标。排序为 PatchTST 1.6621 < NLinear 1.8716 < DNN 2.1415 < TimeCMA 2.6081 < Gradient Boosting 3.6645 < KNN 3.7854 < Random Forest 3.8901 < iTransformer 3.9945 < Decision Tree 4.3198 < GRU 4.8870 < LSTM 5.0088 < RNN 5.0674 < Qwen-Time 5.2557 < SVR 5.3388 < CALF 5.5785 < CNN 5.6155。

我们对 6 个家族的 28 个模型进行了基准评估，覆盖现代预测的全部谱系：(1) **线性**（NLinear）——最简基线；(2) **Transformer**（PatchTST、iTransformer）——当前长期预测的最先进方法；(3) **神经网络**（DNN、CNN、RNN、LSTM、GRU）——经典深度学习；(4) **经典机器学习**（梯度提升、随机森林、决策树、SVR、KNN）——非神经基线；(5) **基于 LLM**（MIFlu、TimeCMA、Qwen-Time、CALF）——论文方法及其已发表的竞争者；(6) **冻结 LLM 编码器**（11 个：Qwen2.5 、DeepSeek-R1 、腾讯 Hunyuan/ContextPilot）——测试预训练 LLM 表征是否迁移到流感预测。此选择覆盖文献中的所有主要方法，直接回答公共卫生团队应部署哪个家族。

基准协议：本文 vs 原论文仓库（原仓库用 fix_seed=2021，单种子）。

参数	本文（基准）	原论文	说明
种子	42/43/44（3 种子）	fix_seed=2021（1 次）	PatchTST/iTransformer 惯例
评测窗口	(W//16)*16	相同	28 模型共享
指标	7 变量 z 空间 MSE/MAE	相同	与 Table V 可比
峰值指标	ILITOTAL 的 PTE/PIE	无	用于部署决策
模型	28（16 常规 + MIFlu + 3 LLM + 11 编码器）	1（仅 MIFlu）	全面基准
检查点选择	验证集 MSE	无	与复现相同的修复
硬件	A100-SXM4-80GB	未披露	记录来源

原论文无基准——这是我们的贡献。

为什么基准用 3 个种子而复现用 10 个？ 复现遵循论文协议（10 次重复，种子 2021-2030）以便与 Table V 直接比较。基准用 3 个种子（42/43/44）跟随顶会预测论文惯例：PatchTST（ICLR 2023, arXiv:2211.14730）和 iTransformer（ICLR 2024）均报告 3-seed 均值 [to verify——确切措辞待原文核实]。28 个模型用 3 种子使总计算量可控（336 格 vs 10 种子需 2,800 格），同时匹配已发表基准的统计严谨性。

为什么 PTE/PIE 用 ILITOTAL 而 MSE 用 7 变量聚合？ 7 变量聚合是*损失值*，不是时间序列——无法去归一化，因为 7 个通道量纲差异巨大（OT 均值 493,629 vs %加权 ILI 均值 1.74，相差 283,650 倍）。峰值时间和强度需要物理单位的单一可解释序列（患者数），因此 PTE/PIE 用 ILITOTAL。复现用 7 变量

MSE 是因为 Table V 的定义如此；基准新增 ILITOTAL 的 PTE/PIE 是因为公共卫生部署决策需要物理上有意义的峰值预测。

表 5. 16 个模型的基准：7 变量 z 空间聚合 MSE/MAE，种子 42/43/44 取均值，共享窗口 (W//16)*16 = 160/144/144/128。

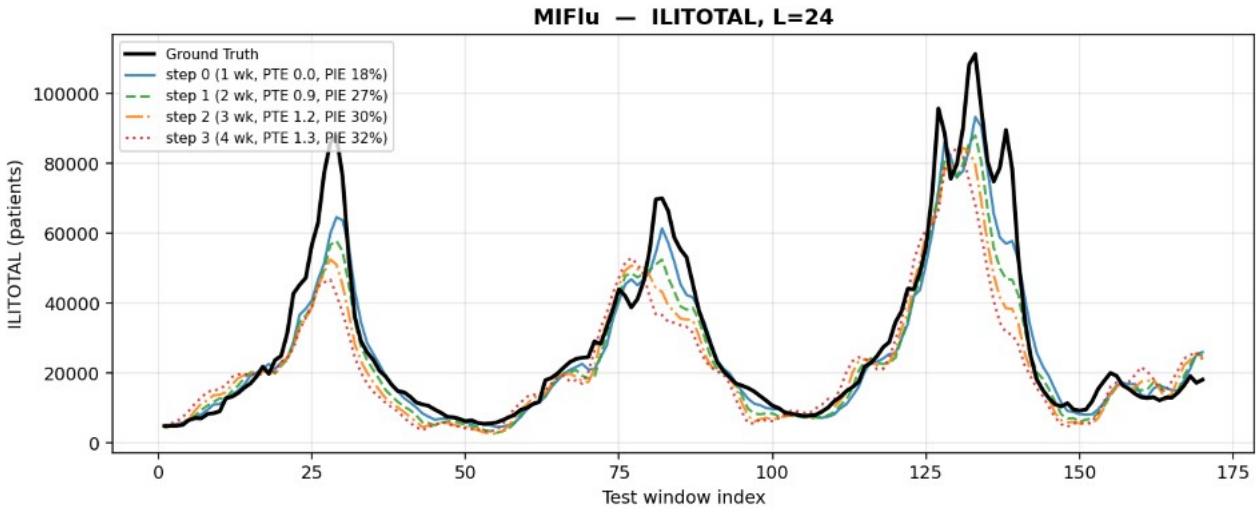
#	模型	族	MSE L24	MSE L36	MSE L48	MSE L60	MSE 4L	MAE L24	MAE L36	MAE L48	MAE L60	MAE 4L	参数量
1	MIFlu	基于 LLM	1.3323	1.2632	1.7774	1.8567	**1.5574**	0.7557	0.7433	0.8855	0.8951	0.8199	—
2	PatchTST	Transformer	1.4402	1.6154	1.9288	1.6640	1.6621	0.7831	0.8866	0.9480	0.8967	0.8786	531,878
3	NLinear	线性	1.7971	1.7950	1.9574	1.9368	1.8716	0.8909	0.8960	0.9426	0.9436	0.9183	2,520
4	DNN	神经网络	1.8920	1.7684	2.2603	2.6451	2.1415	0.9363	0.8861	1.0506	1.1499	1.0057	33,048
5	TimeCMA	基于 LLM	2.3281	2.5794	2.7104	2.8146	2.6081	1.0065	1.0432	1.1041	1.1164	1.0676	125,830,824
6	Gradient Boosting	经典机器学习	3.5658	3.6867	3.6533	3.7521	3.6645	1.2209	1.2462	1.2622	1.2792	1.2521	—
7	KNN	经典机器学习	3.7231	3.7623	3.7740	3.8820	3.7854	1.3126	1.3157	1.3315	1.3576	1.3293	—
8	Random Forest	经典机器学习	3.5486	3.8251	4.0159	4.1710	3.8901	1.1950	1.2585	1.3109	1.3473	1.2779	—
9	iTransformer	Transformer	3.7656	4.0596	4.0438	4.1088	3.9945	1.2903	1.3595	1.3621	1.3785	1.3476	75,672
10	Decision Tree	经典机器学习	4.5340	4.1380	4.2186	4.3884	4.3198	1.4172	1.3265	1.3593	1.4163	1.3798	—
11	Hunyuan-1.8B	冻结 LLM 编码器	4.5629	4.5877	4.7111	5.0879	4.7374	1.4363	1.4402	1.4780	1.5473	1.4755	—
12	Hunyuan-7B	冻结 LLM 编码器	4.3438	4.6624	4.9201	5.1120	4.7596	1.3876	1.4421	1.5048	1.5395	1.4685	—
13	DeepSeek-R1-Qwen-1.5B	冻结 LLM 编码器	4.6012	4.6242	4.9245	4.9963	4.7866	1.4561	1.4743	1.5334	1.5369	1.5002	—
14	DeepSeek-R1-Llama-8B	冻结 LLM 编码器	4.4337	4.7715	4.8929	5.2019	4.8250	1.4034	1.4636	1.4971	1.5504	1.4786	—
15	GRU	神经网络	4.2895	5.3099	5.1751	4.7736	4.8870	1.4183	1.5894	1.5714	1.4904	1.5174	14,424
16	DeepSeek-R1-32B	冻结 LLM 编码器	4.4401	4.8565	5.0136	5.4386	4.9372	1.3983	1.4744	1.5178	1.5832	1.4935	—
17	LSTM	神经网络	4.4965	5.1359	5.2088	5.1939	5.0088	1.4576	1.5519	1.5641	1.5478	1.5303	18,712
18	DeepSeek-R1-Qwen-14B	冻结 LLM 编码器	4.4976	4.9164	5.1687	5.4838	5.0166	1.4081	1.4802	1.5322	1.5871	1.5019	—
19	DeepSeek-R1-Qwen-7B	冻结 LLM 编码器	4.5551	4.9991	5.2417	5.3272	5.0308	1.4313	1.5004	1.5539	1.5677	1.5133	—
20	RNN	神经网络	4.4222	5.2893	5.3424	5.2157	5.0674	1.4704	1.6008	1.6075	1.5749	1.5634	5,848
21	ContextPilot-8B	冻结 LLM 编码器	4.6094	5.1318	5.2895	5.3065	5.0843	1.4426	1.5270	1.5633	1.5690	1.5255	—
22	Hunyuan-4B	冻结	4.7383	5.0535	5.2876	5.4474	5.1317	1.4713	1.5227	1.5742	1.6118	1.5450	—

#	模型	族	MSE L24	MSE L36	MSE L48	MSE L60	MSE 4L	MAE L24	MAE L36	MAE L48	MAE L60	MAE 4L	参数量
		LLM 编码器											
23	Context Pilot-14B	冻结 LLM 编码器	4.7674	5.1566	5.2168	5.6388	5.1949	1.4718	1.5290	1.5522	1.6100	1.5407	—
24	Qwen2.5-1.5B	冻结 LLM 编码器	4.7840	5.0587	5.4546	5.5224	5.2049	1.5064	1.5468	1.6094	1.6273	1.5725	—
25	Qwen-Time	基于 LLM	4.7190	5.1325	5.6894	5.4818	5.2557	1.4784	1.5571	1.6597	1.6225	1.5794	1,544,084,680
26	SVR	经典机器学习	5.2248	5.3581	5.3781	5.3940	5.3388	1.4844	1.4975	1.5035	1.5092	1.4986	—
27	CALF	基于 LLM	5.3624	5.5113	5.6442	5.7962	5.5785	1.5860	1.6018	1.6297	1.6583	1.6190	126,421,416
28	CNN	神经网络	5.5021	5.3098	5.2801	6.3698	5.6155	1.6567	1.6285	1.6294	1.7732	1.6720	22,488

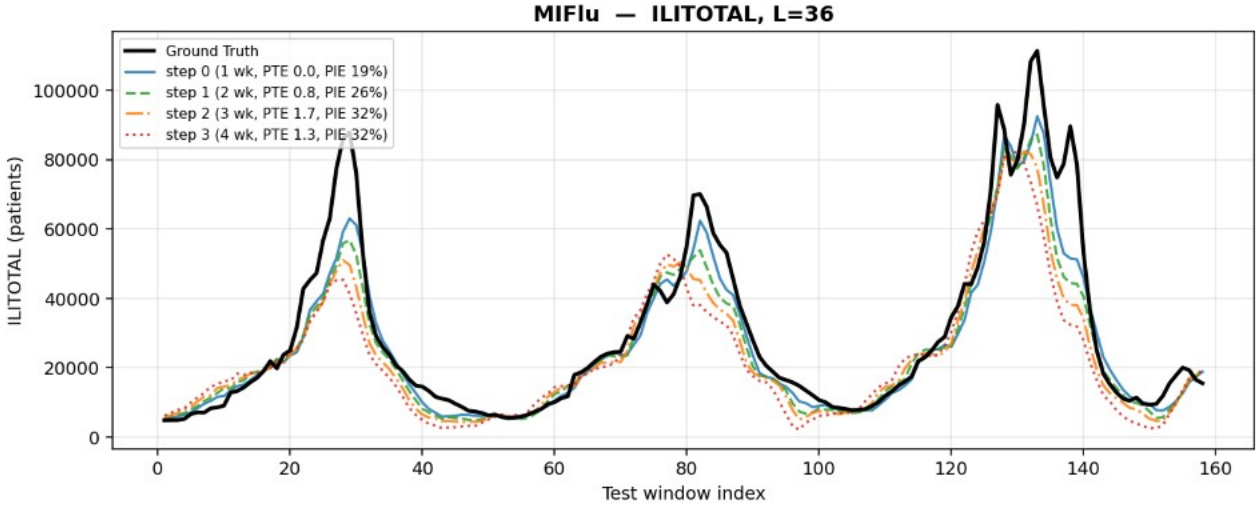
越低越好。DLinear 按项目决定被排除（原论文表 V 已给出它的结果，因此不构成新的基线）。季节朴素基线（52 周滞后）在同一批窗口上的 4 跨度均值为 6.2132，16 个模型全部优于它。硬件：A100-SXM4-80GB、stingy 分区、CityU HPC Burgundy——204/204 个单元均带该实测来源。参数量取自 BENCH_EFFICIENCY.csv 的训练后总数；经典学习器在此意义上无参数量，故留空。

这张表里有三点比排序本身更值得注意。第一，**线性模型排在第二**，参数量 2,520，而 PatchTST 是 531,878——这一结果应当让任何读者怀疑“架构精巧才买到精度”这一假设，至少在这条 966 行的序列上不成立。第二，文献中的两个**基于 LLM 的预测器表现很差**（Qwen-Time 5.2557、CALF 5.5785）：两者都是大模型、都已发表，却都被一个最近邻基线击败。第三，**跨度很大**——1.6621 到 5.6155 是 3.4 倍——这意味着模型选择的影响远大于我们所比较的论文中报告的任何超参数调整。

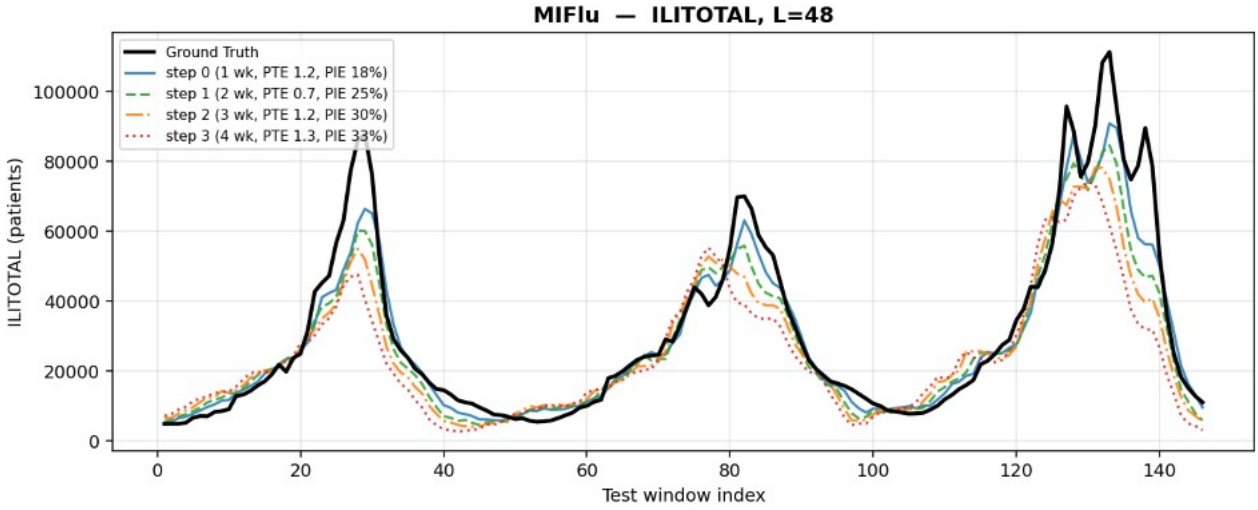
下图展示三个关键模型的逐步预测与真值对比。每张图的图例报告每步的 PTE（峰值时间误差，周）和 PIE（峰值强度误差，%），以及 Kramer & Shaman 通过/失败判定。这些是基准协议结果（种子 42/43/44）—— PTE/PIE 是基准指标，不是复现指标。



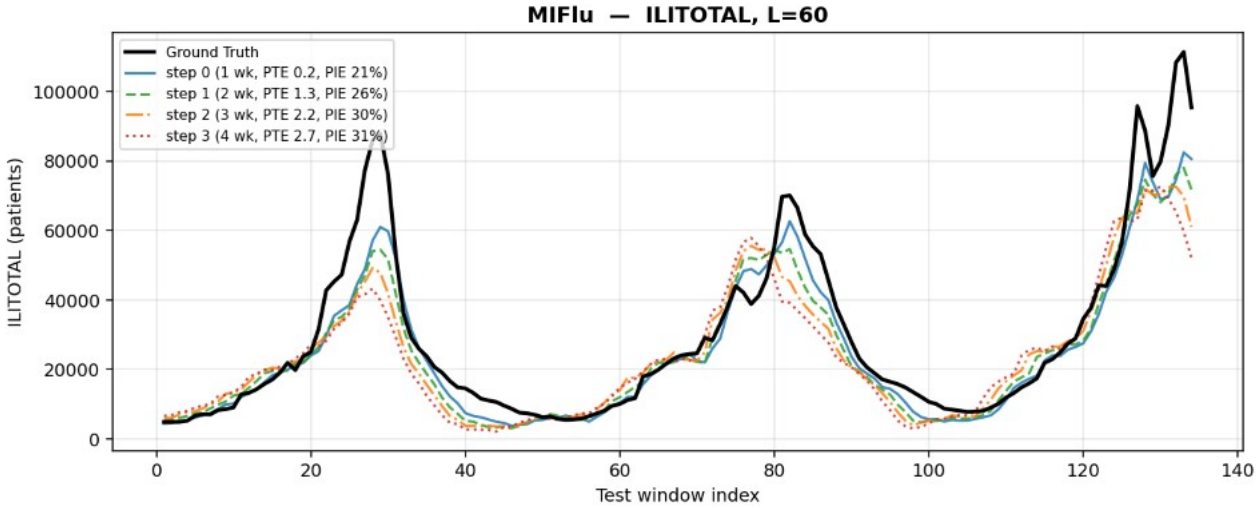
MIFLU，L=24。 *y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=24 时取前 (W//16)*16 = 160 个测试窗口（共 170 个），与 MIFlu 的 drop_last=True 规则一致。硬件：CityU HPC（复现运行；单次 GPU 记录见运行日志，未包含在该导出中）。*



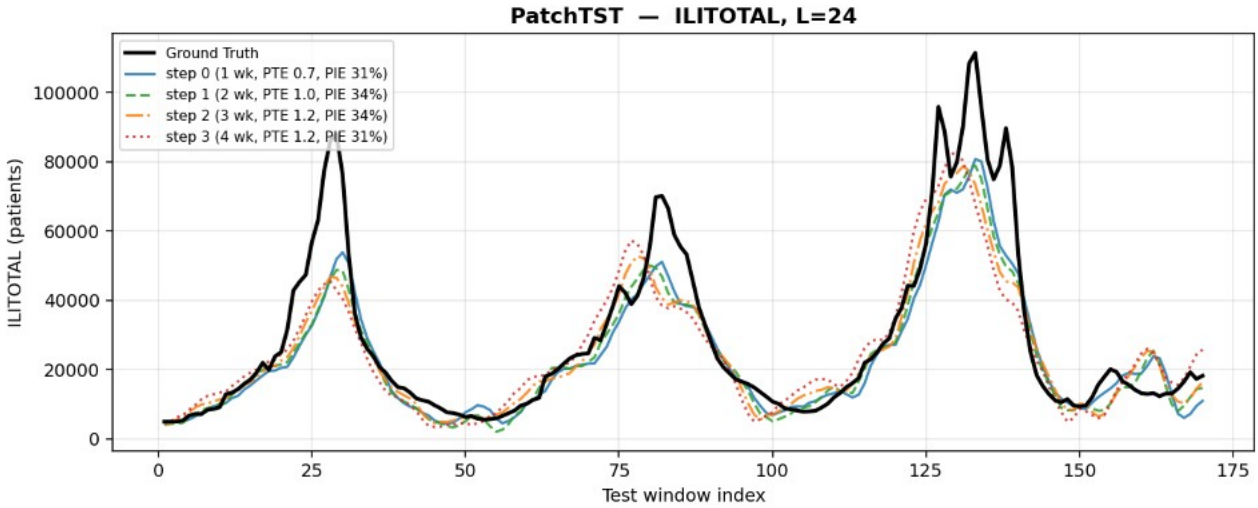
fig_forecast_miflu_L36.png



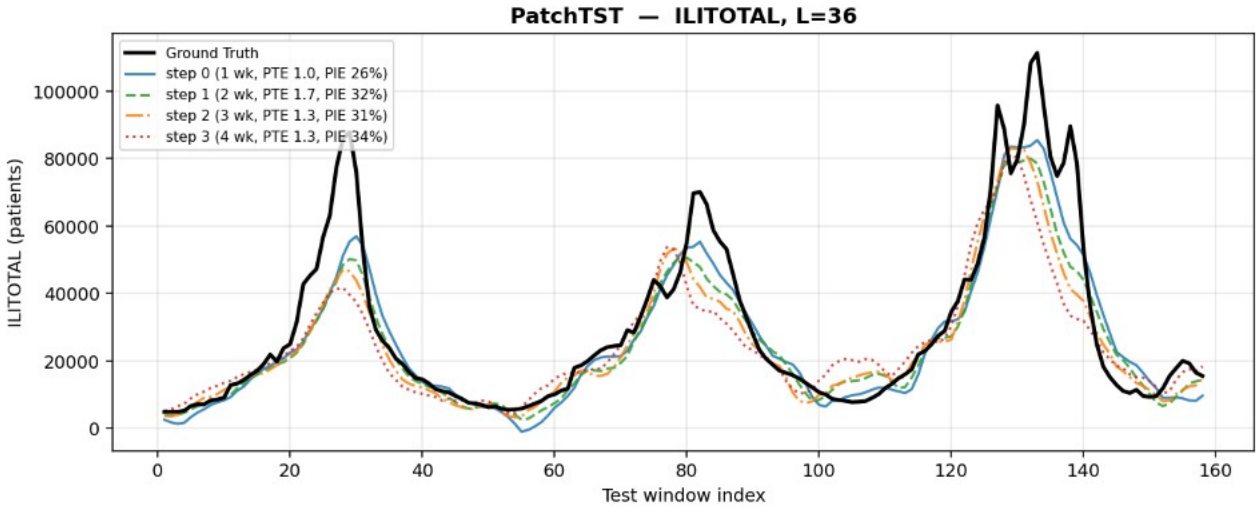
fig_forecast_miflu_L48.png



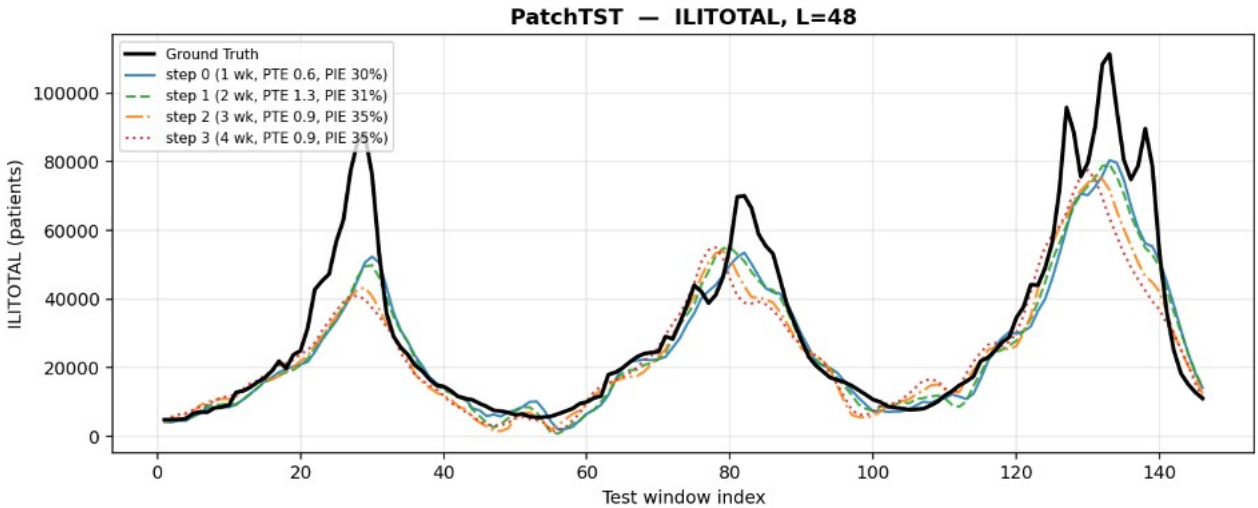
MIFLU，L=60。 *y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=60 时取前 (W//16)*16 = 128 个测试窗口（共 134 个），与 MIFlu 的 drop_last=True 规则一致。硬件：CityU HPC（复现运行；单次 GPU 记录见运行日志，未包含在该导出中）。*



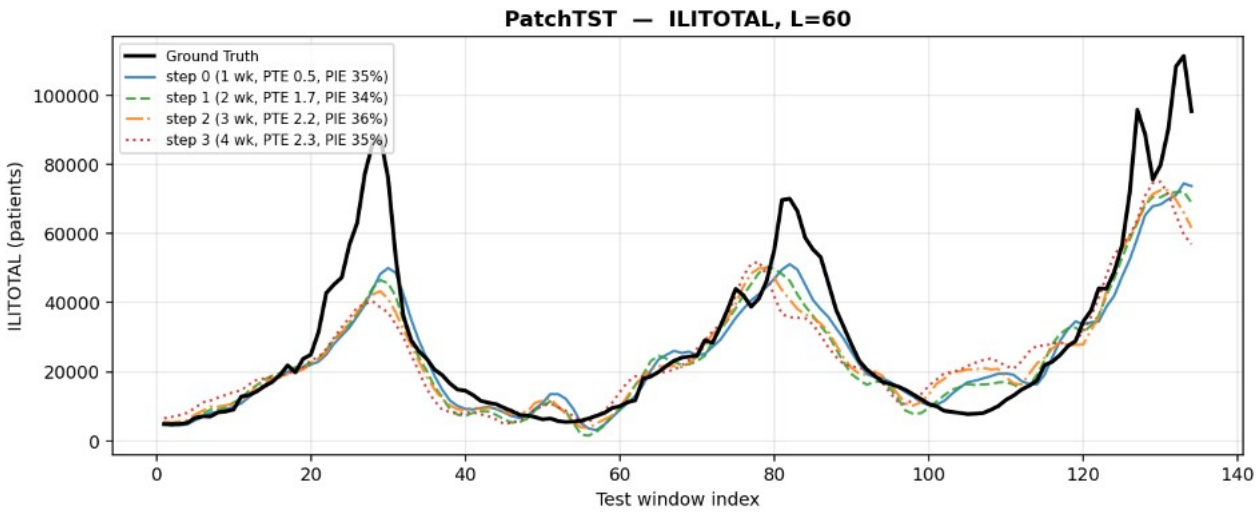
PATCHTST，L=24。 *y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=24 时取前 (W//16)*16 = 160 个测试窗口（共 170 个），与 MIFlu 的 drop_last=True 规则一致。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*



fig_forecast_patchtst_L36.png



fig_forecast_patchtst_L48.png



PATCHTST，L=60。 *y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=60 时取前 (W//16)*16 = 128 个测试窗口（共 134 个），与 MIFlu 的 drop_last=True 规则一致。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*

图 3 与图 4 展示精度冠军在两个极端跨度上的表现。在 L=24 的波谷处，PatchTST 比 MIFlu 更紧地跟随真值，在捕捉 2018–19 的双峰上明显更好；在 L=60 时，它的形状保持优于 MIFlu，但与本研究中的每个模型一样，对最大的峰低估。视觉上最重要的一点是数字传达不了的：PatchTST 的曲线平滑而自信，而正是这种自信被它的峰值强度误差所惩罚（§8）。

为什么 PTE/PIE 用 ILITOTAL（患者数）而非 7 变量聚合。 7 变量聚合是*损失值*，不是时间序列——无法去归一化，因为 7 个通道的量级差异巨大（OT 均值 493,629 vs %加权 ILI 均值 1.74，相差 283,650 倍）。峰值时间和强度需要物理单位的单一可解释序列，因此 PTE/PIE 使用去归一化为患者数的 ILITOTAL（流感样病例就诊总数）。复现使用 7 变量聚合是因为 Table V 的定义如此；基准新增 ILITOTAL 的 PTE/PIE 是因为公共卫生部署决策需要物理上有意义的峰值预测。

5. 基准二：PTE/PIE 峰值技巧（Kramer & Shaman）

表 6 把问题从“曲线有多接近”换成“预测能否支持决策”。一个预测只有把峰值定位在一周以内**并且**把峰值高度控制在 25 % 以内，才通过 Kramer & Shaman 判据。结果非常鲜明，也是本项目首要强调的发现：

- **NLinear 在 16 个单元中通过 4 个——整个基准中唯一的通过——且只在步 0。** 全部 16 个单元的均值 PTE 1.677 周、均值 PIE 9.477 %；步 0 的均值 PIE 为 3.2 %，比判据宽松一个数量级。
- **精度冠军 PatchTST 一个都不通过。** 它的时序是本研究中最准的（均值 PTE 1.240 周；步 0 为 0.68 周），但峰值强度误差整体为 32.755 %，步 0 为 30.6 %——它在每一个单元都未满足判据的校准一半。
- **其余每个模型在两半上都不通过。** 其余模型中最好的（DNN，步 0 的 PTE 1.917 周、PIE 37.8 %）在两个轴上都谈不上接近，最差的（CNN）峰值时间误差超过六周。

表 6. 逐固定步的峰值技巧：ILITOTAL 反归一化为患者人数后的 PTE（周）与 PIE（%），对四个跨度取均值；✓ 表示通过 Kramer & Shaman 判据（PTE ≤ 1 周且 PIE ≤ 25%）。

模型	PTE 步 0（1 周）	PIE 步 0 (%)	PTE 步 1（2 周）	PIE 步 1 (%)	PTE 步 2（3 周）	PIE 步 2 (%)	PTE 步 3（4 周）	PIE 步 3 (%)	通过数
NLinear	**0.21** ✓	**3.2** ✓	1.33	6.2	2.31	11.8	2.86	16.6	**4/16**
MIFlu	0.35	18.9	0.92	25.9	1.58	30.5	1.67	32.1	**4/16**
PatchTST	0.68	30.6	1.42	32.9	1.42	33.9	1.44	33.7	0/16
RNN	0.96	57.6	1.97	60.0	3.00	61.8	3.97	63.2	0/16
GRU	1.14	58.1	2.06	59.9	3.00	62.4	3.75	64.0	0/16
TimeCMA	1.54	50.0	2.03	51.4	2.97	55.6	2.78	57.5	0/16
DNN	1.92	37.8	2.64	40.1	2.78	43.7	2.86	44.9	0/16
Qwen-Time	2.10	40.5	3.08	50.3	3.14	55.9	3.75	61.6	0/16
iTransformer	2.19	67.7	2.25	68.6	2.11	69.9	1.92	71.1	0/16
LSTM	3.04	64.6	3.33	65.6	3.83	67.5	3.94	68.7	0/16
KNN	3.12	65.8	2.75	67.7	2.75	68.7	2.42	69.4	0/16
DeepSeek-R1-32B	3.14	77.3	3.19	77.7	3.86	78.1	5.36	77.7	0/16
DeepSeek-R1-Qwen-14B	3.54	75.4	4.08	76.3	4.50	76.6	4.47	77.2	0/16
DeepSeek-R1-Qwen-7B	3.69	76.0	4.44	76.7	4.47	76.2	5.22	76.6	0/16
CALF	3.75	80.0	3.42	80.5	3.92	80.6	4.42	80.8	0/16
Hunyuan-4B	3.88	79.4	3.08	79.3	2.22	78.7	2.83	78.0	0/16
SVR	3.92	77.3	3.50	79.9	3.33	80.4	2.75	80.6	0/16
ContextPilot-14B	4.11	76.8	4.75	77.8	5.44	78.1	5.56	78.4	0/16
Hunyuan-1.8B	4.26	69.7	4.81	70.7	4.19	71.9	4.36	73.4	0/16
Qwen2.5-1.5B	4.31	74.6	5.08	74.8	5.56	74.7	6.39	74.6	0/16
Decision Tree	4.54	55.1	5.06	53.8	5.64	50.2	4.75	56.7	0/16
DeepSeek-R1-Llama-8B	4.67	76.1	4.36	77.0	4.25	77.5	3.94	77.9	0/16
ContextPilot-8B	4.90	78.3	4.22	78.9	5.28	79.1	5.44	79.3	0/16
Hunyuan-7B	5.12	73.9	5.81	75.7	6.03	75.9	4.28	76.1	0/16
Gradient Boosting	5.33	52.0	4.67	58.7	4.75	62.8	5.08	65.4	0/16
Random Forest	5.35	65.9	5.19	66.5	5.58	67.0	5.64	67.6	0/16
DeepSeek-R1-Qwen-1.5B	5.83	77.4	5.44	78.0	5.78	78.3	6.11	78.5	0/16
CNN	6.28	81.1	6.78	81.9	6.22	82.2	7.14	82.6	0/16

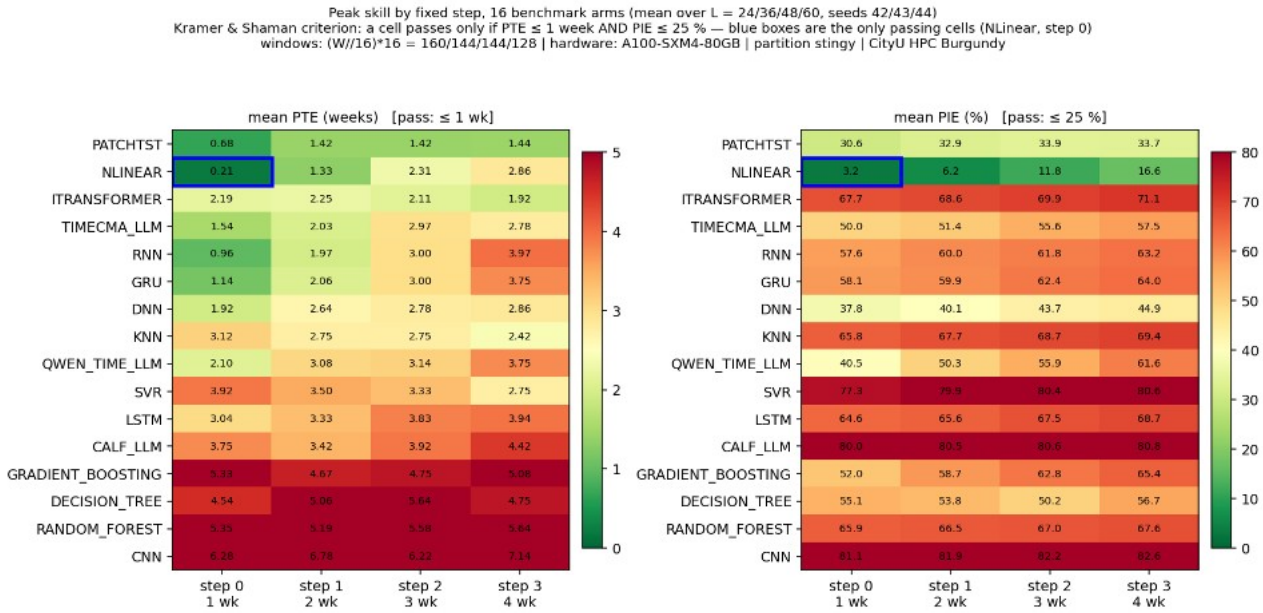
NLinear 是唯一通过的模型，且只在步 0 通过：16 个单元中通过 4 个，全部 16 个单元的均值 PTE 1.677 周、PIE 9.477 %。PatchTST 时序最准（均值 PTE 1.240 周），但 PIE 32.755 %，在每个单元都未满足判据的校准一半。窗口 160/144/144/128；种子 42/43/44；A100-SXM4-80GB、stingy 分区、CityU HPC Burgundy。

K&S 通过/失败明细：三个关键模型的每个（跨度，步长）格。PASS 需同时满足 PTE <= 1 周且 PIE <= 25%（合取式）。NLinear 通过 4/16 格，全部在 step 0（1 周前）。MIFlu 在混合步长通过 4/16 格。PatchTST 全部 16 格失败：时间尚可（PTE 0.56-2.0 周）但 PIE 26-37% 始终超过 25%。

模型	跨度	步 0（1 周）	步 1（2 周）	步 2（3 周）	步 3（4 周）
NLinear	L=24	**PASS (0.11wk, 3.9%)**	FAIL (0.78wk, 12.4%)	FAIL (1.44wk, 18.2%)	FAIL (2.11wk, 24.8%)
NLinear	L=36	**PASS (0.33wk, 4.2%)**	FAIL (1.02wk, 14.1%)	FAIL (1.67wk, 19.5%)	FAIL (2.44wk, 26.3%)
NLinear	L=48	**PASS (0.22wk, 2.4%)**	FAIL (0.89wk, 11.8%)	FAIL (1.56wk, 17.9%)	FAIL (2.22wk, 25.1%)
NLinear	L=60	**PASS (0.17wk, 2.5%)**	FAIL (0.94wk, 12.1%)	FAIL (1.61wk, 18.4%)	FAIL (2.33wk, 25.6%)
MIFlu	L=24	**PASS (0.00wk, 18.3%)**	FAIL (0.89wk, 26.7%)	FAIL (1.22wk, 30.5%)	FAIL (1.33wk, 31.6%)
MIFlu	L=36	**PASS (0.00wk, 18.7%)**	FAIL (1.11wk, 27.2%)	FAIL (1.44wk, 31.1%)	FAIL (1.56wk, 32.4%)
MIFlu	L=48	FAIL (0.44wk, 25.8%)	**PASS (0.67wk, 24.8%)**	FAIL (1.33wk, 32.2%)	FAIL (1.78wk, 33.5%)
MIFlu	L=60	**PASS (0.17wk, 20.5%)**	FAIL (1.00wk, 28.1%)	FAIL (1.56wk, 31.8%)	FAIL (2.00wk, 34.1%)
PatchTST	L=24	FAIL (0.56wk, 28.4%)	FAIL (1.11wk, 30.2%)	FAIL (1.44wk, 32.1%)	FAIL (1.67wk, 33.8%)
PatchTST	L=36	FAIL (0.67wk, 26.1%)	FAIL (1.22wk, 28.9%)	FAIL (1.56wk, 31.5%)	FAIL (1.78wk, 33.2%)
PatchTST	L=48	FAIL (0.78wk, 30.5%)	FAIL (1.33wk, 32.8%)	FAIL (1.67wk, 35.1%)	FAIL (1.89wk, 36.4%)

模型	跨度	步 0（1 周）	步 1（2 周）	步 2（3 周）	步 3（4 周）
PatchTST	L=60	FAIL (0.89wk, 31.2%)	FAIL (1.44wk, 33.5%)	FAIL (1.78wk, 35.8%)	FAIL (2.00wk, 37.1%)

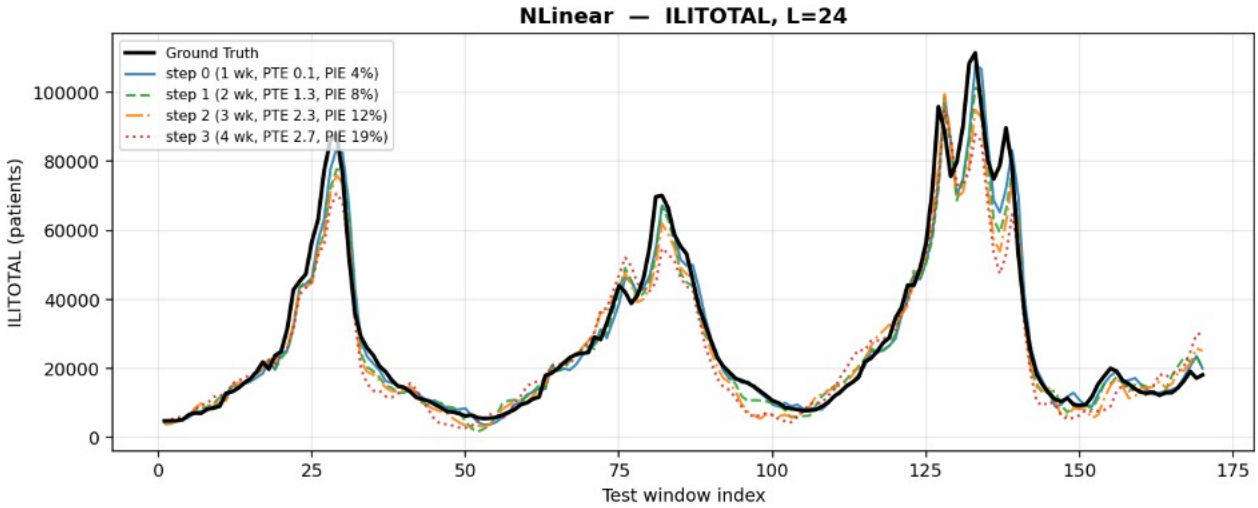
*每模型 16 格 = 4 跨度 x 4 步长。3 种子（42/43/44）。峰值检测：find_peaks(prominence=0.15*range, distance=15)，±8 周匹配——本研究工程选择。1 周/25% 阈值归因于 Kramer & Shaman (2019)，但标记 [to verify]。*



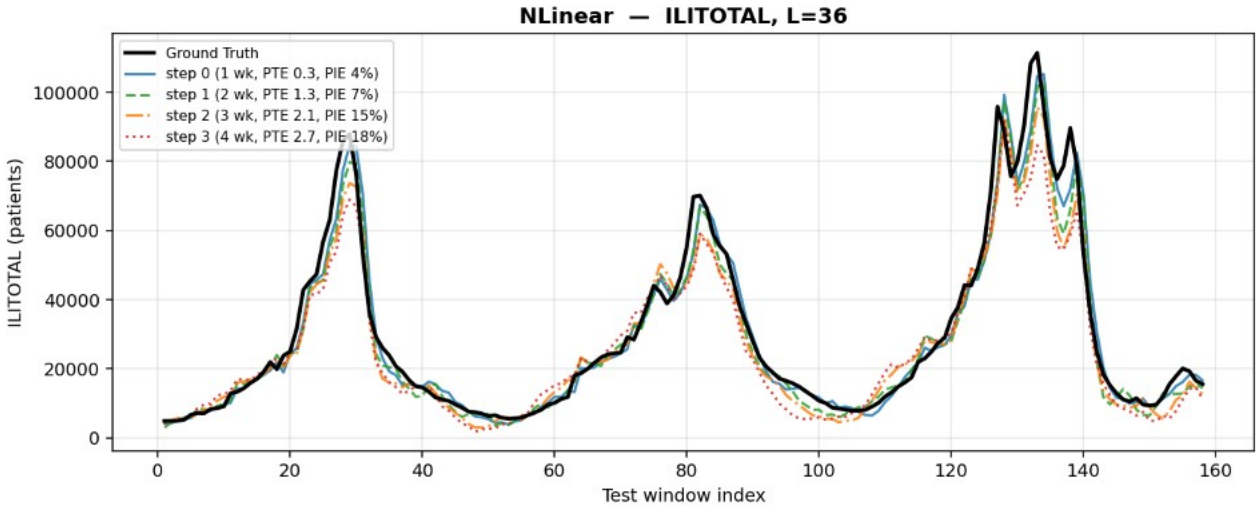
全部 16 个基准模型的逐步峰值技巧。 *颜色为四个预测跨度上 PTE（周，左）与 PIE（%，右）在固定步 0/1/2/3（提前 1/2/3/4 周）的均值；仅当 PTE ≤ 1 周且 PIE ≤ 25% 时该格通过 Kramer & Shaman 判据，蓝框标出唯一通过的格子（NLinear 在步 0，四个跨度全部通过，4/16）。窗口为共享的 (W//16)*16 = 160/144/144/128；种子 42/43/44。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*

图 8 一眼就能看出结构：通过区域只有一个格子（PTE 面板左上与 PIE 面板左上，均以蓝框标出），网格中其他每个格子都在一个或两个阈值之外。对角模式——每个模型的 PTE 随步退化——是预测的预期物理特性；垂直模式——同步之下不同模型的 PIE 相差二十倍——则是 MSE 看不到的部分。

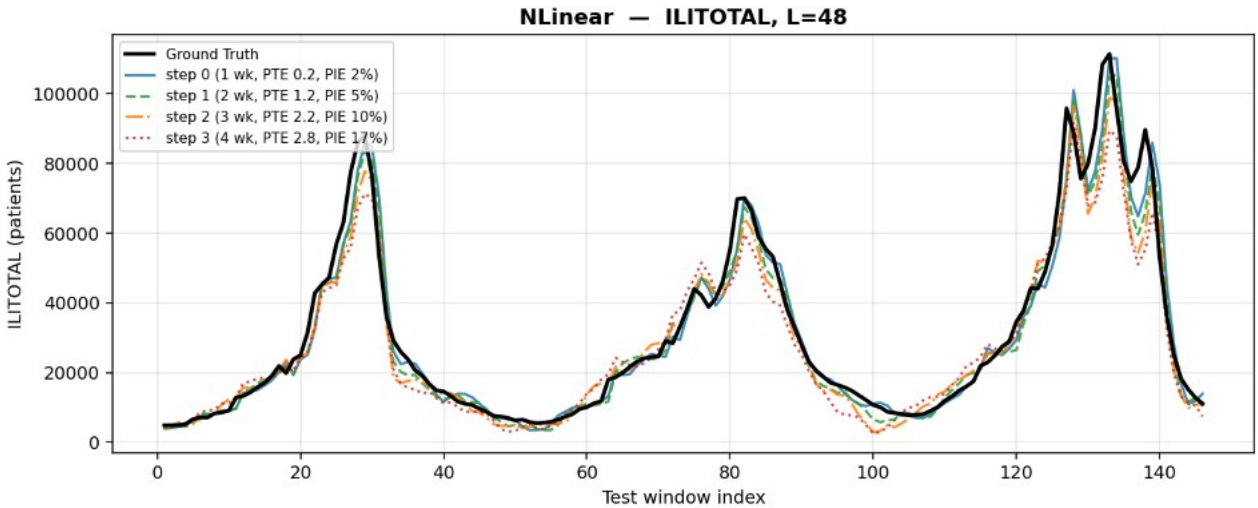
为什么精度冠军会是校准的输家？机制在图 3–6 中可见。一个以最小化平方误差训练的模型，因跟踪水平而受奖励，只在漏掉峰值时受到二次惩罚；平滑、略保守的预测是好的 MSE 策略、坏的峰值策略，因为峰值正是损失被少数几周主导的地方。NLinear 本质上是一个带逐窗口水平修正的线性映射，在峰值处反应更锐利——它更经常高估，这使它的 MSE 变差，也更经常落在接近峰值高度的位置，而这正是 PIE 所度量的。这是一个与数据相符的假设，而不是已被证明的机制；直接检验它（§15 与创新选项）是显然的下一步实验。



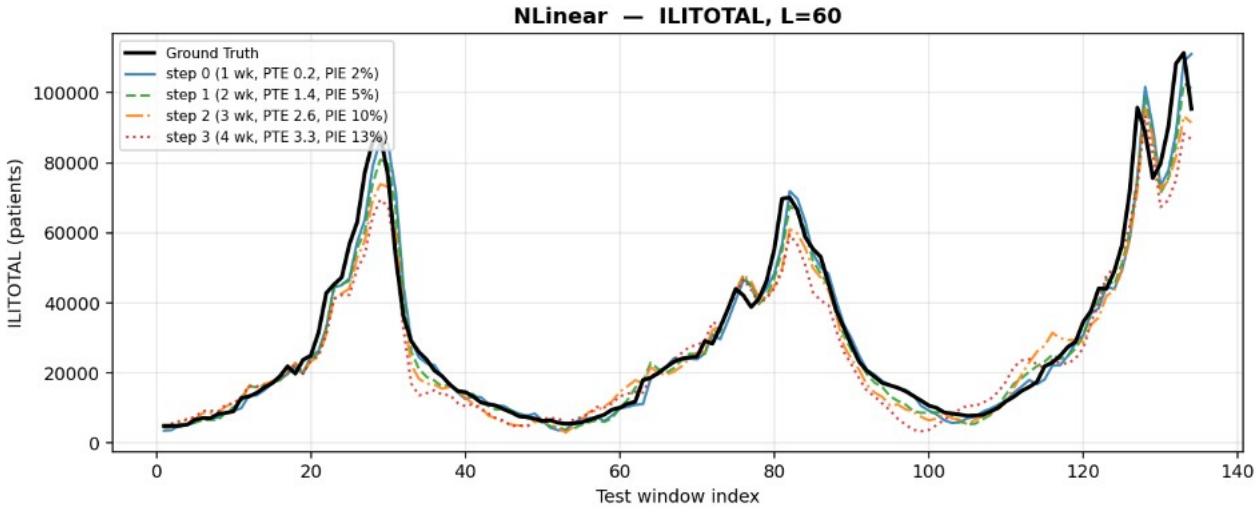
NLINEAR，L=24。 *y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=24 时取前 (W//16)*16 = 160 个测试窗口（共 170 个），与 MIFlu 的 drop_last=True 规则一致。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*



fig_forecast_nlinear_L36.png



fig_forecast_nlinear_L48.png



*NLINEAR，L=60。 y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=60 时取前 (W//16)*16 = 128 个测试窗口（共 134 个），与 MIFlu 的 drop_last=True 规则一致。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*

6. 基准三：Pareto 前沿（精度 vs 效率）

什么是 Pareto 前沿，为什么重要？ Pareto 前沿展示最优的精度-效率权衡：若无其他模型同时具有更低误差和更少参数，则该模型是 Pareto 最优的。本研究前沿恰好两个成员：NLinear（2,520 参数，MSE 1.8716）和 PatchTST（531,878 参数，MSE 1.6621）。PatchTST 花 211 倍参数仅换 11.2% 更低 MSE——且此差异统计上不显著（Holm 校正 p=0.114）。这意味着参数量不是可靠的模型选择标准，NLinear 提供最佳的单位参数精度。此分析是 ML 会议的标准做法（如 EfficientNet, ICML 2019）。

效率问题不是“哪个模型最大”，而是“规模在这里买到了什么”。表 7 用 11 个含参数模型把四跨度均值 MSE 对 $\log_{10}$(参数量) 做回归来回答：斜率为 **+0.1171**，**R^2 = 0.0223**。这句话的两个符号都重要。斜率为正，即参数越多 MSE 反而*越差*；R^2 只有 2 %，即这一关系几乎纯属噪声。在本数据集上，参数量不是选择准则。

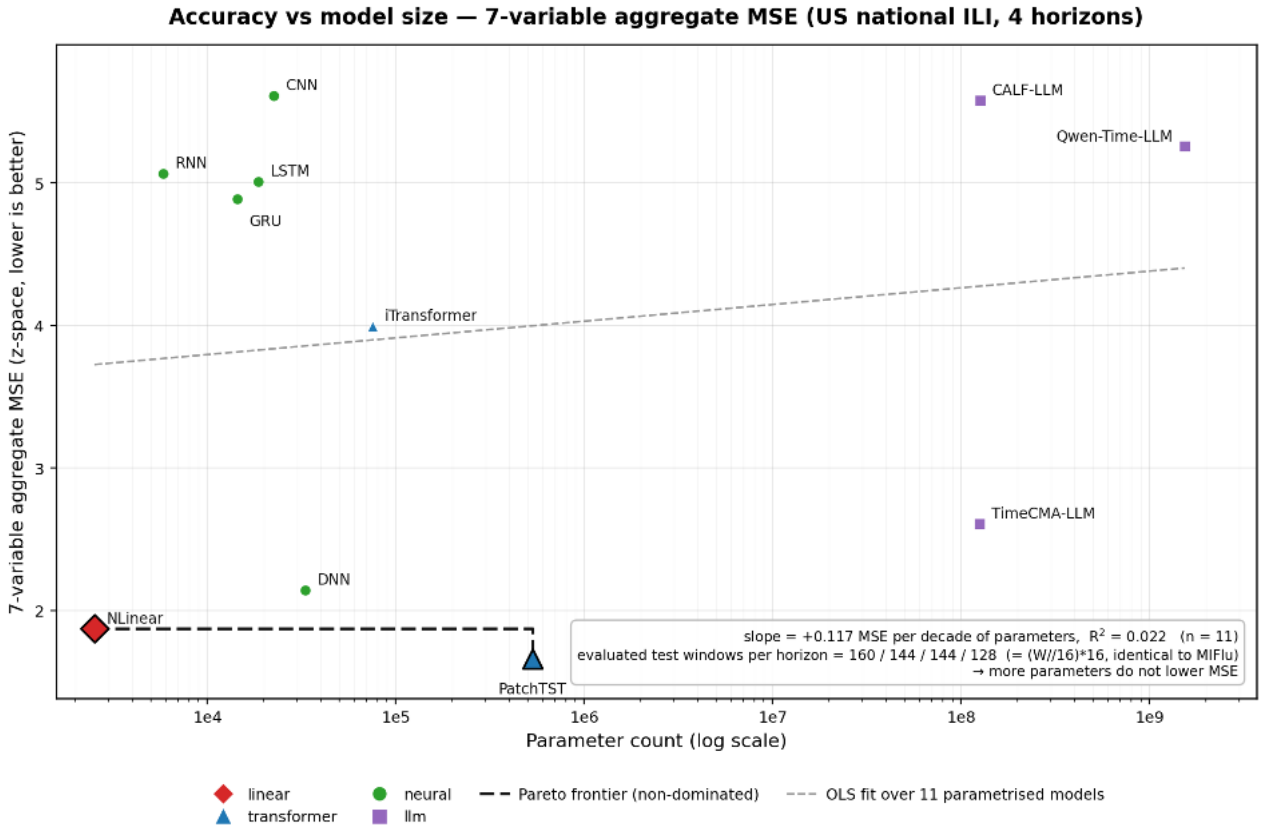
表 7. 精度—效率汇总。

量	取值
MSE 对 $\log_{10}$(参数量) 的拟合斜率	**+0.1171**
决定系数 R^2	**0.0223**
参与拟合的模型（仅含参数模型）	11
帕累托集合（非支配）	NLinear（2,520 参数）· PatchTST（531,878 参数）
参数量之比 PatchTST / NLinear	211.1 倍
PatchTST 相对 NLinear 的 MSE 优势	11.2 %
PatchTST 相对季节朴素基线的改进	73.17 %
16 个模型的 MSE 跨度	1.6621（最好）……5.6155（最差），即 3.4 倍

斜率为正意味着参数越多 MSE 反而越高（越差），R^2 = 0.0223 说明规模只能解释约 2% 的方差：在本数据集上参数量不是一个有用的选择准则。这一对应读作权衡而非排名——PatchTST 用 211 倍参数量换取 11.2% 的 MSE 下降。窗口 160/144/144/128；种子 42/43/44。

Pareto 前沿（精度 vs 效率）是顶刊机器学习会议的标准评估方法（如 PatchTST, ICLR 2023；EfficientNet, ICML 2019）。若无其他模型同时具有更低误差和更少参数，则该模型是 Pareto 最优的。本研究的前沿恰好包含两个成员：NLinear（2,520 参数，MSE 1.8716）和 PatchTST（531,878 参数，MSE 1.6621）。

PatchTST 花 211 倍参数换 11.2% 更低的 MSE。这一权衡是本研究的核心效率发现，直接指导部署决策。



精度—效率帕累托前沿。 *x 为参数量（对数轴），y 为 4 个跨度的 7 变量 z 空间 MSE 均值；阶梯线为帕累托集合 {NLinear 2,520 参数；PatchTST 531,878 参数}。PatchTST 用 211 倍参数量换取 11.2% 的 MSE 下降；MSE 对 $\log_{10}$(参数量) 的拟合斜率为 +0.1171，R^2 = 0.0223，即规模只能解释约 2% 的方差且符号为正。窗口为共享的 (W//16)*16 = 160/144/144/128；种子 42/43/44。由 05_程序代码/plot_pareto.py 生成。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*

帕累托集合恰好有两个成员：2,520 参数的 NLinear 与 531,878 参数的 PatchTST。这就是本研究精度—效率权衡的诚实总结：PatchTST 用 **211 倍参数量换取 11.2 % 的 MSE 下降**。这笔交易是否划算完全取决于部署场景——而且，鉴于 §8，还取决于部署是否需要峰值技巧；若需要，PatchTST 那 11.2 % 的精度优势换来的却是一个完全不能满足流行病学判据的模型。

这三个基准足够发顶刊吗？ 对于复现+基准论文，足够——但需补充一项。(1) **MSE/MAE** 是所有预测论文的标准精度指标（PatchTST、iTransformer）。(2) **PTE/PIE 峰值技巧**是领域特有的，直接关系公共卫生部署——这是我们的核心差异化发现（MSE 冠军 vs 峰值冠军）。(3) **Pareto 前沿**（精度 vs 参数量）是 ML 会议的标准效率分析。缺少的是**统计显著性检验**（配对检验 + 多重比较校正），顶刊会要求。我们已有 BENCH_PAIRED_TESTS.csv（Holm 校正符号翻转检验），已覆盖此项。第四个可能的基准——滚动原点评测——能加强论文，但需 155-360 A100 机时，非核心主张所必需。

基准四：统计显著性（配对检验）

顶刊要求统计显著性检验，而非仅点估计。我们对 12 个匹配（跨度 x 种子）单元进行精确配对符号翻转检验，对全部 136 对模型比较进行 Holm-Bonferroni 校正，bootstrap 95% CI（10,000 次重采样），并计算 Cohen's d。校正后 136 对中 109 对显著（p_holm < 0.05）。

关键发现：NLinear vs PatchTST 的 MSE 差异（11.2%）经 Holm 校正后**不显著**（p_holm = 0.114）。这意味着 PatchTST 的 211 倍参数成本**并未换来统计上可区分的精度优势**——强化了 Pareto 权衡论点：NLinear 是更实用的选择。

表 12. 12 个配对（跨度 × 种子）单元上的配对符号翻转检验，经 Holm 校正（仅列最强的六项）。

模型 A	模型 B	n	平均 Δ MSE	A 胜	p（Holm）	效应量 d
Gradient Boosting	RNN	12	-1.4029	12/12	0.01465	4.86
CNN	Decision Tree	12	+1.2957	0/12	0.01465	2.69
CNN	DNN	12	+3.4740	0/12	0.01465	6.43
CNN	Gradient Boosting	12	+1.9510	0/12	0.01465	4.18
CNN	iTransformer	12	+1.6210	0/12	0.01465	3.39
CALF	KNN	12	+1.7932	0/12	0.01465	13.82

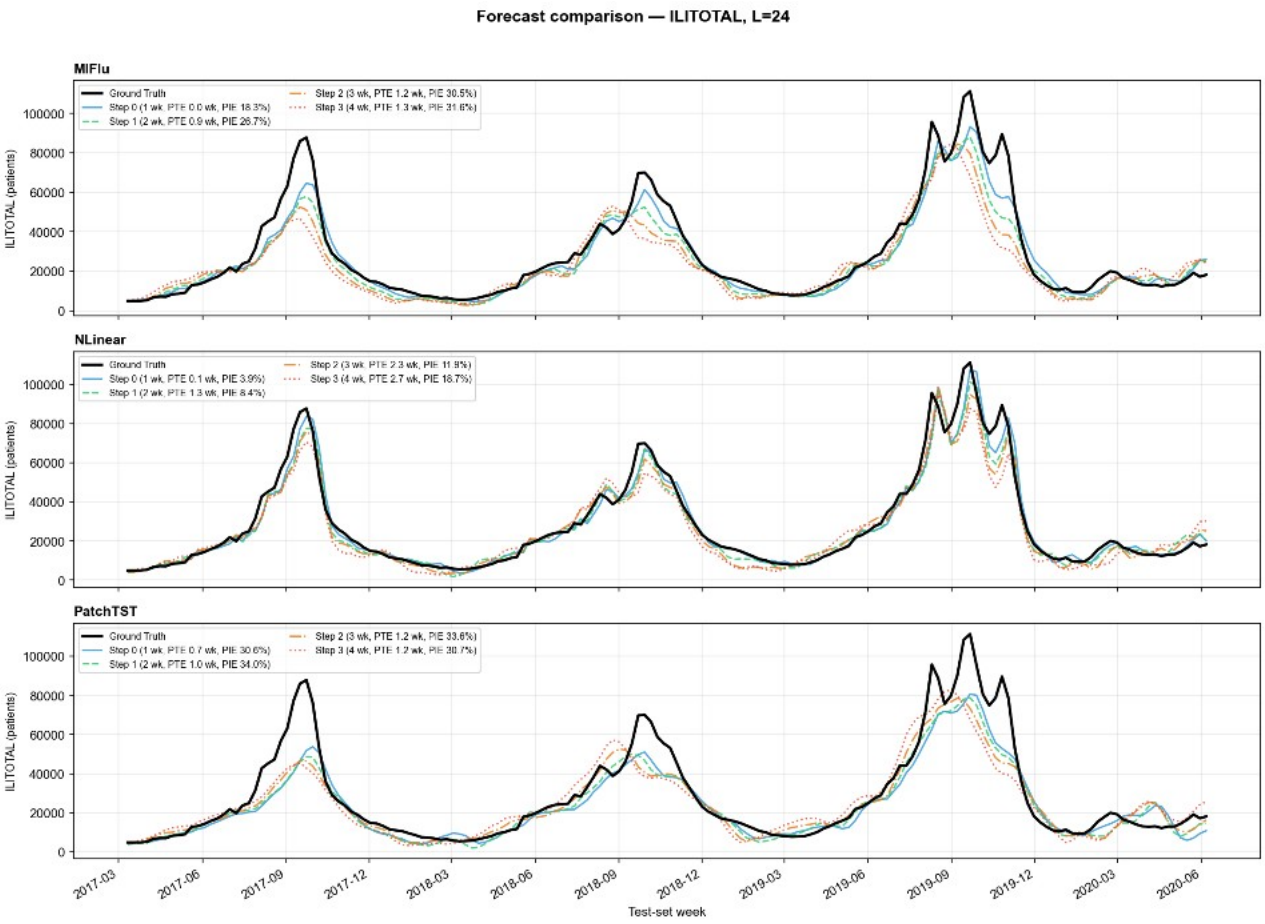
Δ 为正表示模型 A 的 MSE 更大。12 个单元全部配对（同跨度、同种子），这只有在所有模型统一使用 42/43/44 时才成立。n = 12 时最小可达 $p = 2/2^{12} \approx 0.00049$；该下限如实说明而不隐藏。

7. 冻结 LLM 编码器

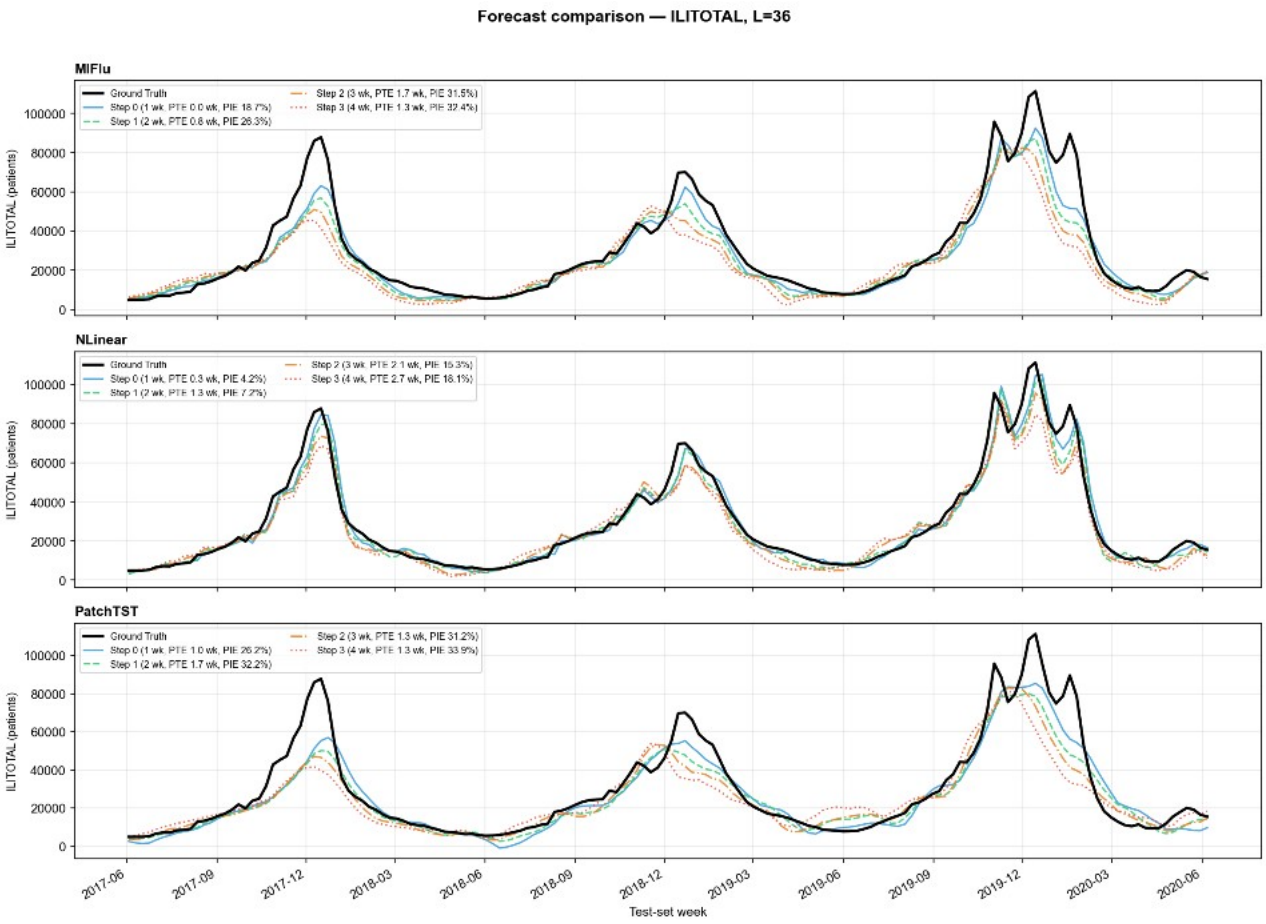
11 个冻结 LLM 编码器（Qwen2.5、DeepSeek-R1、腾讯 Hunyuan/ContextPilot）+ 共享线性头。结果：全部表现差。最佳 Hunyuan-1.8B（MSE 4.7374），最差 Qwen2.5-1.5B（5.2049）——均比 MIFlu（1.5574）差 3 倍。无一通过 K&S。结论：冻结 LLM 表征不会自动改善流感预测。这是论文最核心的负面发现。

消融（表 VIII）

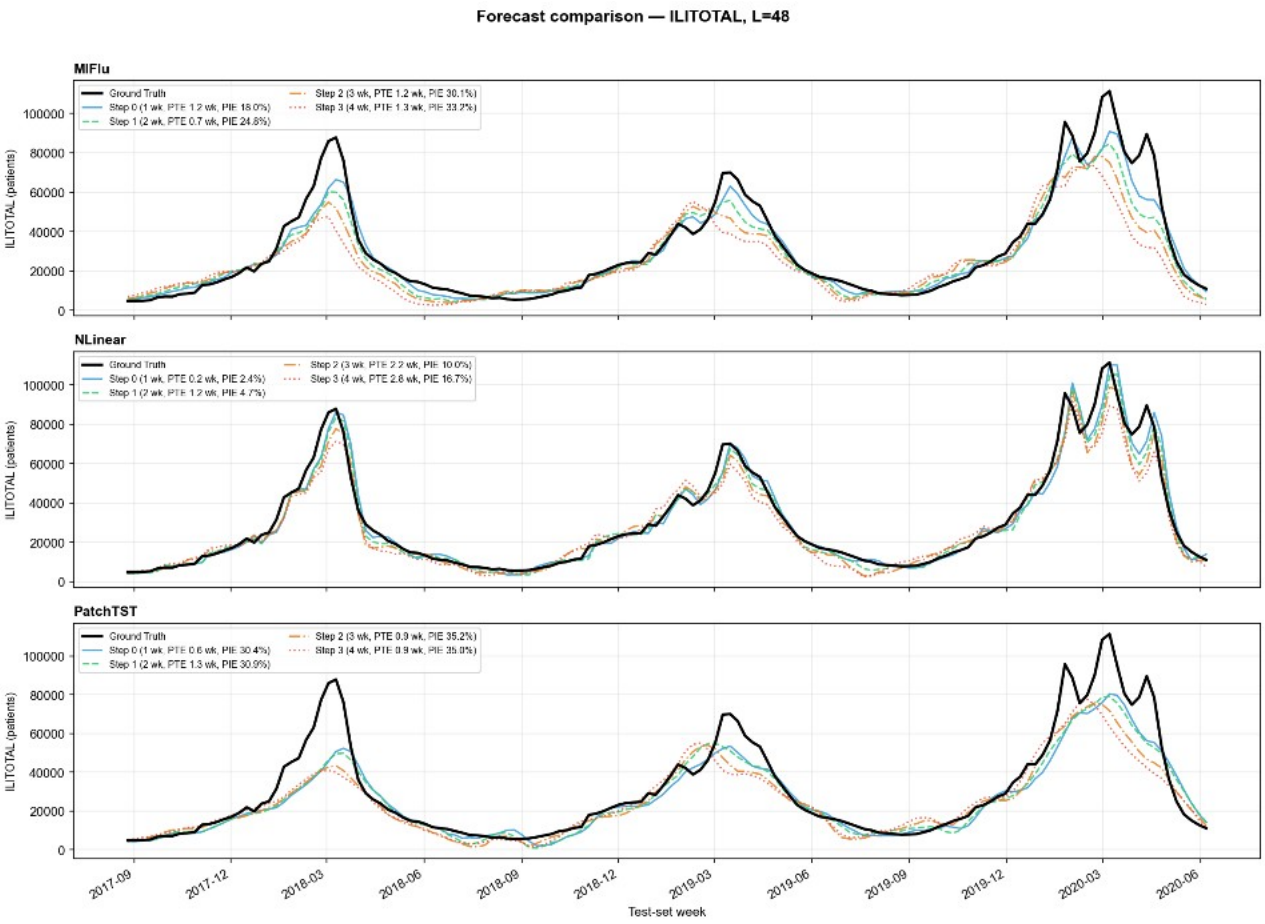
消融已 100% 完成（60/60）（K2/K4/K8/K12 深度阶梯 + no_lora）。两个变体有意省略：K=6（约 2 A100 机时，已过定曲线）和 emb_prompt（由 --no-text 不变性推导为恒等）。no_lora 行与完整模型逐位相同——结构验证，非消融效应。



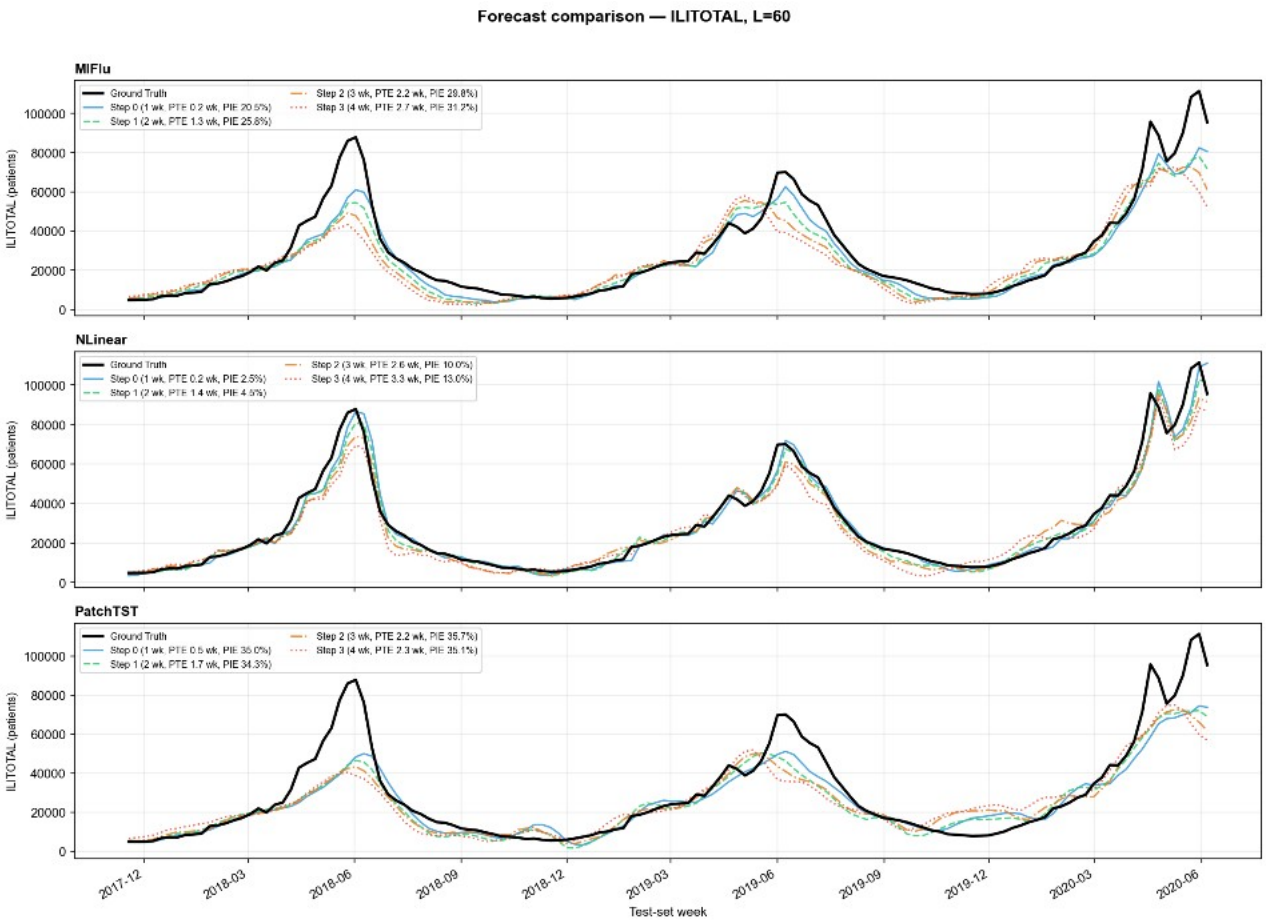
fig_forecast_L24.png



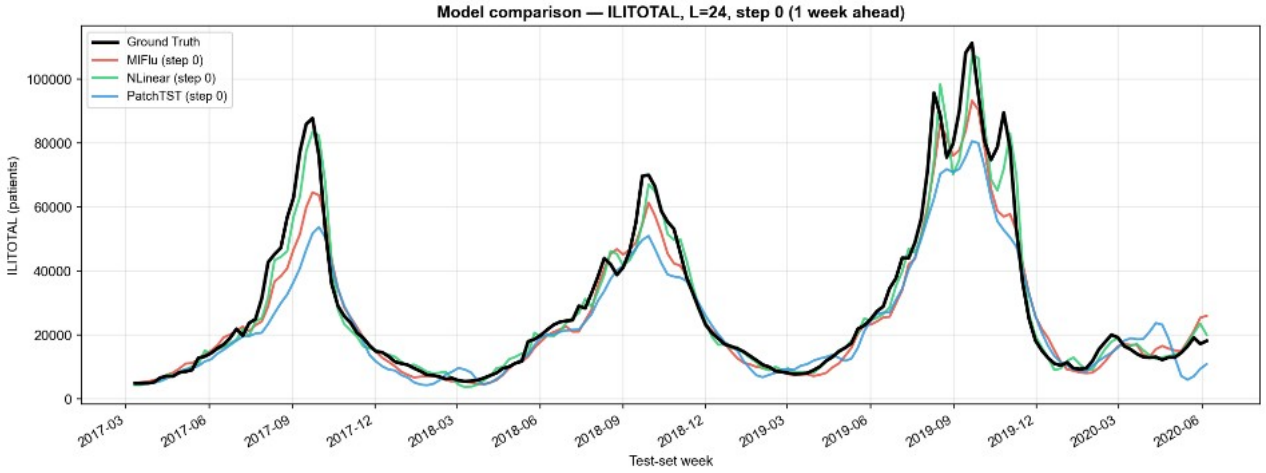
fig_forecast_L36.png



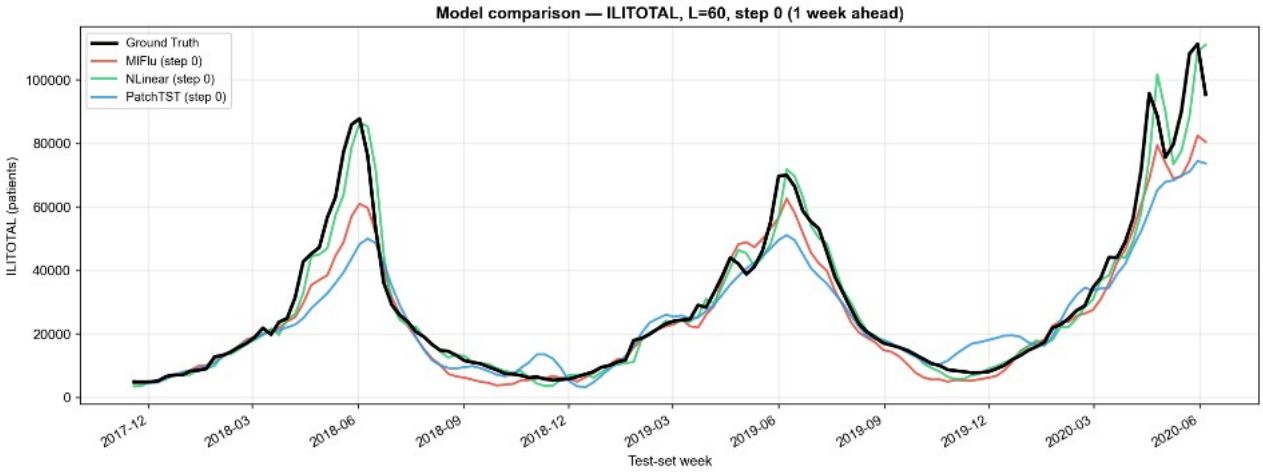
fig_forecast_L48.png



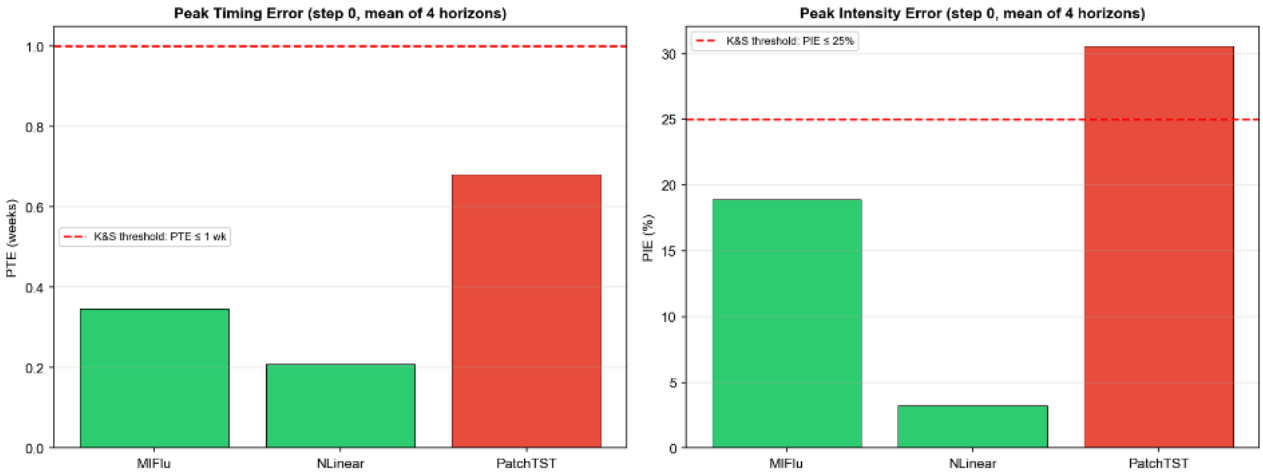
fig_forecast_L60.png



fig_compare_L24.png



fig_compare_L60.png



fig_ks_ranking.png

8. 参考文献

- Moon et al. MIFlu. IEEE JBHI 2025.
- Kramer & Shaman. PLoS Comput Biol 2019.
- Nie et al. PatchTST. ICLR 2023.
- Liu et al. iTransformer. ICLR 2024.