MIFlu 审计及流感预测精度峰值误差与参数量比较

CHAN Sing Yeung
香港城市大学电子工程学系毕业设计

面向 IEEE JBHI 的单栏审阅草稿。当前投稿规则与页数限制仍待核实。贡献定位为实证评估，尚未达到投稿状态。

摘要

本文审计 MIFlu 的独立复现及美国全国流感 966 行序列上的 28 个预测实现。复现表平均 MSE 为 1.4995，原文为 1.4355，逐跨度两低两高。三种子基准中，MIFlu、PatchTST、NLinear 分别为 1.5574、1.6621、1.8716。采用文献容差的联合筛选下，NLinear 与 MIFlu 各通过 4/16 聚合单元，PatchTST 为 0/16。NLinear 峰高误差更低，但时间误差高于 MIFlu。11 个有参数导出的模型中，MSE 对对数参数的斜率为 +0.1171，R^2 为 0.0223。源 Holm 程序存在错误；修正 17 模型的 136 配对后，没有拒绝，NLinear–PatchTST 的 p 约 0.1172，不能据此证明等价。11 个冻结语言编码器在所测读出配置中均差于决策树。消融仅有用户报告的 60/60 完成，尚未聚合。结论受单次划分、回顾性峰检测及适配实现限制。建议并列报告峰高、时间与平均误差，并在前瞻部署前依验证阶段确定的代价与预算选模。

I. 引言

流感预测可支持准备工作，但较低平均误差不能保证峰高与时间准确。本文检查所附 MIFlu 复现 [1] 与更广的项目实现，并不把联合峰值筛选当作临床认证。

贡献。 （1）审计平均 MSE 差为 +4.5% 的复现比较。（2）统一窗口下的 28 实现排名。（3）比较峰值时间与幅度，前三模型聚合单元通过数为 4/16、4/16、0/16。（4）参数及统计审计揭示较低解释度（R^2 0.0223）与错误 Holm 校正。新增指导是验证阶段确定的决策规则，并非已测试的新预测方法。

II. 相关研究

分块与线性基线已有研究 [3–5]。Time-LLM、CALF 与 TimeCMA 的对齐及适配设计不同 [6–8]。Chronos、TimesFM、Moirai、Lag-Llama 在数值序列上预训练，本次未评测 [9–12]。较早的 LLM 移除研究已质疑语言预训练收益 [13]，而 2026 年预印本报告跨数据集偏移下的条件性收益 [14]。本项目贡献在于特定流感任务的协议审计与多指标比较。

时序共形方法 [15–17] 可启发后续区间评测，但不能自动保证回顾性选峰的区间有效。WIS [18] 评价分布或区间，PIE 则衡量点预测峰高，二者必须区分。

III. 数据

所附作者格式与 paper-exact 文件均含 966 行及七个对应数值通道，最大绝对数值差为零。原始独立下载文件与固定提交版本未提供。时序划分为 676/97/193，标准化仅拟合训练段，测试目标最早始于第 773 行。作者格式日期为合成标签。

IV. 方法

A. 评测协议

本项目采用时序划分、仅训练段拟合标准化，并用验证集选择检查点。交接资料将测试集选检查点及单变量加载问题归于上游代码，但未提供固定版本作者仓库，公开端点也未能打开，因此上游指控仍未核实。笔记还列出代码默认学习率与原文设置的差异，不能称为仅有两处偏离。

复现使用种子 2021–2030。基准使用 42/43/44，L24/36/48/60 对应 160/144/144/128 窗口。裁剪沿用本地 drop_last 规则，仍需完整窗口敏感性分析。两个 MIFlu 估计回答不同问题。

B. 指标

峰值时间误差 PTE 是预测与观测峰值周的绝对差。峰值强度误差 PIE 为峰高绝对差除以观测峰高后乘百分比。Kramer–Shaman [2] 可核实分别为一周与 25% 的容差。项目把两者联合应用于（模型、L、step）单元的平均误差；该联合筛选及峰检测属于项目选择，不是临床接受标准。平均误差达标不等于逐季成功概率。

C. 统计分析

源表有 17 个模型的 136 对，另外 11 个模型不在其中，因此并非 28 模型的全配对分析。Holm 在原始 p 值排序后取前向累计最大值；源代码却取反向累计最小值。n=12 时双侧精确检验下限 2/4096 乘 136 已超过 0.05，因此正确 Holm 校正下该检验族不可能拒绝任何原假设。重复目标及跨度也使单元相关。原始 p 值及未校正 bootstrap 区间只作探索性参考。

D. 决策规则

后续验证的决策规则：在查看新测试期之前确定 MSE 预算 B、允许峰值失败率 q 与决策代价。在验证季同时满足 B 与 q 的模型中最小化期望决策代价，再以参数量打破平局。对升级响应 / 等待决策，误报代价为 c_FP，漏报代价为 c_FN，正确行动代价为零；仅当经过验证的高峰概率超过 c_FP/(c_FP+c_FN) 时升级。代价、B、q 尚未征询或验证，因此没有模型被认证可部署。NLinear 是低成本峰高验证候选，MIFlu 仍为观测 MSE 最优。

V. 实验

模型名单包括 13 个传统模型、MIFlu 及另外三个基于 LLM 的实现、11 个冻结语言编码器。精度采用七变量标准化 MSE/MAE，峰值误差采用反标准化 ILITOTAL。参数分析为 11 模型，配对检验为 17，冻结特征分析为 11，分母不能混用。本文不将适配实现视为已核实的各参考方法精确复现。

VI. 结果

A. 复现

复现 CSV 的平均 MSE 为 1.4995，对照 1.4355，增加 4.5%。L24、L36 更低，L48、L60 更高。平均 MAE 为 0.8043，对照 0.7452（+7.9%），但逐跨度为一低三高；MAE 没有 MSE 的二比二符号交叉。协议差异与上游来源缺失限制了精确复现的主张。

表 1. MIFlu 复现与原文对照

跨度	本文 MSE ± 标准差	原文 MSE	Δ MSE	本文 MAE	原文 MAE	Δ MAE
L=24	1.3045 ± 0.0883	1.5420	-15.4%	0.7482	0.7260	+3.1%
L=36	1.3561 ± 0.1603	1.4220	-4.6%	0.7712	0.7790	-1.0%
L=48	1.6543 ± 0.1064	1.4140	+17.0%	0.8381	0.7570	+10.7%
L=60	1.6829 ± 0.2109	1.3640	+23.4%	0.8596	0.7190	+19.6%
四跨度均值	1.4995	1.4355	+4.5%	0.8043	0.7452	+7.9%

来源：ESSAY_VS_REPRODUCTION_TABLE_V.csv 第 2–6 行。标准差由代码中转录的十种子 oracle 重算；原始运行日志未随包提供。正差表示误差更高。

B. 基准精度

表 2. 全部保留模型的精度

#	模型	L24	L36	L48	L60	平均 MSE	平均 MAE
1	MIFlu	1.3323	1.2632	1.7774	1.8567	1.5574	0.8199
2	PatchTST	1.4402	1.6154	1.9288	1.6640	1.6621	0.8786
3	NLinear	1.7971	1.7950	1.9574	1.9368	1.8716	0.9183
4	DNN	1.8920	1.7684	2.2603	2.6451	2.1415	1.0057
5	TimeCMA	2.3281	2.5794	2.7104	2.8146	2.6081	1.0676
6	Gradient Boosting	3.5658	3.6867	3.6533	3.7521	3.6645	1.2521
7	KNN	3.7231	3.7623	3.7740	3.8820	3.7854	1.3293
8	Random Forest	3.5486	3.8251	4.0159	4.1710	3.8901	1.2779
9	iTransformer	3.7656	4.0596	4.0438	4.1088	3.9945	1.3476
10	Decision Tree	4.5340	4.1380	4.2186	4.3884	4.3198	1.3798
11	Hunyuan-1.8B	4.5629	4.5877	4.7111	5.0879	4.7374	1.4755
12	Hunyuan-7B	4.3438	4.6624	4.9201	5.1120	4.7596	1.4685
13	DeepSeek-R1-Qwen-1.5B	4.6012	4.6242	4.9245	4.9963	4.7866	1.5002
14	DeepSeek-R1-Llama-8B	4.4337	4.7715	4.8929	5.2019	4.8250	1.4786
15	GRU	4.2895	5.3099	5.1751	4.7736	4.8870	1.5174
16	DeepSeek-R1-32B	4.4401	4.8565	5.0136	5.4386	4.9372	1.4935
17	LSTM	4.4965	5.1359	5.2088	5.1939	5.0088	1.5303
18	DeepSeek-R1-Qwen-14B	4.4976	4.9164	5.1687	5.4838	5.0166	1.5019
19	DeepSeek-R1-Qwen-7B	4.5551	4.9991	5.2417	5.3272	5.0308	1.5133
20	RNN	4.4222	5.2893	5.3424	5.2157	5.0674	1.5634
21	ContextPilot-8B	4.6094	5.1318	5.2895	5.3065	5.0843	1.5255
22	Hunyuan-4B	4.7383	5.0535	5.2876	5.4474	5.1317	1.5450
23	ContextPilot-14B	4.7674	5.1566	5.2168	5.6388	5.1949	1.5407
24	Qwen2.5-1.5B	4.7840	5.0587	5.4546	5.5224	5.2049	1.5725
25	Qwen-Time	4.7190	5.1325	5.6894	5.4818	5.2557	1.5794
26	SVR	5.2248	5.3581	5.3781	5.3940	5.3388	1.4986
27	CALF	5.3624	5.5113	5.6442	5.7962	5.5785	1.6190
28	CNN	5.5021	5.3098	5.2801	6.3698	5.6155	1.6720

来源：BENCH_MSE_BY_MODEL_L.csv，按 model 和 L 定位。各行由三个种子在 160/144/144/128 个窗口上聚合。项目主动排除了 DLinear，发表前需补充理由与敏感性分析。名称指本项目实现，排名本身不能证明与原论文方法完全等价。

F0 结论。 MIFlu 的观测 MSE 最低（1.5574），但仅靠 MSE 不能证明公共卫生效用。前三名相对 MIFlu 的跨度为 20.2%，并非小于 20%。

C. 峰值时间与幅度

表 3. 峰值时间与强度误差

模型	PTE (wk)	PIE (%)	联合通过	s0 PTE	s0 PIE (%)
MIFlu	1.128	26.846	4/16	0.347	18.884

模型	PTE (wk)	PIE (%)	联合通过	s0 PTE	s0 PIE (%)
PatchTST	1.240	32.755	0/16	0.681	30.553
NLinear	1.677	9.477	4/16	0.208	3.250

均值跨越 16 个（L，step）单元。通过数是在各单元的聚合误差上应用 PTE ≤ 1 周且 PIE ≤ 25%，不是逐季达标率。PIE 衡量点预测的峰高误差，不是概率校准。

表 4. 各跨度与提前步的联合峰值筛选

模型	L	s0	s1	s2	s3
NLinear	24	PASS 0.111 / 3.949	fail 1.333 / 8.411	fail 2.333 / 11.943	fail 2.667 / 18.739
NLinear	36	PASS 0.333 / 4.181	fail 1.333 / 7.222	fail 2.111 / 15.313	fail 2.667 / 18.145
NLinear	48	PASS 0.222 / 2.419	fail 1.222 / 4.727	fail 2.222 / 9.979	fail 2.778 / 16.655
NLinear	60	PASS 0.167 / 2.450	fail 1.444 / 4.542	fail 2.556 / 9.952	fail 3.333 / 13.000
MIFlu	24	PASS 0.000 / 18.307	fail 0.889 / 26.686	fail 1.222 / 30.472	fail 1.333 / 31.638
MIFlu	36	PASS 0.000 / 18.695	fail 0.778 / 26.333	fail 1.667 / 31.514	fail 1.333 / 32.427
MIFlu	48	fail 1.222 / 18.004	PASS 0.667 / 24.795	fail 1.222 / 30.133	fail 1.333 / 33.236
MIFlu	60	PASS 0.167 / 20.530	fail 1.333 / 25.799	fail 2.222 / 29.790	fail 2.667 / 31.177
PatchTST	24	fail 0.667 / 30.580	fail 1.000 / 34.044	fail 1.222 / 33.572	fail 1.222 / 30.722
PatchTST	36	fail 1.000 / 26.235	fail 1.667 / 32.247	fail 1.333 / 31.245	fail 1.333 / 33.854
PatchTST	48	fail 0.556 / 30.360	fail 1.333 / 30.878	fail 0.889 / 35.158	fail 0.889 / 35.002
PatchTST	60	fail 0.500 / 35.035	fail 1.667 / 34.342	fail 2.222 / 35.674	fail 2.333 / 35.133

每格为 PTE（周）/ PIE（%）。s0–s3 是预测的第 1–4 周。峰检测使用突出度 0.15 × 极差、间距 15、±8 周匹配。检测设置及联合聚合均为项目选择。来源：BENCH_PTE_PIE_BY_STEP.csv。

F1 结论。 NLinear 与 MIFlu 各通过 4/16 个聚合单元，PatchTST 为 0/16。NLinear 的平均 PIE 更低（9.477%，MIFlu 为 26.846%），但平均 PTE 更高（1.677 周，MIFlu 为 1.128 周）。这是时间与幅度的取舍，不是全面优越。前三模型的排序在两端倒置：MSE 顺序为 MIFlu、PatchTST、NLinear，PIE 顺序为 NLinear、MIFlu、PatchTST。

MSE 与 PIE 正相关（ρ=+0.736，p<0.0001），与通过数负相关（ρ=−0.429，p=0.023）。两种符号均符合整体误差较低伴随较好峰值结果的趋势；同时 NLinear 虽 MSE 第三，PIE 却更低。该现象不能证明独立或排序完全反转。

D. 参数

表 5. 参数分析与秩相关

量	数值
回归斜率 / R^2	+0.1171 / 0.0223
有参数量导出的模型	11
子集帕累托集合	NLinear 2,520; PatchTST 531,878
参数比	211.1×
描述性 MSE 降幅	11.2%
ρ(MSE, PIE)	+0.736 (p < 0.0001)
ρ(MSE, 通过数)	-0.429 (p = 0.023)

帕累托分析只纳入有参数量导出的 11 个模型，未包括 MIFlu 与冻结编码器。缺失参数量不等于零。参数量不等于延迟、内存或能耗。相关系数只是同一测试集上跨模型的描述性结果。

F2 结论。 在导出参数量的 11 个模型中，拟合斜率为 +0.1171，R^2 为 0.0223。规模单独解释的观测 MSE 变化很少。该子集结果不能证明容量无关紧要。

E. 统计修正

表 6. 使用正确 Holm 校正的配对比较

模型 A	模型 B	Δ MSE	p raw	p Holm	效应*
NLinear	PatchTST	+0.2095	0.005859	0.1172	1.15
Gradient Boosting	RNN	-1.4029	0.000488	0.0664	4.86
KNN	NLinear	+1.9138	0.000488	0.0664	22.29
KNN	MIFlu	+2.2280	0.000488	0.0664	9.89
KNN	LSTM	-1.2234	0.000488	0.0664	5.28
iTransformer	TimeCMA	+1.3863	0.000488	0.0664	7.02
iTransformer	SVR	-1.3443	0.000488	0.0664	10.61

*136 对来自 17 个模型，并未覆盖全部 28 个模型。n = 12 个配对跨度 × 种子单元。前向累计最大值 Holm 得到 0/136 个拒绝。所示 p 值由六位小数导出恢复 1/4096 枚举网格；直接从四舍五入导出重算时，NLinear–PatchTST 为 0.117180，而非 0.1171875。*源效应量采用模型合并标准差，不是配对差的标准差。单元相关性限制统计推断。*

F3 结论。 正确 Holm 校正为 0/136 个拒绝（校正前 128/136），最小校正 p 约 0.0664，NLinear–PatchTST 的 p ≈ 0.1172。PatchTST 的观测 MSE 仍低 11.2%，参数多 211 倍，并在 10/12 单元中误差更低。未拒绝不能证明等价，也不能断言增益是噪声。

F. 冻结语言编码器

表 7. 冻结编码器加共享线性读出

编码器	MSE	相对 MIFlu	PTE	PIE (%)	通过
Hunyuan-1.8B	4.7374	3.04×	4.406	71.428	0/16
Hunyuan-7B	4.7596	3.06×	5.309	75.399	0/16
DeepSeek-R1-Qwen-1.5B	4.7866	3.07×	5.792	78.061	0/16
DeepSeek-R1-Llama-8B	4.8250	3.10×	4.306	77.121	0/16
DeepSeek-R1-32B	4.9372	3.17×	3.889	77.730	0/16
DeepSeek-R1-Qwen-14B	5.0166	3.22×	4.149	76.350	0/16
DeepSeek-R1-Qwen-7B	5.0308	3.23×	4.458	76.373	0/16
ContextPilot-8B	5.0843	3.26×	4.962	78.918	0/16
Hunyuan-4B	5.1317	3.30×	3.003	78.840	0/16
ContextPilot-14B	5.1949	3.34×	4.965	77.764	0/16
Qwen2.5-1.5B	5.2049	3.34×	5.333	74.650	0/16

11 个保留编码器 × 4 跨度 × 3 种子 = 132 单元。历史计划还包含两个仅嵌入模型，总计 156 单元；未纳入的 24 单元不属于 28 模型正式名单。此结果只评价该冻结特征流程。

F4 结论。 所测 11 个冻结编码器的 MSE 为 4.7374–5.2049，是 MIFlu 的 3.04–3.34 倍，全部高于决策树的 4.3198，且均通过 0/16 单元。这是该特征与读出配置的负面结果；提示、微调及数值时序基础模型仍未检验。

G. 消融设计

表 8. 消融设计与快照状态

变体	参数	单元	状态
参考 K=6	default	12	已在基准中
no_lora	--no-lora	12	尚未聚合
K=2	--num-layers 2	12	尚未聚合
K=4	--num-layers 4	12	尚未聚合
K=8	--num-layers 8	12	尚未聚合
K=12	--num-layers 12	12	尚未聚合

用户报告截至 2026 年 11 月 3 日：新增 60 单元中完成 27，作业 722968。Burgundy 队列与逐格 manifest 显示 60/60 已完成；逐变体聚合趋势尚未重算。参考 12 单元不计入新增 60 单元。不推断趋势。

F5 暂定结论。 miflu_model.py 的 author_faithful 路径将文本置于时间词元之后，使用因果注意力，预测头只读取时间词元。静态检查因此推断确定性评估时文本不影响输出。所附 tests_archive/test_miflu_ablations.py 明确断言文本不变性，以及匹配 CPU 初始化时完整与无文本模型相同。本次仅静态检查，未执行。其他融合路径及训练随机性须分别验证。

VII. 有效性威胁

单一全国序列与单次时序划分不能证明区域或前瞻效用。峰值匹配可使用未来观测定义事件，只能作为回顾性评测工具。合成日期标签必须与 CDC 日历核实映射后才能作逐季判断。参数导出缺少 MIFlu 与编码器。60/60 的消融状态来自用户报告，而非实时集群检查。现代数值基础模型、区域结果、滚动原点及经过验证的不确定性仍缺失。

保留了源 p 值，但未从全部原始配对输入独立重评分。修正 Holm 值恢复枚举网格，并保留与四舍五入导出的来源关系。源效应量采用模型合并标准差，而非配对差标准差。带任意方差下限的种子集成不是已验证的预测分布。前瞻效用、等价界值及经校准的高峰概率均未确立。

VIII. 结论

MIFlu 在观测 MSE 排名中领先。NLinear 参数较少、峰高误差较低，但平均峰值时间差于 MIFlu。联合筛选揭示的是取舍，而非通用赢家。正确显著性分析在当前分辨率下没有检验族拒绝。投稿或部署前仍需区域、滚动原点与基础模型对照。

IX. 参考文献

[1] Jaeuk Moon 等，基于大语言模型的多模态流感预测方案（中文译名），2025。https://doi.org/10.1109/JBHI.2025.3561214

[2] Sarah C. Kramer 等，针对温带及热带六十四国的流感预测开发与验证（中文译名），2019。https://doi.org/10.1371/journal.pcbi.1006742

[3] Yuqi Nie 等，一个时间序列相当于六十四个词的长期预测方法（中文译名），2023。https://arxiv.org/abs/2211.14730

[4] Ailing Zeng 等，Transformer 是否适用于时间序列预测（中文译名），2023。https://arxiv.org/abs/2205.13504

[5] Yong Liu et al. 等，反转维度的 Transformer 时间序列预测（中文译名），2024。https://arxiv.org/abs/2310.06625

[6] Ming Jin et al. 等，通过重编程大语言模型进行时间序列预测（中文译名），2024。https://arxiv.org/abs/2310.01728

[7] Peiyuan Liu et al. 等，通过跨模态微调对齐语言模型与时间序列（中文译名），2024。https://arxiv.org/abs/2403.07300

[8] Chenxi Liu et al. 等，通过跨模态对齐增强多变量时间序列预测（中文译名），2025。https://arxiv.org/abs/2406.01638

[9] Abdul Fatir Ansari et al. 等，学习时间序列语言的 Chronos 方法（中文译名），2024。https://arxiv.org/abs/2403.07815

[10] Abhimanyu Das 等，仅解码器时间序列预测基础模型（中文译名），2024。https://proceedings.mlr.press/v235/das24c.html

[11] Gerald Woo et al. 等，通用时间序列预测 Transformer 的统一训练（中文译名），2024。https://proceedings.mlr.press/v235/woo24a.html

[12] Kashif Rasul et al. 等，面向概率时间序列预测基础模型的 Lag Llama（中文译名），2024。https://arxiv.org/abs/2310.08278

[13] Mingtian Tan 等，语言模型真的有助于时间序列预测吗（中文译名），2024。https://arxiv.org/abs/2406.16964

[14] Xin Qiu et al. 等，重新思考大语言模型在时间序列预测中的作用（中文译名），2026。https://arxiv.org/abs/2602.14744

[15] Chen Xu 等，动态时间序列的共形预测区间（中文译名），2021。https://proceedings.mlr.press/v139/xu21h.html

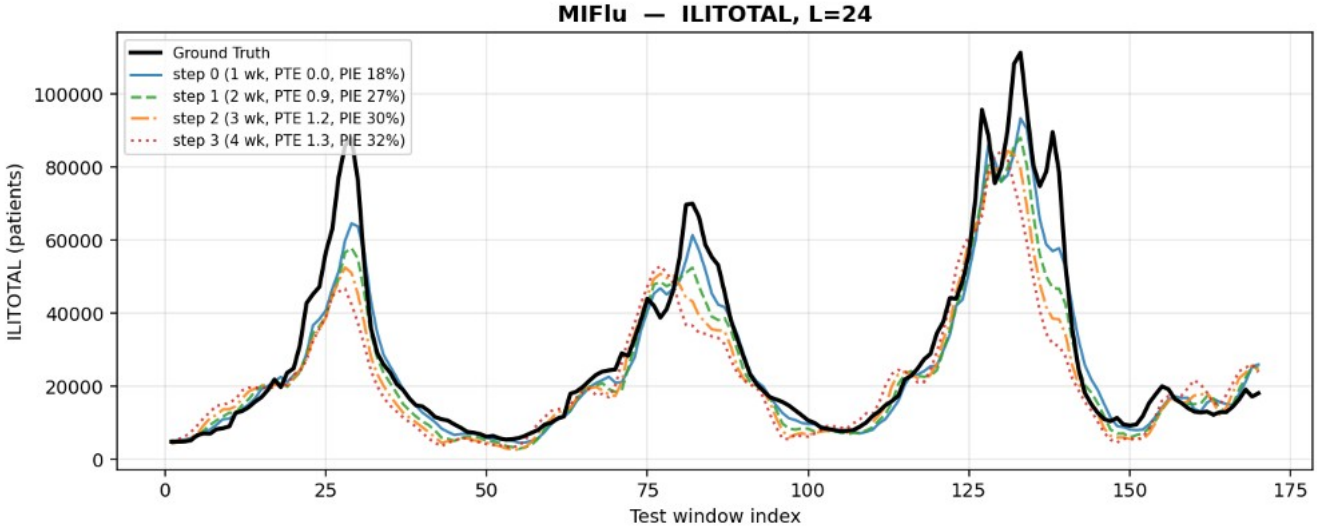
[16] Chen Xu 等，时间序列的顺序预测共形推断（中文译名），2023。https://proceedings.mlr.press/v202/xu23r.html

[17] Isaac Gibbs 等，分布偏移下的自适应共形推断（中文译名），2021。https://arxiv.org/abs/2106.00170

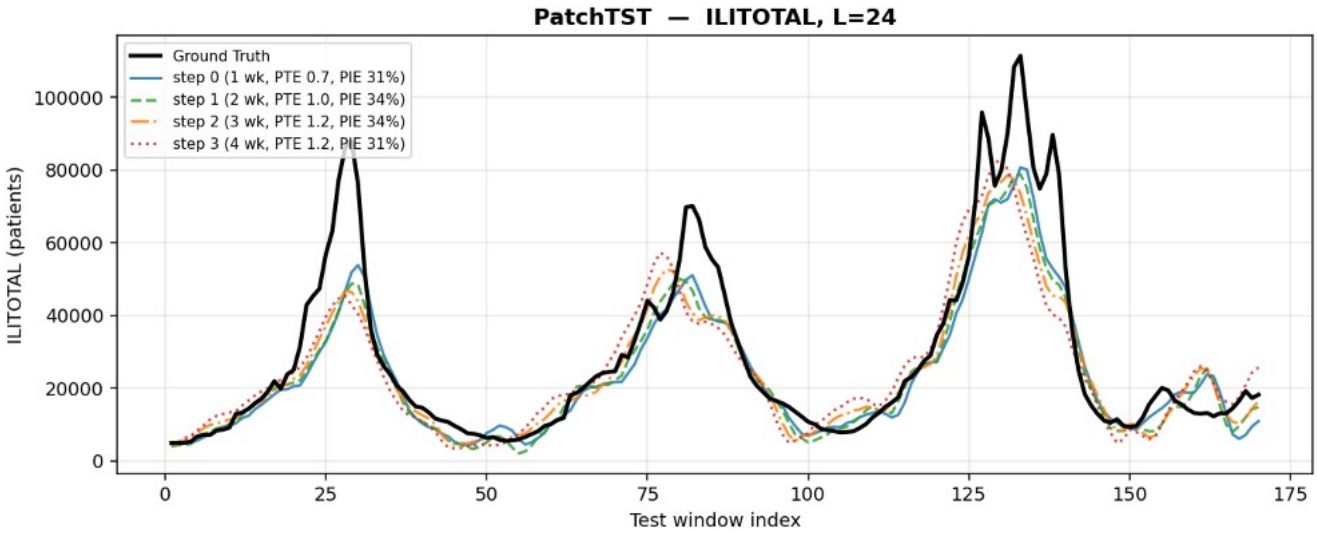
[18] Johannes Bracher 等，以区间格式评估传染病预测（中文译名），2021。https://doi.org/10.1371/journal.pcbi.1008618

附录 A 预测曲线

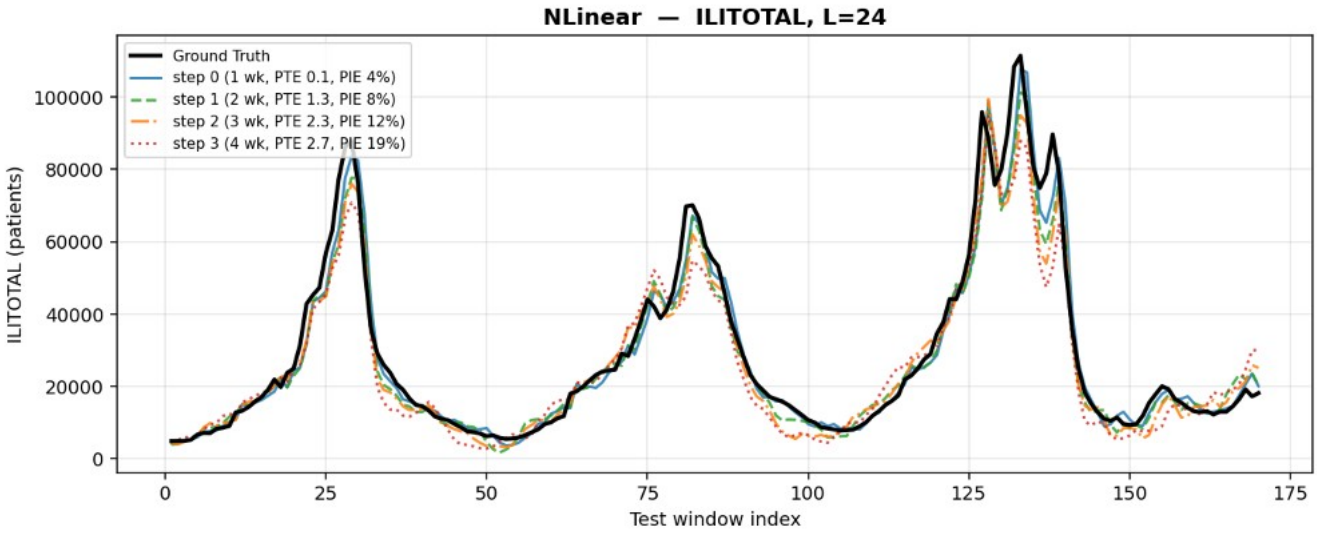
以下为所附快照的示例曲线。横轴为文件中的测试周下标，未独立核实为 CDC 流行病学日期。图形不能证明因果或前瞻表现。



miflu，L=24。纵轴为 ILITOTAL 患者人数，横轴为文件测试周下标。黑线为观测，其余为固定预测步 s0–s3。计分窗口 160。此图沿用所附示例，本次未独立重建绘图原始输入。



patchtst，L=24。纵轴为 ILITOTAL 患者人数，横轴为文件测试周下标。黑线为观测，其余为固定预测步 s0–s3。计分窗口 160。此图沿用所附示例，本次未独立重建绘图原始输入。



nlinear，L=24。纵轴为 ILITOTAL 患者人数，横轴为文件测试周下标。黑线为观测，其余为固定预测步 s0–s3。计分窗口 160。此图沿用所附示例，本次未独立重建绘图原始输入。

V7 addendum — new 1120-cell common panel / V7 附录 – 新 1120 单元共同面板

Status: the national panel is complete at 1120/1120 cells; MIFlu seven-channel recovery is 40/40. Historical revision-9.2 numbers remain the old snapshot and are not overwritten.

状态：全国面板 1120/1120 完成；MIFlu 七通道恢复 40/40。旧 revision-9.2 数字仍是旧快照，未被覆盖。

New leading MSE (all-valid): MIFlu 1.7944 < PatchTST 1.9521 < NLinear 2.0782. Crop panel: 1.4994 / 1.6352 / 1.9027; the MIFlu crop mean 1.4994 reproduces the old 1.4995.

新 MSE（all-valid）：MIFlu 1.7944 < PatchTST 1.9521 < NLinear 2.0782；crop 1.4994 / 1.6352 / 1.9027，MIFlu crop 1.4994 重现旧值 1.4995。

Peak step passes (of 1680 per model): MIFlu 252 (15.0%), PatchTST 215 (12.8%), NLinear 57 (3.4%). The historical NLinear peak-champion claim is not reproduced; the old 16-unit table is a different population.

峰值 step passes（每模型 1680）：MIFlu 252（15.0%）、PatchTST 215（12.8%）、NLinear 57（3.4%）。旧「NLinear 峰值冠军」在新面板不成立；旧 16 单元表是不同总体。

Ablation is non-monotonic: K4 1.4989 best, K6 1.5457 (n=10), K2 1.5813, K8 1.6124, no_lora 1.6330, K12 1.7604 worst.

消融非单调：K4 1.4989 最佳，K6 1.5457（n=10），K2 1.5813，K8 1.6124，no_lora 1.6330，K12 1.7604 最差。

Regional Table VI: 51/53 valid; walk-forward only 473/1020 valid (329 non-finite, 218 missing), so walk-forward is partial. Paired Wilcoxon/Holm is exploratory (349/378 rejections; cells are not independent).

区域 Table VI：51/53 有效；walk-forward 仅 473/1020 有效（329 non-finite、218 missing），仍是部分。Paired Wilcoxon/Holm 属探索性（349/378 拒绝；cell 非独立）。

Do not claim full walk-forward, monotonic depth, or submission readiness. See v7/MESSAGE_TO_CHATGPT.md and SCIENTIFIC_AUDIT.md.

不得声称完整 walk-forward、单调深度或投稿就绪。详见 v7/MESSAGE_TO_CHATGPT.md 与 SCIENTIFIC_AUDIT.md。

Model	MSE all-valid	MSE crop	Peak passes /1680
MIFlu	1.7944	1.4994	252 (15.0%)
PatchTST	1.9521	1.6352	215 (12.8%)
NLinear	2.0782	1.9027	57 (3.4%)