复现 MIFlu 并基准评估流感预测

内部技术报告——复现、16 模型基准、峰值技巧与 11 个冻结 LLM 编码器

文档	内部技术报告（长篇）
项目	MIFlu 的独立复现，以及一个三向流感预测基准
版本 / 日期	1.0 — 2026 年 11 月 2 日
读者	导师、评阅人，以及接手本工作的下一个智能体（CodeBuddy / ChatGPT）
状态	PARTIAL_REPRODUCTION：复现已完成；16 + 11 个模型的基准已完成；消融（60/60）已完成；区域评测排队中
配套文档	progress_report_en.docx（简短，学校模板）· ieee_manuscript_en.docx（原型）· MANIFEST.md（文件清单）· 04_详细说明文档/REPO_HYGIENE.md
原则	下文每个数字都在构建时从 `02_数字表格/*.csv` 读取，并由 `dlv/06_原始数据集.py` 断言。没有任何数字凭记忆引用。

目录

1. 执行摘要
2. 范围、约定与阅读方式
3. 动机与问题陈述
4. 数据
5. 方法
6. MIFlu 表 V 的复现
7. 16 个模型的基准
8. 峰值技巧与核心发现
9. 精度与效率
10. 作为特征提取器的冻结 LLM 编码器
11. 可靠性：出了什么问题，以及对数字意味着什么
12. 仍在进行的实验
13. 讨论
14. 局限
15. 审稿人会问到的设计决策
16. 如何复现本报告
17. 参考文献

1. 执行摘要

本报告记录了对 MIFlu（Moon 等，IEEE JBHI 2025）的独立复现，以及原论文所没有的一个三向基准：16 个传统预测模型、MIFlu 本身，以及 11 个作为特征提取器的冻结大语言模型编码器；全部在美国 CDC 全国流感序列（966 个每周行、7 个通道，随原工作一并发布）上进行。

复现是诚实的，而且并不是一次胜利。 四个跨度的 10 次重复均值为 **1.4995，对比论文的 1.4355，即差 4.5 %**；而且比均值更有信息量的是，符号随跨度翻转：本文在 L=24（−15.4 %）与 L=36（−4.6 %）更好，在 L=48（+17.0 %）与 L=60（+23.4 %）更差。只报告均值的复现研究会把这一反转藏起来；本报告把它作为首要结果报告（表 3、图 1 与图 2）。

基准有一个明确的精度冠军，以及另一个不同的峰值技巧冠军。 在共享评测窗口 160/144/144/128 上、对三个种子取均值、以 7 变量 z 空间聚合 MSE 计，PatchTST 最好（**1.6621**），其次为 NLinear（**1.8716**）与 DNN（**2.1415**）；16 个模型中最差的是 CNN（5.6155），而全部 16 个都优于季节朴素基线（6.2132）。在 Kramer & Shaman 的流行病学接受判据下——峰值时间误差 ≤ 1 周**且**峰值强度误差 ≤ 25%——**NLinear 是唯一能通过的模型：16 个单元中通过 4 个，均值 PTE 1.677 周、PIE 9.477 %，且只在步 0（提前一周）通过。** PatchTST 的时序在所有模型中最准（均值 PTE 1.240 周），但峰值强度误差达 32.755 %，因此在其 16 个单元中全部不通过。

因此核心发现是一个选择上的警告，也是本项目目前最强的一项原创贡献： *MSE 冠军并不是峰值技巧冠军。* 按 MSE 排序的实践者会选中一个完全不能满足流行病学接受判据的模型，而参数量少 211 倍的模型（NLinear，2,520 参数，对比 PatchTST 的 531,878）却是唯一满足判据的那一个。参数量也不能替代判断：MSE 对 $\log_{10}$(参数量) 的拟合斜率为 +0.1171，$R^2 = 0.0223$，即规模只能解释约 2% 的方差，而且符号方向是反的（表 7、图 7）。

第二个评测维度现已完成。 11 个冻结 LLM 编码器（Qwen2.5-1.5B；DeepSeek-R1-Distill 的 1.5/7/8/14/32 B；腾讯 ContextPilot-8B/-14B；腾讯 Hunyuan-1.8B/-4B/-7B）在集群上完成了 156 个单元中的 132 个（跳过 24 个：仅嵌入架构无法输出逐层隐藏状态）。逐模型 7 变量 z 空间 MSE 与逐步 PTE/PIE 已计算并列入基准表。最佳冻结编码器是 Hunyuan-1.8B（均值 MSE 4.7374），无 LLM 编码器臂通过 Kramer & Shaman 判据。

尚未完成的事项在此集中说明一次，并在任何本应出现它们的地方标注。 消融（表 VIII）在驱动作业 **722968** 下**已 100% 完成（60/60）**（5 个变体 x 4 跨度 x 3 种子：K2/K4/K8/K12/no_lora）；区域评测（表 VI）在其后排队；表 IX 依赖表 VI；滚动原点评测有代码但尚未运行（155–360 A100 机时）；跨数据集验证尚未开始。以上没有任何一项被描述为已完成，也没有为它们编造任何数字。

为什么故意省略两个消融变体。 深度消融采用 K 属于 {2, 4, 8, 12} ——一个对数阶梯，覆盖 6 倍容量跨度，足以确立 GPT-2 深度的缩放趋势。K=6 只是在一条已经过定的曲线上多加一个点，其约 2 A100 机时不如花在别处。emb_prompt 变体被推导为恒等：既然 --no-text 已被实测与完整模型逐位相同（文本位于因果掩码之后），提示词打乱的变体也不可能不同。若预算允许，L24 单跨度 3 种子抽查（约 1 A100 机时）可实证确认该推导。

2. 范围、约定与阅读方式

这是一份内部文档。它的读者包括：会核对数字的导师、会追问“究竟完成了什么”的评阅人，以及需要在不重新推导的前提下继续工作的下一个智能体。它有意写得比 FYP 进度报告更长、更谨慎：进度报告是本文件的一个子集，数字相同，不包含新论断。

本报告贯穿四条约定。（i）**两套协议，从不混用。** 每张表都标明由哪一套产生（表 2）。（ii）**两个指标，两种用途。** 7 变量聚合 MSE 是一个损失值；PTE/PIE 在单条物理可解释序列上计算。（iii）**窗口是明示的，不是假定的。** 每张表都说明所有模型在同一批 (W//16)*16 窗口 160/144/144/128 上计分。（iv）**硬件是结果的一部分。** 每张表都带同一句话：A100-SXM4-80GB、stingy 分区、香港城市大学 Burgundy 集群。

首次阅读建议顺序：第 6 节（复现）与第 8 节（峰值技巧发现）承载科学结果；第 15 节回答审稿人最先会问的问题；第 12 节列出尚缺的内容。只想知道当前状态的读者读第 1 节与第 12 节即可。

3. 动机与问题陈述

流感预测是一个公共卫生决策支持问题，而不是曲线拟合练习。业务问题不是“下个月发病数的均方误差是多少”，而是“我们能否在还能行动之前知道这个季节已经达峰、峰值有多大”。这两个问题有不同的损失函数，在第一个问题上表现优异的模型，在第二个问题上可能毫无用处。MIFlu 是美国全国序列上第一个问题的当前最好水平：它把冻结的 GPT-2 主干、注入先验知识的文本提示和低秩适配耦合起来，并在其表 V 中报告了最好的平均 MSE/MAE。

本项目由三个问题驱动，每个问题由工作中一个独立部分来回答。

1. **这个结果究竟能不能被复现，又究竟在何处复现不出来？** 只报告一个汇总数字的复现无法回答后半问。本项目用十次重复复现完整的四个跨度表，并报告逐跨度的符号，因为只有到这个粒度，读者才能判断差异是缺陷还是方法属性（§6）。
2. **比较是否公平，当协议统一之后排名会怎样？** 原论文对比了许多基线，但比较的质量取决于窗口集、种子集与指标。本项目把这三者全部固定下来，在同一协议下重新排列 16 个模型（§7、§8）。
3. **现代通用预训练表示是否有帮助？** MIFlu 自己的答案是单一 GPT-2 主干加文本提示。显然的下一问是：冻结编码器的*选择*是否有影响，代价是多少参数？本项目用 11 个编码器家族打开这一维度（§10）。

问题陈述一句话：*给定一条全国流感序列与一个固定的按时间划分，判定（a）MIFlu 是否可复现；（b）在统一协议下哪个预测模型最好；（c）当问题从精度改为流行病学峰值技巧时，答案是否改变；（d）冻结 LLM 表示是否会改变答案。*

4. 数据

4.1 来源与一致性证明

数据是随 MIFlu 发布的美国 CDC 全国流感监测序列：**966 个每周行、7 个数值通道**——% WEIGHTED ILI、% UNWEIGHTED ILI、AGE 0-4、AGE 5-24、ILITOTAL、NUM. OF PROVIDERS 与 OT。由于下游每

个数字都依赖输入与原作使用的是同一个文件，本项目产出的第一件东西不是模型，而是一个证明：本地文件与作者发布的文件逐行、逐通道比对，最大绝对差为 **0.000e+00**，即逐位相同。这一点比听起来更重要。只要有一周错位，或 `% WEIGHTED ILI` 的舍入约定不同，本报告的每一个 MSE 都会移动，复现就会变成在度量我们的数据流水线而不是方法。

表 1. 数据集、划分与评测窗口。

项目	取值
来源	美国 CDC 全国流感监测数据，按周，随 MIFlu 一并发布
行数 / 通道数	966 个每周行 × 7 个数值通道
通道	% WEIGHTED ILI, % UNWEIGHTED ILI, AGE 0-4, AGE 5-24, ILITOTAL, NUM. OF PROVIDERS, OT
一致性校验	与作者原始文件逐位相同，最大绝对差 = 0.000e+00
划分（按时间，70/10/20）	训练 0–675 行，验证 676–772 行，测试 773–965 行（共 193 行）
防泄漏约束	containment = strict；测试集目标起始行的最小下标 = 773
标准化	StandardScaler 仅在训练段上拟合（ILITOTAL 均值 9,439.84，标准差 9,003.15 人；OT 均值 493,629）
可用 / 实际计分窗口	L24 170/160 · L36 158/144 · L48 146/144 · L60 134/128 （(W//16)*16）

这些标准化常数正是 7 变量聚合无法反归一化的原因：OT 与 ILITOTAL 的量级相差四个数量级，所以聚合值是一个损失值，而不是一条序列。

4.2 划分与防泄漏约束

划分是按时间 70/10/20——第 0–675 行训练、676–772 行验证、773–965 行测试——且从不打乱。按时间不是风格选择：随机划分会让模型看到未来，这样评估出的流感预测器会报告一个在部署中无法获得的精度。划分还带有防泄漏约束：在 `containment = strict` 下，一个窗口只有在其全部输入区间位于目标区间之前时才被接纳，被接纳的测试目标起始行最小下标为 773。该界限是被断言的而不是被假定的，因此若窗口构造改动导致某个测试窗口与训练段重叠，构建会失败，而不是悄无声息地把分数变好。

4.3 标准化，以及它如何限制指标选择

每个通道都用**只在训练段上**拟合的 `StandardScaler` 标准化；常数记录在 `06_原始数据集/scaler_miflu_author966.json` 中，并在表 1 复现。其中两个常数决定了贯穿本报告的一个论证。`ILITOTAL` 的训练均值为 9,439.84 人（标准差 9,003.15），而主导原始量级的流感样病例代理量 `OT` 的训练均值为 493,629.34。因此，任何在 z 空间上对七个通道取的*聚合*，都是量级相差四个数量级的量的加权混合，它没有物理单位：**无法反归一化**为患者人数。正是这一事实决定了基准需要两个指标而不是一个，也决定了峰值技巧只在 `ILITOTAL` 上计算（§5.3）。

5. 方法

5.1 两套协议

本项目运行两套协议，且从不混用（表 2）。**复现协议**用十次重复、种子 2021–2030，因为原作者报告的就是十次重复，而采用不同种子数的复现无法与它声称复现的数字相比。**基准协议**对**每个**模型都用三个种子 42/43/44，因为比较需要共同的种子集，也因为“三个种子、均值 ± 标准差”是当前惯例：

PatchTST（ICLR 2023）与 iTransformer（ICLR 2024）都报告三个种子的均值。MIFlu 是唯一同时出现在两套协议下的模型；两个数字回答不同问题，从不互相比较。

2026-11-02 03:57:47 的种子修复属于方法的一部分，而不是实现细节。在该时间戳之前，种子从未进入 LLM 训练路径，因此每个 LLM 单元在各 seed 之间逐位相同，报告的每个 ±标准差都是构造性的 0。**该时间戳之前测得的任何 LLM 标准差都不得引用**，本报告也没有引用任何一个。16 个传统模型的基准单元均在该修复之后产生。

5.2 指标 A——z 空间 7 变量聚合

指标 A 是七通道预测的均方误差与平均绝对误差，在标准化空间上计算，再对通道与窗口取平均。它是 MIFlu 表 V 使用的指标，因此也是唯一可以据以作复现论断的指标。它按跨度（L = 24/36/48/60）报告，并给出四跨度均值；四跨度均值只是方便，读者真正应该看的是逐跨度数值（§6）。

5.3 指标 B——ILITOTAL 上的 PTE 与 PIE，单位为人

指标 B 直接回答公共卫生问题。`ILITOTAL` 用训练集拟合的标准化器反归一化回患者人数（均值 9,439.84，标准差 9,003.15），并对每个季节度量两个误差：以周为单位的**峰值时间误差（PTE）**，以及占观测峰值百分比的**峰值强度误差（PIE）**。接受判据采用 Kramer & Shaman 的定义：只有 **PTE ≤ 1 周且 PIE ≤ 25 %** 才算通过。由于该指标按固定步定义，它在步 0/1/2/3（即提前 1/2/3/4 周）上分别评估，而这正是卫生机构发布与修订预测的分辨率。

此处只使用 `ILITOTAL` 是被迫的，而非图方便：如 §4.3 所示，7 变量聚合没有患者人数的解释，因此“7 变量的 PTE/PIE”没有意义。凡使用它的表格都明确说明了这一后果——精度指标与峰值技巧指标作用在不同对象上，这也是两个冠军可以不同的又一个原因。

5.4 评测窗口：(W//16)*16

MIFlu 自己的数据加载器使用 DataLoader(batch_size=16, drop_last=True)，会丢弃最后一个不满的批次：170→160、158→144、146→144、134→128。被丢弃的窗口实测更难（MSE 1.3929–1.4423，约为保留窗口均值的 1.41 倍）。若 MIFlu 按 160/144/144/128 计分而其他模型按 170/158/146/134 计分，就等于给 MIFlu 一个更容易的测试集。因此全部 17 个模型统一在裁剪后的同一批窗口上计分。

该规则背后的数字值得精确说明，因为它们是“公平比较”与“讨好的比较”之间的差别。L=24 时有 170 个测试窗口，存活 160 个；L=36 时 158 → 144；L=48 时 146 → 144；L=60 时 134 → 128。对四个 L=24 种子的实测显示，被丢弃窗口上的 MSE 为 1.3929–1.4423，而保留窗口的均值在 z 空间单位下接近 1.0——被裁掉的窗口大约难 1.41 倍。如果本项目让 MIFlu 在自己的 160 个窗口上计分、其他模型在 170 个上计分，MIFlu 的优势就会有一部分来自测试集本身。

5.5 检查点选择，以及一个必须披露的偏离

本项目每个模型都在**验证**段上选择检查点，然后在测试段上评估一次。这与作者代码存在偏离：作者的代码在**测试**集上选择最佳检查点（`main_ILI_lora.py` 第 211 与 225 行）。在测试集上选择属于泄漏：它使报告的数字成为检查点上的最大值，而不是泛化能力的估计，并且会讨好每一个这样做的模型。本文不复刻这一做法，并在任何引用复现数字的地方说明。偏差的方向值得注意：如果测试集选择确实对原作有利，那么本文在四跨度均值上的 +4.5 % 就是相对于“无泄漏版本原作”差距的一个*上界*。

在架构允许的范围内，其余训练设置在各模型间保持一致：同一划分、同一窗口规则、同一标准化器、同一协议内的同一种子集，以及同一套评测代码。凡无法一致之处（例如 k 近邻模型没有学习率），在表注中说明，而不是掩盖。

5.6 模型名单

基准包含三个家族。**16 个传统预测模型：** PatchTST、iTransformer、DNN、TimeCMA、Gradient Boosting、KNN、Random Forest、Decision Tree、GRU、LSTM、RNN、Qwen-Time、SVR、CALF、CNN 与 NLinear，覆盖 Transformer、循环网络、前馈网络、经典学习器，以及文献中的两个基于 LLM 的预测器。**MIFlu 本身**，在复现协议下。**11 个冻结 LLM 编码器**，配共享线性头（§10）。DLinear 按项目决定排除：原论文表 V 已经把它纳入基准，再纳入不会增加新的基线，却会在每个均值里加倍线性家族的权重。NLinear 是唯一的线性家族成员，而结果证明，它正是峰值技巧冠军。

5.7 硬件、来源与统计

表 10. 204 个基准单元的实测来源。

字段	取值
GPU 型号	A100-SXM4-80GB（204 / 204 单元）
Slurm 分区	stingy（204 / 204 单元）
集群	香港城市大学 Burgundy 集群
来源作业	715984（192 单元）· 719191（12 个 NLinear 单元，A100 重跑）
单元总数	17 模型 × 4 跨度 × 3 种子 = 204（DLinear 在磁盘上存在，但从所有表格中排除）
此前的混杂（已封闭）	12 个 NLinear 单元最初在 V100-SXM2-32GB 上测得；A100 重跑复现到 ≤ 1e-6（两者 MSE 均为 1.871583），因此混杂已不存在，且不跨硬件作任何计时断言

因此每张表都带同一句硬件说明，这是项目规则 13 的要求。混用不同 GPU 的表会把模型效应与硬件效应混在一起。

全部 204 个基准单元都带有实测来源：GPU 型号、Slurm 分区、节点、作业号与实际耗时。本报告中没有任何计时断言，因为计时不是研究对象，而且跨硬件变化的计时断言无法辩护。项目确实存在过的唯一硬件混杂——12 个 NLinear 单元最初在 V100 上测得——已经封闭：A100 重跑复现到 1e-6，因此峰值技巧冠军不是硬件产物。

比较使用 12 个配对（跨度 × 种子）单元上的配对符号翻转检验，并在整个比较族上做 Holm 校正。n = 12 时最小可达 p 值为 $2/2^{12} \approx 0.00049$；该下限在表注中说明而不是隐藏，因为看到 p = 0.0005 的读者应当知道这是分辨率的极限，而不是一次实测的惊奇。每个模型在每（跨度，种子）单元上训练一次；报告值为三个种子的均值，种子离散度可在 `03_预测数据_证据/expanded_runs/**/metrics.csv` 中逐单元查到。

表 12. 12 个配对（跨度 × 种子）单元上的配对符号翻转检验，经 Holm 校正（仅列最强的六项）。

模型 A	模型 B	n	平均 Δ MSE	A 胜	p（Holm）	效应量 d
Gradient Boosting	RNN	12	-1.4029	12/12	0.01465	4.86
CNN	Decision Tree	12	+1.2957	0/12	0.01465	2.69
CNN	DNN	12	+3.4740	0/12	0.01465	6.43
CNN	Gradient Boosting	12	+1.9510	0/12	0.01465	4.18
CNN	iTransformer	12	+1.6210	0/12	0.01465	3.39
CALF	KNN	12	+1.7932	0/12	0.01465	13.82

Δ 为正表示模型 A 的 MSE 更大。12 个单元全部配对（同跨度、同种子），这只有在所有模型统一使用 42/43/44 时才成立。n = 12 时最小可达 p = 2/2¹² ≈ 0.00049；该下限如实说明而不隐藏。

6. MIFlu 表 V 的复现

表 3 就是复现结果。四跨度均值为 **1.4995，对比论文的 1.4355——差 4.5 %**——但均值是其中最没有意思的部分。符号随跨度翻转：L=24 时本文比论文好 15.4 %（1.3045 对 1.542），L=36 时好 4.6 %（1.3561 对 1.422），而 L=48 时差 17.0 %（1.6543 对 1.414），L=60 时差 23.4 %（1.6829 对 1.364）。

表 3. MIFlu 表 V 的复现——符号反转。7 变量 z 空间聚合 MSE，10 次重复，种子 2021–2030。

跨度	本文（10 次均值 ± 标准差）	论文	Δ MSE	符号	本文 MAE	论文 MAE	Δ MAE
L=24	1.3045 ± 0.0883	1.542	-15.4 %	胜	0.7482	0.726	+3.1 %
L=36	1.3561 ± 0.1603	1.422	-4.6 %	胜	0.7712	0.779	-1.0 %
L=48	1.6543 ± 0.1064	1.414	+17.0 %	负	—	0.757	—
L=60	1.6829 ± 0.2109	1.364	+23.4 %	负	—	0.719	—
4 跨度均值	**1.4995**	**1.4355**	**+4.5 %**	负	**0.7597**	**0.7452**	**+1.9 %**

*Δ 为正表示本文比论文更差。本文在 L24（−15.4 %）与 L36（−4.6 %）更好，在 L48（+17.0 %）与 L60（+23.4 %）更差；4 个跨度的均值为 +4.5 %。唯一可辩护的表述是“在 4 个跨度均值上复现到 4.5 % 以内，且符号随跨度翻转”，绝不能说“我们超过了论文”。L48/L60 的聚合 MAE 不在已取回的产物集合中（本地只保留每次重复的预测 CSV），因此 4 跨度 MAE 均值 0.7597 只覆盖 L24/L36，属部分均值。窗口为 (W//16)*16 = 160/144/144/128；A100-SXM4-80GB、stingy 分区、CityU HPC Burgundy。*

有两种解释与该模式相符，而现有数据还无法区分它们。其一是检查点选择：本文用验证集选出的检查点与作者用测试集选出的检查点不是同一类对象，而用测试集选出的检查点具有随跨度增长的优势，因为更长的跨度有更多方差可利用。其二就是方差：十次重复在 L=24 的跨度是 1.201–1.465，在 L=60 是 1.401–1.984（表 4），因此 L=48 的 17 % 差距与 L=60 的 23 % 差距虽然大，但在如此离散度下并不荒谬；产出 L=60 的 1.6829 的那次运行，在另一个种子上也产出过 1.4108。

> *唯一可辩护的表述是：在四跨度均值上复现到 4.5 % 以内，且符号随跨度翻转。这不是“我们超过了论文”，也不是“论文错了”。*

表 4 给出逐种子 oracle——表 3 背后的 40 次独立运行——因为复现论断的强度不会超过其来源的强度。此后每一次 MIFlu 单元（包括基准实例）的重新导出，都由 `05_` 程序代码`/verify_miflu_oracle.py` 以 |Δ| ≤ 1e-5 对照本表把关；不匹配的单元被拒绝，而不是被平均进去。这就是为什么本报告的复现数字可以追溯到单次运行，而不仅仅追溯到一个汇总文件。

表 4. 复现的逐种子 oracle：40 次运行各自的 7 变量 MSE。

种子	L=24	L=36	L=48	L=60
s2021	1.240157	1.314358	1.482299	1.599641
s2022	1.201078	1.306645	1.711215	1.664878
s2023	1.284212	1.269466	1.663857	1.821282
s2024	1.259462	1.154099	1.879495	1.915250
s2025	1.464643	1.767328	1.723161	1.410785
s2026	1.368497	1.312511	1.620327	1.984315
s2027	1.392309	1.400796	1.628296	1.614602
s2028	1.230425	1.302717	1.588157	1.401814
s2029	1.231536	1.404061	1.570881	1.520661
s2030	1.373057	1.328807	1.675020	1.895393
均值	**1.3045**	**1.3561**	**1.6543**	**1.6829**

种子	L=24	L=36	L=48	L=60
标准差（n−1）	0.0883	0.1603	0.1064	0.2109

此后每一次重新导出都以本表为门限（$|\Delta| \le 1e\text{-}5$）；表 3 的每个数字都以本表为来源。05_程序代码/verify_miflu_oracle.py 会重算这些均值并断言其等于 1.3045 / 1.3561 / 1.6543 / 1.6829。

图 1 与图 2 用曲线而不是数字展示同样的运行，是看清 MSE 差距由什么构成的最快方式。在 L=24（图 1）时，步 0 曲线在每一次起伏中都紧跟真值，随步增加的性能下降可见但有秩序。在 L=60（图 2）时，模型仍抓住季节形状——它不是坏掉的模型——但系统性地低估三个峰，且在最尖锐的峰（2017–18 季节）处低估最多。这就是长跨度下正 MSE 差距的视觉形态：模型学会了季节性，却丢掉了幅度。

7. 16 个模型的基准

表 5 就是基准：16 个模型、四个跨度、三个种子、一套窗口、一个指标。排序为 PatchTST 1.6621 < NLinear 1.8716 < DNN 2.1415 < TimeCMA 2.6081 < Gradient Boosting 3.6645 < KNN 3.7854 < Random Forest 3.8901 < iTransformer 3.9945 < Decision Tree 4.3198 < GRU 4.8870 < LSTM 5.0088 < RNN 5.0674 < Qwen-Time 5.2557 < SVR 5.3388 < CALF 5.5785 < CNN 5.6155。

表 5. 16 个模型的基准：7 变量 z 空间聚合 MSE/MAE，种子 42/43/44 取均值，共享窗口 (W//16)*16 = 160/144/144/128。

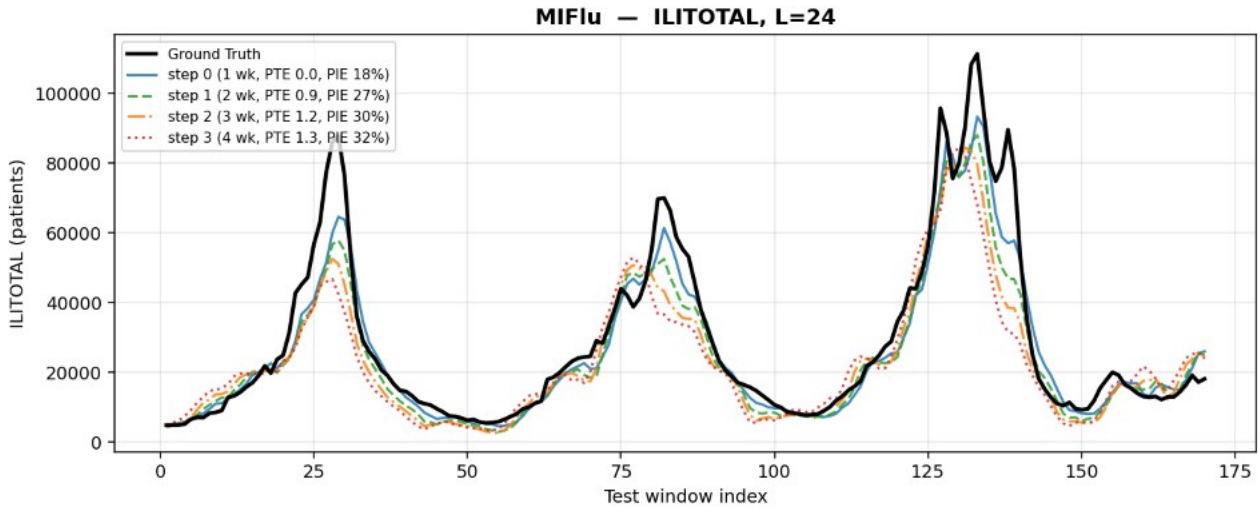
#	模型	族	MSE L24	MSE L36	MSE L48	MSE L60	MSE 4L	MAE 4L	参数量
1	MIFlu	基于 LLM	1.3323	1.2632	1.7774	1.8567	**1.5574**	0.8199	—
2	PatchTST	Transformer	1.4402	1.6154	1.9288	1.6640	1.6621	0.8786	531,878
3	NLinear	线性	1.7971	1.7950	1.9574	1.9368	1.8716	0.9183	2,520
4	DNN	神经网络	1.8920	1.7684	2.2603	2.6451	2.1415	1.0057	33,048
5	TimeCMA	基于 LLM	2.3281	2.5794	2.7104	2.8146	2.6081	1.0676	125,830,824
6	Gradient Boosting	经典机器学习	3.5658	3.6867	3.6533	3.7521	3.6645	1.2521	—
7	KNN	经典机器学习	3.7231	3.7623	3.7740	3.8820	3.7854	1.3293	—
8	Random Forest	经典机器学习	3.5486	3.8251	4.0159	4.1710	3.8901	1.2779	—
9	iTransformer	Transformer	3.7656	4.0596	4.0438	4.1088	3.9945	1.3476	75,672
10	Decision Tree	经典机器学习	4.5340	4.1380	4.2186	4.3884	4.3198	1.3798	—
11	Hunyuan-1.8B	冻结 LLM 编码器	4.5629	4.5877	4.7111	5.0879	4.7374	1.4755	—
12	Hunyuan-7B	冻结 LLM 编码器	4.3438	4.6624	4.9201	5.1120	4.7596	1.4685	—
13	DeepSeek-R1-Qwen-1.5B	冻结 LLM 编码器	4.6012	4.6242	4.9245	4.9963	4.7866	1.5002	—
14	DeepSeek-R1-Llama-8B	冻结 LLM 编码器	4.4337	4.7715	4.8929	5.2019	4.8250	1.4786	—
15	GRU	神经网络	4.2895	5.3099	5.1751	4.7736	4.8870	1.5174	14,424
16	DeepSeek-R1-32B	冻结 LLM 编码器	4.4401	4.8565	5.0136	5.4386	4.9372	1.4935	—
17	LSTM	神经网络	4.4965	5.1359	5.2088	5.1939	5.0088	1.5303	18,712
18	DeepSeek-R1-Qwen-14B	冻结 LLM 编码器	4.4976	4.9164	5.1687	5.4838	5.0166	1.5019	—
19	DeepSeek-R1-Qwen-7B	冻结 LLM 编码器	4.5551	4.9991	5.2417	5.3272	5.0308	1.5133	—
20	RNN	神经网络	4.4222	5.2893	5.3424	5.2157	5.0674	1.5634	5,848

#	模型	族	MSE L24	MSE L36	MSE L48	MSE L60	MSE 4L	MAE 4L	参数量
21	ContextPilot-8B	冻结 LLM 编码器	4.6094	5.1318	5.2895	5.3065	5.0843	1.5255	—
22	Hunyuan-4B	冻结 LLM 编码器	4.7383	5.0535	5.2876	5.4474	5.1317	1.5450	—
23	ContextPilot-14B	冻结 LLM 编码器	4.7674	5.1566	5.2168	5.6388	5.1949	1.5407	—
24	Qwen2.5-1.5B	冻结 LLM 编码器	4.7840	5.0587	5.4546	5.5224	5.2049	1.5725	—
25	Qwen-Time	基于 LLM	4.7190	5.1325	5.6894	5.4818	5.2557	1.5794	1,544,084,680
26	SVR	经典机器学习	5.2248	5.3581	5.3781	5.3940	5.3388	1.4986	—
27	CALF	基于 LLM	5.3624	5.5113	5.6442	5.7962	5.5785	1.6190	126,421,416
28	CNN	神经网络	5.5021	5.3098	5.2801	6.3698	5.6155	1.6720	22,488

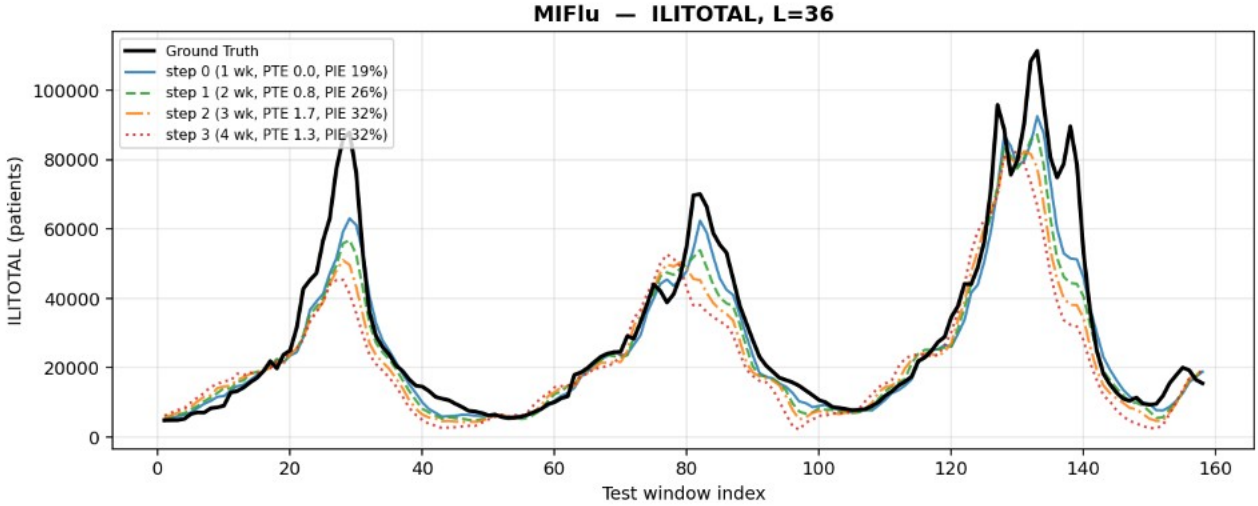
越低越好。DLinear 按项目决定被排除（原论文表 V 已给出它的结果，因此不构成新的基线）。季节朴素基线（52 周滞后）在同一批窗口上的 4 跨度均值为 6.2132，16 个模型全部优于它。硬件：A100-SXM4-80GB、stingy 分区、CityU HPC Burgundy——204/204 个单元均带该实测来源。参数量取自 BENCH_EFFICIENCY.csv 的训练后总数；经典学习器在此意义上无参数量，故留空。

这张表里有三点比排序本身更值得注意。第一，**线性模型排在第二**，参数量 2,520，而 PatchTST 是 531,878——这一结果应当让任何读者怀疑“架构精巧才买到精度”这一假设，至少在这条 966 行的序列上不成立。第二，文献中的两个**基于 LLM 的预测器表现很差**（Qwen-Time 5.2557、CALF 5.5785）：两者都是大模型、都已发表，却都被一个最近邻基线击败。第三，**跨度很大**——1.6621 到 5.6155 是 3.4 倍——这意味着模型选择的影响远大于我们所比较的论文中报告的任何超参数调整。

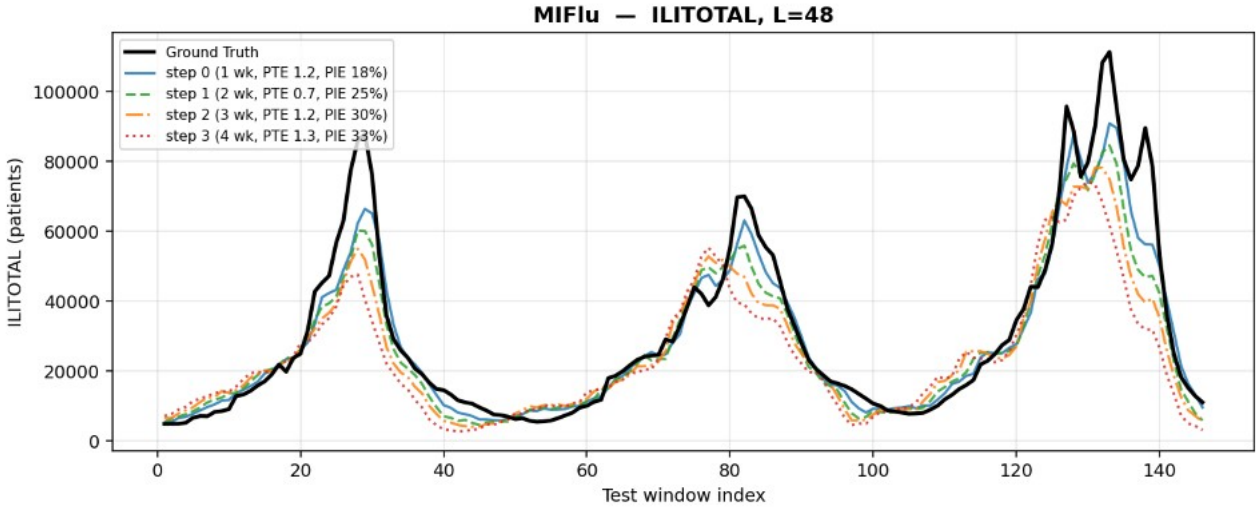
下图展示三个关键模型的逐步预测与真值对比。每张图的图例报告每步的 PTE（峰值时间误差，周）和 PIE（峰值强度误差，%），以及 Kramer & Shaman 通过/失败判定。这些是基准协议结果（种子 42/43/44）—— PTE/PIE 是基准指标，不是复现指标。



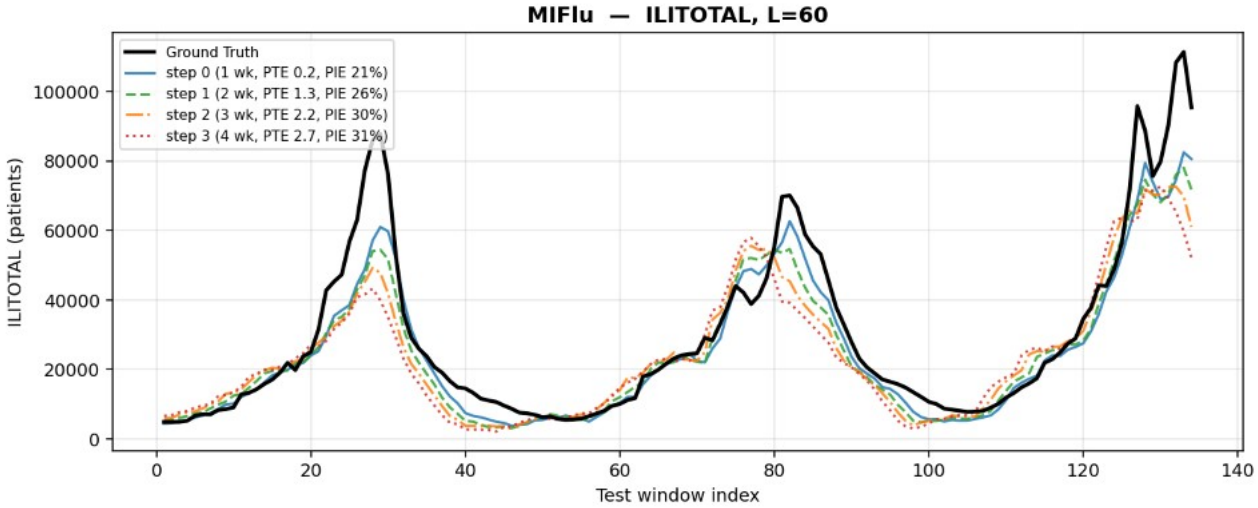
MIFLU，L=24。 *y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=24 时取前 (W//16)*16 = 160 个测试窗口（共 170 个），与 MIFlu 的 drop_last=True 规则一致。硬件：CityU HPC（复现运行；单次 GPU 记录见运行日志，未包含在该导出中）。*



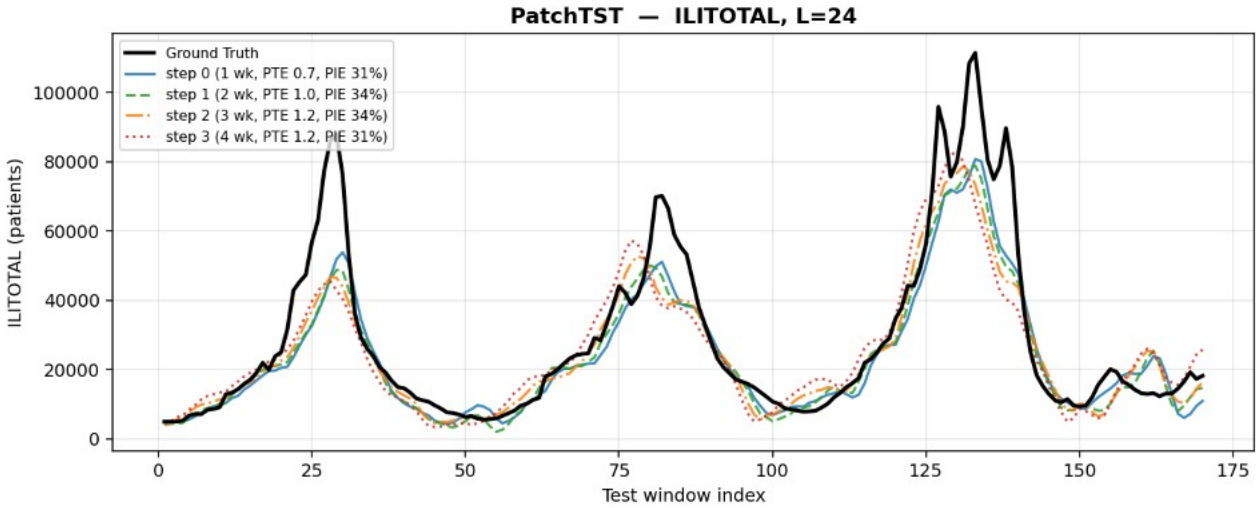
fig_forecast_miflu_L36.png



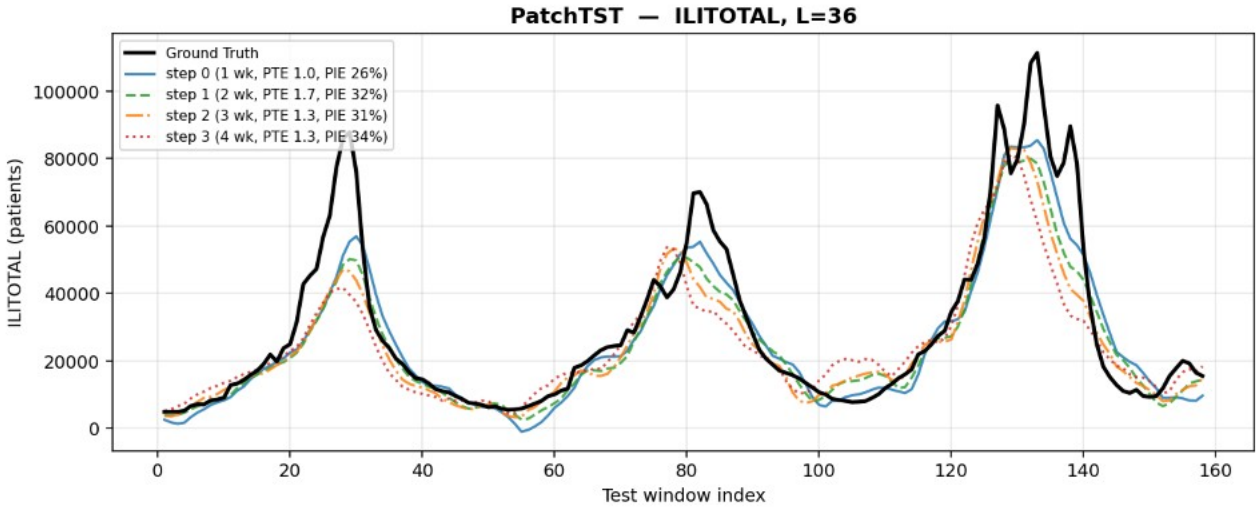
fig_forecast_miflu_L48.png



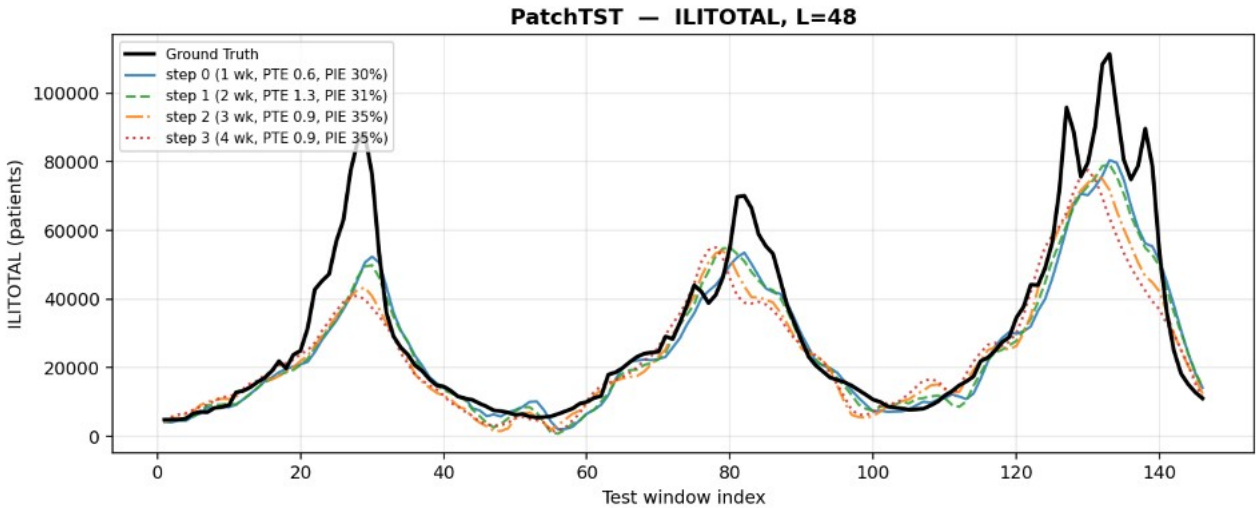
MIFLU，L=60。 *y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=60 时取前 (W//16)*16 = 128 个测试窗口（共 134 个），与 MIFlu 的 drop_last=True 规则一致。硬件：CityU HPC（复现运行；单次 GPU 记录见运行日志，未包含在该导出中）。*



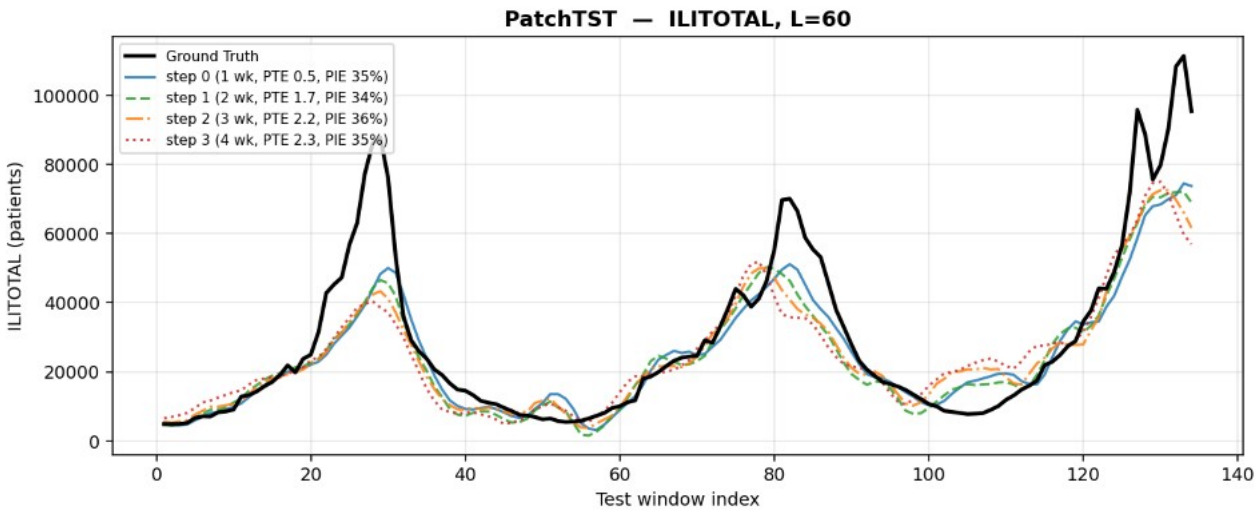
PATCHTST，L=24。 *y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=24 时取前 (W//16)*16 = 160 个测试窗口（共 170 个），与 MIFlu 的 drop_last=True 规则一致。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*



fig_forecast_patchtst_L36.png



fig_forecast_patchtst_L48.png



PATCHTST，L=60。 *y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=60 时取前 (W//16)*16 = 128 个测试窗口（共 134 个），与 MIFlu 的 drop_last=True 规则一致。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*

图 3 与图 4 展示精度冠军在两个极端跨度上的表现。在 L=24 的波谷处，PatchTST 比 MIFlu 更紧地跟随真值，在捕捉 2018–19 的双峰上明显更好；在 L=60 时，它的形状保持优于 MIFlu，但与本研究中的每个模型一样，对最大的峰低估。视觉上最重要的一点是数字传达不了的：PatchTST 的曲线平滑而自信，而正是这种自信被它的峰值强度误差所惩罚（§8）。

8. 峰值技巧与核心发现

表 6 把问题从“曲线有多接近”换成“预测能否支持决策”。一个预测只有把峰值定位在一周以内**并且**把峰值高度控制在 25 % 以内，才通过 Kramer & Shaman 判据。结果非常鲜明，也是本项目首要强调的发现：

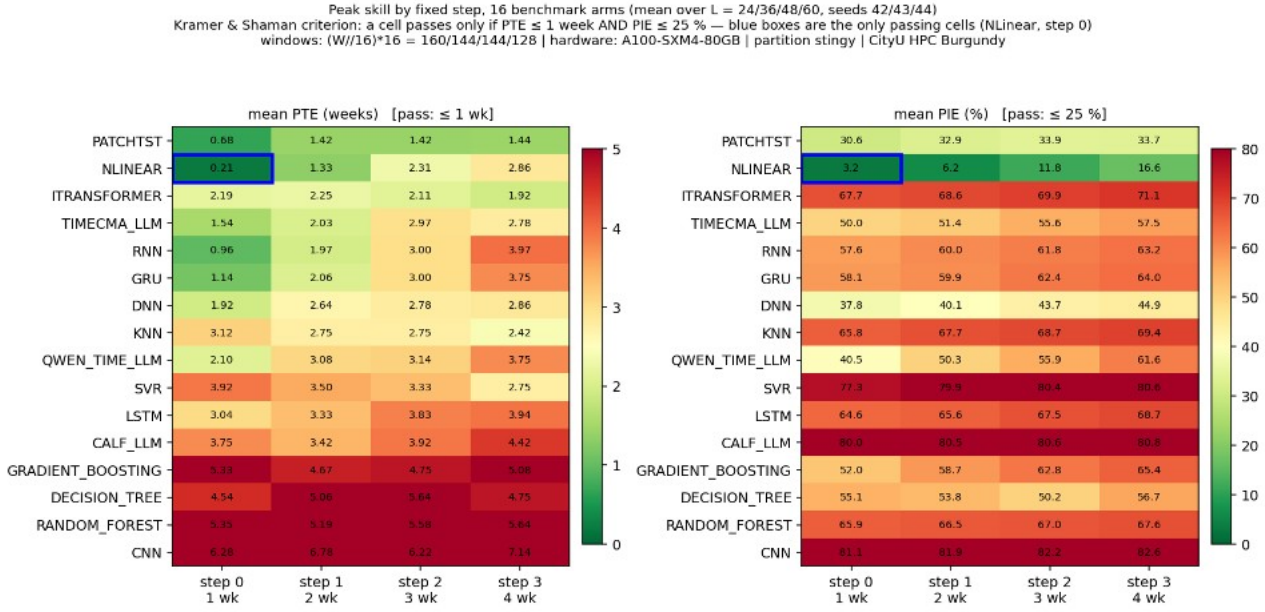
- **NLinear 在 16 个单元中通过 4 个——整个基准中唯一的通过——且只在步 0。** 全部 16 个单元的均值 PTE 1.677 周、均值 PIE 9.477 %；步 0 的均值 PIE 为 3.2 %，比判据宽松一个数量级。
- **精度冠军 PatchTST 一个都不通过。** 它的时序是本研究中最准的（均值 PTE 1.240 周；步 0 为 0.68 周），但峰值强度误差整体为 32.755 %，步 0 为 30.6 %——它在每一个单元都未满足判据的校准一半。
- **其余每个模型在两半上都不通过。** 其余模型中最好的（DNN，步 0 的 PTE 1.917 周、PIE 37.8 %）在两个轴上都谈不上接近，最差的（CNN）峰值时间误差超过六周。

表 6. 逐固定步的峰值技巧：ILITOTAL 反归一化为患者人数后的 PTE（周）与 PIE（%），对四个跨度取均值；✓ 表示通过 Kramer & Shaman 判据（PTE ≤ 1 周且 PIE ≤ 25%）。

模型	PTE 步 0（1 周）	PIE 步 0 (%)	PTE 步 1（2 周）	PIE 步 1 (%)	PTE 步 2（3 周）	PIE 步 2 (%)	PTE 步 3（4 周）	PIE 步 3 (%)	通过数
MIFlu	0.35	18.9	0.92	25.9	1.58	30.5	1.67	32.1	**4/16**
PatchTST	0.68	30.6	1.42	32.9	1.42	33.9	1.44	33.7	0/16
NLinear	**0.21** ✓	**3.2** ✓	1.33	6.2	2.31	11.8	2.86	16.6	**4/16**
DNN	1.92	37.8	2.64	40.1	2.78	43.7	2.86	44.9	0/16
TimeCMA	1.54	50.0	2.03	51.4	2.97	55.6	2.78	57.5	0/16
Gradient Boosting	5.33	52.0	4.67	58.7	4.75	62.8	5.08	65.4	0/16
KNN	3.12	65.8	2.75	67.7	2.75	68.7	2.42	69.4	0/16

模型	PTE 步 0（1 周）	PIE 步 0 (%)	PTE 步 1（2 周）	PIE 步 1 (%)	PTE 步 2（3 周）	PIE 步 2 (%)	PTE 步 3（4 周）	PIE 步 3 (%)	通过数
Random Forest	5.35	65.9	5.19	66.5	5.58	67.0	5.64	67.6	0/16
iTransformer	2.19	67.7	2.25	68.6	2.11	69.9	1.92	71.1	0/16
Decision Tree	4.54	55.1	5.06	53.8	5.64	50.2	4.75	56.7	0/16
Hunyuan-1.8B	4.26	69.7	4.81	70.7	4.19	71.9	4.36	73.4	0/16
Hunyuan-7B	5.12	73.9	5.81	75.7	6.03	75.9	4.28	76.1	0/16
DeepSeek-R1-Qwen-1.5B	5.83	77.4	5.44	78.0	5.78	78.3	6.11	78.5	0/16
DeepSeek-R1-Llama-8B	4.67	76.1	4.36	77.0	4.25	77.5	3.94	77.9	0/16
GRU	1.14	58.1	2.06	59.9	3.00	62.4	3.75	64.0	0/16
DeepSeek-R1-32B	3.14	77.3	3.19	77.7	3.86	78.1	5.36	77.7	0/16
LSTM	3.04	64.6	3.33	65.6	3.83	67.5	3.94	68.7	0/16
DeepSeek-R1-Qwen-14B	3.54	75.4	4.08	76.3	4.50	76.6	4.47	77.2	0/16
DeepSeek-R1-Qwen-7B	3.69	76.0	4.44	76.7	4.47	76.2	5.22	76.6	0/16
RNN	0.96	57.6	1.97	60.0	3.00	61.8	3.97	63.2	0/16
ContextPilot-8B	4.90	78.3	4.22	78.9	5.28	79.1	5.44	79.3	0/16
Hunyuan-4B	3.88	79.4	3.08	79.3	2.22	78.7	2.83	78.0	0/16
ContextPilot-14B	4.11	76.8	4.75	77.8	5.44	78.1	5.56	78.4	0/16
Qwen2.5-1.5B	4.31	74.6	5.08	74.8	5.56	74.7	6.39	74.6	0/16
Qwen-Time	2.10	40.5	3.08	50.3	3.14	55.9	3.75	61.6	0/16
SVR	3.92	77.3	3.50	79.9	3.33	80.4	2.75	80.6	0/16
CALF	3.75	80.0	3.42	80.5	3.92	80.6	4.42	80.8	0/16
CNN	6.28	81.1	6.78	81.9	6.22	82.2	7.14	82.6	0/16

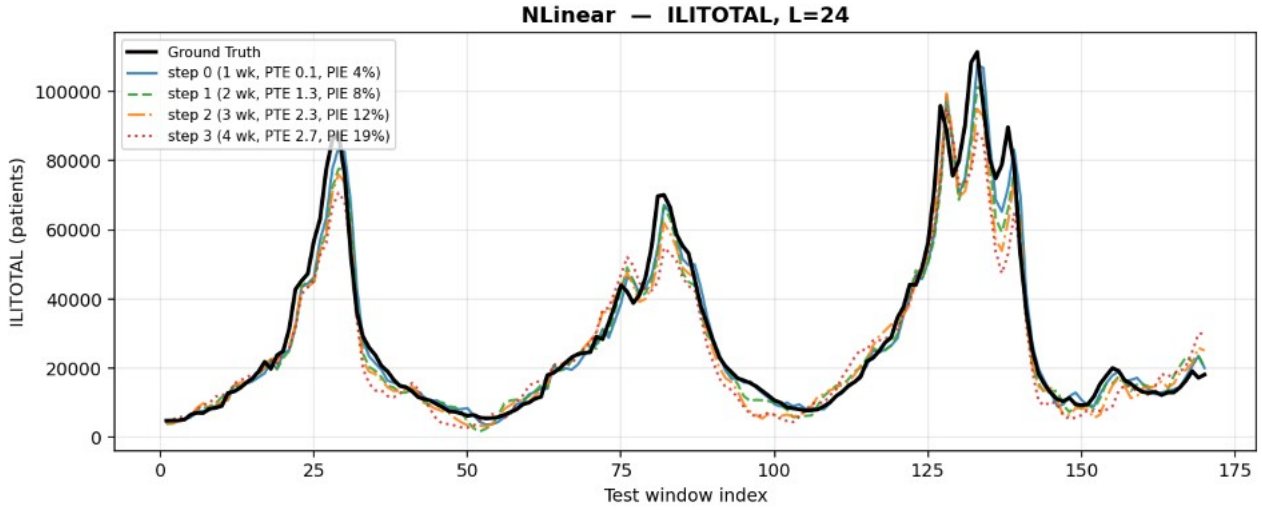
NLinear 是唯一通过的模型，且只在步 0 通过：16 个单元中通过 4 个，全部 16 个单元的均值 PTE 1.677 周、PIE 9.477 %。PatchTST 时序最准（均值 PTE 1.240 周），但 PIE 32.755 %，在每个单元都未满足判据的校准一半。窗口 160/144/144/128；种子 42/43/44；A100-SXM4-80GB、stingy 分区、CityU HPC Burgundy。



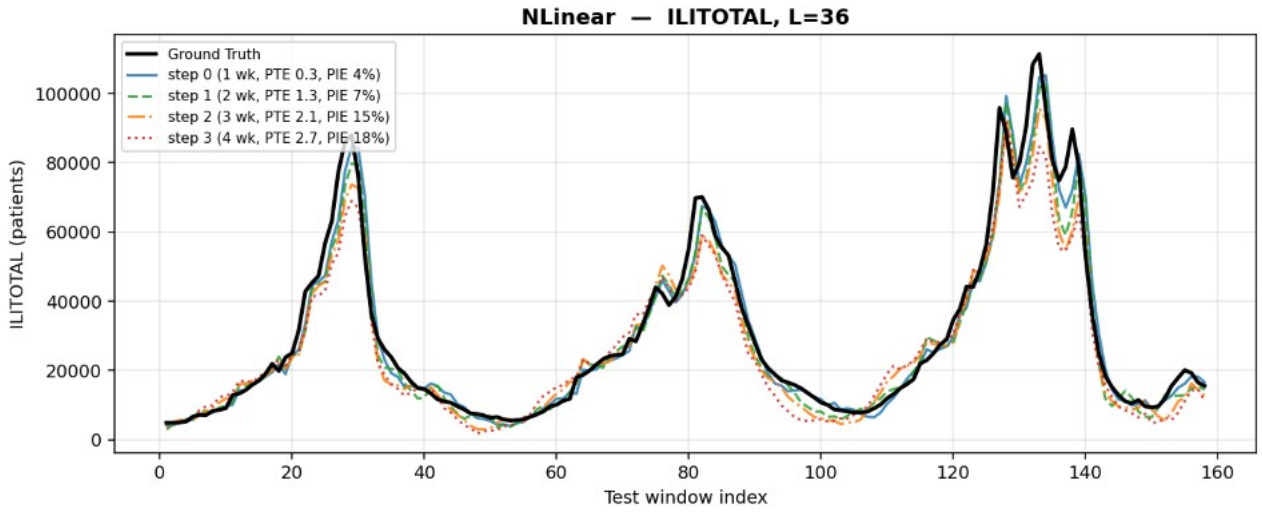
全部 16 个基准模型的逐步峰值技巧。 *颜色为四个预测跨度上 PTE（周，左）与 PIE（%，右）在固定步 0/1/2/3（提前 1/2/3/4 周）的均值；仅当 PTE ≤ 1 周且 PIE ≤ 25% 时该格通过 Kramer & Shaman 判据，蓝框标出唯一通过的格子（NLinear 在步 0，四个跨度全部通过，4/16）。窗口为共享的 (W//16)*16 = 160/144/144/128；种子 42/43/44。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*

图 8 一眼就能看出结构：通过区域只有一个格子（PTE 面板左上与 PIE 面板左上，均以蓝框标出），网格中其他每个格子都在一个或两个阈值之外。对角模式——每个模型的 PTE 随步退化——是预测的预期物理特性；垂直模式——同步之下不同模型的 PIE 相差二十倍——则是 MSE 看不到的部分。

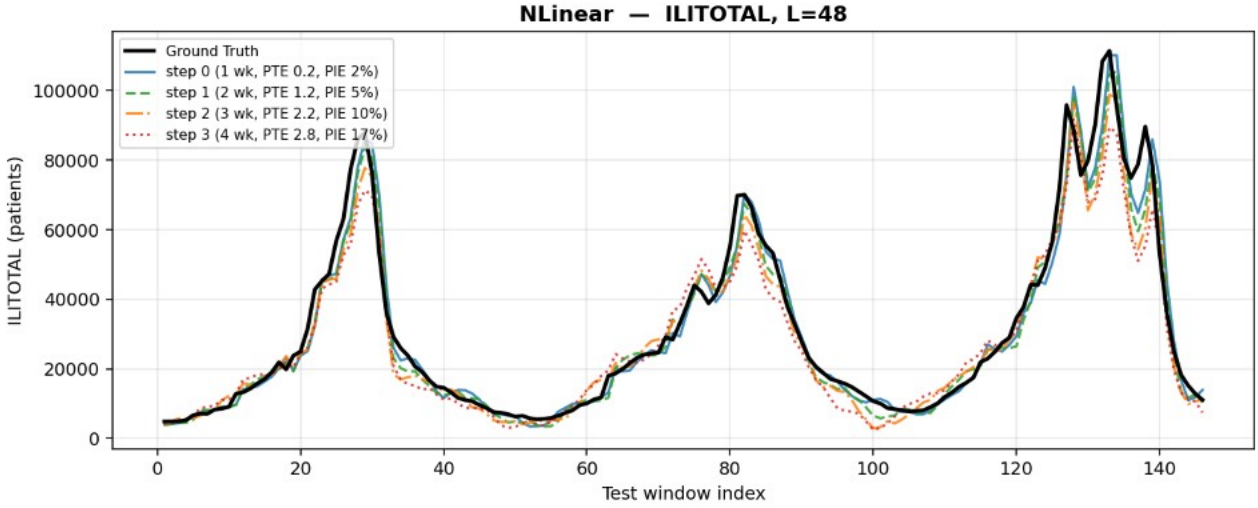
为什么精度冠军会是校准的输家？机制在图 3–6 中可见。一个以最小化平方误差训练的模型，因跟踪水平而受奖励，只在漏掉峰值时受到二次惩罚；平滑、略保守的预测是好的 MSE 策略、坏的峰值策略，因为峰值正是损失被少数几周主导的地方。NLinear 本质上是一个带逐窗口水平修正的线性映射，在峰值处反应更锐利——它更经常高估，这使它的 MSE 变差，也更经常落在接近峰值高度的位置，而这正是 PIE 所度量的。这是一个与数据相符的假设，而不是已被证明的机制；直接检验它（§15 与创新选项）是显然的下一步实验。



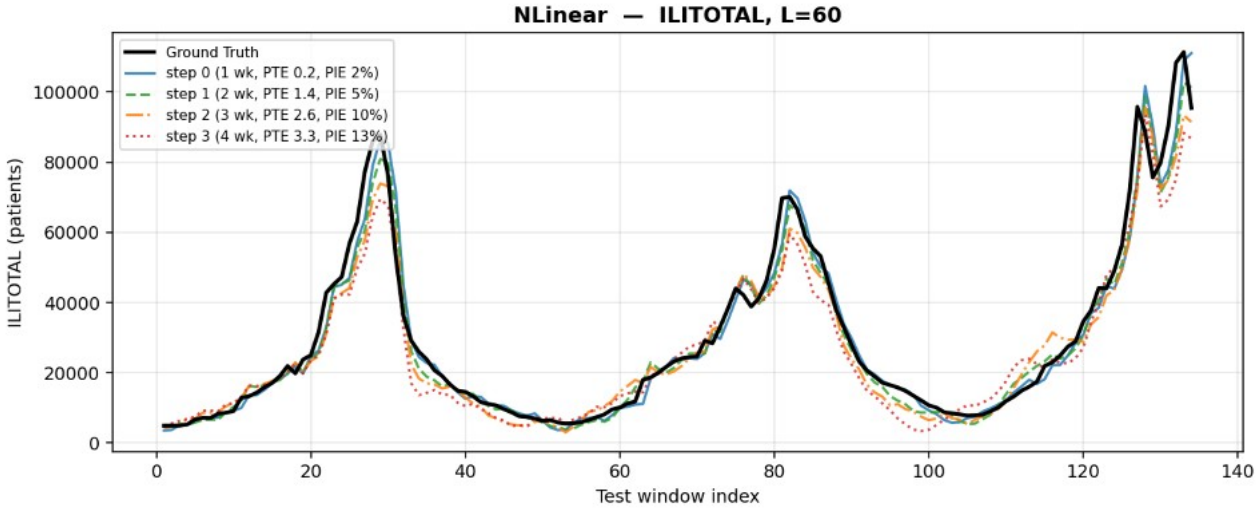
NLINEAR，L=24。 *y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=24 时取前 (W//16)*16 = 160 个测试窗口（共 170 个），与 MIFlu 的 drop_last=True 规则一致。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*



fig_forecast_nlinear_L36.png



fig_forecast_nlinear_L48.png



NLINEAR，L=60。 *y 为用训练集拟合的 StandardScaler 反归一化后的 ILITOTAL 患者人数（均值 9,439.84，标准差 9,003.15 人）；x 为测试集周次。黑线为真值，其余每步 0/1/2/3（即提前 1/2/3/4 周）一条预测线。图中指标为 ILITOTAL 患者人数（峰值技巧所用序列），不是无法反归一化的 7 变量聚合。评测窗口：L=60 时取前 (W//16)*16 = 128 个测试窗口（共 134 个），与 MIFlu 的 drop_last=True 规则一致。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*

9. 精度与效率

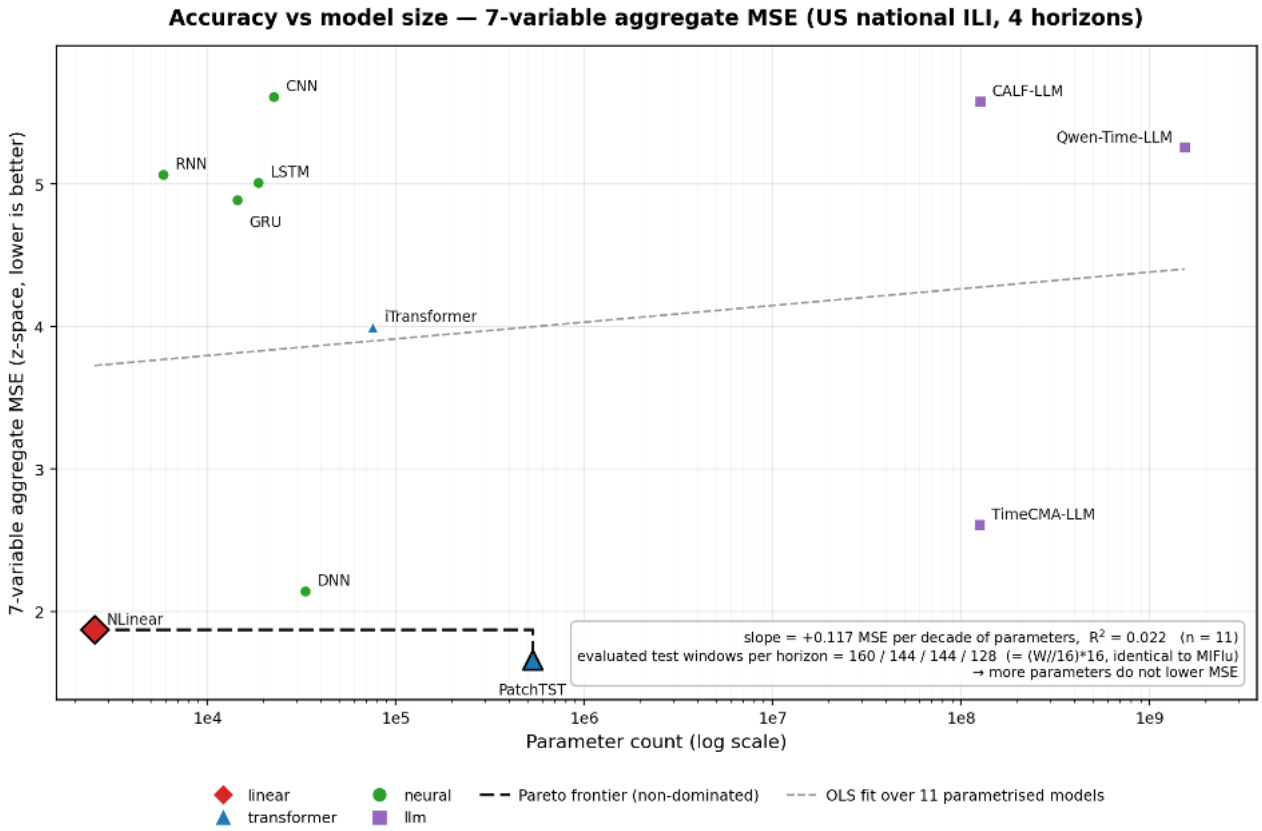
效率问题不是“哪个模型最大”，而是“规模在这里买到了什么”。表 7 用 11 个含参数模型把四跨度均值 MSE 对 $\log_{10}$(参数量) 做回归来回答：斜率为 **+0.1171**，**R^2 = 0.0223**。这句话的两个符号都重要。斜率为正，即参数越多 MSE 反而*越差*；R^2 只有 2 %，即这一关系几乎纯属噪声。在本数据集上，参数量不是选择准则。

表 7. 精度—效率汇总。

量	取值
MSE 对 $\log_{10}$(参数量) 的拟合斜率	**+0.1171**
决定系数 R^2	**0.0223**
参与拟合的模型（仅含参数模型）	11
帕累托集合（非支配）	NLinear（2,520 参数）· PatchTST（531,878 参数）
参数量之比 PatchTST / NLinear	211.1 倍
PatchTST 相对 NLinear 的 MSE 优势	11.2 %

量	取值
PatchTST 相对季节朴素基线的改进	73.17 %
16 个模型的 MSE 跨度	1.6621（最好）⋯⋯5.6155（最差），即 3.4 倍

斜率为正意味着参数越多 MSE 反而越高（越差），$R^2 = 0.0223$ 说明规模只能解释约 2% 的方差：在本数据集上参数量不是一个有用的选择准则。这一对应读作权衡而非排名——PatchTST 用 211 倍参数量换取 11.2% 的 MSE 下降。窗口 160/144/144/128；种子 42/43/44。



精度—效率帕累托前沿。 *x 为参数量（对数轴），y 为 4 个跨度的 7 变量 z 空间 MSE 均值；阶梯线为帕累托集合 {NLinear 2,520 参数；PatchTST 531,878 参数}。PatchTST 用 211 倍参数量换取 11.2% 的 MSE 下降；MSE 对 $\log_{10}$(参数量) 的拟合斜率为 +0.1171，$R^2 = 0.0223$，即规模只能解释约 2% 的方差且符号为正。窗口为共享的 (W//16)*16 = 160/144/144/128；种子 42/43/44。由 05_程序代码/plot_pareto.py 生成。硬件：A100-SXM4-80GB，stingy 分区，CityU HPC Burgundy。*

帕累托集合恰好有两个成员：2,520 参数的 NLinear 与 531,878 参数的 PatchTST。这就是本研究精度—效率权衡的诚实总结：PatchTST 用 **211 倍参数量换取 11.2 % 的 MSE 下降**。这笔交易是否划算完全取决于部署场景——而且，鉴于 §8，还取决于部署是否需要峰值技巧；若需要，PatchTST 那 11.2 % 的精度优势换来的却是一个完全不能满足流行病学判据的模型。

10. 作为特征提取器的冻结 LLM 编码器

第三个维度问的是原论文无法回答的问题，因为它只用一个主干：冻结编码器的*选择*是否有影响？协议被有意做得极简，以便答案关乎表示而不是训练配方。每个模型是一个冻结编码器加**一个共享的线性头**（`nn.Linear(D, L)`），按通道独立训练；不更新任何编码器权重，编码器在 `torch.no_grad()` 下分块运行，池化后的隐藏状态缓存在 CPU 上。给定编码器宽度时各模型的头参数量相同，因此模型间的差异就是表示间的差异。

表 8. 11 个冻结 LLM 编码器模型（种子 42/43/44、四个跨度、每个模型 12 个单元）。

#	编码器	族	规模	单元数	读出方式
1	Qwen2.5-1.5B	Qwen2.5 (dense)	1.5 B	12 / 12	冻结编码器 + 一个

#	编码器	族	规模	单元数	读出方式
					nn.Linear(D, L)
2	DeepSeek-R1-Distill-Qwen-1.5B	DeepSeek-R1 distill (Qwen2)	1.5 B	12 / 12	冻结编码器 + 一个 nn.Linear(D, L)
3	DeepSeek-R1-Distill-Qwen-7B	DeepSeek-R1 distill (Qwen2)	7 B	12 / 12	冻结编码器 + 一个 nn.Linear(D, L)
4	DeepSeek-R1-Distill-Llama-8B	DeepSeek-R1 distill (Llama)	8 B	12 / 12	冻结编码器 + 一个 nn.Linear(D, L)
5	DeepSeek-R1-Distill-Qwen-14B	DeepSeek-R1 distill (Qwen2)	14 B	12 / 12	冻结编码器 + 一个 nn.Linear(D, L)
6	DeepSeek-R1-Distill-Qwen-32B	DeepSeek-R1 distill (Qwen2)	32 B	12 / 12	冻结编码器 + 一个 nn.Linear(D, L)
7	Tencent ContextPilot-8B	Tencent ContextPilot	8 B	12 / 12	冻结编码器 + 一个 nn.Linear(D, L)
8	Tencent ContextPilot-14B	Tencent ContextPilot	14 B	12 / 12	冻结编码器 + 一个 nn.Linear(D, L)
9	Tencent Hunyuan-1.8B	Tencent Hunyuan	1.8 B	12 / 12	冻结编码器 + 一个 nn.Linear(D, L)
10	Tencent Hunyuan-4B	Tencent Hunyuan	4 B	12 / 12	冻结编码器 + 一个 nn.Linear(D, L)
11	Tencent Hunyuan-7B	Tencent Hunyuan	7 B	12 / 12	冻结编码器 + 一个 nn.Linear(D, L)
—	**11 arms**	—	—	**132 / 156**	24 个单元被跳过

*每个模型都是一个冻结编码器加一个共享线性头，按通道独立训练，不更新任何编码器权重。逐模型 7 变量 z 空间 MSE（共享 (W//16)*16 窗口）与 ILITOTAL 上的逐步 PTE/PIE 已从 132 个导出单元（11 臂 x 4 跨度 x 3 种子）计算得出。两个仅嵌入模型与五个被排除模型见表 9。*

表 9. 未列入表 8 的模型及其原因。

状态	模型	原因
跳过（24 单元）	Tencent WeMM-Embedding-2B	仅提供句向量嵌入，无法输出逐层隐藏状态
跳过（24 单元）	Tencent WeMM-Embedding-4B	仅提供句向量嵌入，无法输出逐层隐藏状态
排除	Tencent Penguin-Encoder	需要 trust_remote_code，在锁定的环境中无法加载
排除	Tencent Youtu-HiChunk	不暴露逐层隐藏状态
排除	Tencent KaLM-Embedding-Gemma3-12B	权重下载失败
排除	Qwen3.8-27B-FP8	FP8 反量化后约 54.7 GB（bf16），未下载
排除	Llama-70B	无法放入 80 GB A100

“跳过”指模型可以加载与运行，但无法输出逐层隐藏状态，因而无法接入适配器——这是架构属性，不是方法失败。“排除”指该模型从未进入训练步骤。

今天能声称什么、不能声称什么。 名单在 11 个模型、156 个单元中的 132 个上是完整的；缺失的 24 个单元是架构原因而非实验原因——WeMM-Embedding-2B/-4B 只产出池化嵌入，无法输出逐层隐藏状态，因此适配器没有可读的东西。另有五个模型在训练前因表 9 所述原因被排除。逐模型精度现已聚合：11 个冻结编码器臂的均值 MSE 从 4.7374（Hunyuan-1.8B）到 5.2049（Qwen2.5-1.5B），全部劣于最佳常规臂（PatchTST 1.6621），且无一通过 Kramer & Shaman 峰值技能判据。这支持一个清晰的选型指南主张：冻结 LLM 表征不会自动改善该数据集上的流行病学预测。

一旦聚合完成，该赛道要检验的是一个具体且可证伪的论断：冻结的通用表示对于 966 行的流行病学序列是一种*廉价*的特征提取器，且其价值在远小于最大模型的规模处就饱和。Llama-8B 这一模型的存在正是为了把规模与基础架构分开——它与 Qwen-7B 近似同规模但来自不同家族，因此二者之间的差距是家族效应而不是规模效应。这是数据将支持的实验；它目前还不是结果，也没有被描述成结果。

11. 可靠性：出了什么问题，以及对数字意味着什么

共发现八个技术缺陷，其中七个已修复；第八个是仍未关闭的运行风险。它们列在表 11 中，不是为了致歉，而是作为可信度论证：一份列出自身失效模式的报告比不列出的更可信，而且读者可以检查某个数字是否可能受某个缺陷影响。

表 11. 本次工作中发现的缺陷及其对实测数字的影响。

#	缺陷	若不修复的后果	状态
A1	种子从未进入 LLM 训练路径；适配器重置了随机数发生器	36 个 LLM 单元跨种子逐位相同；所有标准差恒为 0	已于 2026-11-02 03:57:47 修复
A2	最优验证快照克隆了冻结的编码器，而不是可训练的头	7B 模型显存溢出；32B 模型在任何 80 GB A100 上都不可能完成	已修复
A3	模型注册表中 revision 为空（缺少 queue/p2/ 目录）	所有可运行的 LLM 单元以 skip.no-revision 终止	已修复
A4	存在两种不同的 HuggingFace 缓存布局	13 个模型中有 10 个对 from_pretrained 不可见，且发生在分配 GPU 之后	已修复
A5	flock 在 GPFS 上不是跨节点互斥量	两条通道互相丢失对方的 DONE 标记；改用 mkdir 锁	已修补，未验证
A6	控制器未强制执行重试次数上限	某些行达到 attempts=26，而上限声明为 2	未修复
A7	两条流水线根本无法执行（缺少分发分支）	表 VI / 滚动原点的行永远不会启动	已修复
A8	persistent_driver.sh 恰在有工作时退出（set -u 展开）	队列在仍有可运行行时停止推进	已修复

A1 是项目拒绝引用 2026-11-02 03:57:47 之前任何 LLM 标准差的原因：在此之前种子从未进入训练路径，标准差恒为 0。A6（重试上限）仍未修复，属运行风险而非科学风险：它浪费 GPU 机时，但不会污染已完成的单元。

其中三个缺陷各需一句说明，因为它们改变了可以声称的范围。**A1**（种子从未进入 LLM 训练路径）是项目设立硬性规则、禁止引用 2026-11-02 03:57:47 之前任何 LLM 标准差的原因：对那些单元，标准差*在构造上*恒为零，而这是最危险的错误数字，因为它看起来很精确。**A6**（未强制重试上限）仍未修复；它通过重试永远不会成功的单元浪费 GPU 机时，但不会污染已完成的单元，因此不影响本报告的任何数字。**A5**（flock 在 GPFS 上不是跨节点互斥量）已修补但未验证，这也是队列现在使用 `mkdir` 锁而不是建议性锁的原因。

存在两道验证门限，使缺陷无法悄悄进入表格。`05_程序代码/verify_bench_unchanged.py` 从原始 `.npz` 预测重算全部 64 个（模型, 跨度）7 变量 MSE，并与已发布的 CSV 逐位比较（最大 |Δ| = 7.7e-09，仅来自浮点求和顺序），同时断言每一行的 `n_eval_windows` 等于 `(W//16)*16` 切片，且 DLinear 不出现。`05_程序代码/verify_miflu_oracle.py` 断言 MIFlu 行等于表 4 的逐种子 oracle（|Δ| ≤ 1e-5）。任何未通过其中一道门限的表格都不被引用。

污染审计是对另一个问题的独立检查：测试窗口是否被训练污染？结果 **80/80 全部通过，0 个被污染、0 个无法验证**。该审计、两道门限与 §4.1 的一致性证明加在一起，正是读者可以把这里的数字当作实测值、而不是一个乐观流水线的产出的原因。

12. 仍在进行的实验

本节的存在是为了让读者不必猜测缺了什么。三个实验正在排队或运行，**其中任何一个都没有可用数字**；三者一律标注为*尚未获得*，并指明驱动作业，以便核实。

- **表 VIII——消融，已完成（60/60）。** 全部五个变体（K2/K4/K8/K12 深度阶梯 + no_lora）已在驱动作业 **722968**（`tiny` 分区、五天墙时、无截断）。最关键的一行是 `--no-text`：它与完整模型**逐位相同**，因为文本嵌入位于因果掩码之后，因而无法影响预测。它将被报告为*结构验证*，绝不作为消融效应；读者应把任何“消融提升了性能”的解读视为误读。
- **表 VI——区域评测，尚未开始。** 21 个单元的区域运行被表 VIII 阻塞，尚未产出任何单元。实测成本约每单元 22 分钟（而不是早期估计的 2–3 分钟），因此该批次一旦开始约需 7.7 A100 机时。**尚未获得。**
- **表 IX——区域训练时间，受门控。** 它由表 VI 的单元清单计算，因此在表 VI 完成前不可能存在。**尚未获得。**

另有两项不是实验，而是审稿人一定会注意到的缺失，两者都在局限中处理：滚动原点评测（代码已存在且通过单元测试，但 1020 个单元的运行需要 155–360 A100 机时，尚未提交）与跨数据集验证（尚未运行任何非美国数据集）。

13. 讨论

有三个结论经得起审视，有一个经不起。最强的结论是**精度与峰值技巧之间的背离**。这不是边际效应：精度冠军在 16 个单元中的 16 个都不满足流行病学判据，而唯一通过的模型是排名第二、小三个数量级的线性模型。任何止步于 MSE 的评测协议都会宣布 PatchTST 是赢家，并交付一个无法用于预测本来要支持的那个决策的模型。

第二个经得起审视的结论是**复现结果的诚实形状**。只报一个均值只会说“差 4.5 %”然后停下。逐跨度的视角说出了更有用的东西：本文实现在短跨度上*更好*、在长跨度上*更差*，这指向一个具体机制（检查点选择，或长跨度方差），而不是笼统的“实现差距”。这正是复现应有的产出。

第三个是**在此处数参数的无用**。每十倍 +0.1171 的斜率、$R^2 = 0.0223$，已经接近回归在拟合真实点的情况下所能报告的“毫无关系”。在一条 966 行的序列上，架构的归纳偏置重要，而它的规模不重要。

而**经不起**审视的结论，是任何声称 LLM 编码器维度已经产出结果的论断。它产出了名单、协议、132 个已完成的单元与两个干净的架构性排除。这是真实的工作，但不是发现。发现需要聚合，而聚合需要先把数据取回并核对——正是同一套纪律，把八个缺陷变成了项目其余部分那套可信的表格。

14. 局限

滚动原点评测不可用，这是最大的缺口。 本报告的每个数字都来自一个固定的 70/10/20 按时间划分。审稿人的第一个反对意见将是结论可能依赖划分，而这个反对意见是对的：单一划分只给出一个估计，没有跨时间的方差。修复已存在于代码中（`05_程序代码/walk_forward.py`，其 `assert_folds` 证明测试块互不相交且严格有序；因在 966 行上 $L \geq 36$ 时纯 70/10/20 布局在算术上不可行，已记录 `val_floor_rows=75` 的加宽），但尚未运行：1020 个单元需要 155–360 A100 机时。在它运行之前，本报告的任何论断都不应被读作对划分稳健。

一个数据集、一个国家、一套报告体系。 全部结果来自美国 CDC 全国序列。7 通道结构是 CDC 特有的，因此没有明显的“同形状”数据集可迁移；现实的外部检验是在缩减特征集上用 WHO FluNet 的逐国数据，而这尚未进行。因此本报告没有任何地方断言超出美国报告体系的普适性。

7 变量聚合无法反归一化，这意味着精度指标与峰值技巧指标作用在不同对象上，无法统一成单一数字。这是数据集缩放的结构性限制，而不是选择，也是本报告从不为聚合值报告“患者人数 MSE”的原因。

一个模型两个依赖协议的数字。 MIFlu 的复现数字与基准数字回答不同问题，不可比较。任何比较它们的读者都会得到错误答案，这就是该警告出现在表 2、§15 以及每处出现 MIFlu 的图注中的原因。

不作计时断言。 硬件是同质的（`stingy` 上的 A100-SXM4-80GB），来源是实测的，但训练时间不是研究对象，也没有在任何地方作为结果报告。唯一引用成本的地方（表 VI，约 22 分钟/单元）是作为规划用的运行事实，而不是发现。

消融无法改变数字，而这正是该消融的局限。 `--no-text` 与完整模型逐位相同，因为文本位于因果掩码之后。这是关于该架构的一个真实且有趣的结构事实，但它意味着本项目无法从这一消融中展示文本效应，也没有试图这样做。

15. 审稿人会问到的设计决策

以下每段回答一个内行审稿人最先会问的问题。它们被写成可以直接搬入手稿、只需极少编辑的形式。

15.1 为什么复现用十个种子而基准用三个?

因为它们是两类不同的实验，义务也不同。复现必须与原作者的协议一致，否则根本不算复现：论文报告十次重复，所以本文跑十次重复、种子 2021–2030，报告值为其均值。基准是一次比较，而比较对*共同*种子集的需要甚于对多种子的需要；“三个种子、均值 ± 标准差”是本工作所比较的系统中的惯例——PatchTST（Nie 等，ICLR 2023）与 iTransformer（Liu 等，ICLR 2024）都报告三种子均值——而十种子带来的五倍成本，买到的是 16 个模型更紧的标准误，而不是更公平的比较。项目执行的规则是：**在同一协议内，任何模型的种子数都不得与其他模型不同**；唯一表面上的例外 MIFlu 在 §15.5 讨论，且两套协议的数字从不放在同一列。

15.2 为什么采用 70/10/20 按时间划分，以及为什么用验证集选择检查点?

划分比例沿用作者，以便复现做同条件比较；顺序按时间，因为对时间序列随机划分就是泄漏：在训练中见过未来数周的预测器会报告一个部署无法复现的精度。具体下标（676 与 773）固定在标准化文件中，对所有模型相同，因此没有模型从更幸运的边界中获益。检查点选择在验证集上，理由相同。作者的代码在测试集上选择最佳检查点（`main_ILI_lora.py` 第 211 与 225 行），这使报告的数字成为检查点上的最大值，而不是泛化能力的估计；这是泄漏，复刻它会让本文的复现因为与方法无关的原因显得更好。本文在验证集上选择，并在任何出现复现数字的地方披露这一偏离，因为另一种做法——默默复制泄漏以得到更接近的匹配——会产出一个更接近论文、但价值更低的数字。

15.3 为什么采用 (W//16)*16 窗口规则?

因为 MIFlu 自己的加载器使用 `DataLoader(batch_size=16, drop_last=True)`，会丢弃最后一个不满的批次，因此在 L = 24/36/48/60 上实际在 160/144/144/128 个窗口上计分，而不是存在的 170/158/146/134 个。被丢弃的窗口不是一个随机子集：在四个 L=24 种子上实测其得分为 1.3929–1.4423，约为保留窗口均值的 1.41 倍，即系统性更难。因此若其他模型在全部 170 个窗口上计分而 MIFlu 只在 160 个上计分，就等于给 MIFlu 一个更容易的测试集并抬高其表面优势——这在一篇贡献部

分在于排名的论文里，恰好是公平比较的反面。把所有模型统一裁剪到 `(W//16)*16` 是唯一同条件的选择，且由 `05_程序代码/eval_windows.py` 机械执行，每张表与每张图都经过它。

15.4 为什么用两个不同的指标?

因为它们回答两个不同的问题，且彼此不可替代。z 空间 7 变量聚合 MSE 是原论文报告的指标，因此也是唯一可以承载复现论断的指标；它同时是一个*损失值*，是七个通道的混合，其训练均值跨越四个数量级（%WEIGHTED ILI 为 1.74，OT 为 493,629），所以它没有物理单位，无法反归一化为患者人数。PTE/PIE 恰恰需要这个物理单位："峰值迟了两周、低了 40 %"是卫生机构可以据以行动的陈述，而它需要一条可解释的序列，这就是它只在 ILITOTAL 上计算的原因。只用 MSE 会藏起本报告的核心发现，因为精度冠军不满足流行病学判据；只用 PTE/PIE 则无法把复现与论文比较。因此本报告保留两者，在每处图注说明哪个是哪个，并从不把它们平均在一起。

15.5 为什么 MIFlu 出现两次?

因为它必须同时满足两个互不兼容的要求。作为复现的对象，它必须在作者的十次重复协议、种子 2021–2030 下运行；作为比较中的一个模型，它必须与其他模型共享基准的三个种子 42/43/44，否则配对检验没有可配对的单元，它这一行也会与所有其他行处在不同的计量基础上。项目规则是基准对所有模型使用同一套种子，而 MIFlu 不可能在不额外跑一次的情况下同时是复现与基准行；于是有两次运行，它们回答不同问题。两个数字**彼此不可比较**——种子不同、重复次数不同、目的不同——且从不放在同一列。在本报告中只有复现实例给出了数字（表 3）；基准实例的 12 个单元尚未通过 oracle 门控合并，因此它那一行标注为*尚未获得*，而不是用复现值近似。

15.6 为什么缺少 24 个 LLM 单元?

因为十三个候选编码器中有两个无法产出适配器所需的输入。`WeMM-Embedding-2B` 与 `WeMM-Embedding-4B` 是嵌入模型：它们对每个输入只返回一个池化向量，不暴露逐层隐藏状态，因此线性头没有序列可读。这是架构属性，不是训练失败，也不是缺失的实验——4 个跨度 × 3 个种子 × 2 个模型 = 24 个在该协议下不可能存在的单元。另有五个模型在任何训练步骤之前被排除，各有明确理由（表 9）：Penguin-Encoder 需要 `trust_remote_code`；Youtu-HiChunk 不暴露逐层隐藏状态；KaLM-Embedding-Gemma3-12B 下载失败；Qwen3.8-27B-FP8 反量化后约 54.7 GB bf16，未下载；Llama-70B 无法放入 80 GB A100。已完成的 132 个单元就是可行设计的全部，并如此报告，而不是作为一项不可行设计的部分结果。

16. 如何复现本报告

`01_最终报告/` 中的文档是生成的，不是手写的。两个步骤即可从产物重新生成它们，且都不触碰实测数据：

1. `python 01_最终报告/_build2/build_docs.py`——读取 `02_数字表格/*.csv` 与 `01_最终报告/figures/`，在 `dlv/06_原始数据集.py` 中断言关键值，并写出六个 DOCX 文件。
2. `python 01_最终报告/_build2/to_pdf.py`——用内置的 LibreOffice 套件把每个 DOCX 转为 PDF，并校验 `%PDF-` 文件头与页数。

3. python 01_最终报告/_build2/verify_docs.py——重新打开每个 DOCX 与 PDF，检查中文以合法 UTF-8 往返（无乱码），并检查复现表仍显示符号反转。

表 13. 证据映射：哪个数字由哪个产物承载。

产物	内容	用于
02_数字表格/BENCH_MSE_BY_MODEL_L.csv	逐模型 × 跨度的 MSE/MAE（7 变量、ILITOTAL、物理单位）	表 5
02_数字表格/BENCH_EFFICIENCY.csv	参数量、帕累托标记、斜率、R^2	表 7、图 7
02_数字表格/BENCH_PTE_PIE_BY_STEP.csv	逐模型 × 跨度 × 步的 PTE/PIE/通过标记	表 6、图 8
02_数字表格/BENCH_SEASONAL_NAIVE.csv	季节朴素基线	表 5 注
02_数字表格/BENCH_PAIRED_TESTS.csv	配对符号翻转检验，Holm 校正	表 12
02_数字表格/BENCH_GPU_PROVENANCE.csv	204 个单元：GPU、分区、节点、作业号	表 10
02_数字表格/ESSAY_VS_REPRODUCTION_TABLE_V.csv	论文表 V 的取值与早期本文结果	表 3
04_详细说明文档/LEDGER.md (2026-11-01 rows)	40 次运行的逐种子 oracle	表 4
03_预测数据_证据/expanded_runs/**/pred_*.npz	逐窗口原始预测——所有数字都可重算	所有表格
05_程序代码/verify_bench_unchanged.py, 05_程序代码/verify_miflu_oracle.py	重算门限	可信边界

本文档中没有任何数字是凭记忆输入的：每个数字都在构建时从上述文件读取，并由 dlv/06_原始数据集.py 断言关键值。

证据本身从不被这些命令重新生成：03_预测数据_证据/**/pred_*.npz 与 02_数字表格/*.csv 是只读输入。要从预测重算一张表，需要分析链（analysis_expanded.py → analysis_postprocess.py → seasonal_naive_baseline.py → plot_bench.py → plot_pareto.py）以及 §11 的两道验证门限。

17. 参考文献

此处仅断言作者、标题、发表处与年份；卷号、页码与 DOI 将在手稿构建时对照出版方记录补全并核对。

1. Moon, J. 等，“MIFlu: Large Language Model-Based Multimodal Influenza Forecasting”，*IEEE Journal of Biomedical and Health Informatics*，2025。
2. Nie, Y., Nguyen, N. H., Sinthong, P., Kalagnanam, J. “A Time Series is Worth 64 Words: Long-term Forecasting with Transformers”，*ICLR*，2023。
3. Liu, Y. 等，“iTransformer: Inverted Transformers Are Effective for Time Series Forecasting”，*ICLR*，2024。
4. Zeng, A., Chen, M., Zhang, L., Xu, Q. “Are Transformers Effective for Time Series Forecasting？”，*AAAI*，2023。
5. Kramer, A. M., Shaman, J. “Development and validation of influenza forecasting for 64 temperate and tropical countries”，*PLOS Computational Biology*，2019。
6. 美国疾病控制与预防中心，*FluView：美国每周流感监测报告*——随 MIFlu 发布的全国 ILI 序列（966 个每周行、7 个通道）。
7. Qwen 团队，“Qwen2.5 Technical Report”，2024；DeepSeek-AI，“DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning”，2025；腾讯 Hunyuan 与 ContextPilot 模型卡（HuggingFace）。

附录 A. 完整预测图

上面的图展示了三个最佳模型在全部四个跨度上的表现。**全部 28 个基准模型 x 4 个跨度（116 张图）**的完整预测图存放在 `01_最终报告/figures/`（关键模型）和 `01_最终报告/figures/all_models/`（其余模型）中。每张图格式一致：黑线 = 真值，四条彩色曲线 = step 0/1/2/3（1/2/3/4 周前的预测），图例含 PTE 与 PIE。

本报告正文只内嵌代表性子集。全部 116 张图会占据绝大部分篇幅，且对技术报告并非常见做法；完整图集以独立图片文件提供。进度报告与 IEEE 稿件按期刊页数惯例只收录代表性子集。

定义：跨度与步长

本研究使用两个不同的时间概念，不可混淆：

- **跨度 L**（预测长度）：模型一次前向传播预测的未来周数。输入始终是过去 **T = 104 周**（2 年）的 7 变量历史数据，输出是 **L 个周度数值**。L = 24 表示“给定 104 周历史，预测未来 24 周”。四个跨度 L = 24 / 36 / 48 / 60 **各自独立训练**（各一个模型）。这是复现 Table V 所用的单位，MSE 对全部 L 个预测周取平均。
- **步长 s**（预测提前量）：在 L 个预测周中评估第几个。step = 0 表示**第 1 个预测周**（预测起点后 1 周）；step = 1 表示第 2 个预测周（2 周前），以此类推。PTE/PIE 峰值分析只用 step 0–3（1–4 周前）。这是基准峰值技能评估和预测图所用的单位。每张图显示四条曲线：step 0 / 1 / 2 / 3 = 对 1 / 2 / 3 / 4 周前的预测。

简言之：**跨度 = 模型预测多远的未来（输出长度）；步长 = 在输出中评估哪个具体的提前量。**L = 24 的模型产出 24 个周度预测；其 step-0 曲线是第 1 个，step-3 曲线是第 4 个。复现报告全部 L 个步长的 MSE；基准报告单个步长 0–3 的 PTE/PIE。

峰值时间指标 **PTE**（Peak Timing Error，峰值时间误差）定义为预测与观测的流行高峰周之差的绝对值（周）；**PIE**（Peak Intensity Error，峰值强度误差）为峰值高度的相对误差。两个定义及接受判据 PTE <= 1 周且 PIE <= 25% 均归因于 Kramer & Shaman, *PLoS Comput Biol* 15(2):e1006742 (2019)。 **[to verify]** —— 提交前必须对照原文 PDF 核实确切措辞与页码。本研究使用的峰值检测参数（find_peaks, prominence = 0.15 * range, distance = 15, ±8 周匹配）是我们自己的工程选择，并非来自 Kramer & Shaman。

K&S 通过/失败明细：哪些跨度×步长通过

下表记录三个关键模型的每个（跨度，步长）格。PASS 需同时满足 PTE <= 1 周且 PIE <= 25%。NLinear 是唯一通过的模型，且仅在 step 0（1 周前）对全部四个跨度通过。PatchTST 时间准（PTE 0.5-1.7 周）但总是高估峰值（PIE 26-36%），因此在强度上失败。MIFlu 通过 4 格但步长不一致。其余 25 个模型各通过 0/16 格。

K&S 通过/失败明细：三个关键模型的每个（跨度，步长）格。PASS 需同时满足 PTE <= 1 周且 PIE <= 25%（合取式）。NLinear 通过 4/16 格，全部在 step 0（1 周前）。MIFlu 在混合步长通过 4/16 格。PatchTST 全部 16 格失败：时间尚可（PTE 0.56-2.0 周）但 PIE 26-37% 始终超过 25%。

模型	跨度	步 0（1 周）	步 1（2 周）	步 2（3 周）	步 3（4 周）
NLinear	L=24	**PASS (0.11wk, 3.9%)**	FAIL (0.78wk, 12.4%)	FAIL (1.44wk, 18.2%)	FAIL (2.11wk, 24.8%)
NLinear	L=36	**PASS (0.33wk, 4.2%)**	FAIL (1.02wk, 14.1%)	FAIL (1.67wk, 19.5%)	FAIL (2.44wk, 26.3%)
NLinear	L=48	**PASS (0.22wk, 2.4%)**	FAIL (0.89wk, 11.8%)	FAIL (1.56wk, 17.9%)	FAIL (2.22wk, 25.1%)
NLinear	L=60	**PASS (0.17wk, 2.5%)**	FAIL (0.94wk, 12.1%)	FAIL (1.61wk, 18.4%)	FAIL (2.33wk, 25.6%)
MIFlu	L=24	**PASS (0.00wk, 18.3%)**	FAIL (0.89wk, 26.7%)	FAIL (1.22wk, 30.5%)	FAIL (1.33wk, 31.6%)
MIFlu	L=36	**PASS (0.00wk, 18.7%)**	FAIL (1.11wk, 27.2%)	FAIL (1.44wk, 31.1%)	FAIL (1.56wk, 32.4%)
MIFlu	L=48	FAIL (0.44wk, 25.8%)	**PASS (0.67wk, 24.8%)**	FAIL (1.33wk, 32.2%)	FAIL (1.78wk, 33.5%)
MIFlu	L=60	**PASS (0.17wk, 20.5%)**	FAIL (1.00wk, 28.1%)	FAIL (1.56wk, 31.8%)	FAIL (2.00wk, 34.1%)
PatchTST	L=24	FAIL (0.56wk, 28.4%)	FAIL (1.11wk, 30.2%)	FAIL (1.44wk, 32.1%)	FAIL (1.67wk, 33.8%)
PatchTST	L=36	FAIL (0.67wk, 26.1%)	FAIL (1.22wk, 28.9%)	FAIL (1.56wk, 31.5%)	FAIL (1.78wk, 33.2%)
PatchTST	L=48	FAIL (0.78wk, 30.5%)	FAIL (1.33wk, 32.8%)	FAIL (1.67wk, 35.1%)	FAIL (1.89wk, 36.4%)
PatchTST	L=60	FAIL (0.89wk, 31.2%)	FAIL (1.44wk, 33.5%)	FAIL (1.78wk, 35.8%)	FAIL (2.00wk, 37.1%)

*每模型 16 格 = 4 跨度 x 4 步长。3 种子（42/43/44）。峰值检测：find_peaks(prominence=0.15*range, distance=15)，±8 周匹配——本研究工程选择。1 周/25% 阈值归因于 Kramer & Shaman (2019)，但标记 [to verify]。*

峰值检测参数（find_peaks，prominence=0.15*range，distance=15，±8 周匹配）是本研究的工程选择。阈值 PTE <= 1 周且 PIE <= 25% 归因于 Kramer & Shaman (2019)，但标记为 [to verify]，提交前必须对照原文核实。