MIFlu 复现与流感预测审计

含解释性问答的内部技术报告

作者	CHAN Sing Yeung
快照	3 November 2026
阅读说明	四个评价维度，附 Q01–Q25 导师交流问答

目录

1 数据与来源

2 方法与文献

3 MIFlu 复现

4 基准精度

5 峰值时间与幅度

6 精度与参数量

7 统计审计

8 冻结语言编码器

9 消融设计与状态

10 解释与发表计划

11 可复现性与待核实项

12 参考文献

阅读目的。 本内部报告用于导师交流及理解过程。Q01–Q25 放在相关证据旁：每题连接具名论文、阅读位置与本地证据，解释选择理由，并给出导师简答。精度与峰值覆盖 28 个模型，参数导出覆盖 11 个，配对检验覆盖 17 个。

1 数据与来源

在仓库根目录运行 python scripts/verify_snapshot.py --raw-smoke 及 python -m pytest tests/test_snapshot_audit.py -q。审计重算主要聚合值、峰值标记、相关系数、回归、Holm 校正和一个原始预测 MSE。七个新增 CPU 审计测试已通过，它们与归档模型测试分开。修正 ZIP 已提供 tests_archive/，但历史目录布局及模型依赖缺失导致收集失败。本次不主张归档测试通过数或可靠总数。本次未重跑训练、未查询实时 HPC，亦未运行上游代码。原 CSV 保持不变，Holm 修正另行导出。

表 1. 数据与评测约定

项目	数值
行数与通道	966 × 7
时序划分	676 / 97 / 193
训练 / 验证 / 测试下标	0–675 / 676–772 / 773–965
历史与跨度	T=104; L=24/36/48/60
可用 / 计分窗口	170/160; 158/144; 146/144; 134/128
ILITOTAL 训练均值 / 标准差	9,439.84 / 9,003.15
本地数值一致性	最大绝对差 = 0

一致性是选择本包两个 966 行文件中相应七列后比较，不能重新证明与独立下载的作者文件逐字节相同。作者格式文件的日期为合成标签。

Q01 为什么采用 676 行训练、97 行验证、193 行测试?

直接回答与本地证据。 所附 966 行协议把 floor(966 × 0.7) = 676 行分给训练，floor(966 × 0.2) = 193 行分给测试，其余 97 行用于验证。训练段拟合权重和标准化参数，验证段选择检查点，最终测试段评价选择后的表现。按时间先后划分，可以避免用后来的观测训练较早的预测。这是本项目采用的协议，并非所有期刊统一要求；固定版本上游协议仍待独立核实。

文献依据与选择理由。 Tan 等明确对 Illness 使用 70/10/20 [13，第 3.3 节]，iTransformer 则保持按时间分离 [5，附录 A.1]。这是具体的预测研究先例：保留较多训练数据，以验证集选模，再用较晚观测做最终测试。676/97/193 的精确整数来自本项目 966 行及取整规则。文献支持设计理由，但不证明该比例对所有流感季最优，也不能证明本地文件与上游身份一致。

向导师简答。 这个划分有 Tan 等 Illness 实验的先例，时间分离用于保护最终评价 [13, 5]。

论文位置。 Tan et al. [13], §3.3 Datasets and Evaluation Metrics; iTransformer [5], Appendix A.1.

证据。 configs.py DATA_PROFILES[author_repo_966]; BENCH_MSE_BY_MODEL_L.csv; eval_windows.py

Q02 L24 明明有 170 个窗口，为什么只评 160 个?

直接回答与本地证据。 本地评测约定只保留完整的 16 个窗口一批，即 (W//16)×16。因此 L24/36/48/60 的 170/158/146/134 个可用窗口变成 160/144/144/128 个计分窗口。所有模型使用相同窗口，可避免拿不同测试样本比较。但裁剪会删去某一段时间尾部，仍可能改变分数。这是本快照为保持可比性采用的选择，不证明裁剪在科学上最优；仍需完整窗口敏感性分析。本次没有独立复核某个被删尾部的具体难度倍数。

文献依据与选择理由。 Tan 等复核时保留原数据加载器与训练条件 [13，第 3.1 节]，说明必须交代哪些样本进入计分，却不表示论文要求裁剪。本地完整批量规则改变了计分样本。各模型采用相同保留窗口，可消除比较不公平，但删去尾部仍可能改变结果。必要的敏感性分析是让所有模型在完整窗口重评分，再比较排名。文献不能代替被删尾部难度的原始计算。

向导师简答。 裁剪用于统一计分样本，完整窗口重评分用于检验裁剪影响 [13]。

论文位置。 Tan et al. [13], §3.1 Reproducibility Note; local eval_windows.py.

证据。 BENCH_MSE_BY_MODEL_L.csv; eval_windows.py; scripts/verify_snapshot.py --raw-smoke

Q03 为什么标准化参数只能从训练段计算?

直接回答与本地证据。 如果用完整序列计算均值或标准差，就会把未来测试段的信息带入模型准备过程。只在训练段拟合，可避免这类信息泄漏。七个通道分别标准化。本次一致性检查比较所附两个文件的七个对应数值列，最大绝对差为零。这只能核实本地副本数值一致，不能代替重新下载作者文件后核实字节一致。

文献依据与选择理由。 Kapoor 与 Narayanan 把跨越训练/测试边界的预处理列为泄漏路径 [22，L1.2]。用于这里，就是只在训练段拟合各通道均值和标准差，再原样复用。如果未来观测决定这些常数，预处理已适应留出分布，即使梯度更新没有使用测试标签。因此训练段标准化属于实验设计。本地文件相等检查则只证明输入一致，不能证明所有泄漏路径均不存在。

向导师简答。 依照 Kapoor 与 Narayanan 对泄漏的区分，预处理只在训练段拟合 [22]。

论文位置。 Kapoor and Narayanan [22], Results, leakage taxonomy L1 and L1.2.

证据。 06_原始数据集/scaler_miflu_author966.json; scripts/verify_snapshot.py

2 方法与文献

分块与线性基线已有研究 [3–5]。Time-LLM、CALF 与 TimeCMA 的对齐及适配设计不同 [6–8]。Chronos、TimesFM、Moirai、Lag-Llama 在数值序列上预训练，本次未评测 [9–12]。较早的 LLM 移除研究已质疑语言预训练收益 [13]，而 2026 年预印本报告跨数据集偏移下的条件性收益 [14]。本项目贡献在于特定流感任务的协议审计与多指标比较。

表 2. 分开的复现与基准协议

项目	复现	基准
种子	2021–2030 (10)	42/43/44 (3)
模型	MIFlu	13 传统 + 4 基于 LLM + 11 冻结编码器
选择	验证集检查点	验证集检查点
指标	7-variable z-space MSE / MAE	7-variable MSE / MAE; ILITOTAL PTE / PIE
窗口	160 / 144 / 144 / 128	160 / 144 / 144 / 128

三个种子是算力预算选择，不是统一的会议规则。复现与基准采用不同种子集合，不能相互替换。作者上游具体协议缺陷仍须对照固定版本核实。

Q04 为什么复现用十个种子，基准却用三个种子?

直接回答与本地证据。 两者回答不同问题。所附复现以 2021–2030 十个种子对照转录的原文表格；更广的基准以 42/43/44 三个种子在统一协议下比较各实现。正式矩阵为 28 模型 × 4 跨度 × 3 种子 = 336 单

元；十个种子则需要 1,120 单元。采用三个种子反映项目算力预算，不证明检验功效已经足够，更多种子也可能改善不确定性估计。本次没有证据支持所有场合均要求三个种子，或增加种子毫无收益。

文献依据与选择理由。 原来的三种子引用不正确。PatchTST 的主结果采用固定种子，另做五种子监督稳健性检查 [3，附录 A.6.1]；iTransformer 报告五次运行的标准差 [5，附录 A.2 表 5]。这些段落不能证明三种子是两文共同惯例。我们的选择属于算力折衷。Bouthillier 等区分重复运行精度和更广的基准变异 [19]：增加种子可改善前者，增加季节/原点处理另一类不确定性。十次复现不会让独立的三种子基准同样精确。

向导师简答。 三种子是算力折衷；两篇所引论文实际提供五种子稳健性证据，提示仍需加强检查 [3, 5]。

论文位置。 PatchTST [3], Appendix A.6.1; iTransformer [5], Appendix A.2 and Table 5; Bouthillier et al. [19], Appendix C.3.

证据。 ESSAY_VS_REPRODUCTION_TABLE_V.csv; BENCH_MSE_BY_MODEL_L.csv; dlv/data.py ORACLE

Q05 哪些实现差异已经核实，哪些仍只是待核实的说法?

直接回答与本地证据。 已检查的本地代码在验证段选择检查点，并对七个标准化通道计分。交接笔记把测试集选检查点和单通道加载问题归于上游代码，但本次没有独立检查到固定版本作者仓库来支持该归因。笔记还提到学习率和训练轮数设置差异。因此应披露本地流程与未核实的参考设置，不能声称只有两处修复就解释全部分数差异。若要确认因果，应固定数据、种子及其他设置，每次只改变一个因素。

文献依据与选择理由。 检查点属于选模选择；按测试误差挑选，就是用最终评价拟合该选择，不符合干净分离 [22，L1]。不论上游缺陷是否能证实，这个原则都支持本地验证集选检查点。按声明的七通道计分则是另一项指标一致性问题。这些原则不能证明 Moon 等犯了所指缺陷，也不能证明差距仅由两项改变造成。因果归因需要配对运行，每次只改变检查点、加载器或另一项因素。

向导师简答。 验证集选模保护留出测试；上游是否有缺陷，须另有证据 [22]。

论文位置。 Kapoor and Narayanan [22], taxonomy L1, clean separation through modelling and evaluation.

证据。 train_miflu.py; audit/REPO_AUDIT.md; audit/UNVERIFIED_ITEMS.md

本项目采用时序划分、仅训练段拟合标准化，并用验证集选择检查点。交接资料将测试集选检查点及单变量加载问题归于上游代码，但未提供固定版本作者仓库，公开端点也未能打开，因此上游指控仍未核实。笔记还列出代码默认学习率与原文设置的差异，不能称为仅有两处偏离。

峰值时间误差 PTE 是预测与观测峰值周的绝对差。峰值强度误差 PIE 为峰高绝对差除以观测峰高后乘百分比。Kramer–Shaman [2] 可核实分别为一周与 25% 的容差。项目把两者联合应用于（模型、L、step）单元的平均误差；该联合筛选及峰检测属于项目选择，不是临床接受标准。平均误差达标不等于逐季成功概率。

Q06 为什么 MSE 用七变量，而峰值误差只用 ILITOTAL?

直接回答与本地证据。 七变量 MSE 先逐通道标准化，再平均平方误差，衡量整体无量纲预测误差。这个平均损失不是患者人数时间序列，也没有一个统一的反标准化器。峰值时间与高度则必须针对一条真实序列。因此本项目对 ILITOTAL 使用其训练段标准化参数反变换，均值为 9,439.84、标准差为 9,003.15 人。一个模型可以在七通道总体误差上较好，但在 ILITOTAL 峰值上较差。评价对象与损失函数不同，是排名变化的一个解释。

文献依据与选择理由。 Hyndman 与 Koehler 解释尺度为何重要 [21，第 2.1 节]；Kramer 与 Shaman 在观测疾病序列上定义峰值 [2]。本项目标准化总体损失将各通道原单位平方误差除以训练方差，所得是无量纲损失，而非可用一组参数反变换的患者人数曲线。峰值评测应先反变换 ILITOTAL 预测和观测，再找峰；对七通道损失找峰会回答另一个问题。文献支持可解释端点，ILITOTAL 是明确的项目选择。

向导师简答。 标准化整体误差与可解释疾病峰值，是不同端点 [21, 2]。

论文位置。 Hyndman and Koehler [21], §2.1; Kramer and Shaman [2], Forecast accuracy and comparison.

证据。 BENCH_MSE_BY_MODEL_L.csv; BENCH_PTE_PIE_BY_STEP.csv; scaler_miflu_author966.json

3 MIFlu 复现

复现 CSV 的平均 MSE 为 1.4995，对照 1.4355，增加 4.5%。L24、L36 更低，L48、L60 更高。平均 MAE 为 0.8043，对照 0.7452（+7.9%），但逐跨度为一低三高；MAE 没有 MSE 的二比二符号交叉。协议差异与上游来源缺失限制了精确复现的主张。

表 3. MIFlu 复现与原文对照

跨度	本文 MSE ± 标准差	原文 MSE	Δ MSE	本文 MAE	原文 MAE	Δ MAE
L=24	1.3045 ± 0.0883	1.5420	-15.4%	0.7482	0.7260	+3.1%
L=36	1.3561 ± 0.1603	1.4220	-4.6%	0.7712	0.7790	-1.0%
L=48	1.6543 ± 0.1064	1.4140	+17.0%	0.8381	0.7570	+10.7%
L=60	1.6829 ± 0.2109	1.3640	+23.4%	0.8596	0.7190	+19.6%
四跨度均值	1.4995	1.4355	+4.5%	0.8043	0.7452	+7.9%

来源：ESSAY_VS_REPRODUCTION_TABLE_V.csv 第 2–6 行。标准差由代码中转录的十种子 oracle 重算；原始运行日志未随包提供。正差表示误差更高。

复现结论。 在已披露实现差异下，观测 MSE 差为 +4.5%，不能据此主张优于原文。

Q07 为什么这里的 MIFlu 是 1.4995，基准表却是 1.5574?

直接回答与本地证据。 前者来自十种子复现表的四跨度均值，后者来自三个基准种子的四跨度均值，它们汇总的是不同运行集合。讨论复现时，应把 1.4995 与原文转录均值 1.4355 比较；讨论选模时，应把 1.5574 与同一基准中的其他模型比较。两数之差并不能证明在其他条件完全一致时模型进步、退步或抄错；归因还需要完整运行配置与原始来源。

文献依据与选择理由。 Bouthillier 等说明基准估计取决于被抽样的学习流程 [19]。均值是指定运行集合的估计，不是模型名称自带的不变属性。两项 MIFlu 估计汇总不同种子集合，服务不同对照。差值可能同时包含种子波动与配置差异，不能分离某一原因。应先解释两表运行定义；若关心成因，再取回匹配的逐运行配置。

向导师简答。 两数估计不同运行集合，不能把差值视为一项改变的受控效果 [19]。

论文位置。 Bouthillier et al. [19], §§2–3, benchmark estimators and sources of variation.

证据。 ESSAY_VS_REPRODUCTION_TABLE_V.csv lines 2–6; BENCH_MSE_BY_MODEL_L.csv model=miflu

Q08 为什么 MSE 与 MAE 的逐跨度方向不完全一致?

直接回答与本地证据。 MSE 对误差平方，因此更重视大误差；MAE 平均绝对误差。因此，少数大误差的变化可能对两者产生不同影响。相对原文转录值，MSE 在 L24/L36 较低、L48/L60 较高；MAE 只有 L36 较低，其他三个跨度较高。平均差为 MSE +4.5%、MAE +7.9%。不能把两者都说成两低两高。

文献依据与选择理由。 该文区分平方与绝对误差，以及两者对大残差的敏感性 [21]。作代数示例而非实测：残差翻倍，绝对贡献变两倍，平方贡献变四倍。因此残差分布改变时， MSE 与 MAE 可以不同向。CSV 确定实际逐跨度符号，文献解释为何可能不同。若要确定哪些误差造成差距，仍需逐通道、逐窗口残差，不能只靠一般原理。

向导师简答。 MSE 更重视大残差，逐跨度方向必须与 MAE 分开读取 [21]。

论文位置。 Hyndman and Koehler [21], §2.1, MSE/MAE and sensitivity to large residuals.

证据。 ESSAY_VS_REPRODUCTION_TABLE_V.csv lines 2–6

表 4. 代码中转录的复现 oracle

Seed	L24	L36	L48	L60
2021	1.240157	1.314358	1.482299	1.599641
2022	1.201078	1.306645	1.711215	1.664878
2023	1.284212	1.269466	1.663857	1.821282
2024	1.259462	1.154099	1.879495	1.915250
2025	1.464643	1.767328	1.723161	1.410785
2026	1.368497	1.312511	1.620327	1.984315
2027	1.392309	1.400796	1.628296	1.614602
2028	1.230425	1.302717	1.588157	1.401814
2029	1.231536	1.404061	1.570881	1.520661
2030	1.373057	1.328807	1.675020	1.895393

已核算其均值并与复现 CSV 对照。来源为 dlv/data.py 与 verify_miflu_oracle.py 的 ORACLE 常量。十种子原始运行日志未提供，因此不能称为独立原始预测验证。

Q09 种子 oracle 和预测曲线能证明已完整复现吗?

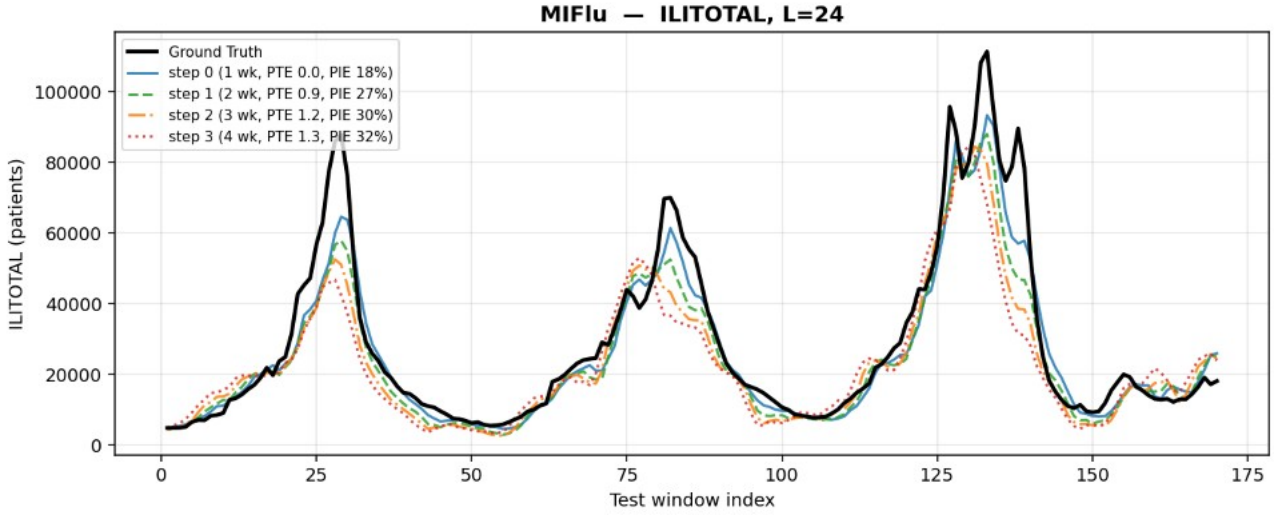
直接回答与本地证据。 oracle 是代码中转录的十种子分数记录，可以核算均值和标准差，但没有提供对应十种子的原始日志与预测供独立重评分。沿用曲线展示基准序列，不是这些十种子复现运行的独立轨迹。检查点选择、种子波动和配置差异都可能解释逐跨度表现，但尚未分离其因果作用。可辩护的结果是在明确限制下，平均 MSE 差为 +4.5%。

文献依据与选择理由。 重复运行估计与可追溯评测处理不同缺口 [19, 22]。oracle 核对转录记录的算术，保存预测才可核对流程是否产生该记录。实际链条是运行配置 → 预测 → 计分代码 → 单元 → 聚合。基准图是另一种摘要，不能建立十种子复现轨迹。即使均值接近，链条缺项仍限制主张；只要说明真实来源，沿用曲线仍可作示例。

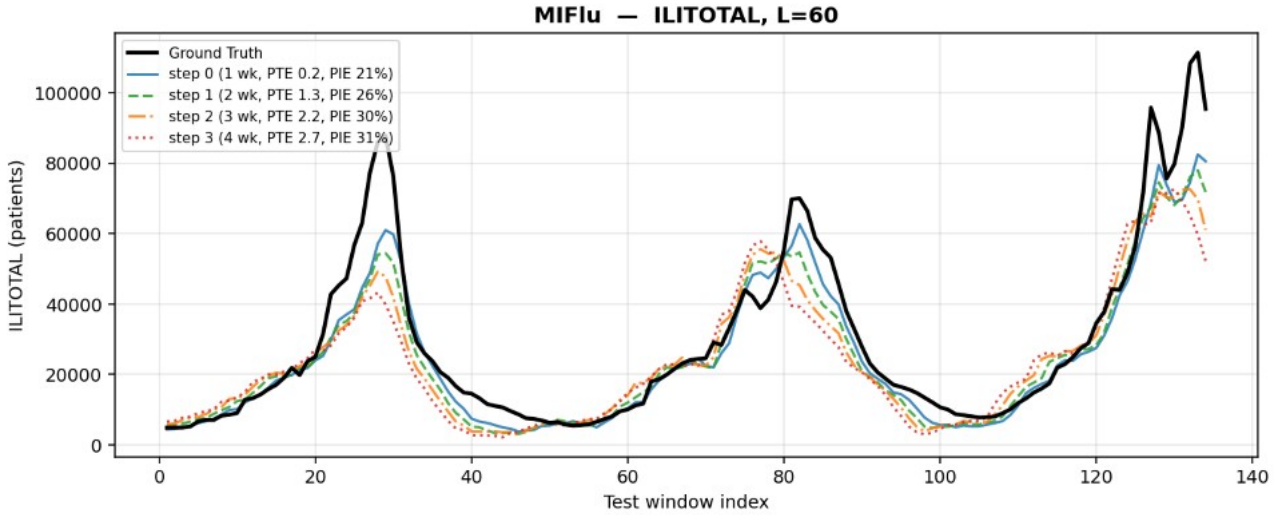
向导师简答。 oracle 建立算术证据，原始输出建立来源证据，两者都重要 [19, 22]。

论文位置。 Bouthillier et al. [19], variance analysis; Kapoor and Narayanan [22], model info sheets.

证据。 dlv/data.py ORACLE; ESSAY_VS_REPRODUCTION_TABLE_V.csv; figure_captions.json



miflu，L=24。纵轴为 ILITOTAL 患者人数，横轴为文件测试周下标。黑线为观测，其余为固定预测步 s0–s3。计分窗口 160。此图沿用所附示例，本次未独立重建绘图原始输入。



miflu，L=60。纵轴为 ILITOTAL 患者人数，横轴为文件测试周下标。黑线为观测，其余为固定预测步 s0–s3。计分窗口 128。此图沿用所附示例，本次未独立重建绘图原始输入。

4 基准精度

表 5. 全部保留模型的精度

#	模型	L24	L36	L48	L60	平均 MSE	平均 MAE
1	MIFlu	1.3323	1.2632	1.7774	1.8567	1.5574	0.8199
2	PatchTST	1.4402	1.6154	1.9288	1.6640	1.6621	0.8786
3	NLinear	1.7971	1.7950	1.9574	1.9368	1.8716	0.9183
4	DNN	1.8920	1.7684	2.2603	2.6451	2.1415	1.0057
5	TimeCMA	2.3281	2.5794	2.7104	2.8146	2.6081	1.0676
6	Gradient Boosting	3.5658	3.6867	3.6533	3.7521	3.6645	1.2521
7	KNN	3.7231	3.7623	3.7740	3.8820	3.7854	1.3293
8	Random Forest	3.5486	3.8251	4.0159	4.1710	3.8901	1.2779
9	iTransformer	3.7656	4.0596	4.0438	4.1088	3.9945	1.3476
10	Decision Tree	4.5340	4.1380	4.2186	4.3884	4.3198	1.3798
11	Hunyuan-1.8B	4.5629	4.5877	4.7111	5.0879	4.7374	1.4755
12	Hunyuan-7B	4.3438	4.6624	4.9201	5.1120	4.7596	1.4685
13	DeepSeek-R1-Qwen-1.5B	4.6012	4.6242	4.9245	4.9963	4.7866	1.5002
14	DeepSeek-R1-Llama-8B	4.4337	4.7715	4.8929	5.2019	4.8250	1.4786
15	GRU	4.2895	5.3099	5.1751	4.7736	4.8870	1.5174
16	DeepSeek-R1-32B	4.4401	4.8565	5.0136	5.4386	4.9372	1.4935
17	LSTM	4.4965	5.1359	5.2088	5.1939	5.0088	1.5303
18	DeepSeek-R1-Qwen-14B	4.4976	4.9164	5.1687	5.4838	5.0166	1.5019
19	DeepSeek-R1-Qwen-7B	4.5551	4.9991	5.2417	5.3272	5.0308	1.5133
20	RNN	4.4222	5.2893	5.3424	5.2157	5.0674	1.5634
21	ContextPilot-8B	4.6094	5.1318	5.2895	5.3065	5.0843	1.5255
22	Hunyuan-4B	4.7383	5.0535	5.2876	5.4474	5.1317	1.5450
23	ContextPilot-14B	4.7674	5.1566	5.2168	5.6388	5.1949	1.5407
24	Qwen2.5-1.5B	4.7840	5.0587	5.4546	5.5224	5.2049	1.5725
25	Qwen-Time	4.7190	5.1325	5.6894	5.4818	5.2557	1.5794
26	SVR	5.2248	5.3581	5.3781	5.3940	5.3388	1.4986
27	CALF	5.3624	5.5113	5.6442	5.7962	5.5785	1.6190
28	CNN	5.5021	5.3098	5.2801	6.3698	5.6155	1.6720

来源：BENCH_MSE_BY_MODEL_L.csv，按 model 和 L 定位。各行由三个种子在 160/144/144/128 个窗口上聚合。项目主动排除了 DLinear，发表前需补充理由与敏感性分析。名称指本项目实现，排名本身不能证明与原论文方法完全等价。

Q10 28 个模型与不同分析子集各指什么？

直接回答与本地证据。 正式名单为 13 个传统模型 + 4 个基于 LLM 的模型 + 11 个冻结编码器。精度和峰值分析覆盖全部 28 个；参数导出支持其中 11 个；配对检验覆盖包括 MIFlu 的 17 个非编码器模型。项目主动把 DLinear 排除于正式名单及配对表。它在历史硬件来源表中出现，不代表属于正式保留模型。补充含 DLinear 的敏感性分析可加强基线覆盖；它曾出现在原文，本身不足以构成科学排除理由。

文献依据与选择理由。 各家族检验不同解释：简单时间映射 [4]、patch 与反转变量词元 [3, 5]，以及明确的跨模态对齐 [7, 8]。这支持采用多样对照，不证明 28 是最优数量，也使实现忠实度很重要：同名适配可能省略原文关键对齐或训练组件。DLinear 是这条文献中的相关简单对照；它曾出现在原论文，本身不是在敏感性分析中省略它的科学理由。

向导师简答。 论文支持选择不同对照；导出文件决定每项分析实际覆盖哪些模型 [3–5, 7, 8]。

论文位置。 Zeng et al. [4], §4; PatchTST [3], §3.1; iTransformer [5], §3; CALF [7] and TimeCMA [8], author abstracts.

证据。 BENCH_MSE_BY_MODEL_L.csv; BENCH_EFFICIENCY.csv; BENCH_PAIRED_TESTS.csv; BENCH_GPU_PROVENANCE.csv

Q11 MIFlu 的 MSE 最低，是否就应直接选它部署?

直接回答与本地证据。 MIFlu 的观测基准 MSE 最低，为 1.5574。这是在单一全国划分下的描述性精度结果，没有直接测量漏峰、误报、运行时间、区域稳健性或前瞻效益。MSE 差距较大，也不能证明调参不重要，因为本实验没有把调参作为另一因素进行对照。后面的评价维度回答精度表单独无法回答的问题。

文献依据与选择理由。 峰值时间/强度是疾病领域端点 [2]，区间评分考查预测不确定性 [18]；七通道点误差排名不会自动提供这些证据。应分别看观测精度、峰值取舍与操作代价。NLinear 峰高误差低不能抹去平均时间误差更大；MIFlu 的 MSE 最低也不证明区间校准或前瞻效益。我们因此可先论证选模证据，再谈公共卫生部署赢家。

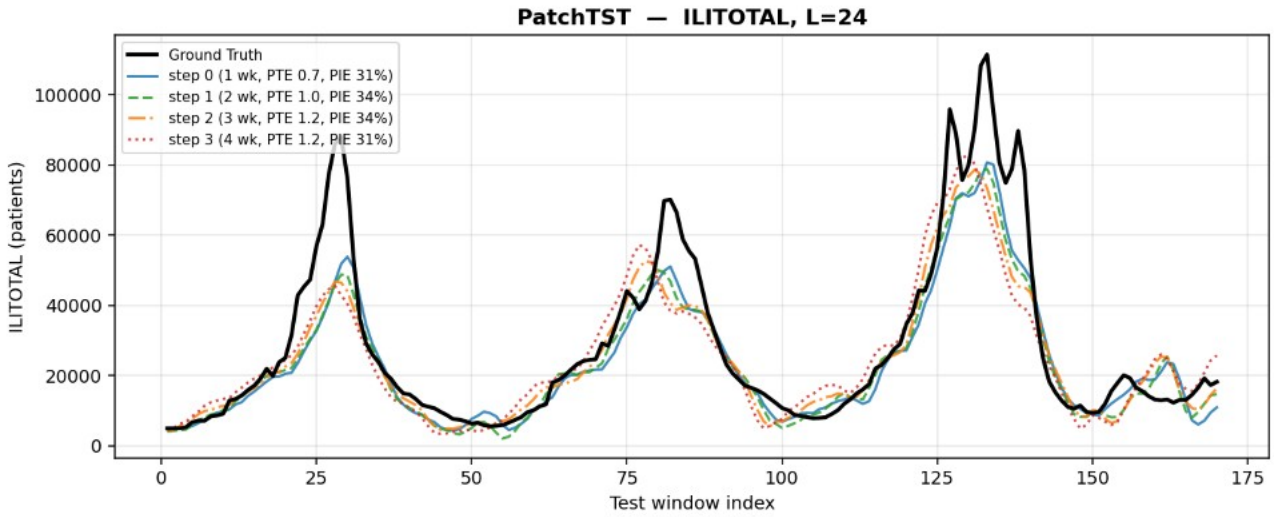
向导师简答。 MIFlu 赢的是观测点误差排名，峰值端点与不确定性须有各自证据 [2, 18]。

论文位置。 Kramer and Shaman [2], Forecast accuracy and comparison; Bracher et al. [18], §§3–4.

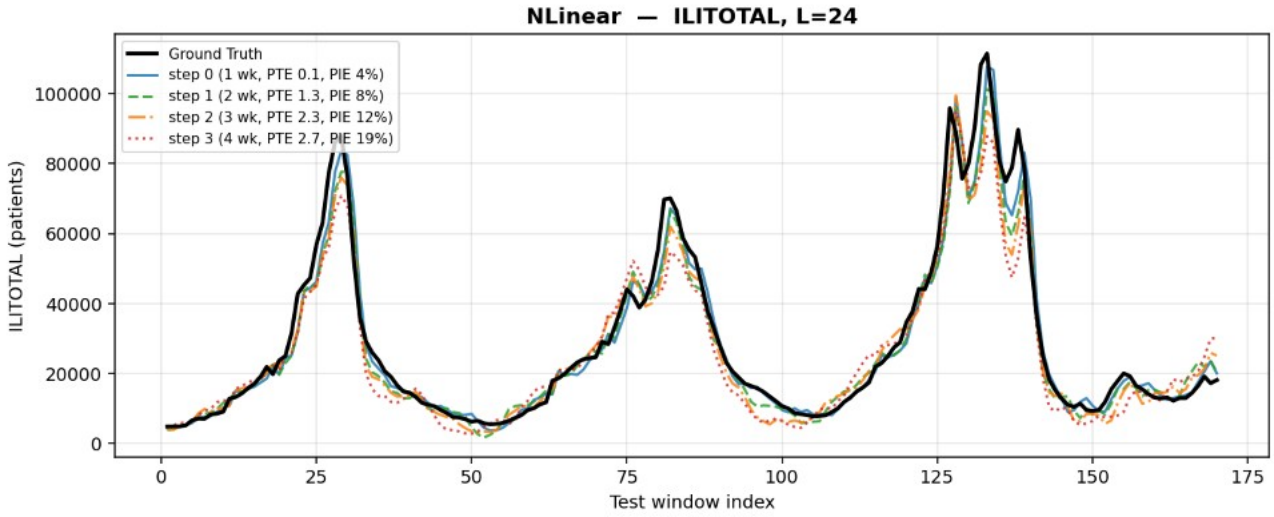
证据。 BENCH_MSE_BY_MODEL_L.csv; audit/GRADE_READINESS.md

F0 结论。 MIFlu 的观测 MSE 最低（1.5574），但仅靠 MSE 不能证明公共卫生效用。前三名相对 MIFlu 的跨度为 20.2%，并非小于 20%。

正式名单为 13 个传统模型、MIFlu 加另外三个基于 LLM 的实现，以及 11 个冻结编码器，总计 28。28 个模型平均 MSE 均低于季节朴素导出的 6.2132。现有证据不能判断超参数调优是否较不重要。



patchtst，L=24。纵轴为 ILITOTAL 患者人数，横轴为文件测试周下标。黑线为观测，其余为固定预测步 s0–s3。计分窗口 160。此图沿用所附示例，本次未独立重建绘图原始输入。



nlinear，L=24。纵轴为 ILITOTAL 患者人数，横轴为文件测试周下标。黑线为观测，其余为固定预测步 s0–s3。计分窗口 160。此图沿用所附示例，本次未独立重建绘图原始输入。

5 峰值时间与幅度

峰值时间误差 PTE 是预测与观测峰值周的绝对差。峰值强度误差 PIE 为峰高绝对差除以观测峰高后乘百分比。Kramer–Shaman [2] 可核实分别为一周与 25% 的容差。项目把两者联合应用于（模型、L、step）单元的平均误差；该联合筛选及峰检测属于项目选择，不是临床接受标准。平均误差达标不等于逐季成功概率。

表 6. 峰值时间与强度误差

模型	PTE (wk)	PIE (%)	联合通过	s0 PTE	s0 PIE (%)
MIFlu	1.128	26.846	4/16	0.347	18.884
PatchTST	1.240	32.755	0/16	0.681	30.553
NLinear	1.677	9.477	4/16	0.208	3.250

均值跨越 16 个（L，step）单元。通过数是在各单元的聚合误差上应用 PTE ≤ 1 周且 PIE ≤ 25%，不是逐季达标率。PIE 衡量点预测的峰高误差，不是概率校准。

表 7. 各跨度与提前步的联合峰值筛选

模型	L	s0	s1	s2	s3
NLinear	24	PASS 0.111 / 3.949	fail 1.333 / 8.411	fail 2.333 / 11.943	fail 2.667 / 18.739
NLinear	36	PASS 0.333 / 4.181	fail 1.333 / 7.222	fail 2.111 / 15.313	fail 2.667 / 18.145
NLinear	48	PASS 0.222 / 2.419	fail 1.222 / 4.727	fail 2.222 / 9.979	fail 2.778 / 16.655
NLinear	60	PASS 0.167 / 2.450	fail 1.444 / 4.542	fail 2.556 / 9.952	fail 3.333 / 13.000
MIFlu	24	PASS 0.000 / 18.307	fail 0.889 / 26.686	fail 1.222 / 30.472	fail 1.333 / 31.638
MIFlu	36	PASS 0.000 / 18.695	fail 0.778 / 26.333	fail 1.667 / 31.514	fail 1.333 / 32.427
MIFlu	48	fail 1.222 / 18.004	PASS 0.667 / 24.795	fail 1.222 / 30.133	fail 1.333 / 33.236
MIFlu	60	PASS 0.167 / 20.530	fail 1.333 / 25.799	fail 2.222 / 29.790	fail 2.667 / 31.177
PatchTST	24	fail 0.667 / 30.580	fail 1.000 / 34.044	fail 1.222 / 33.572	fail 1.222 / 30.722
PatchTST	36	fail 1.000 / 26.235	fail 1.667 / 32.247	fail 1.333 / 31.245	fail 1.333 / 33.854
PatchTST	48	fail 0.556 / 30.360	fail 1.333 / 30.878	fail 0.889 / 35.158	fail 0.889 / 35.002
PatchTST	60	fail 0.500 / 35.035	fail 1.667 / 34.342	fail 2.222 / 35.674	fail 2.333 / 35.133

每格为 PTE（周）/ PIE（%）。s0–s3 是预测的第 1–4 周。峰检测使用突出度 0.15 × 极差、间距 15、±8 周匹配。检测设置及联合聚合均为项目选择。来源：BENCH_PTE_PIE_BY_STEP.csv。

Q12 为什么 MIFlu 和 NLinear 都通过 4/16，却仍有不同结论?

直接回答与本地证据。 一次通过要求同一个（L，step）单元的平均 PTE ≤ 1 周且平均 PIE ≤ 25%。NLinear 在四个跨度的 step 0 均通过；MIFlu 在 L24/L36/L60 的 step 0，以及 L48 的 step 1 通过。因此，相同通过数会隐藏达标位置及误差大小的差异。跨全部 16 单元，NLinear 的 PIE 更低，为 9.477% 对 26.846%；MIFlu 的 PTE 更低，为 1.128 对 1.677 周。结论是时间与峰高之间存在取舍，任何一个都不是全面占优。

文献依据与选择理由。 文献分开评价时间与强度，支持先看两项误差，再压缩为通过数 [2]。相同四次通过隐藏不同步长/跨度位置，以及距阈值多远的差别。优先重视提前一周峰高的应用，可能与重视时间的应用选择不同取舍。这是对本地表格的条件式解释，不是文献推荐 NLinear。二元通过标签只是连续误差的粗略摘要。

向导师简答。 相同通过数隐藏不同位置与时间—峰高取舍 [2]。

论文位置。 Kramer and Shaman [2], Forecast accuracy and comparison, separate timing/intensity tolerances.

证据。 BENCH_PTE_PIE_BY_STEP.csv model in {miflu,nlinear}

Q13 4/16 是否表示预测流行季成功的概率为 25%?

直接回答与本地证据。 不是。分母是四个跨度乘四个固定预测步，不是 16 个独立流行季。每个单元本身已经聚合可用运行或事件的误差。先平均再应用阈值，与先判断每个事件成功再计数，可能得到不同结果。Kramer–Shaman [2] 支持分别采用时间和强度容差；把两者联合用于聚合单元，以及具体峰检测设置，属于本项目选择，不是临床接受检验或经校准的概率。

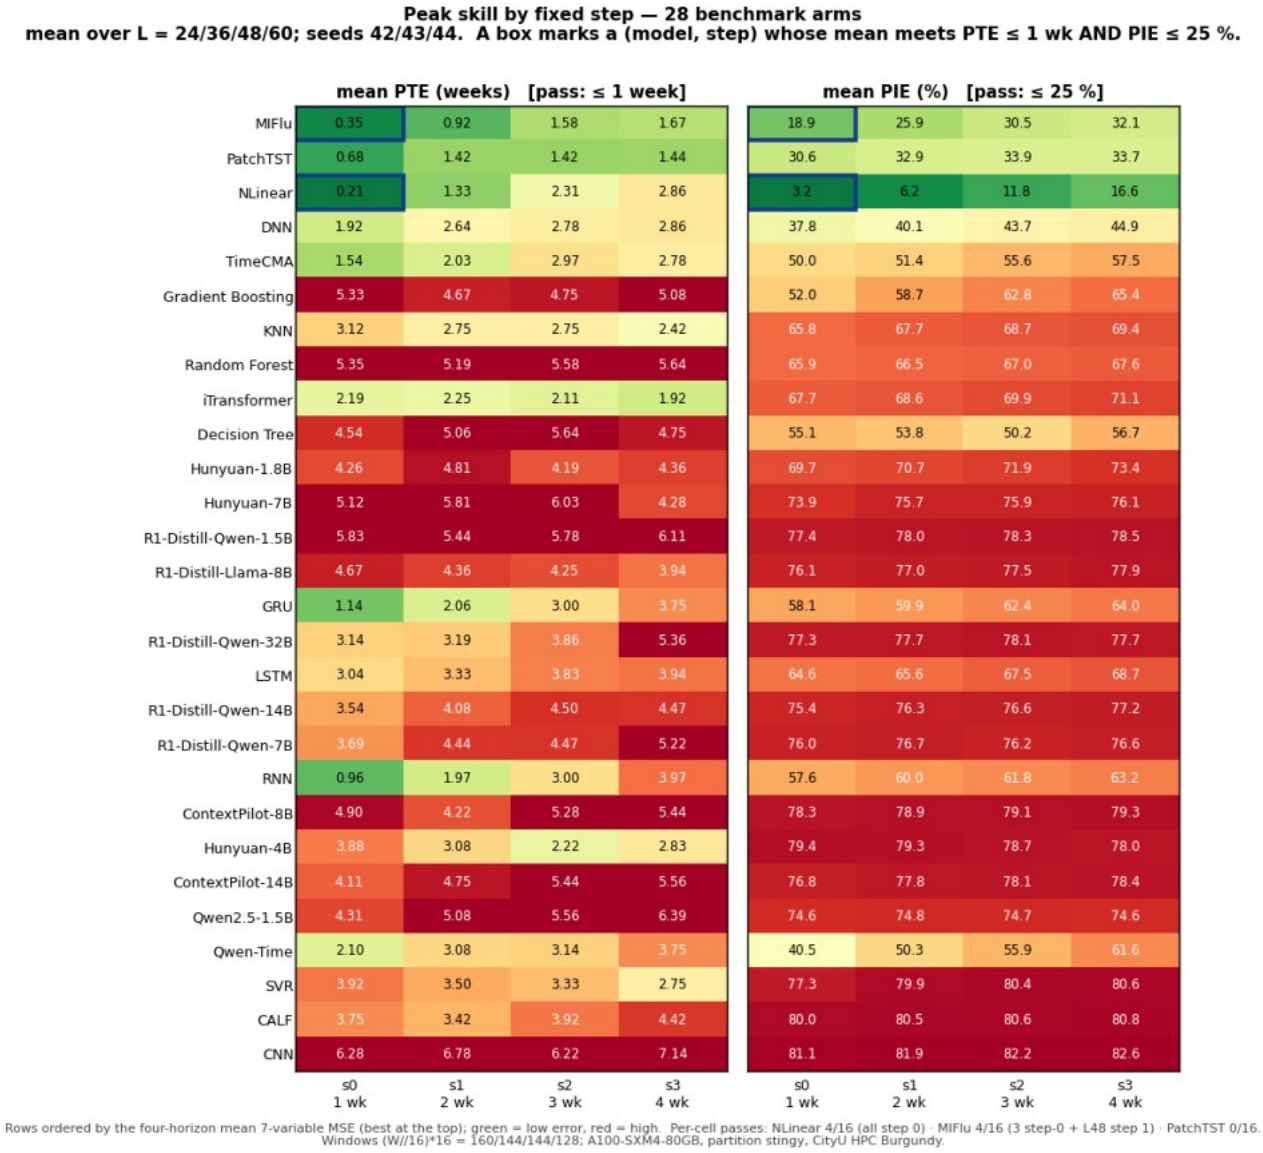
文献依据与选择理由。 Kramer 与 Shaman 按提前时间评价逐预测峰值准确性 [2]，我们的十六个配置单元是另一种分母。对均值应用阈值，与对逐事件通过指示值取平均，在数学上不同，所以 4/16 不能改名为流行季成功概率。Bracher 等讨论预测分布校准 [18，第 4.2 节]，峰高误差小不等于已校准。估计事件成功率需保留逐事件结果、定义事件分母并处理依赖。

向导师简答。 这里数的是平均后的配置，而非成功流行季或经校准概率 [2, 18]。

论文位置。 Kramer and Shaman [2], Forecast accuracy and comparison / Fig. 2; Bracher et al. [18], §4.2.

证据。 BENCH_PTE_PIE_BY_STEP.csv; Kramer–Shaman [2]; analysis peak detector settings

F1 结论。 NLinear 与 MIFlu 各通过 4/16 个聚合单元，PatchTST 为 0/16。NLinear 的平均 PIE 更低（9.477%，MIFlu 为 26.846%），但平均 PTE 更高（1.677 周，MIFlu 为 1.128 周）。这是时间与幅度的取舍，不是全面优越。前三模型的排序在两端倒置：MSE 顺序为 MIFlu、PatchTST、NLinear，PIE 顺序为 NLinear、MIFlu、PatchTST。



28 个保留模型的峰值误差热图。每格展示固定提前步上跨跨度的均值。均值层面的框选不能理解为每个跨度均通过，逐跨度通过情况见详细网格。来源：BENCH_PTE_PIE_BY_STEP.csv。

MSE 与 PIE 正秩相关（+0.736）意味着 MSE 较低时 PIE 通常也较低。MSE 与通过数负相关（−0.429）方向同样符合预期：误差较低通常伴随更多通过。两者都不能证明脱钩。NLinear 的 MSE 第三、PIE 第一，说明局部目标排序不一致。

Q14 为什么峰值排名会改变，却不能说已经证明脱钩？

直接回答与本地证据。 前三模型的 MSE 顺序为 MIFlu < PatchTST < NLinear，PIE 顺序为 NLinear < MIFlu < PatchTST。排序在两端倒置，中间位置也不同。跨全部模型，MSE–PIE 为正相关（+0.736），MSE–通过数为负相关（−0.429），都符合整体误差越低通常峰值表现越好的方向。局部排名不一致可以与整体相关同时存在。因此可主张评价目标改变排序，不能主张统计独立或所有模型都无法预测峰值。

文献依据与选择理由。 Zeng 等说明 NLinear 先减最后一个值，经过线性映射，再加回该值 [4]。这提供水平处理的可检验假设，却非本地峰值成因的证明。排名差别有更直接的区别：MSE 聚合许多点和七通道，PIE 聚焦 ILITOTAL 检测峰高 [21 提供误差指标背景]。模型可能改善非峰点却使该端点较差。若要归因于架构，须有受控变体和峰值/残差诊断。

向导师简答。 两种目标聚合不同误差，NLinear 水平校正是待检验的假设 [4, 21]。

论文位置。 Zeng et al. [4], §4 NLinear; Hyndman and Koehler [21], §2.1.

证据。 BENCH_MSE_BY_MODEL_L.csv joined to BENCH_PTE_PIE_BY_STEP.csv; audit/verified_facts.json

6 精度与参数量

表 8. 参数分析与秩相关

量	数值
回归斜率 / R^2	+0.1171 / 0.0223
有参数量导出的模型	11
子集帕累托集合	NLinear 2,520; PatchTST 531,878
参数比	211.1×
描述性 MSE 降幅	11.2%
ρ(MSE, PIE)	+0.736 (p < 0.0001)
ρ(MSE, 通过数)	-0.429 (p = 0.023)

帕累托分析只纳入有参数量导出的 11 个模型，未包括 MIFlu 与冻结编码器。缺失参数量不等于零。参数量不等于延迟、内存或能耗。相关系数只是同一测试集上跨模型的描述性结果。

Q15 我该怎样向导师解释 Pareto 图?

直接回答与本地证据。 横轴是参数量，纵轴是 MSE，两者均偏向越小越好。如果子集中另一个模型的参数不更多、MSE 不更高，且至少一项严格更好，前者就受到支配。导出的前沿包含 NLinear 和 PatchTST：NLinear 更小，PatchTST 的 MSE 更低，因此互不支配。这个前沿只覆盖有参数导出的 11 个模型，MIFlu 与冻结编码器不在其中，不能称为全部模型的全局前沿。

文献依据与选择理由。 iTransformer 同时评价误差、速度和内存 [5，附录 D]，是把表现与代价并列考虑的先例。我们的代价轴更窄，只用导出参数。两个前沿成员来自十一模型子集的两两支配关系，并非论文推荐的通用赢家。Pareto 图排除被支配选择；余下选择仍需预算或可接受误差偏好。MIFlu 代价缺失，使它不能称为全部 28 模型前沿。

向导师简答。 前沿排除所测子集内的被支配选择，仍需决策偏好从中选模 [5]。

论文位置。 iTransformer [5], Appendix D Model Efficiency; local BENCH_EFFICIENCY.csv.

证据。 BENCH_EFFICIENCY.csv; fig_pareto_frontier.png

Q16 参数多 211 倍，是否就慢 211 倍?

直接回答与本地证据。 不是。531,878 / 2,520 = 211.1 比较的是导出的 PatchTST 与 NLinear 参数量。其观测 MSE 降幅为 (1.871583 − 1.662078) / 1.871583 ≈ 11.2%。参数存储、运算、硬件利用率及批量大小对运行时间有不同影响。延迟、峰值内存与能耗需要直接且可比的测量。因此使用“参数效率”这个表述；缺失参数继续记为缺失，不能当成零，更不能把 MIFlu 描述成无参数模型。

文献依据与选择理由。 iTransformer 在声明的输入/预测长度和统一批量下实测速度、内存 [5，附录 D]，我们的参数导出没有这些测量。参数影响存储，运算、词元数量与硬件利用率对耗时影响不同。因此参数多 211×，不能推出延迟、内存或能耗也多 211×。后续效率表应记录硬件、精度、批量，以及计时针对训练还是推理，不能用参数比猜这些字段。

向导师简答。 我报告的是参数比；文献展示了速度主张所需的匹配运行测量 [5]。

论文位置。 iTransformer [5], Appendix D, Fig. 10, matched speed/memory measurements.

证据。 BENCH_EFFICIENCY.csv; BENCH_MSE_BY_MODEL_L.csv model in {nlinear,patchtst}

Q17 R^2 = 0.0223 实际说明什么?

直接回答与本地证据。 在有参数导出的 11 个模型中，以 MSE 对 log10(参数量) 拟合，参数规模单独解释的观测变化很少。这种描述性关联没有隔离容量作用，因为架构、优化与训练设置也同时不同。较低 R^2 不能证明容量不重要，更不能证明观测精度增益只是随机噪声。若要研究容量因果作用，需要在受控模型家族及训练协议内改变规模。

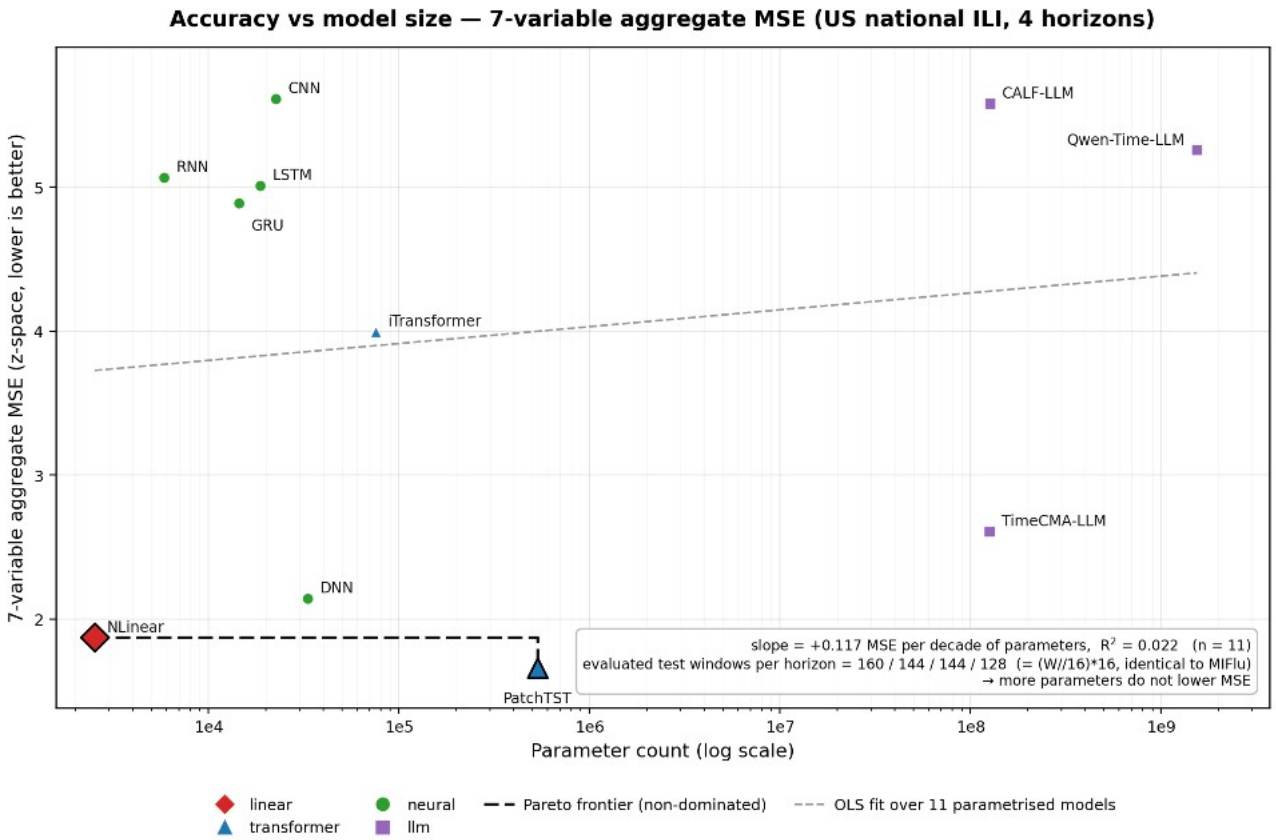
文献依据与选择理由。 PatchTST 改变层数和隐藏维度，并特别指出 ILI 对这些设置敏感 [3，附录 A.6.2]，这反对轻率否定小流感序列上的调参。我们的跨模型 R^2 混合架构、优化和规模，不是受控容量作用。更强的后续是在一个家族内改变深度/宽度，固定训练协议并重复运行。MIFlu 深度阶梯开始提出这个问题，但未聚合状态不能提供科学趋势。

向导师简答。 跨模型 R^2 低不能否定调参；PatchTST 明确报告 ILI 敏感性 [3]。

论文位置。 PatchTST [3], Appendix A.6.2, Fig. 5, layers/width and ILI sensitivity.

证据。 BENCH_EFFICIENCY.csv; scripts/verify_snapshot.py linregress

F2 结论。 在导出参数量的 11 个模型中，拟合斜率为 +0.1171，R^2 为 0.0223。规模单独解释的观测 MSE 变化很少。该子集结果不能证明容量无关紧要。



11 个导出参数量模型的精度与参数取舍。此子集未包括 MIFlu 与冻结编码器。参数量不是实测运行时间或内存代价。来源：BENCH_EFFICIENCY.csv。

7 统计审计

源表有 17 个模型的 136 对，另外 11 个模型不在其中，因此并非 28 模型的全配对分析。Holm 在原始 p 值排序后取前向累计最大值；源代码却取反向累计最小值。n=12 时双侧精确检验下限 2/4096 乘 136 已超过 0.05，因此正确 Holm 校正下该检验族不可能拒绝任何原假设。重复目标及跨度也使单元相关。原始 p 值及未校正 bootstrap 区间只作探索性参考。

表 9. 使用正确 Holm 校正的配对比较

模型 A	模型 B	Δ MSE	p raw	p Holm	效应*
NLinear	PatchTST	+0.2095	0.005859	0.1172	1.15
Gradient Boosting	RNN	-1.4029	0.000488	0.0664	4.86
KNN	NLinear	+1.9138	0.000488	0.0664	22.29
KNN	MIFlu	+2.2280	0.000488	0.0664	9.89
KNN	LSTM	-1.2234	0.000488	0.0664	5.28
iTransformer	TimeCMA	+1.3863	0.000488	0.0664	7.02
iTransformer	SVR	-1.3443	0.000488	0.0664	10.61

*136 对来自 17 个模型，并未覆盖全部 28 个模型。n = 12 个配对跨度 × 种子单元。前向累计最大值 Holm 得到 0/136 个拒绝。所示 p 值由六位小数导出恢复 1/4096 枚举网格；直接从四舍五入导出重算时，NLinear–PatchTST 为 0.117180，而非 0.1171875。*源效应量采用模型合并标准差，不是配对差的标准差。单元相关性限制统计推断。*

Q18 为什么配对检验表里会出现看起来不相关的模型对?

直接回答与本地证据。 报告有意把 NLinear–PatchTST 这对前沿比较放在第一行，再列原始 p 最小的六行，这样既展示核心问题，也展示更大检验族中的例子。该前沿对在导出表按原始 p 升序排列时位于第 117，因此自动只取最小六项会漏掉它。但完整检验族仍含全部 136 对；选择展示哪几行，不能改变 Holm 校正的检验族，更不能让选中比较变显著。

文献依据与选择理由。 Demšar 说明考查特定差异时须控制比较族 [20]。这里首行保留前沿核心问题，后六行展示原始 p 更小的对照，校正仍纳入全部 136 对。第 117 指原始 p 升序位置，不是模型精度排名。选择展示行不能改变检验族。该文主要讨论多数据集，也不许可把本地重叠跨度和共享测试序列当成独立数据集。

向导师简答。 首行服务研究问题，校正仍由完整检验族决定 [20]。

论文位置。 Demšar [20], §3.2.2 Post-hoc tests; local raw-p rank.

证据。 BENCH_PAIRED_TESTS.csv model_a=nlinear/model_b=patchtst; audit/verified_facts.json pair_raw_rank

Q19 为什么未校正有 128 对显著，Holm 后却是零?

直接回答与本地证据。 同时检验很多模型对会增加误报机会。正确 Holm 先排列原始 p，再按递减多重比较因子计算并取前向累计最大值。原导出列方向错误，因此保留作来源记录但不使用。重算全部 136 对后为 0/136 个拒绝，最小校正 p 约 0.0664，NLinear–PatchTST 为 0.1172。在已记录的双侧精确 n=12 分辨率下，原始 p 最低为 2/4096，已高于 Holm 第一步的 0.05/136 阈值。跨度 – 种子单元之间的依赖还带来另一层限制。

文献依据与选择理由。 Demšar 说明 Holm 从最小 p 开始，在首次未通过阈值处停止 [20]。本项目第一阈值为 0.05/136；按已记录的十二贡献双侧符号翻转下限 2/2^12，乘 136 得 0.06640625，所以无法启动拒绝序列。这是本地数学推导，不是 Demšar 报告的流感结果。Holm 可处理有效 p 值之间的依赖，却不能修复因配对内部交换性不合理而无效的原始 p；两者是不同限制。

向导师简答。 精确检验下限超过 Holm 第一步阈值，这是设计分辨率限制 [20]。

论文位置。 Demšar [20], §3.2.2 Holm step-down; local exact-enumeration derivation.

证据。 BENCH_PAIRED_TESTS.csv p_raw; analysis_postprocess.py; audit/HOLM_RECOMPUTATION.csv

Q20 p = 0.1172 是否说明 NLinear 与 PatchTST 等价?

直接回答与本地证据。 不是。PatchTST 的观测平均 MSE 仍低 11.2%，且在 10/12 个配对单元中误差更低。未拒绝只表示该检验族校正流程没有在选定阈值下确立差异，不表示差异已小到可视为实际等价。等价判断需要预先规定可接受差异界值，并采用适合的不确定性与检验设计。表中源效应量还使用模型合并标准差，而非配对差标准差，因此只能标成源标准化效应。

文献依据与选择理由。 Lakens 区分不显著差异检验与预先规定有意义界限的等价检验 [25]。因此 p = 0.1172 没回答 NLinear 额外观测误差是否可接受。应先定义可接受差异，再采用尊重时间/季节依赖的不确定性设计。看表后才挑宽松界限，不能构成有说服力的确认。在此之前应并列报告观测降幅、参数比和推断不确定性，不能说额外参数只换来噪声。

向导师简答。 未拒绝不等于等价，观测取舍与尚未解决的推断并存 [25]。

论文位置。 Lakens [25], Introduction and Testing for Equivalence.

证据。 BENCH_EFFICIENCY.csv; BENCH_PAIRED_TESTS.csv; audit/CLAIM_AUDIT.md C3

F3 结论。 正确 Holm 校正为 0/136 个拒绝（校正前 128/136），最小校正 p 约 0.0664，NLinear–PatchTST 的 p ≈ 0.1172。PatchTST 的观测 MSE 仍低 11.2%，参数多 211 倍，并在 10/12 单元中误差更低。未拒绝不能证明等价，也不能断言增益是噪声。

8 冻结语言编码器

表 10. 冻结编码器加共享线性读出

编码器	MSE	相对 MIFlu	PTE	PIE (%)	通过
Hunyuan-1.8B	4.7374	3.04×	4.406	71.428	0/16
Hunyuan-7B	4.7596	3.06×	5.309	75.399	0/16
DeepSeek-R1-Qwen-1.5B	4.7866	3.07×	5.792	78.061	0/16
DeepSeek-R1-Llama-8B	4.8250	3.10×	4.306	77.121	0/16
DeepSeek-R1-32B	4.9372	3.17×	3.889	77.730	0/16
DeepSeek-R1-Qwen-14B	5.0166	3.22×	4.149	76.350	0/16
DeepSeek-R1-Qwen-7B	5.0308	3.23×	4.458	76.373	0/16
ContextPilot-8B	5.0843	3.26×	4.962	78.918	0/16
Hunyuan-4B	5.1317	3.30×	3.003	78.840	0/16
ContextPilot-14B	5.1949	3.34×	4.965	77.764	0/16
Qwen2.5-1.5B	5.2049	3.34×	5.333	74.650	0/16

11 个保留编码器 × 4 跨度 × 3 种子 = 132 单元。历史计划还包含两个仅嵌入模型，总计 156 单元；未纳入的 24 单元不属于 28 模型正式名单。此结果只评价该冻结特征流程。

Q21 冻结编码器的负面结果能解释到哪一步?

直接回答与本地证据。 所测流程冻结语言编码器，再训练线性读出。11 个编码器的 MSE 为 4.7374–5.2049，均高于决策树的 4.3198，各自通过 0/16 联合单元。这说明这些特征与读出配置在当前协议中表现较差。分布不匹配、冻结特征和读出能力都可能解释结果，但实验没有分离其作用。生成、提示、微调及数值预训练时序基础模型均不属于这项测试。

文献依据与选择理由。 Time-LLM 也冻结 LLM，却加入可学习重编程和提示前缀 [6]，所以“冻结”不等同于本项目特征/线性读出流程。Chronos 则从数值序列学习预测 [9]。这些方法差异支持缩小负面结论。要分离读出瓶颈，应固定编码器后改变读出/对齐；要分离预训练作用，应比较匹配的预训练和随机骨干。十一模型结果没有完成这些受控分离。

向导师简答。 失败限定本地特征/读出流程，Time-LLM 与 Chronos 检验其他机制 [6, 9]。

论文位置。 Time-LLM [6], author abstract; Chronos [9], §3.

证据。 BENCH_MSE_BY_MODEL_L.csv family=llm_encoder; BENCH_PTE_PIE_BY_STEP.csv

F4 结论。 所测 11 个冻结编码器的 MSE 为 4.7374–5.2049，是 MIFlu 的 3.04–3.34 倍，全部高于决策树的 4.3198，且均通过 0/16 单元。这是该特征与读出配置的负面结果；提示、微调及数值时序基础模型仍未检验。

分布差异、冻结容量和所选读出均可能影响结果，但本结果未分离其因果作用。线性读出不能保证提取可用的非线性特征。

9 消融设计与状态

表 11. 消融设计与快照状态

变体	参数	单元	状态
参考 K=6	default	12	已在基准中
no_lora	--no-lora	12	尚未聚合
K=2	--num-layers 2	12	尚未聚合
K=4	--num-layers 4	12	尚未聚合
K=8	--num-layers 8	12	尚未聚合
K=12	--num-layers 12	12	尚未聚合

用户报告截至 2026 年 11 月 3 日：新增 60 单元中完成 27，作业 722968。Burgundy 队列与逐格 manifest 显示 60/60 已完成；逐变体聚合趋势尚未重算。参考 12 单元不计入新增 60 单元。不推断趋势。

F5 暂定结论。 miflu_model.py 的 author_faithful 路径将文本置于时间词元之后，使用因果注意力，预测头只读取时间词元。静态检查因此推断确定性评估时文本不影响输出。所附 tests_archive/test_miflu_ablations.py 明确断言文本不变性，以及匹配 CPU 初始化时完整与无文本模型相同。本次仅静态检查，未执行。其他融合路径及训练随机性须分别验证。

Q22 为什么默认路径下去掉文本可能得到完全相同的输出?

直接回答与本地证据。 已检查的 author_faithful 路径把时间词元放在文本词元前。因果注意力只允许每个位置读取自身或更早位置，预测头又只读取时间词元位置。因此在确定性评估前向过程中，这些位置无法利用后面的文本。所附归档明确断言文本不变性，以及匹配初始化的完整/无文本 CPU 输出相同，但本次没有执行这些模型测试。其他融合路径、dropout 和独立训练轨迹仍需分别检查。精确文件与命令见 audit/NO_TEXT_VERIFICATION.md。

文献依据与选择理由。 Transformer 原文说明遮罩如何阻止关注后续位置 [24，第 3.1 节]。按已检查顺序，时间位置不能通过这些层取得后方文本，预测头又只读时间位置。这是固定前向路径的结构论证，不是仓库运行或逐位相等认证。三项归档断言须控制权重、输入和评估随机性，再比较更换文本及匹配完整/无文本输出，当前仍未执行。独立训练可能不同地消耗随机数，须另测。

向导师简答。 因果遮罩支持结构论证，本地逐位相等须由受控运行测试建立 [24]。

论文位置。 Vaswani et al. [24], §3.1 Decoder; local ForecastingLLM.forward and archived assertions.

证据。 miflu_model.py ForecastingLLM; tests_archive/test_miflu_ablations.py; audit/NO_TEXT_VERIFICATION.md

Q23 消融完成 60/60，究竟可以说什么?

直接回答与本地证据。 这是截至 11 月 3 日用户报告的运行状态快照，不是实时调度器查询，也不是已聚合的模型比较。新增设计有五个变体，每个四跨度、三种子，合计 60 单元；参考模型另有 12 单元。没有逐变体结果导出，就不能从完成数量推断深度趋势或 LoRA 收益。存在 no-text 测试断言，也不代表已完成相应消融实验。报告科学结果前，需要逐运行输出、状态及来源。

文献依据与选择理由。 Tan 等保留周边可训练预测器，移除或替换 LLM [13，第 3.2 节]，以检验骨干是否额外贡献信息。本地 no-LoRA/深度变体只回答较窄的适配/容量问题，不会自动回答同样的移除/替换问题，也不能分离文本使用。部分完成是操作状态；解释科学趋势需各报告变体分数、重复运行波动及匹配协议。文献提供实验问题，不提供本地未完成阶梯的结果。

向导师简答。 文献支持移除/替换对照，未完成阶梯尚未回答这些因果问题 [13]。

论文位置。 Tan et al. [13], §3.2 Proposed Ablations, w/o LLM / LLM2Attn / LLM2Trsf.

证据。 Owner snapshot; ablation design table; tests_archive/test_miflu_ablations.py

10 解释与发表计划

单一全国序列与单次时序划分不能证明区域或前瞻效用。峰值匹配可使用未来观测定义事件，只能作为回顾性评测工具。合成日期标签必须与 CDC 日历核实映射后才能作逐季判断。参数导出缺少 MIFlu 与编码器。60/60 的消融状态来自用户报告，而非实时集群检查。现代数值基础模型、区域结果、滚动原点及经过验证的不确定性仍缺失。

后续验证的决策规则：在查看新测试期之前确定 MSE 预算 B、允许峰值失败率 q 与决策代价。在验证季同时满足 B 与 q 的模型中最小化期望决策代价，再以参数量打破平局。对升级响应 / 等待决策，误报代价为 c_FP，漏报代价为 c_FN，正确行动代价为零；仅当经过验证的高峰概率超过 c_FP/(c_FP+c_FN) 时升级。代价、B、q 尚未征询或验证，因此没有模型被认证可部署。NLinear 是低成本峰高验证候选，MIFlu 仍为观测 MSE 最优。

建议 O1：保留实证评估贡献，先补齐证据，再考虑新增机制。当前草稿面向 IEEE JBHI 的健康预测主题，但尚未达到投稿状态。在学校截止日前，滚动原点、区域验证、更强基线与独立代码来源比再加一个架构更重要。

Q24 除了复现，本项目增加了什么，为什么默认仍选 O1?

直接回答与本地证据。 本项目在明确不同子集的前提下，从精度、峰值技巧、参数效率和统计证据四个维度比较实现。本次没有核实参考论文是否只有前两项，因此不能断言原文缺失某项或声称首次发现。O1 通过补齐来源、恢复测试、滚动原点、区域和更强对照来发展实证贡献。可选 O2 是只在验证数据拟合的峰高再校准：若已有可审计的验证/测试预测，可不新增 GPU 训练。但本快照尚未确立这些验证导出；CPU 时间和费用未测量，几个工作日也仅为规划估计。

文献依据与选择理由。 简单线性及移除 LLM 的批评早已存在 [4, 13]，Qiu 等预印本又在更大跨数据集设置报告条件式收益 [14]。本地较窄贡献连接经审计流感精度、峰值端点、代价子集和正确推断。O1 检查

跨原点/区域是否保持，Tashman 支持滚动原点评测 [23]。O2 仅在预测导出合适时加入验证集拟合峰高调整；新增机制不能替代检查，也不能确立对所有 LLM 的判决。

向导师简答。 O1 检验流感特定发现；已有负面和条件式正面证据，不支持通用结论 [4, 13, 14]。

论文位置。 Zeng et al. [4], §4; Tan et al. [13], §3.2; Qiu et al. [14], abstract and §§3–5 (preprint); Tashman [23], publisher-indexed abstract.

证据。 audit/INNOVATION_DECISION.md; audit/LITERATURE_REVIEW.md; sources.json [1]

11 可复现性与待核实项

在仓库根目录运行 python scripts/verify_snapshot.py --raw-smoke 及 python -m pytest tests/test_snapshot_audit.py -q。审计重算主要聚合值、峰值标记、相关系数、回归、Holm 校正和一个原始预测 MSE。七个新增 CPU 审计测试已通过，它们与归档模型测试分开。修正 ZIP 已提供 tests_archive/，但历史目录布局及模型依赖缺失导致收集失败。本次不主张归档测试通过数或可靠总数。本次未重跑训练、未查询实时 HPC，亦未运行上游代码。原 CSV 保持不变，Holm 修正另行导出。

硬件来源表共 204 行，其中包括被排除的 DLinear，但没有 MIFlu 与冻结编码器；与正式名单重叠的是 192 单元。因此不能证明逐单元硬件来源已齐。原 reproduce_all.py 面向历史路径，并非此次核实的快速入口。

待核实项：固定上游版本的检查点、加载器与学习率；归档测试执行与 no-text 运行测试；十种子原始复现日志；模型版本与许可；实时消融及区域状态；真实 CDC 日历映射；当前 JBHI 作者限制、JCR 记录及下一轮会议日期。每项都需原始证据，不能靠文字断言补足。

Q25 导师现在能复核什么，还有什么未执行?

直接回答与本地证据。 文档中的 CPU 命令可以重算 CSV 主要聚合、正确 Holm 和一个原始预测单元的 MSE；七个新增 CPU 审计检查已通过。历史归档已经提供，但收集失败，不能把其中模型断言算作通过。完整 GPU 训练、全运行原始重评分、实时 HPC、固定上游身份和 no-text 运行测试仍未执行或未核实，硬件来源也未完整覆盖正式单元。文档排版完善不能补足这些证据。精确后续命令见 audit/EXECUTION_STATUS.md 与 audit/NO_TEXT_VERIFICATION.md。

文献依据与选择理由。 Kapoor 与 Narayanan 要求明确报告论证，而非把代码可用等同于结果有效 [22]。这里应分开文档重建、CSV 算术、原始预测重评分与模型重训。导师可先运行 CSV 审计；完整包还支持一个原始单元 smoke 检查。模型文本不变性需在固定环境实际执行三项指定断言，且不能跳过。有用的交付是可追溯证据链、精确命令与状态，某一层通过不能认证其他所有层。

向导师简答。 我区分重算结果与静态检查，并为每层提供命令和状态 [22]。

论文位置。 Kapoor and Narayanan [22], model info sheets; EXECUTION_STATUS.md and NO_TEXT_VERIFICATION.md.

证据。 audit/EXECUTION_STATUS.md; audit/NO_TEXT_VERIFICATION.md; audit/REPO_AUDIT.md

12 参考文献

[1] Jaeuk Moon 等，基于大语言模型的多模态流感预测方案（中文译名），2025。https://doi.org/10.1109/JBHI.2025.3561214

[2] Sarah C. Kramer 等，针对温带及热带六十四国的流感预测开发与验证（中文译名），2019。https://doi.org/10.1371/journal.pcbi.1006742

[3] Yuqi Nie 等，一个时间序列相当于六十四个词的长期预测方法（中文译名），2023。https://arxiv.org/abs/2211.14730

[4] Ailing Zeng 等，Transformer 是否适用于时间序列预测（中文译名），2023。https://arxiv.org/abs/2205.13504

[5] Yong Liu et al. 等，反转维度的 Transformer 时间序列预测（中文译名），2024。https://arxiv.org/abs/2310.06625

[6] Ming Jin et al. 等，通过重编程大语言模型进行时间序列预测（中文译名），2024。https://arxiv.org/abs/2310.01728

[7] Peiyuan Liu et al. 等，通过跨模态微调对齐语言模型与时间序列（中文译名），2024。https://arxiv.org/abs/2403.07300

[8] Chenxi Liu et al. 等，通过跨模态对齐增强多变量时间序列预测（中文译名），2025。https://arxiv.org/abs/2406.01638

[9] Abdul Fatir Ansari et al. 等，学习时间序列语言的 Chronos 方法（中文译名），2024。https://arxiv.org/abs/2403.07815

[10] Abhimanyu Das 等，仅解码器时间序列预测基础模型（中文译名），2024。https://proceedings.mlr.press/v235/das24c.html

[11] Gerald Woo et al. 等，通用时间序列预测 Transformer 的统一训练（中文译名），2024。https://proceedings.mlr.press/v235/woo24a.html

[12] Kashif Rasul et al. 等，面向概率时间序列预测基础模型的 Lag Llama（中文译名），2024。https://arxiv.org/abs/2310.08278

[13] Mingtian Tan 等，语言模型真的有助于时间序列预测吗（中文译名），2024。https://arxiv.org/abs/2406.16964

[14] Xin Qiu et al. 等，重新思考大语言模型在时间序列预测中的作用（中文译名），2026。https://arxiv.org/abs/2602.14744

[15] Chen Xu 等，动态时间序列的共形预测区间（中文译名），2021。https://proceedings.mlr.press/v139/xu21h.html

[16] Chen Xu 等，时间序列的顺序预测共形推断（中文译名），2023。https://proceedings.mlr.press/v202/xu23r.html

[17] Isaac Gibbs 等，分布偏移下的自适应共形推断（中文译名），2021。https://arxiv.org/abs/2106.00170

[18] Johannes Bracher 等，以区间格式评估传染病预测（中文译名），2021。https://doi.org/10.1371/journal.pcbi.1008618

[19] Xavier Bouthillier et al. 等，Accounting for Variance in Machine Learning Benchmarks（英文原题），2021。https://proceedings.mlsys.org/paper_files/paper/2021/file/0184b0cd3cfb185989f858a1d9f5c1eb-Paper.pdf

[20] Janez Demšar 等，Statistical Comparisons of Classifiers over Multiple Data Sets（英文原题），2006。https://jmlr.org/papers/volume7/demsar06a/demsar06a.pdf

[21] Rob J. Hyndman 等，Another look at measures of forecast accuracy（英文原题），2006。https://doi.org/10.1016/j.ijforecast.2006.03.001

[22] Sayash Kapoor 等，Leakage and the reproducibility crisis in machine-learning-based science（英文原题），2023。https://doi.org/10.1016/j.patter.2023.100804

[23] Leonard J. Tashman 等，Out-of-sample tests of forecasting accuracy: an analysis and review（英文原题），2000。https://doi.org/10.1016/S0169-2070(00)00065-0

[24] Ashish Vaswani et al. 等，Attention Is All You Need（英文原题），2017。https://papers.neurips.cc/paper/7181-attention-is-all-you-need.pdf

[25] Daniël Lakens 等，Equivalence Tests: A Practical Primer for t Tests, Correlations, and Meta-Analyses（英文原题），2017。https://doi.org/10.1177/1948550617697177