MIFlu 非 LLM 与 LLM 流感预测最终报告

——作者 966 行严格包含（strict-containment）八模型一次性测试冠军版

生成日期：2026-10-07 ｜ 主实验轨道：Track C ｜ 冻结种子：42 / 43 / 44

一、结论摘要

在作者 966 行 National-Illness 数据集、严格包含（strict-containment）窗口契约、匹配种子 42/43/44 的条件下，八个模型全部在训练集训练、以验证集选择 checkpoint、并以一次性测试集（Test）评价。

最终冠军为【官方仓库修正版 MIFlu】，测试集四 horizon 等权平均 MSE = 1.8652（标准差 0.0916），平均 MAE = 0.8842。

该模型在 L=24/36/48/60 四个 horizon 上均为第一名，并非依靠加权平均掩盖局部落后。

需要同时保留的第二个结论：LLM 侧组的平均分为 3.8175，非 LLM 侧组的平均分为 3.0756，即【按组平均而言非 LLM 侧更优】。两者并不矛盾——冠军是 LLM 侧的 MIFlu，但 LLM 侧其余成员（Qwen-Time-LLM、CALF-LLM）明显偏弱，拉低了整组均值。

二、项目历程与三条轨道

本项目最终区分三条互不可比的结果轨道，绝对 MSE 数值不得跨轨道比较。

- **Track H**：历史 1025 行受控替换实验：使用旧自建 MIFlu，且历史窗口按“目标起点”归属划分，存在跨划分污染。已冻结为 PARTIAL_HISTORICAL_CONTROLLED_REPLACEMENT_EVIDENCE，仅作历史证据，不参与最终冠军评选。

- **Track R**：作者 966 行 R1-B 论文复现：使用官方仓库修正版 MIFlu，结论为 PARTIAL_REPRODUCTION（四个 horizon 全部落在预声明 ±0.10 容差之外）。用于验证 MIFlu 实现，本身不是八模型冠军实验。
- **Track C**：作者 966 行严格包含八模型一次性测试冠军实验——即本报告的主结果。

三、为何采用 966 行数据集

论文 Table II 的七个变量描述统计与 966 行作者文件【7/7 完全吻合】（最大相对偏差约 0.02%）；而 2026 年 7 月的 1025 行快照仅 1/7 吻合。因此 966 行文件才是论文分析所用的数据集，其 70:10:20 整数划分为 676 / 97 / 193。1025 行快照属于 Track H，其绝对数值不得与 Track C 混用。

数据身份（SHA-256）：

```
2a96dfed7db532f0a36b6fddb3f4091e665b3d36b7662292589e3bbca95ebfe5
```

四、Train / Validation / Test 的分工

严格区分三者职责，是本实验公正性的核心：

- Train（676 行）：仅用于拟合模型参数与标准化器（scaler 仅用训练行拟合）。
- Validation（97 行）：仅用于选择 checkpoint 与早停；不进入最终排名，不进入分组均值，不作为主要性能结果。
- Test（193 行）：在 checkpoint 冻结后【只评价一次】，是唯一决定冠军的依据，并用于分 horizon 冠军、最佳 LLM / 最佳非 LLM、分组汇总与配对统计。

明确禁止且未发生：逐 epoch 读取 Test、用 Test 选择 checkpoint、看过 Test 后调参、依据 Test 挑选种子、剔除表现不佳的种子、混用 Validation 与 Test 结果。

五、历史划分污染与严格包含的修正

历史 1025 行契约按“目标起点”把窗口归入划分（train 若 ts < 717，val 若 ts ≤ 819），完全不考虑目标长度。实测在 L=24 时，23 个训练目标越界进入验证段、23/103 个验证目标越界进入 Test 段——而验证集正是选择 checkpoint 的依据，构成实质性污染。

Track C 改用严格包含：对每个窗口，目标块必须完整落在其所属划分内：

- target_start ≥ split_start
- target_end ≤ split_end − 1
- target_end = target_start + L − 1

由此得到的严格窗口数（已逐项验证）：

horizon L	训练起点数	验证起点数	测试起点数
24	549	74	170
36	537	62	158
48	525	50	146
60	513	38	134

测试集键数分别等于 170×24×7、158×36×7、146×48×7、134×60×7，八个模型共用完全相同的键集合，重复键为 0。

六、模型身份与单元格分类

八个模型身份固定，未增加、删除、改名或替换。96 个单元格分类如下：

RESCORE_ONLY（重新评分）：84 个；GPU_RETRAIN（重新训练）：12 个。

官方仓库修正版 MIFlu：以作者仓库为基座，七通道输出、文本通路有效、PEFT 启用、LoRA 施加于 c_attn、参数冻结有效、验证集选择 checkpoint、Test 只读一次、锁定式 checkpoint 与独立评分。12 个单元格全部重新训练（配置冻结，未依据任何结果调整）。

七、为何拒绝 Stage-6 的 MIFlu 预测

stage-6 的 pred_miflu_* 通过了全部结构性检查（strict containment、author_966、z 空间、规范起点、变量列顺序与形状均正确），但仍被判定为不可用：它与 A2 产物【逐字节相同】（sha256 76b81b5b0dfa5bde），即项目早期自建重构版，而非本实验要求的官方仓库实现。

【键兼容不等于实现身份。】若按“全部复用”的表面结论执行，最终冠军实验将静默替换为规则明确禁止的模型。该拒绝记录于 TRACK_C_MODEL_IDENTITY.csv 的 gpt2_miflu_REJECTED 行。

八、最终测试集排名

全部 96 个单元格由同一个规范评分器重算，未使用任何模型自带的评分代码路径。排序依据为测试集四个 horizon 等权平均 MSE（越低越好）。

排名	模型	平均 MSE (4L)	标准差	平均 MAE (4L)	阵营
1	官方仓库修正版 MIFlu	1.8652	0.0916	0.8842	LLM 侧
2	NLinear	2.0495	0.0299	0.9566	非 LLM 侧
3	DLinear	2.3478	0.0040	1.0884	非 LLM 侧
4	TimeCMA-LLM	2.6700	0.0177	1.0927	LLM 侧
5	PatchTST	3.9205	0.0543	1.3826	非 LLM 侧
6	iTransformer	3.9847	0.0317	1.3545	非 LLM 侧
7	Qwen-Time-LLM	5.2196	0.0701	1.5784	LLM 侧
8	CALF-LLM	5.5153	0.0307	1.6080	LLM 侧

按平均 MAE 的排名（次序与 MSE 一致）：

排名 (MAE)	模型	平均 MAE (4L)	平均 MSE (4L)
1	官方仓库修正版 MIFlu	0.8842	1.8652
2	NLinear	0.9566	2.0495
3	DLinear	1.0884	2.3478
4	TimeCMA-LLM	1.0927	2.6700
5	iTransformer	1.3545	3.9847
6	PatchTST	1.3826	3.9205
7	Qwen-Time-LLM	1.5784	5.2196
8	CALF-LLM	1.6080	5.5153

九、各 horizon 冠军

horizon L	冠军	MSE	MAE
24	官方仓库修正版 MIFlu	1.9686	0.8793
36	官方仓库修正版 MIFlu	1.9332	0.8857

horizon L	冠军	MSE	MAE
48	官方仓库修正版 MIFlu	1.7547	0.8778
60	官方仓库修正版 MIFlu	1.8042	0.8939

MIFlu 在四个 horizon 上全部排名第一，未出现“总体第一但个别 horizon 落后”的情形。

十、逐种子排名与稳定性

种子	该种子内排名	模型	该种子平均 MSE
42	1	官方仓库修正版 MIFlu	1.7917
42	2	NLinear	2.0351
42	3	DLinear	2.3521
42	4	TimeCMA-LLM	2.6904
42	5	iTransformer	3.9482
42	6	PatchTST	3.9683
42	7	Qwen-Time-LLM	5.2973
42	8	CALF-LLM	5.5200
43	1	官方仓库修正版 MIFlu	1.9677
43	2	NLinear	2.0840
43	3	DLinear	2.3470
43	4	TimeCMA-LLM	2.6597
43	5	PatchTST	3.8614
43	6	iTransformer	4.0051
43	7	Qwen-Time-LLM	5.1611
43	8	CALF-LLM	5.4825
44	1	官方仓库修正版 MIFlu	1.8361
44	2	NLinear	2.0296
44	3	DLinear	2.3443
44	4	TimeCMA-LLM	2.6600
44	5	PatchTST	3.9317
44	6	iTransformer	4.0008
44	7	Qwen-Time-LLM	5.2003
44	8	CALF-LLM	5.5434

排名在三个匹配种子上完全稳定，冠军未随种子改变；但绝对数值存在真实种子波动（MIFlu 标准差 0.0916），因此三个种子全部保留、未做任何剔除。

十一、配对统计与 11/12 完整性校验

配对差异定义为 diff = A − B；MSE 越低越好，故【仅当 diff < 0 时 A 获胜】。

A	对手	配对数	平均差异	A 胜	B 胜	平局
miflu	NLinear	12	-0.1844	11	1	0
miflu	DLinear	12	-0.4827	12	0	0
miflu	PatchTST	12	-2.0553	12	0	0
miflu	iTransformer	12	-2.1195	12	0	0
miflu	Qwen-Time-LLM	12	-3.3544	12	0	0
miflu	CALF-LLM	12	-3.6501	12	0	0
miflu	TimeCMA-LLM	12	-0.8049	12	0	0

关键校验：MIFlu 对 NLinear 的平均差异为 -0.1844，胜场 11/12。差异符号与胜场计数一致——若曾出现符号与计数相反（此前的反向计数缺陷），此处将显示为 1/12。其中确有 1 个单元格 NLinear 获胜，说明并未只保留有利结果。

十二、分组汇总（两个结论并存）

阵营	组内模型均值
LLM 侧	3.8175
非 LLM 侧	3.0756

必须同时陈述两点：(1) 修正版 MIFlu 是最佳单一模型；(2) 非 LLM 侧按组平均优于 LLM 侧。第二点的成因是 LLM 侧的 Qwen-Time-LLM 与 CALF-LLM 明显偏弱，而非冠军归属有争议。

十三、预测键校验与门禁

种子 42 八模型门禁：22 项通过 / 0 项失败，共 22 项检查。

门禁覆盖：八个模型身份、四个 horizon 完整性、数据集哈希、676/97/193 划分、严格包含断言、训练集独占标准化、验证集选择 checkpoint、测试集不参与选择、Test 只评价一次、预测与目标文件齐备、八模型测试键集合完全相同、无缺失键、无重复键、独立评分器接受全部单元格、MIFlu 文本通路有效、LoRA 安装于 c_attn、冻结正确、锁定式 checkpoint 与 sidecar 一致、stage-6 自建 MIFlu 被标记为拒绝、输出目录合规、无被替代产物进入排名。

十四、计算成本与存储

GPU 作业数：12；GPU 小时总计：1.5083；全部作业退出码为 0：True。评分与门禁为 CPU-only 作业，不占用 GPU 小时。

存储（取自 mmlsquota 的权威用户配额，而非文件系统空闲空间）：

文件系统	已用 (GB)	软配额 (GB)	硬上限 (GB)	宽限期	距软配额余量 (GB)
home	31	50	100	none	19
scratch	285	300	1024	none	15

checkpoint 策略：每个单元格仅保留验证集选出的锁定式 checkpoint（可训练张量 + 冻结键 sidecar），不保留逐 epoch checkpoint、不保留优化器/调度器状态；冻结的文本骨干张量不落盘，故 Qwen 拟合体积约 5 MB 而非约 3 GB。

十五、其他必须说明的事项

- Seasonal Naive 泄漏区分：历史 4-vs-4 所用的 Seasonal Naive 实现是安全的（钳制式公式）；作者 966 自建实现存在 L=60 未来泄漏；Track C 的受控替换不继承该缺陷。
- R1-B 论文复现结论：PARTIAL_REPRODUCTION。四个 horizon 全部落在预声明 ±0.10 MSE 容差之外（均值 1.9477 对论文 1.4355）。该结论不因 Track C 夺冠而改变。
- F1 仅作补充：冻结为 EXPLORATORY_A2F_CORRECTED_CONTRACT_PILOT，不作为主要结果；F2 未执行；R1-C 未执行。
- 受阻的论文表图：Table VI（US-Region 区域数据未公开）为 BLOCKED_BY_MISSING_DATA；Fig. 7（few-shot）为 BLOCKED_BY_MISSING_CONFIGURATION；Table II/III 原文单元格为图像，Table III 不可读。以上均不得以替代数据充数。
- 变量标签修正：旧 1025 行产物的 variable 名称整体错位两位（把 epiweek、release_date 当作变量）。本报告一律使用正确变量名，且该错位不影响任何 MSE（指标按数组索引计算）。

十六、局限性与冠军结论的适用范围

- 冠军结论仅适用于：作者 966 行数据、676/97/193 划分、严格包含窗口、匹配种子 42/43/44、验证集选择 checkpoint、一次性测试集评价。
- 换用其他数据集、划分、窗口规则或种子集合，结论不自动成立。
- 三个种子可给出标准差，但不足以支撑强显著性主张；本报告不宣称统计显著性，只报告配对差异与胜场计数。
- horizon 之间并非相互独立的重复实验，配对统计的解释需保留该限定。

- qwen_time_llm / calf_llm / timecma_llm 是“受启发的简化实现”（冻结骨干 + 命名组件契约），并非已发表系统的复现，因此“LLM 侧偏弱”的表述限于本实验的实现口径。
- MIFlu 的论文级复现仍为 PARTIAL_REPRODUCTION，本报告的冠军身份不构成“论文已复现”的主张。

十七、最终答案

在作者 966 行、严格包含、一次性测试集契约下，八模型比较的冠军是【官方仓库修正版 MIFlu】（以作者仓库为实现基座的修正版），测试集四 horizon 等权平均 MSE = 1.8652，平均 MAE = 0.8842，四个 horizon 全部第一。

非 LLM 侧最佳为 NLinear（MSE 2.0495）；LLM 侧最佳即总冠军。按组平均，非 LLM 侧（3.0756）优于 LLM 侧（3.8175）。

验证集结果未参与冠军评选；本报告未将验证集或 1025 行历史成绩混入最终排名。