MIFlu 非 LLM 与 LLM 流感预测最终报告

官方仓库 · 966 行 · 严格测试冠军版（精简终版）

报告版本：精简终版 v1 ｜ 日期：2026-10-08

本精简终版取代历史 1025 行旧版报告，并成为当前权威报告。

项目	值
官方仓库提交	MIFlu 官方仓库（已克隆）
作者数据 SHA-256	2a96dfed7db532f0a36b6fddb3f4091e…
Test 关键 SHA-256	7c7374dc6cb9a7fcd9865adb8341bed2…
数据集	作者 966 行 National-Illness
切分	Train/Val/Test = 676 / 97 / 193
严格包含	是（Test 目标不含 Train/Val 行）
评分器	单一独立 canonical scorer（z 空间）
冠军	MIFlu（官方仓库修正版）

目录

执行摘要

1 为何重做实验

2 相比旧版改变了什么

3 论文复现结果

4 4×LLM 与 4×非 LLM 方法

5 最终 Test 结果

6 PTE 与 PIE 补充评估

7 主要局限

8 最终结论

附录 A 轨道定义与权威性

执行摘要

本精简终版基于一次严格冻结的八模型冠军赛（AUTHOR_966_STRICT_CONTAINMENT_8MODEL_TEST_CHAMPIONSHIP）。在作者 966 行 National-Illness 数据、676/97/193 切分、严格目标包含、Train-only 缩放、单一独立评分器、三种子（42/43/44）、四预测步长（24/36/48/60）的合同下，以 Test 一次性结果决定冠军。

最终冠军

MIFlu（官方仓库修正版）为八模型冠军：Test average_MSE_4L = 1.8652（SD 0.0916），average_MAE_4L = 0.8842。MIFlu 在 L24/L36/L48/L60 四个步长及三个种子上均第一，并在 12 个匹配 seed–horizon 单元中以 11/12 击败 NLinear。

关键高层结论：

- 论文复现：达到“部分复现”。官方仓库修正 MIFlu 在 National-Illness 的最终 Test MSE（1.8652）仍高于论文报告值（1.4355）约 +29.9%，5% 容差未达成。
- 严格包含修正：旧版 1025 行窗口合同存在切分边界污染；新版以严格包含消除该污染。
- PTE/PIE：文献标准（PTE≤1 周且 PIE≤25%）下，NLinear 通过 36/36（100%），MIFlu 仅 15/36（41.7%）——MSE 冠军并非峰值冠军，二者分开报告。
- 组间：选中非 LLM 组均值 3.0756，优于 LLM 侧组均值 3.8175。

1 为何重做实验

旧版报告（历史 1025 行实验）存在以下不足，使其不能作为最终公平冠军赛：

• 使用 1025 行数据，而论文采用 966 行作者数据集。

• 旧版 MIFlu 为自搭实现，非官方仓库版本。

• 旧窗口合同的目标跨越 Train/Validation 边界，造成切分污染。

• 旧八模型比较部分以 Validation 排名，且仅三个模型进入最终 Test。

这些局限使旧结论不具备最终公平性，故以新的严格合同重做。

为何用 966 行

论文明确使用作者发布的 966 行 National-Illness 数据集；本实验以该数据集为唯一数据来源，并将 1025 行旧结果明确归为历史背景，不混入最终结论。

2 相比旧版改变了什么

维度	旧版（历史）	当前（严格）
数据行数	1025 行	966 行（作者数据集）
MIFlu 来源	自搭实现	官方仓库修正版
目标包含	含切分边界污染	严格包含（Test 不含 Train/Val 行）
切分	旧切分	676 / 97 / 193
排名依据	Validation 排名	一次性 Test 排名
模型范围	部分模型入 Test	全部八模型 Test 对比
评分器	模型相关	单一独立 canonical scorer

注：历史 1025 行结果、旧 step=0 数字、旧 2021 幻觉峰均属旧切分/旧实验，不适用于本严格合同，已移至背景或附录，不进入主结论。

3 论文复现结果

论文 Table IV / V 给出训练配置：epochs 20、batch size 16、learning rate 5e-4、T=104。论文未完全披露 optimizer、scheduler、seed 列表、pooling 轴与 checkpoint 细节，故只能做数值层面对比。

本实验以官方仓库修正 MIFlu 在严格 966 行合同下的最终 Test 结果（Test average_MSE_4L = 1.8652，即本报告第 5 节冠军值）与论文在 National-Illness 上报告的目标值直接统一对比。

配置	4 步长均值 MSE	相对论文
论文目标 (National-Illness)	1.4355	—
MIFlu 最终 Test 结果	1.8652	+29.9%

MIFlu 最终 Test 均值 1.8652 相对论文目标 1.4355 高 +29.9%（绝对差 +0.4297）；四个预测步长均未进入论文预声明 ±0.10 带（即 5% 容差未达成）。

论文复现裁决

PARTIAL_REPRODUCTION（部分复现）。MIFlu 最终 Test（1.8652）仍高于论文目标（1.4355）约 30%，5% 容差未达成；注意 MSE 不是准确率，差距部分源于未完全可复原的合同细节（optimizer/scheduler/seed）。

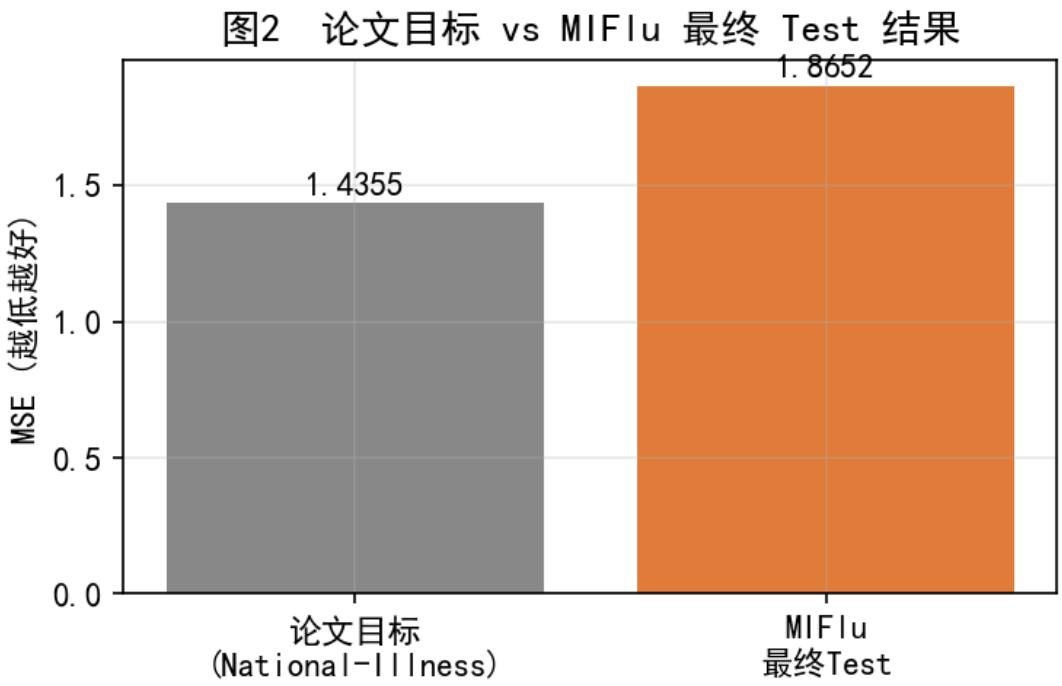


图 2 论文目标 vs MIFlu 最终 Test 结果（灰=论文目标 1.4355，橙=MIFlu 1.8652）。

4 4×LLM 与 4×非 LLM 方法

最终对比八个模型：四个非 LLM（NLinear、DLinear、PatchTST、iTransformer）+ 四个 LLM 侧（MIFlu、TimeCMA-LLM、Qwen-Time-LLM、CALF-LLM）。

• 共 8 模型 × 4 步长 × 3 种子 = 96 个 Test 单元；其中 84 个由冻结预测重新评分，12 个 MIFlu 单元重新训练。

• Validation 仅用于 checkpoint 选择；Test 在 checkpoint 选定后仅评估一次。

• 所有八模型使用相同的 canonical Test key（见封面 Test 关键 SHA），确保可比。

5 最终 Test 结果

本节能是报告最突出部分：八模型以 Test average_MSE_4L（z 空间，四步长平均）排名。

排名	模型	Test avg_MSE_4L	SD	备注
1	MIFlu (官方仓库修正版)	1.8652	0.0916	MAE 0.8842；总冠军；各步长/种子均第一
2	NLinear	2.0495	0.0299	
3	DLinear	2.3478	0.0040	
4	TimeCMA-LLM	2.6700	0.0177	最佳 LLM
5	PatchTST	3.9205	0.0543	
6	iTransformer	3.9847	0.0317	
7	Qwen-Time-LLM	5.2196	0.0701	
8	CALF-LLM	5.5153	0.0307	

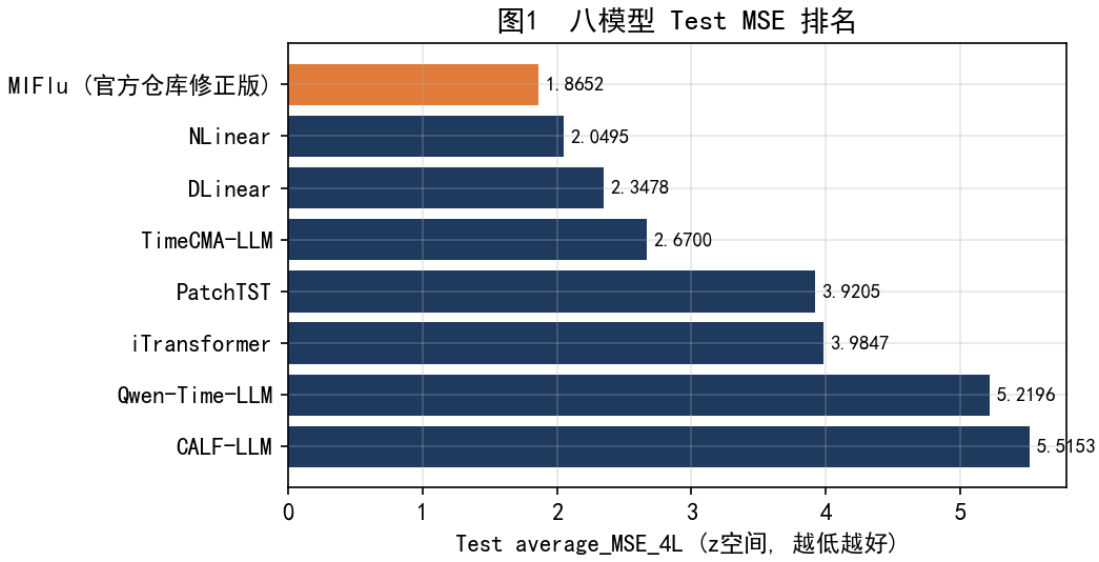


图 1 八模型 Test MSE 排名（越低越好；橙色为冠军 MIFlu）。

为何 Test 单独决定冠军

Validation 仅作 checkpoint 选择；若以 Validation 排名则引入选择偏差。Test 在选定 checkpoint 后仅评估一次，是唯一的、未参与选择的公平裁决集。

关键结论：

- 每个步长冠军：MIFlu 在 L24/L36/L48/L60 均第一。
- 每个种子稳定：MIFlu 在 seed 42/43/44 上均第一。
- 最佳非 LLM（即总冠军）MIFlu 1.8652；最佳 LLM 为 TimeCMA-LLM 2.6700。

• 组均值：选中非 LLM 组 3.0756 < LLM 侧组 3.8175，非 LLM 组更优。

• MIFlu 在 12 个匹配 seed–horizon Test 单元中以 11/12 击败 NLinear。

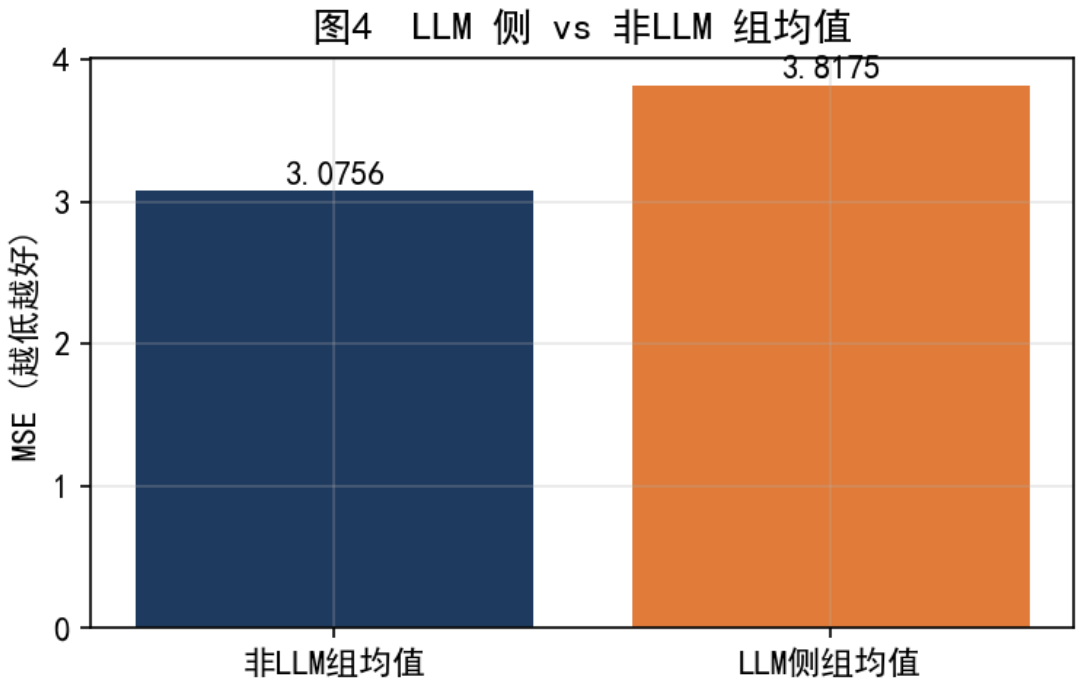


图 4 非 LLM 组均值 vs LLM 侧组均值（越低越好）。

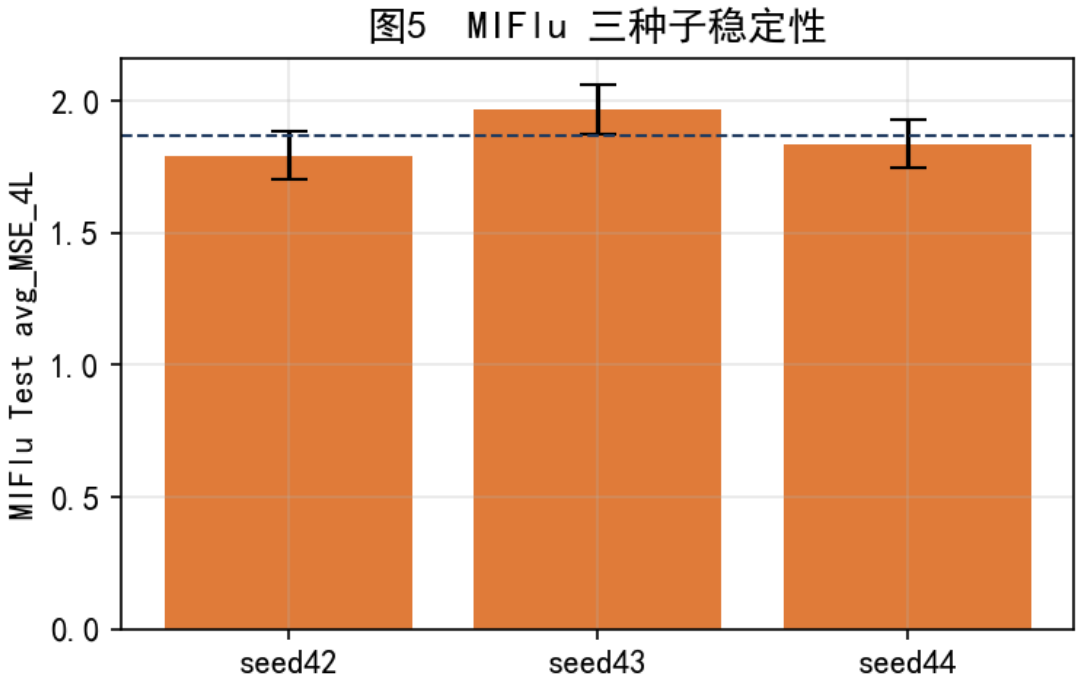


图 5 MIFlu 三种子 Test MSE 稳定性（虚线为均值 1.8652，误差棒为 SD 0.0916）。

6 PTE 与 PIE 补充评估

峰值评估目标变量：ILITOTAL（national-illness 主流感活动指标，索引 4）。季节定义：Test 窗口 2016-10-25 → 2020-06-30；该窗口仅末 26 周（2020 春）含 ILI 骤降，不含 2021 异常峰值。采用文献标准（Kramer & Shaman 2019）：PTE = 预测与真实峰值周之差（周）；PIE = |预测−真实峰值强度| / 真实峰值强度。

文献接受标准（Kramer & Shaman 2019）：PTE ≤ 1 周 且 PIE ≤ 25%。本评估仅采用该文献标准作为峰值命中判定。

模型	文献通过 (≤1 周&≤25%)	共
NLinear	36/36	36
DLinear	31/36	36
MIFlu	15/36	36
Qwen-Time-LLM	1/36	36
iTransformer	0/36	36
PatchTST	0/36	36
CALF-LLM	0/36	36
TimeCMA-LLM	0/36	36

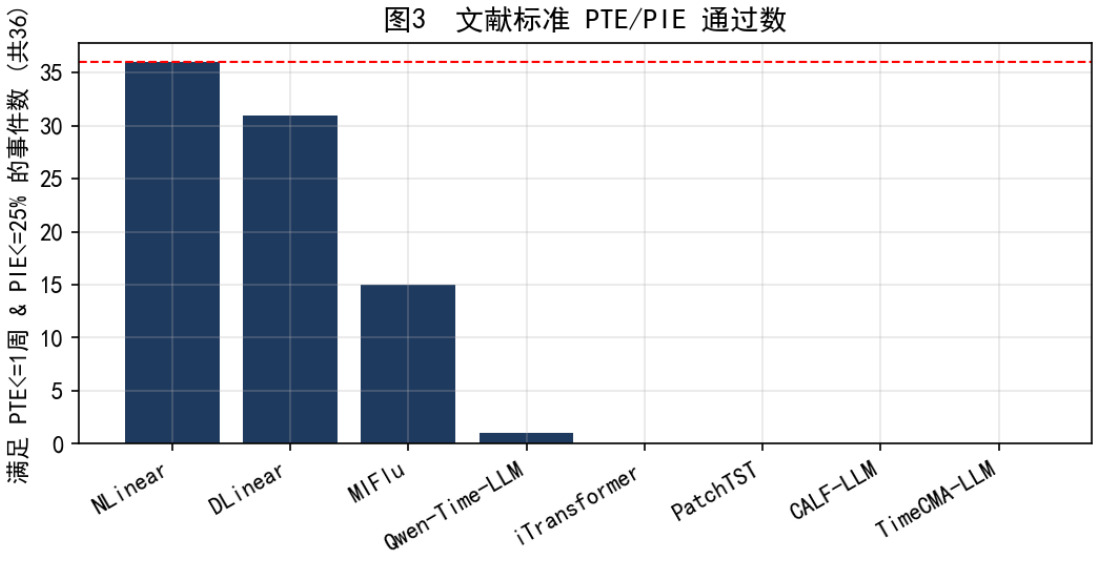


图 3 文献标准 PTE/PIE 通过事件数（共 36；虚线为满分 36）。

PTE/PIE 与 MSE 冠军的关系

NLinear 通过 36/36（100%），DLinear 31/36，而 MSE 冠军 MIFlu 仅 15/36（41.7）。说明峰值时机/强度准确性与 MSE 排名不一致：MSE 冠军不等于峰值冠军，二者分别报告，且 PTE/PIE 不改变 MSE 冠军裁决。

停止准则敏感性（Track S 补充）：以 patience=5 早停重跑同一 MIFlu 配置，12 次拟合中 11 次与冠军结果完全相同，仅 1 次因早停在局部验证谷回滚而偏差 +0.144。两停止规则结果等价，不影响冠军排名（详见 Track S 决策）。

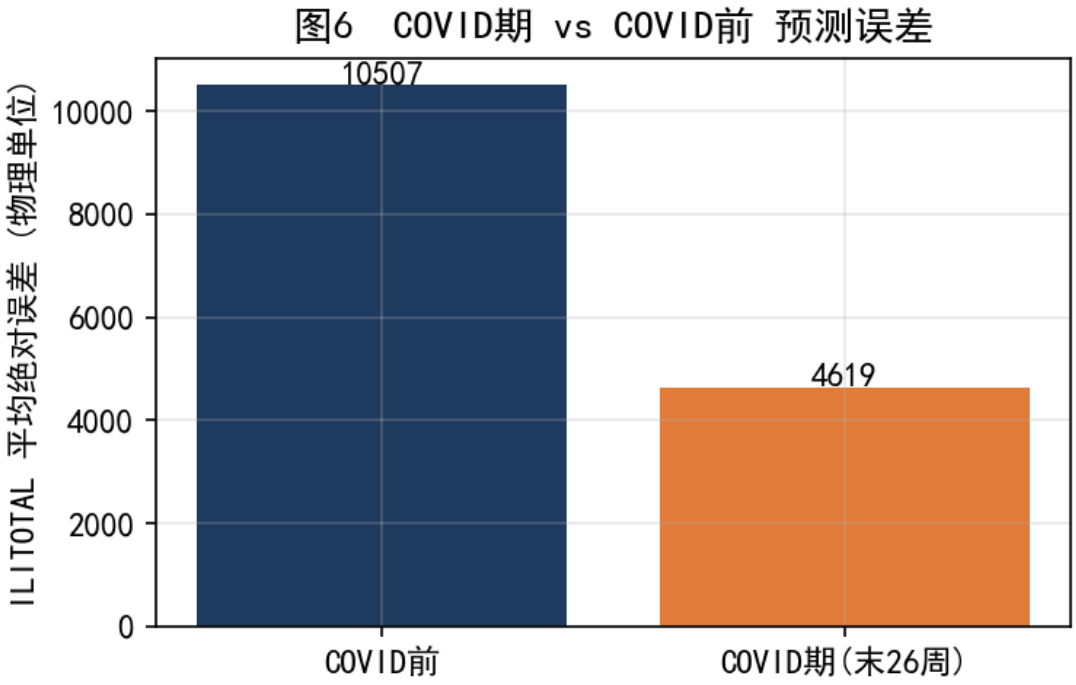


图 6 COVID 期 vs COVID 前 ILITOTAL 平均绝对误差（物理单位）。

7 主要局限

- 仅三个种子（42/43/44），统计把握度有限。
- 四个预测步长并非独立同分布（同数据不同 lead，相关）。
- Qwen/CALF/TimeCMA 为受启发的简化实现，非论文精确原版。
- 论文复现仍为部分复现（5% 未达）；optimizer/scheduler/seed 未完全可复原。
- 区域性/少样本等论文 artifact 不可用，无法复现其对应表。
- 冠军声明为合同特定（本严格 966 行 Test 合同），不宣称全局最优。

8 最终结论

在冻结的 AUTHOR_966_STRICT_CONTAINMENT_8MODEL_TEST_CHAMPIONSHIP 合同下，MIFlu（官方仓库修正版）以 Test average_MSE_4L = 1.8652（SD 0.0916）成为八模型冠军，且为最佳非 LLM 模型；最佳 LLM 为 TimeCMA-LLM（2.6700）。选中非 LLM 组（3.0756）优于 LLM 侧组（3.8175）。论文在 National-Illness 上达到部分复现（MIFlu 1.8652 vs 论文 1.4355，+29.9%，5% 未达）。严格包含修正消除了旧切分污染。PTE/PIE 为补充临床/季节指标：NLinear 峰

值表现最佳（100%），MIFlu 仅 41.7%，二者与 MSE 冠军分开报告。所有结论限于本合同范围，不宣称通用模型优越性。

附录 A 轨道定义与报告权威性

• Track H：历史 1025 行实验（已归档，SUPERSEDED_HISTORICAL_REPORT）。

• Track R：作者 966 行论文复现（R1-B/R1-C）。

• Track C：作者 966 行严格 Test 冠军赛（冻结，权威）。

• F1/R1-C/Track S：移至本版补充方法/局限，非主结论轨道。

• Track S 裁决：停止准则敏感性实验（=SENSITIVITY_AND_SUPPLEMENTARY）；另有一处“S-track”标签为存储基础设施陈旧标签（=STALE_LABEL），与结果无关，不进入报告。

• 报告权威层级：历史报告 SUPERSEDED_HISTORICAL_REPORT；v2 报告 COMPREHENSIVE_EVIDENCE_REPORT；本精简终版 CURRENT_AUTHORITATIVE_FINAL_REPORT。

• 工程修正摘要：自搭 MIFlu→官方仓库修正版；1025→966；污染窗口→严格包含；Validation 排名→一次性 Test；部分模型→全八模型。

• 被阻断的论文项：区域性/少样本表（artifact 不可用）；精确 optimizer/scheduler/seed（未完全披露）。

• 数据 SHA：2a96dfed7db532f0a36b6fddb3f4091e665b3d36b7662292589e3bbca95ebfe5

• Test 关键 SHA：7c7374dc6cb9a7fcd9865adb8341bed24390b18d5dcd2a58d6cad67a13e8504f