导师会议简报（中文）—— 最终 Test/Holdout 结果

一句话结论： Wave-1 验证集冠军 `gpt2_miflu`（0.771）**没有**泛化到留出的 COVID 时代 Test 窗口——在那里，简单线性模型 `nlinear`（2.739）显著优于它（3.051，$p = 4.0\times10^{-4}$）；两个模型仍优于零参数的 `seasonal_naive` 基线（4.279），后者在分布偏移下崩盘。

导师必须看到的三件事

事实一：验证集排序在 Test 上反转

模型	验证集 avg MSE 4L	Test avg MSE 4L	95% CI（Test）
`nlinear`	1.070	**2.739**	[2.731, 2.747]
`gpt2_miflu`	**0.771**	3.051	[2.922, 3.179]
`seasonal_naive`	0.771	4.279	不适用

冠军的验证集优势是窗口特异的。Test 上 `nlinear` 在**全部四个时长**都更好（L24 +0.413，$p = 0.004$；L36 +0.477，$p = 0.004$；L48 $p = 0.055$；L60 $p = 0.175$）。确认性检验 C1（配对 $t = 5.46$，$p = 4.0\times10^{-4}$，Holm 校正）拒绝"两者相等"的假设。

事实二：季节性不是预测——基线在 Test 上崩盘

	验证集	Test	差距
`seasonal_naive`	0.771	4.279	**+3.51**

验证集上 `seasonal_naive` 与 `gpt2_miflu` 打平——它的成功只是记住了 2016–2018 强季节时段的形状。在 COVID 时代 Test 窗口上，它以巨大差距成为最差模型，峰值强度误差高达 124%。这是本研究最清晰的证明："重复去年"不是预测。

事实三：`nlinear` 是 Test 上最好的运维模型（而且最简单）

	参数量	Test avg MSE 4L	Test PIE（峰值强度）
`nlinear`	2,520	2.739	9–21%（命中 75–94%）
`gpt2_miflu`	1,030,056	3.051	41–62%

对疫情检测真正重要的峰值强度预测而言，`nlinear` 大幅领先。两个学习模型仍优于基线（C2 $p = 4.6\times10^{-9}$，C3 $p = 7.7\times10^{-21}$）。

与导师讨论 / 决定的问题

1. **最终叙述框架：** 论文标题是否应为"简单线性预测器在留出数据上优于 LLM"，而非任何"LLM 优越"主张？
2. **冠军身份：** 冻结的 Wave-1 选型作为验证集结果成立，但 Test 赢家是 `nlinear`。如何措辞"冻结选型"与"最终推荐"，使两者互不矛盾？
3. **`seasonal_naive` 作为正式基线：** 其验证集 vs Test 的崩盘是最具说服力的结果——是否将其提升为主表基线？
4. **成本论证：** `nlinear` 参数量少 409 倍、训练快约 28 倍，如今 Test 上还更准确。LLM 机制在最终论文中是否还保有存在理由？
5. **局限性措辞：** Test 窗口是单个连续 COVID 时代窗口——确认我们明确写出"分布偏移与 COVID 混淆"，而非过度声称稳健性。

快速数字（可引用）

- Test 主要指标：`nlinear` 2.739、`gpt2_miflu` 3.051、`seasonal_naive` 4.279。

- 确认性（均 Holm 显著，m = 3）：C1 gpt2 对 nlinear $p = 4.0\times10^{-4}$；C2 gpt2 对 seasonal $p = 4.6\times10^{-9}$；C3 nlinear 对 seasonal $p = 7.7\times10^{-21}$。
- 验证集到 Test 差距：nlinear +1.67、gpt2 +2.28、seasonal +3.51。
- Test 峰值强度（PIE）：nlinear 9–21%、gpt2 41–62%、seasonal 50–124%。
- 完整性：84/84 运行、25/25 终端审计、无第 85 个任务、冻结脚本哈希未变。

产物路径： 完整报告 `MIFlu_Final_Supervisor_Report_EN.md` / `_ZH.md`（及 .docx/.pdf）；指标与图表位于 `results/v3_clean/final/`。