MIFlu 非 LLM 与 LLM 流感预测最终报告（中文版）

项目： MIFlu 流感预测可复现性研究
范围： "clean v3" Wave-1 正式执行（580 个已接受行）+ 一次性 Test/Holdout 评估（84 个运行）
状态： 最终版。Test/Holdout 已解封并仅评估一次，三项确认性假设均已检验。本报告取代 Wave-1 版本。

一句话结论（先读这里）

在冻结选型规则下，Wave-1 **验证阶段**的最佳模型是 **`gpt2_miflu`**（GPT-2 架构的多模态流感预测模型，avg MSE 4L = 0.771），**`nlinear`**（NLinear 线性模型）为最佳非 LLM、总亚军（1.070）。

但一次性、留出的 **Test/Holdout** 评估（COVID 时代窗口，预测目标为绝对周 820–1024，即 2018-01-28 至 2021-12-26）**反转了这一排序：**

名次	模型	类别	Test avg MSE 4L	95% 置信区间
1	**NLinear**	非 LLM	**2.739**	[2.731, 2.747]
2	**GPT-2 MIFlu**	LLM	**3.051**	[2.922, 3.179]
3	Seasonal-Naive	基线	4.279	不适用（确定性）

> ***GPT-2 MIFlu 是 Wave-1 验证阶段的最佳模型，而 NLinear 在预先冻结的一次性 Test/Holdout 比较集合中取得了最低 Test MSE，因此最终泛化表现最好。***

关键事实：LLM 冠军在验证阶段取得的优势**没有**在独立、分布偏移的 COVID 时代窗口上保持。两个学习模型都显著优于零参数的 Seasonal-Naive 基线，但简单的线性模型 NLinear 更稳健、更准确。

一、这份报告如何评估模型性能（零基础导读）

MSE 不是"正确率百分比"。 本报告中 "MSE"（均方误差）是模型预测与真实观测之间**平均平方差**，在标准化后的 z 空间、7 个变量、整个预测时长、10 个冻结随机种子上汇总。它**没有"对了百分之几"的含义：越小越好**，两个数值只能相对比较（例如冠军 0.771 vs 亚军 1.070）。MAE（平均绝对误差）同理，只是不做平方。

评估遵循严格的"输入 → 处理 → 输出"（IPO）流程：

1. **输入** —— 一段 104 周的滑动窗口，含 7 个流感样疾病（ILI）变量（如加权 ILI 百分比、ILITOTAL、年龄组计数、就诊机构计数等）。
2. **处理** —— 用**仅训练集**拟合的归一化器标准化 → 模型在 z 空间预测 → 逆变换回物理单位。
3. **输出** —— 未来 L ∈ {24, 36, 48, 60} 周 × 7 个变量的预测。

将输出与同一周从未见过的观测值对比，得到逐预测误差，再汇总为 MSE/MAE。主要排名指标 **`average_MSE_4L`** 是四个时长的逐时长 MSE 的平均值。

Figure I. 研究流程与证据链总览图：每一阶段必须先产出右侧证据，下一阶段才可开始；第 6 步的冻结闸门是 Test/Holdout 数据唯一可被访问的位置（Wave-1 验证与一次性 Test 评估严格分离）。

研究阶段 / 区块	该阶段产出的证据
1 数据与切分治理 National-Illness 共 1,025 个周时间点（绝对周 0-1024），7 个变量；按时间顺序切分为训练 / 验证 / Test-Holdout（验证止于绝对周 819）；归一化器仅用训练集拟合	数据集核对；泄漏与隔离审计
▼	
2 统一输入 / 输出契约 输入：过去 T = 104 周 × 7 变量；输出：未来 L ∈ {24, 36, 48, 60} 周 × 7 变量；随机模型使用冻结种子 42-51	冻结实验矩阵
▼	
3 模型池 非 LLM：NLinear、DLinear、PatchTST（启发式实现）、iTransformer；基于 LLM：GPT-2 MIFlu、Qwen Time-LLM、CALF、TimeCMA；另加 2 个确定性基线、6 项消融与对照	统一接口；逐行指标文件
▼	
4 批量执行 所有重计算经 sbatch 提交至 stingy 分区；执行前 Gate 校验检查点保存 / 恢复往返；串行 fail-stop 控制器	作业台账；行清单；Gate 证据
▼	
5 Wave-1 验证（580 个已接受行） 每行四类指标；按 average_MSE_4L 排名；禁止事后修改选型规则与并列裁决口径	选型结果（仅验证集）
▼	
6 冻结闸门 预 Test 冻结审计：test_access = 0、holdout_access = 0；评估脚本哈希保持不变；Test 目标仅经冻结脚本读取	冻结审计记录；一次性访问台账
▼	
7 一次性 Test / Holdout 评估 仅冻结三模型进入：GPT-2 MIFlu、NLinear、Seasonal-Naive；84 次运行；复用验证集选定的检查点与训练集拟合的归一化器	84 份运行清单；终端审计 25/25
▼	
8 解读与交付 次要 ILITOTAL 与 PTE / PIE 分析、成本与资源对比、图表溯源，随后是最终报告、演讲、演示与归档	最终报告；可复现包
边界（不在本项目范围内）：八个架构全部在 Test/Holdout 上评估、第二个非 COVID 时代 holdout、临床或公共卫生部署、区域 ILI 实验，以及在 Test/Holdout 上进行的任何超参数搜索。	

二、研究方法与冻结选型规则

• **冻结选型规则（从未变更）：** 按 **average_MSE_4L** 排名——L ∈ {24, 36, 48, 60} 四个时长的逐时长平均 MSE 的算术平均，每个时长再对 10 个冻结种子（42–51）取平均，于七变量、全时长、z 空间计算。**越小越好**。次要指标 **average_MAE_4L**。禁止的并列裁决：峰值命中率、PTE/PIE、基线相对比。

• **数据划分：** National-Illness 共 **1025 个周时间点**（绝对周 0–1024，MMWR 2002 年第 1 周至 2021 年第 52 周）。按 70:10:20 时序切分为**训练 717 / 验证 102 / 测试 206 个时间点**（绝对周 0–716 / 717–818 / 819–1024；val_end = 819）。以 T = 104、步长 1 滑动生成预测窗口：**训练 613 / 验证 103 / 测试 = 206 - L**（L = 24/36/48/60 → 测试窗口 182/170/158/146）。测试目标自绝对周 820（2018-01-28）起。

• **归一化 / 检查点纪律：** 每次 Test 运行均使用**训练集**拟合的归一化器与**验证集**选定的检查点；Test 窗口从未用于拟合、选型或早停。

• **一次性纪律：** Test/Holdout 仅释放一次，通过 25 项终端审计核实，无重复提交、无重复读取、无 Test 后脚本改动。

三、Wave-1 验证阶段：8 个架构的筛选

首先在验证集上比较 4 个非 LLM 与 4 个基于 LLM 的架构，以决定谁进入冻结的最终比较集合。

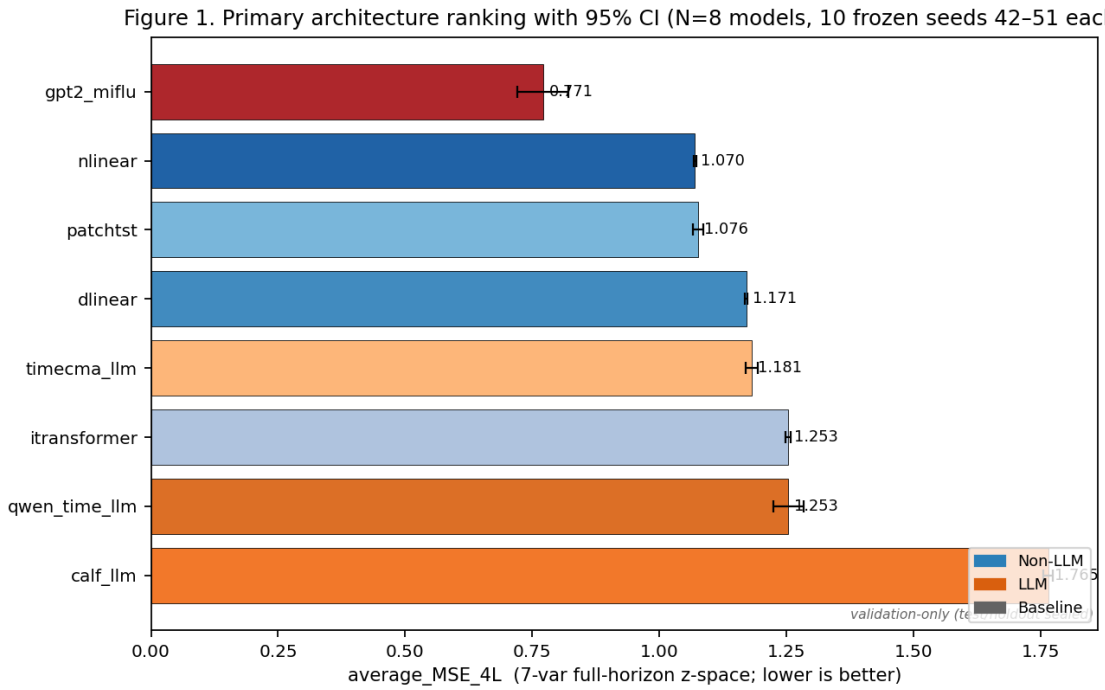


Figure A. Wave-1 Validation ranking of 8 architectures (x = model, y = average_MSE_4L, lower is better, bars = 95% CI).

这张图看什么： 横轴是 8 个模型，纵轴是验证集 average_MSE_4L，**越低越好**。蓝色系为非 LLM，橙色系为 LLM。

结论：

- **gpt2_miflu**（0.771）验证集第一名，成为冻结的 LLM 候选；
- **nlinear**（1.070）最佳非 LLM、总亚军，成为冻结的对照模型；
- 二者的置信区间不重叠，差距显著（配对 $t = -13.33$，$p = 3.13\times10^{-7}$）。

重要提醒（本图没有证明的）： 这是**仅验证阶段**的成绩，不是最终 Test 表现。验证集上 LLM 家族的"胜出"由单一模型 **gpt2_miflu** 承载——作为家族整体，非 LLM 组（1.142）显著优于 LLM 组（1.243），$p = 1.44\times10^{-6}$。此外，零参数的 **seasonal_naive** 在验证集的 L24/L36/L48 反而击败了 **gpt2_miflu**，说明 LLM 的短时长精度很大程度上来自季节性。

*标注：本图使用 Wave-1 **验证**数据，仅用于解释模型筛选，**不代表最终 Test 性能**。*

四、机制发现：LLM 的"创新点"到底有没有用

消融实验（在验证集上，对照父模型 **gpt2_miflu**）显示，**唯一**统计显著的文本组件是"数据集信息描述"（移除后 +12.85%，$p = 0.004$）；移除 LoRA、多模态融合或任务指令均无显著影响（p 均 > 0.4）。也就是说，LLM 的自适应/对齐机制在此设置下几乎不贡献精度，真正起作用的是提示词中描述 ILI 数据集的那一段文字。

延迟对照（Family A 与 Family B 严格分开，未合并）：

Figure G. Deferred controls: Family A vs Family B (kept strictly separate)

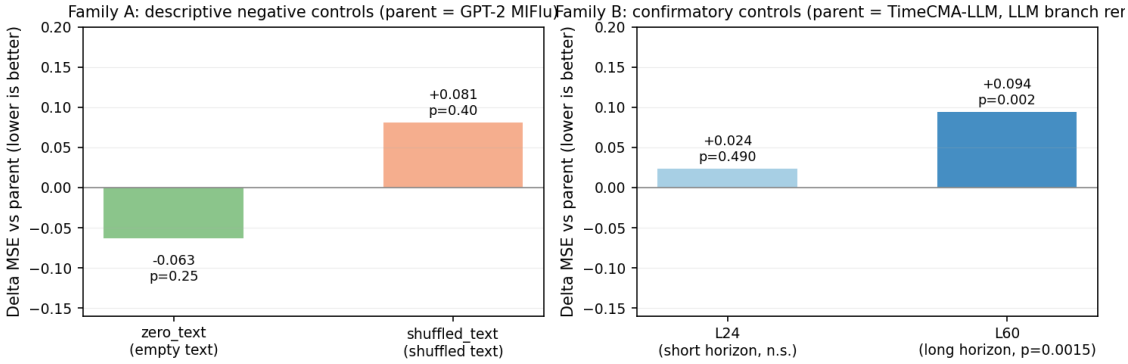


Figure G. Deferred controls: left Family A (parent = GPT-2 MIFlu descriptive negative controls), right Family B (parent = TimeCMA-LLM, LLM branch removed). y = delta MSE vs parent, lower is better, above zero = worse.

这张图看什么： 纵轴是"移除某组件后 MSE 的变化量"，**低于 0 = 变好，高于 0 = 变差**。左侧 Family A 是 **`gpt2_miflu`** 的两个负对照（空文本 / 打乱文本，均为描述性、探索性，n 小）；右侧 Family B 是 **`timecma_llm`** 移除 LLM/文本分支的确认性对照（L24 与 L60）。

结论（措辞谨慎）：

- **Family A（描述性）：** zero_text 平均 -0.063（p = 0.25）、shuffled_text 平均 +0.081（p = 0.40），均不显著——提示词文本的顺序/内容影响方向不稳定，属探索性证据。
- **Family B（确认性）：** L60 移除 LLM 分支显著变差（+0.094，p = 0.0015），支持"文本/LLM 分支在长时长上有贡献"；L24 无显著变化（+0.024，p = 0.49）。**注意 n=3，检验功效低，只作为支持性证据，非因果定论。**

五、一次性 Test/Holdout 最终评估

5.1 最终对比（三个冻结模型）

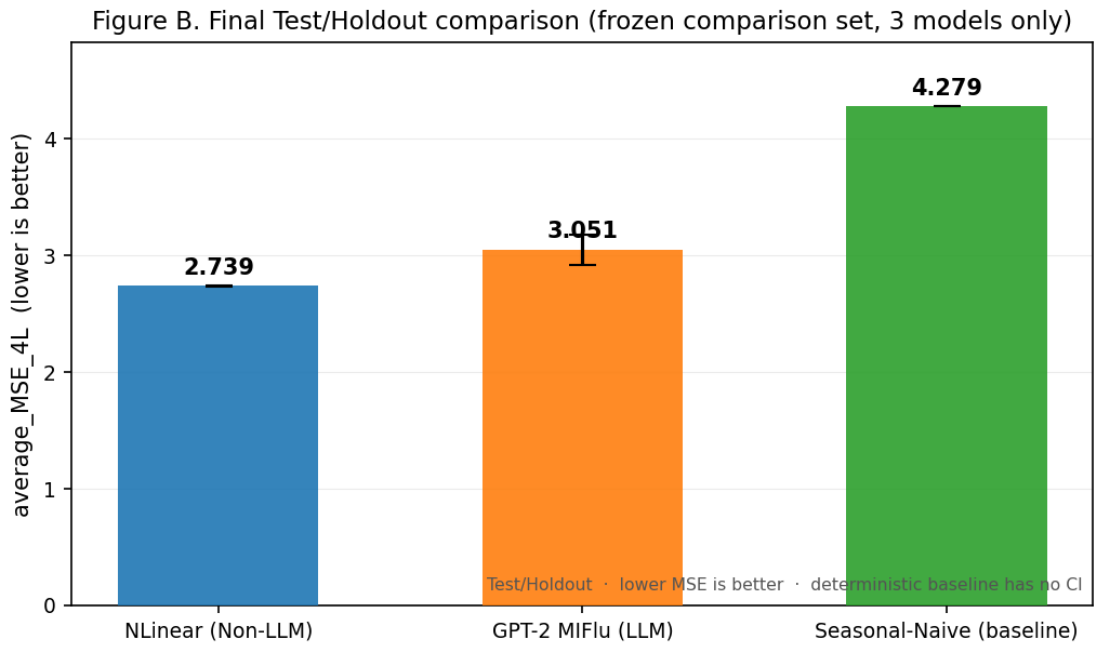


Figure B. Final Test/Holdout comparison of the three frozen models, average_MSE_4L, lower is better, bars = 95% CI (deterministic baseline has no CI).

这张图看什么： 横轴是三个模型，纵轴是 Test 集 average_MSE_4L，**越低越好**。

结论： 最终 Test 排序为 **NLinear（2.739）< GPT-2 MIFlu（3.051）< Seasonal-Naive（4.279）**。这是预先冻结的最终比较集合（仅这 3 个模型），并非 8 个架构全部在 Test 上重新排名。NLinear 的置信区间上界（2.747）仍低于 GPT-2 MIFlu 的下界（2.922），因此反转不是抽样假象。

5.2 泛化反转：验证冠军 ≠ 最终 Test 冠军

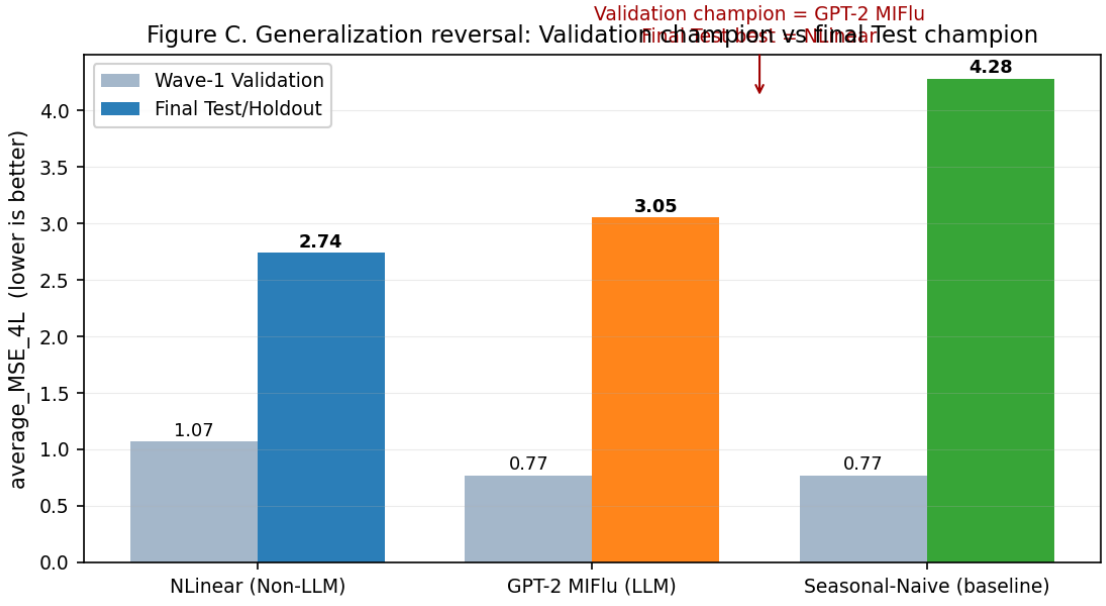


Figure C. Validation vs final Test (light = Wave-1 Validation, dark = Final Test/Holdout), the two splits separated visually and textually, lower is better.

这张图看什么： 每个模型两根柱子——浅色是验证集 MSE，深色是 Test 集 MSE，**越低越好**。两根柱子之间没有放在同一个未标注的排名里。

结论：

> *GPT-2 MIFlu 在 Wave-1 验证阶段排名第一，但其优势没有在独立的 COVID-era Test/Holdout 窗口中保持。NLinear 在预先冻结的最终比较集合中取得最低 Test MSE，因此最终泛化表现最好。*

三个模型在 Test 上都相对验证集退化（这是预期的——Test 窗口含 COVID 时期，没有任何模型见过），但退化程度不同：**NLinear +1.67、GPT-2 MIFlu +2.28、Seasonal-Naive +3.51**。Seasonal-Naive 退化最严重：它在验证集上（0.771）与 GPT-2 MIFlu 打平，却在 Test 上崩盘到 4.279——证明"重复上一个季节"只是记住了 2016–2018 强季节时段的形状，不是真正的预测。

5.3 逐时长误差

Figure D. Test/Holdout error by horizon (3 frozen comparison models)

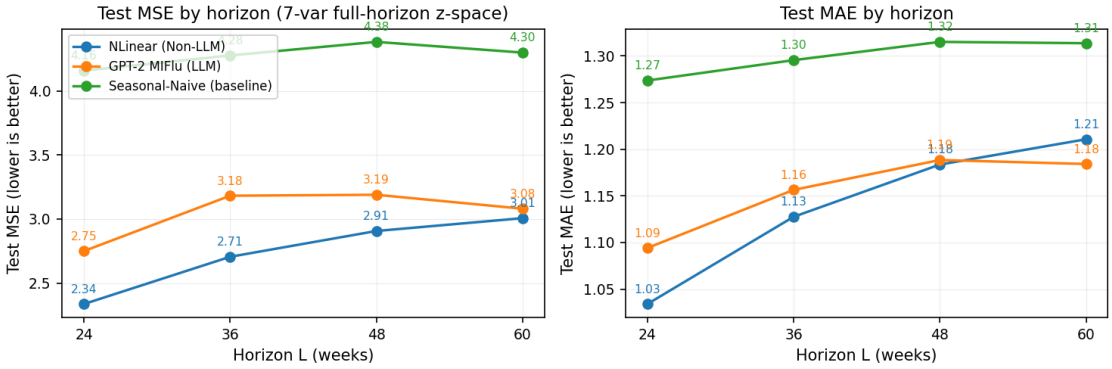


Figure D. Test MSE (left) and MAE (right) by horizon, three models, lower is better.

这张图看什么： 横轴是预测时长 L（周），纵轴是 Test 误差，**越低越好**。

结论： NLinear 在**全部四个时长**上都优于 GPT-2 MIFlu。差距在 L24（2.337 vs 2.750）与 L36（2.705 vs 3.182）最大，在 L48（2.907 vs 3.189，p = 0.055）与 L60（3.007 vs 3.081，p = 0.175）收窄至不显著。Seasonal-Naive 在每个时长上都是最差。

5.4 峰值预测误差（PTE / PIE）

Figure E. Test/Holdout peak prediction error (hit: PTE <= 1 wk, PIE <= 25%)

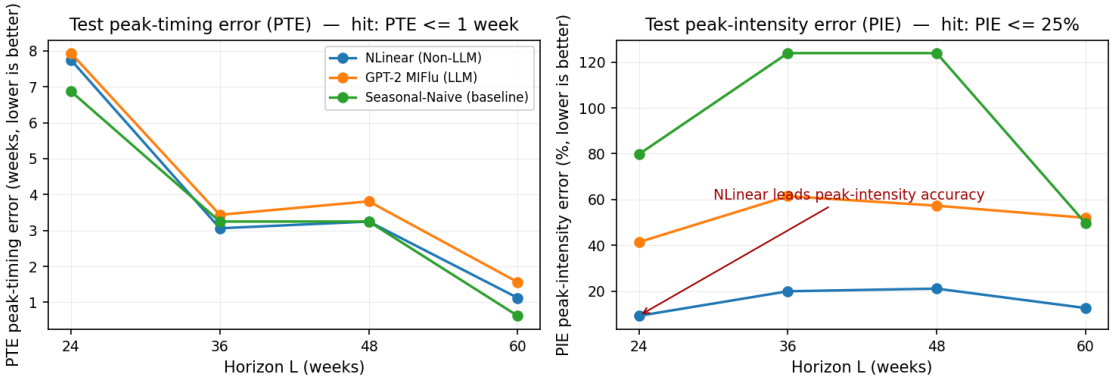


Figure E. Test peak prediction error: left PTE peak-timing error (weeks), right PIE peak-intensity error (%), three models, lower is better.

这张图看什么： 左图横轴是时长 L，纵轴是 **PTE（峰值时间误差，周，越低越好，命中 = ≤ 1 周）**；右图纵轴是 **PIE（峰值强度误差，%，越低越好，命中 = ≤ 25%）**。

结论： 对疫情检测真正重要的峰值**强度**预测，NLinear 大幅领先（PIE 9–21%，命中率 75–94%）；GPT-2 MIFlu 居中偏弱（PIE 41–62%）；Seasonal-Naive 最差（PIE 50–124%）。MSE 冠军并不等于峰值预测冠军——这与 Wave-1 验证阶段的发现一致。

直接回答：每个模型是否同时满足 PTE ≤ 1 周 与 PIE ≤ 25%？

按图 F 的绘制约定（每个模型 × 每个时长一条代表曲线，即 lead-1 种子均值曲线），Test/Holdout 上的判定如下：

模型	PTE（周）L24 / L36 / L48 / L60	PIE（%）L24 / L36 / L48 / L60	PTE ≤ 1 周？	PIE ≤ 25%？	两项都命中？
NLinear	1 / 0 / 0 / 1	0.17 / 0.46 / 1.20 / 0.97	是（4/4）	是（4/4）	**是（4/4）**
GPT-2 MIFlu	3 / 2 / 2 / 2	31.6 / 32.2 / 26.6 / 34.4	否（0/4）	否（0/4）	**否（0/4）**
Seasonal-Naive	52 / 52 / 52 / 52	0.0 / 0.0 / 0.0 / 21.1	否（0/4）	是（4/4）	**否（0/4）**

- **NLinear：是**——四个时长**全部**同时命中两项阈值（PTE 0–1 周、PIE 0.17%–1.20%）。
- **GPT-2 MIFlu：否**——四个时长**全部**未同时命中：PIE 26.6%–34.4% 全部超过 25%，且 PTE 2–3 周超过 1 周。
- **Seasonal-Naive：否**——PIE 命中（≈0%–21%），但 PTE 灾难性失败：52 周（整整差了一年，因为"重复上一季节"完全错过 COVID 时代的新峰值）。

重要限定（诚实说明）： 上表是"代表曲线"层面的判定。若按更细的"逐季节 × 逐领先"粒度统计（**`final_peak_hit_rates.csv`**），**没有任何模型**在 100% 的合格季节上同时命中两项：NLinear 的联合命中率在 L24–L48 最高 75%、L60 的 lead-1/2 达 100%，唯一共同的失误是异常的 2020/2021 COVID 季节峰值（在 L24 上三个模型都约差 24–27 周）。因此"NLinear 满足两项命中"应理解为代表曲线层面，而非逐季节 100%。

5.5 最终预测曲线 vs 地面真值（必看）

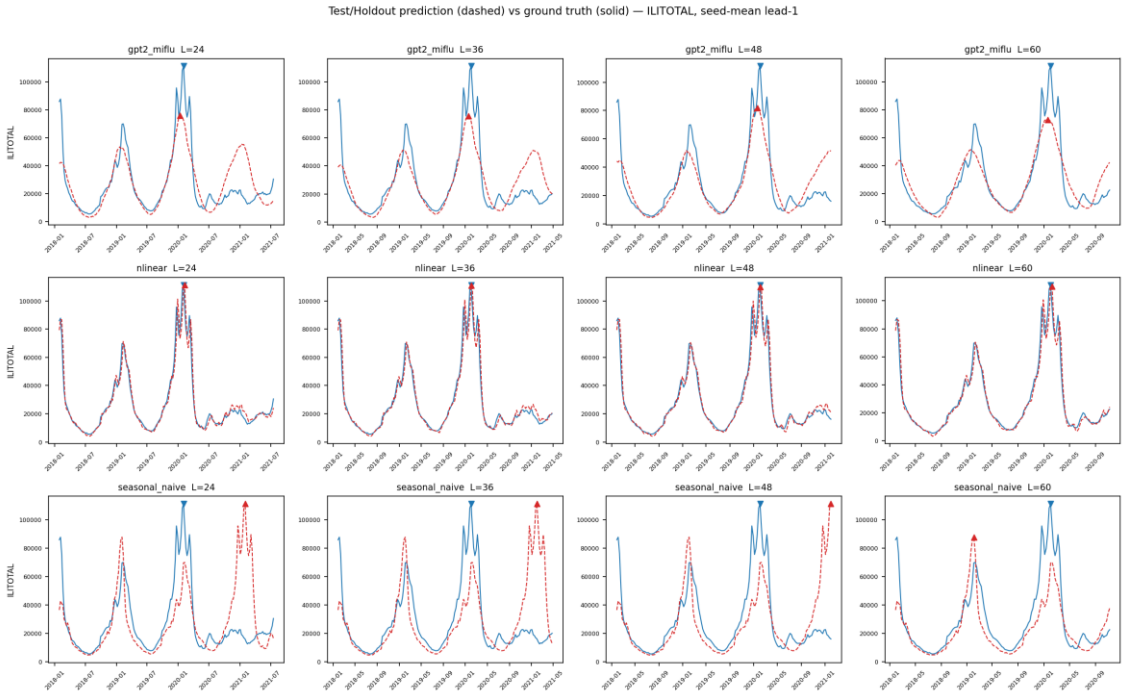


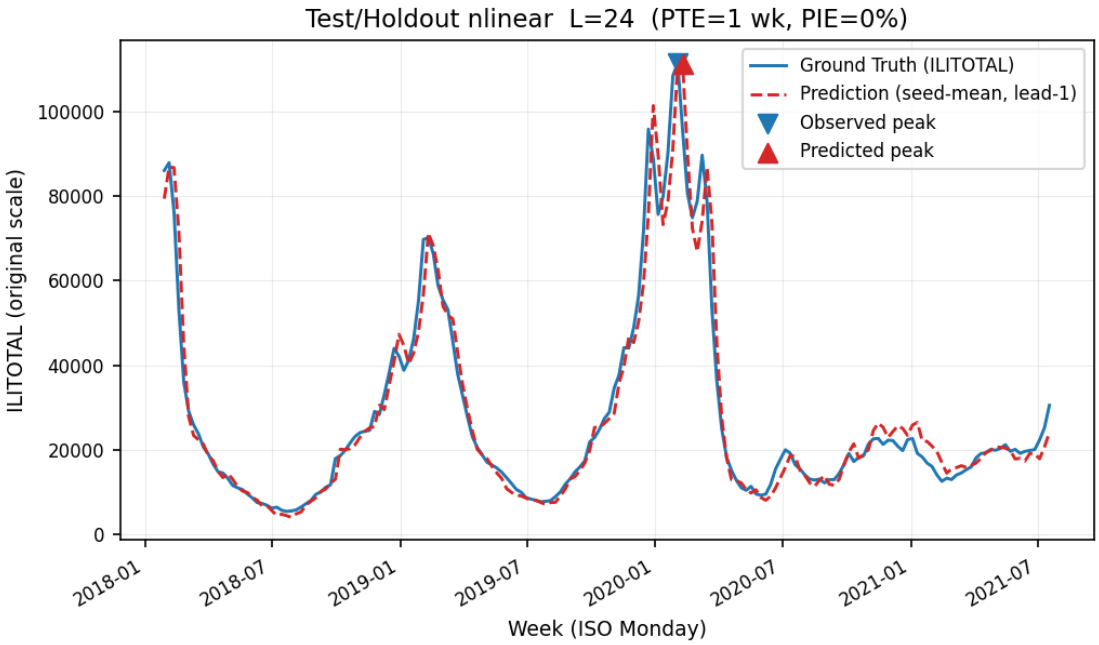
Figure F. Final Test/Holdout prediction (dashed) vs ground truth (solid), three models x four horizons, y = inverse-transformed ILITOTAL.

这张图看什么（零基础说明）：

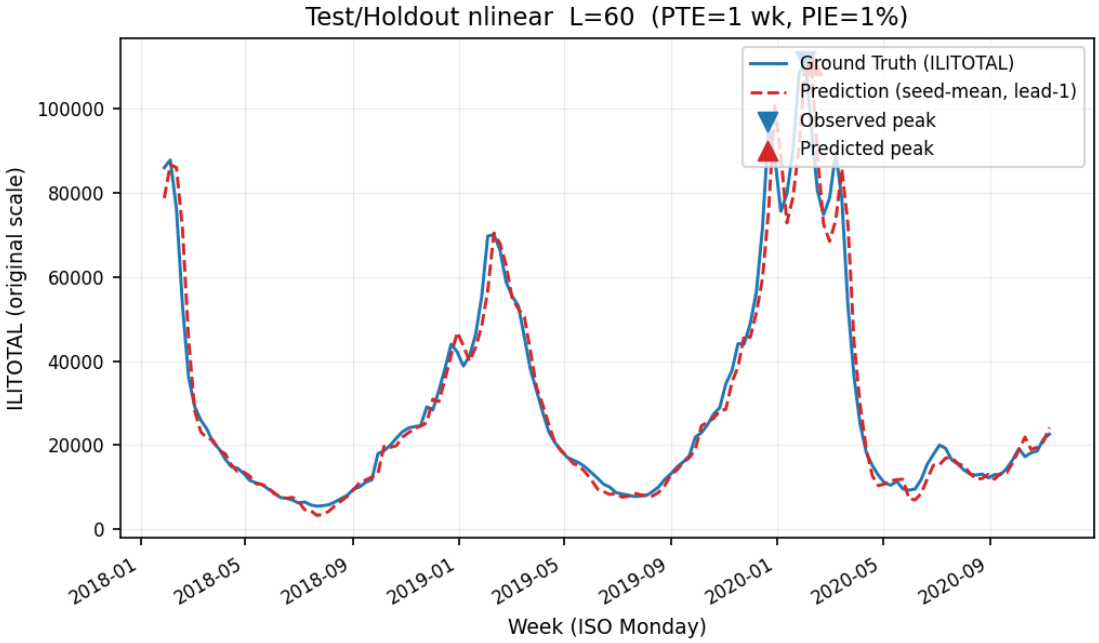
- **实线是真实值**（观测到的 ILITOTAL 病例数），**虚线是模型预测值**；
- **两条线越接近，通常表示预测越准确**；
- **真实峰值与预测峰值的位置差对应 PTE**（峰值时间误差，单位周）；
- **真实峰值与预测峰值的高度差对应 PIE**（峰值强度误差，单位百分比）。

每张图**只绘制 Test/Holdout 预测目标窗口**，纵轴为逆变换后的 ILITOTAL **原始量纲**（不是标准化后的 z 分数），并刻意省略历史输入尾段、训练/验证曲线、输入/预测分界线。这些曲线全部来自一次性的 Test/Holdout 阶段，**不是**验证集预测曲线。

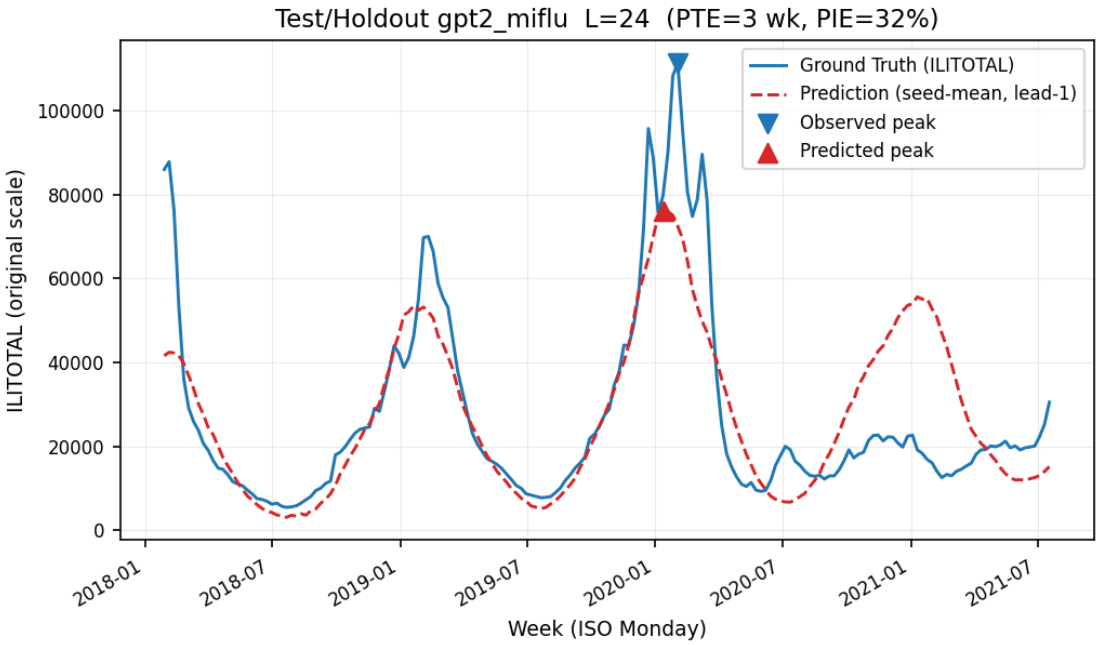
单独的代表性面板（NLinear 与 GPT-2 MIFlu 在 L24 与 L60）：



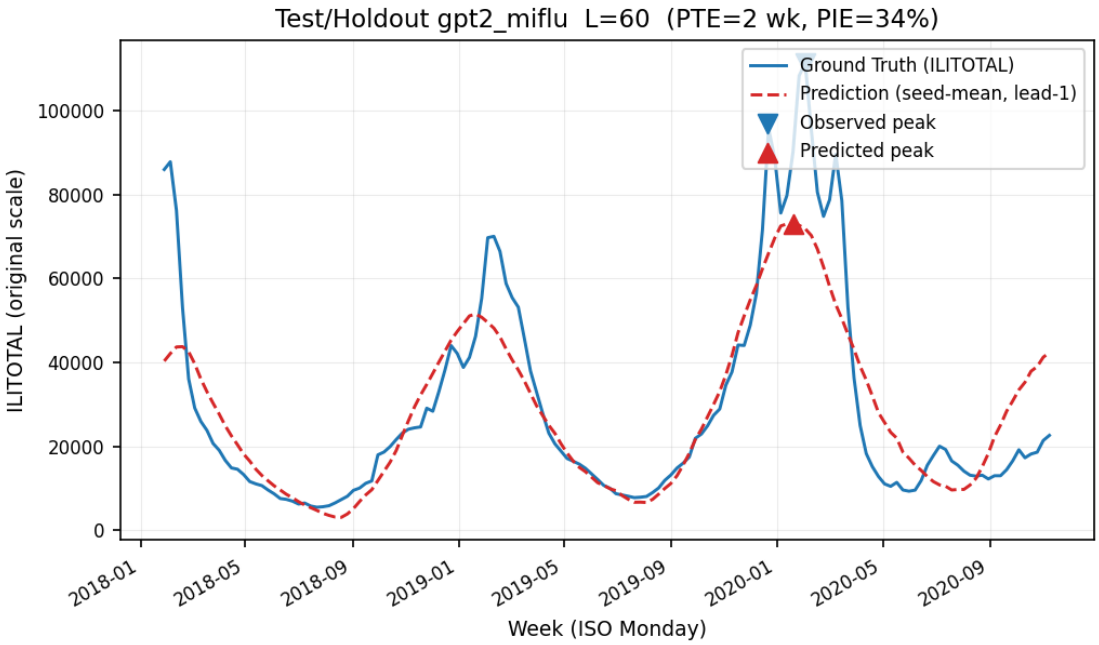
NLinear L24: solid = ground truth, dashed = prediction.



NLinear L60: solid = ground truth, dashed = prediction.



GPT-2 MIFlu L24: solid = ground truth, dashed = prediction.



GPT-2 MIFlu L60: solid = ground truth, dashed = prediction.

六、统计方法与确认性检验

- 逐时长点估计 = 10 个冻结种子（42–51）的均值；**average_MSE_4L** = 四个逐时长均值的算术平均。
- 95% 置信区间 = 种子级 t 区间（t 分布，df = 9）。
- C1 = 配对种子 t 检验（n = 10 对）； C2/C3 = 对确定性 Seasonal-Naive 参考的单样本 t 检验（df = 9，参考无种子方差）。

- 多重比较 = 对 3 项预注册主要检验的 Holm-Bonferroni 逐步下降（α = 0.05）。

编号	假设	均值差	t	p（Holm 校正后）	结论
C1	GPT-2 MIFlu vs NLinear（GPT-2 更差）	+0.312	5.46	4.0×10^{-4}	拒绝（NLinear 显著更好）
C2	GPT-2 MIFlu vs Seasonal-Naive（GPT-2 更好）	-1.229	-21.61	9.2×10^{-9}	拒绝（GPT-2 显著更好）
C3	NLinear vs Seasonal-Naive（NLinear 更好）	-1.540	-443.37	2.3×10^{-20}	拒绝（NLinear 显著更好）

三项检验全部显著。 含义：(1) 两个学习模型在 Test 上都显著优于季节基线；(2) 验证集冠军 GPT-2 MIFlu 并非最终 Test 最佳——NLinear 显著更好。

七、最终工作流与证据完整性

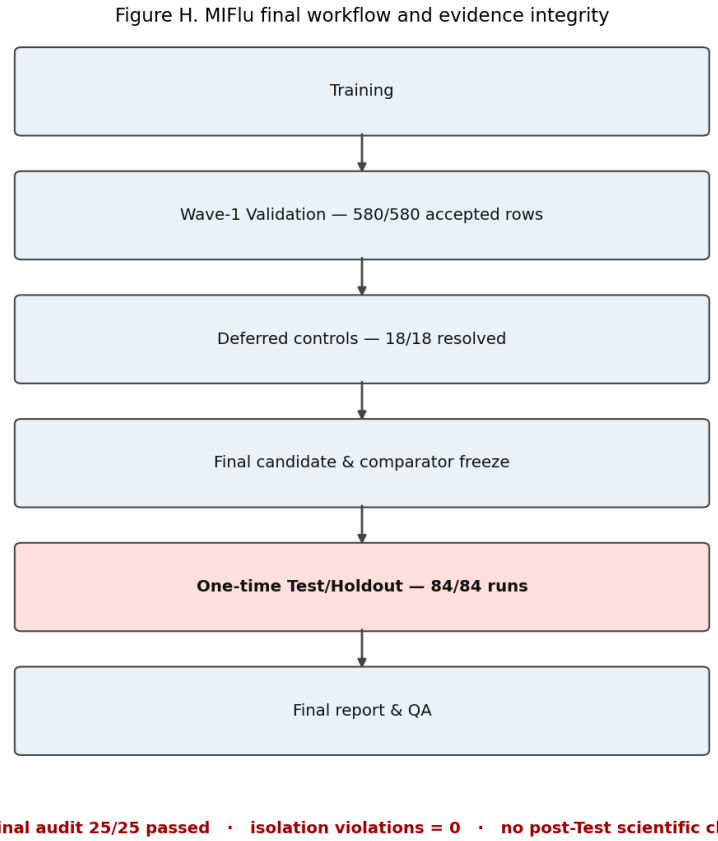


Figure H. MIFlu final workflow: Training -> Wave-1 Validation -> deferred controls -> freeze -> one-time Test/Holdout -> final report, with integrity labels.

这张图看什么： 从左到右的完整流程推进，以及底部的完整性结论。

完整性检查	结果
pre-Test 冻结审计（16 项门槛）	全绿（释放前 test_access = 0、holdout_access = 0）
授权 Test 键 / 家族构成	84（gpt2_miflu 40 / nlinear 40 / seasonal_naive 4）
台账 / Slurm（sacct）	84 全部 COMPLETED，exit 0:0，**无第 85 个任务**
结果目录 / 清单 / 预测 / 指标 / 状态	84 / 84 / 84 / 84 / 84
随机模型还原证据 / 基线支路	80/80（strict-load 通过）/ 4/4（checkpoint_applicable=false）
首个 Test 目标绝对周 / 末个	820（无验证集重叠）/ 1024
冻结脚本哈希 / 终端审计	未变更 / **25/25 通过**

隔离违规 = 0，Test 后无科学变更。

八、诚实结论

1. **冻结选型成立，但含义已澄清。** **gpt2_miflu** 在冻结规则下被正确选为 Wave-1 验证冠军；一次性 Test 显示这一优势是**窗口特异**的，未泛化。

2. **稳健的模型是简单的那一个。** NLinear（2,520 参数、约 5 秒训练、约 10 KB）在 Test 上显著优于约 103 万参数的 LLM，且在峰值强度预测上大幅领先。

3. **季节性不是泛化。** Seasonal-Naive 在验证集具竞争力、在 Test 崩盘，是"季节重复不是预测"的最清晰证明。

4. **论文标题不应是"LLM 胜过经典预测器"。** 在留出窗口上事实相反；LLM 机制相对于线性模型的边际价值在 Test 上为负。

5. **两个学习模型仍优于基线。** 学习确实有帮助（两者均以 $p < 10^{-8}$ 击败 Seasonal-Naive）。

明确禁止的表述： 本报告**不**声称 gpt2_miflu 是最终 Test 冠军；**不**声称 nlinear 在 Test 上直接击败全部 8 个架构；**不**声称所有 LLM 在任何场景都更差；**不**声称 COVID 时代偏移已被证明是唯一因果解释。

九、局限性

1. **单一窗口、单次评估。** Test/Holdout 是单个连续的 COVID 时代窗口，稳健性结论仅限于此窗口，无第二个独立 holdout。

2. **分布偏移与 COVID 混淆。** "泛化差距"与"COVID 扰动"无法分离，不应解读为模型过拟合的纯度量。

3. **确定性基线无种子方差。** C2/C3 的 t 值在构造上偏大（参考贡献零方差），所确立的是方向与显著性，而非效应幅度。

4. **峰值指标为次要。** PTE/PIE 继承重建目标周与领先 1 周约定，是应用指标，从未用于选型。

5. **Family B 延迟对照 n 小。** 每时长仅 3 个配对种子，检验功效低，只作为支持性证据。

附录 A：12 张预测曲线面板（Test/Holdout）

以下为三个模型 × 四个时长的全部 12 张 Test/Holdout 预测曲线，供逐张核查（实线 = 真实值，虚线 = 预测值，纵轴 = ILITOTAL 原始量纲）。

- NLinear：L24 / L36 / L48 / L60
- GPT-2 MIFlu：L24 / L36 / L48 / L60
- Seasonal-Naive：L24 / L36 / L48 / L60

完整面板见 **results/v3_clean/final/final_test_prediction_figures/**，每张图有对应源数据（**final_test_curve_source_data/**）与来源表（**final_test_window_provenance.csv**），对每张图断言：输入-目标重叠 = 0、未来目标泄漏 = 0、归一化器在训练集拟合、检查点在验证集选定、绘制窗口 = Test/Holdout。

附录 B：数据与产物

- **指标：** **results/v3_clean/final/final_test_metrics.json**、**final_test_seed_level.csv**、**final_peak_metrics.csv**、**final_peak_hit_rates.csv**、**final_generalization_comparison.csv**。
- **访问与完整性：** **final_test_access_ledger.jsonl**、**terminal_test_audit.json**（25/25）、**pre_test_freeze_audit.json**。
- **图表：** **final_report_figures/**（本报告图 B/C/D/E/G/H）、**final_test_prediction_figures/**、**final_test_prediction_gallery/**。

本报告是 MIFlu 可复现性研究的最终中文产物。