MIFlu 非 LLM 与 LLM 流感预测最终报告

——作者官方仓库复现、966 行严格测试八模型冠军与历史结果修正版

Official-repository reproduction, strict-containment Test championship and historical comparison correction

项目	内容
生成日期	2026-10-07
报告版本	v2
仓库 commit	5304f9473e8f67b97c23abda1b31775439d5a353
作者数据 SHA-256	2a96dfed7db532f0a36b6fddb3f4091e665b3d36b7662292589e3bbca95ebfe5
严格 Test 键集 SHA-256	4ad79bb14b2cc11ec3ae1e07e13ae4bdcf41a87161d5149774ab1a94f95d1961
最终结果目录	/gpfs1/home/sychan552/official_repo_reproduction_20261006/strict966_championship_20261007
当前正式报告	官方仓库 966 行严格测试冠军版（本 v2 通过审计后接管）
历史报告状态	已归档为 SUPERSEDED_HISTORICAL_REPORT，不再作为当前最终结论

本报告为完整版报告，非缩写摘要。所有表格均由冻结 CSV 工件重新生成，所有数值均可追溯到 Slurm 作业与独立打分器。

目录

目录 2

一、报告版本、文件权限与归档状态 4

二、执行摘要 4

三、项目时间线与轨道划分 5

3.1 Track H（历史 1025 行） 5

3.2 Track R（作者 966 行论文复现） 5

3.3 Track C（作者 966 行严格冠军赛） 6

3.4 Track F1（补充探索性试点） 6

四、论文复现及其剩余数值差距 6

4.1 论文表 V 的已核实目标值 6

4.2 差距计算 6

4.3 剩余差距的可能来源（区分证据等级） 7

五、与项目早期 MIFlu 的比较 8

六、为什么使用 966 行数据 8

七、严格包含与泄漏修正 9

7.1 历史划分边界污染 9

7.2 严格包含规则 9

7.3 三个集合的用途 9

八、八个模型的身份 9

九、冠军赛方法 10

十、最终 Test 排名 10

10.1 分 horizon 结果 12

10.2 分种子结果 13

十一、分组结论 14

十二、配对比较 14

十三、计算与存储 15

十四、工程修正与事故记录 16

十五、局限性 17

15.1 表 III 状态的更正 17

十六、最终结论 17

附录 A　证据路径与哈希 18

附录 B　图表来源对照 19

一、报告版本、文件权限与归档状态

本项目存在两份最终报告。为避免引用混乱，先明确权限：

表 1-1　报告权限清单

报告	轨道	状态	SHA-256
官方仓库 966 行严格测试冠军版（v1）	Track R + Track C	CURRENT（v2 通过审计后由 v2 接管）	f41652ff3d108575a9e93d78…
官方仓库 966 行严格测试冠军版_v2（本报告）	Track R + Track C	CURRENT_AFTER_AUDIT	见 FINAL_REPORT_V2_SHA256.txt
中文版（旧）	Track H	SUPERSEDED_HISTORICAL_REPORT	9c573f48fb65e590c7973223…

数据来源：REPORT_AUTHORITY_AND_ARCHIVAL_NOTE.md

旧报告被取代，不是因为它的陈述为假，而是因为它描述的是另一套实验：1025 行历史数据集、项目自建 MIFlu、存在边界污染的历史划分契约，且最终 Test 仅覆盖三个冻结模型。其结论在自身契约内成立，故分类为 SUPERSEDED_HISTORICAL_REPORT 并完整保留归档，不做删除、不做修改。

二、执行摘要

1. 历史实验（Track H）使用 1025 行数据、项目自建 MIFlu、后来被发现存在边界污染的历史划分契约；八个模型仅在 Validation 上比较，最终 Test / Holdout 只覆盖三个冻结模型。该实验的旧报告已归档。

2. 作者官方仓库是在上述历史实验完成之后才被克隆的。因此历史报告不可能使用官方仓库代码——这是它的时代属性，不是它的缺陷。

3. 已发布的作者代码经审计发现多处实现/评估问题：文本通路失效、LoRA/PEFT 默认不启用、冻结无效、单通道（feature-0）评估、用 Test 辅助选点、以及不保存预测。

4. 修正后的 R1-B 模型恢复了七通道输出、可用的文本通路、有效的 LoRA、有效的冻结、Validation 选点、一次性 Test、预测保存、独立打分与可重载的锁定 checkpoint。

5. 论文层面结果为 PARTIAL_REPRODUCTION。

6. Track C 冠军结果为：基于官方仓库的修正版 MIFlu 是冻结的严格 966 行 Test 契约下最优的单个模型。

7. 在所选实现上，非 LLM 组均值仍优于 LLM 侧组均值。

8. 冠军结论并不意味着论文已被完整复现。

三、项目时间线与轨道划分



图 3-1　按轨道划分的项目时间线

数据来源：TRACK_C_EXECUTION_LOG.md；R1B_CORRECTED_PILOT_REPORT.md

Track separation — scores must never be mixed

Track	Data	MIFlu impl.	Split / windows	Test scope
Track H (historical)	1025 rows	self-built MIFlu	historical split (boundary contamination)	Validation 8 models Test 3 models
Track R (paper repro.)	966 rows	official repo + R1-B corrections	strict containment	Track R only not a ranking
Track C (championship)	966 rows	official repo + R1-B corrections	strict containment 676/97/193	Test-only 8 models, 96 cells
Track F1 (pilot)	966 rows	exploratory	shared eval contract	not used for championship

图 3-2　Track H / R / C / F1 的契约分离

数据来源：TRACK_C_MASTER_CONTRACT.md

3.1 Track H（历史 1025 行）

- 历史 1025 行项目，在作者仓库被克隆之前完成。
- 使用项目自建 MIFlu。
- 旧的 4-vs-4 Validation 比较。
- 历史的三模型 Test / Holdout 实验。
- 划分边界污染（见第八节）。
- 旧报告已归档为 SUPERSEDED_HISTORICAL_REPORT。

3.2 Track R（作者 966 行论文复现）

- 作者 966 行数据上的论文复现工作。
- 已发布代码审计（八项冲突）。
- A0-R：忠实复现已发布行为。

- 修正后的 R1-B。
- 结论为 PARTIAL_REPRODUCTION。

3.3 Track C（作者 966 行严格冠军赛）

- 作者 966 行、严格包含窗口。
- 八个模型、匹配种子 42/43/44。
- 仅由 Test 选出冠军。
- 本报告当前的最终结果。

3.4 Track F1（补充探索性试点）

- 补充性探索试点，不用于最终冠军赛。

跨轨道的分数不得混用。

四、论文复现及其剩余数值差距

4.1 论文表 V 的已核实目标值

表 4-1　论文表 V 目标值与 R1-B 实测值

horizon	论文 MSE	论文 MAE	R1-B MSE	R1-B MAE	Δ MSE	相对 MSE
L24	1.542	0.726	2.1335	0.9298	0.5915	38.4%
L36	1.422	0.779	2.0227	0.9977	0.6007	42.2%
L48	1.414	0.757	1.8413	0.8957	0.4273	30.2%
L60	1.364	0.719	1.7933	0.9116	0.4293	31.5%
平均	1.4355	0.74525	1.9477	0.9337	+0.5122	+35.7%

数据来源：R1B_CORRECTED_PILOT_REPORT.md §2；TABLE_V_REPRODUCIBILITY_VERDICT.md

4.2 差距计算

R1-B 观测到的四 horizon 平均 MSE 为 1.9477。

表 4-2　论文结果差距计算

量	计算	值
论文目标平均 MSE	—	1.4355
R1-B 平均 MSE	—	1.9477
绝对差距	1.9477 − 1.4355	0.5122
相对论文结果差距	(1.9477 − 1.4355) ÷ 1.4355 × 100	约 35.68%

数据来源：PAPER_GAP_REDUCTION_CALCULATION.md

基于证据的官方仓库重建结果，仍比论文报告的四 horizon 平均 MSE 高出约 35.7%。

MSE 是平方误差度量，不是准确率。35.7% 是相对论文报告值的平方误差相对偏差，不得表述为模型准确率百分比，也不得读作“准确率低 35.7%”。

四个 horizon 中，进入预先声明的 ±0.10 MSE 带的数量为：0 / 4。

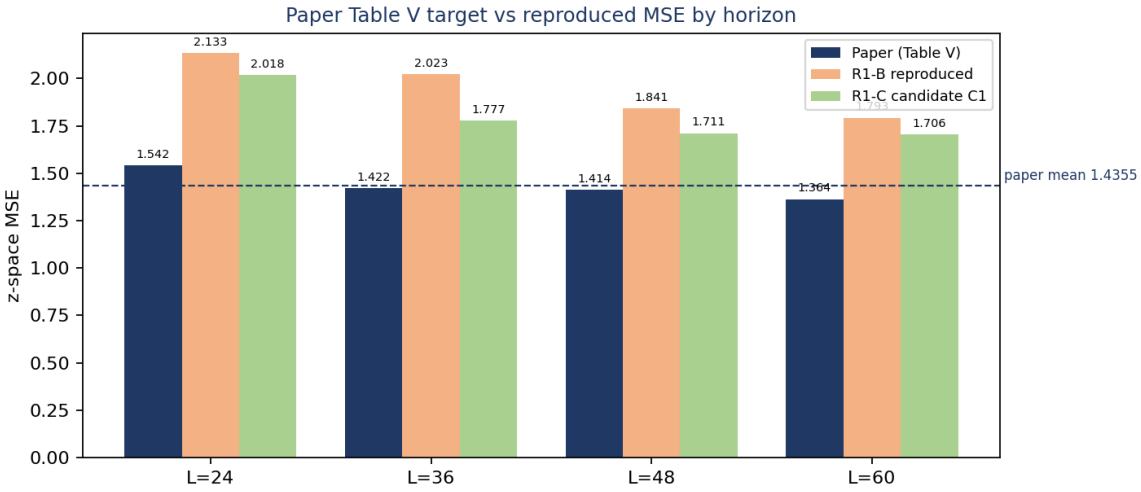


图 4-1　论文目标值与复现值分 horizon 对比

数据来源：PAPER_GAP_REDUCTION_CALCULATION.md；R1C_RESULTS_PER_CANDIDATE.csv

4.3 剩余差距的可能来源（区分证据等级）

表 4-3　剩余差距的可能来源与证据等级

可能来源	证据等级	说明
优化器未恢复	已恢复并匹配	Adam 为已发布默认，R1-B 亦用 Adam
调度器未恢复	已恢复但不匹配	已发布代码使用 type1 衰减；R1-B 未调用。R1-C 已测试（C1）
种子清单未恢复	未恢复	已发布代码中无种子清单
精确选点规则未恢复	未恢复	已发布代码用 Test 选点，论文未说明
精确池化轴未恢复	未恢复	z 空间池化为选择项，非恢复项
已发布代码与论文机制冲突	已确认	八项冲突中四项永久无法解决
已发布数据/代码工件不完整	已确认	缺 US-Region 与 few-shot
硬件/软件版本差异	可能存在	未量化
重复聚合方式差异	未恢复	论文称十次重复，聚合规则未说明

数据来源：R1C_DOCUMENTARY_EVIDENCE.md；R1_PAPER_CODE_CONFLICTS.md

除已标注为“已确认”的项外，不得断言任何单一来源为因果。

五、与项目早期 MIFlu 的比较

不得直接把论文值与 1025 行历史 Test MSE 比较——数据集与契约不兼容。先确定最具可比性的“作者 966 行自建 MIFlu”结果，再逐项核对契约。

表 5-1　契约可比性审计

契约项	旧（自建 A2）	新（R1-B）	可比
同为 966 行数据集	是（SHA 一致）	是（SHA 一致）	✅
同一划分	676/97/193	676/97/193	✅
同一变量	7 通道	7 通道	✅
同一度量空间	z 空间	z 空间	✅
同一 horizon	24/36/48/60	24/36/48/60	✅
同一池化	average_MSE_4L	average_MSE_4L	✅
同一严格起点	170/.../134	170/158/146/134	✅
同一种子策略	3 种子 42/43/44	1 次重复 seed 1000+	❌
同一选点策略	未记录	仅 Validation	❌

数据来源：PAPER_GAP_COMPARABILITY_AUDIT.csv

整体判定：NOT_SUFFICIENTLY_COMPARABLE。存在三项阻断性差异：种子策略（3 种子 vs 1 次重复）、选点策略（旧侧未记录）、以及新侧 SD 为 n/a 因而无法给出任何区间。

因此采用规定表述：由于新旧两次运行使用了不同契约，数值下降百分比不得在无条件限制的情况下给出。

若仅作算术参考（明确不构成主张）：旧相对误差 +42.22%，新相对误差 +35.68%，百分点下降 6.54 pp，差距相对缩小 15.5%。该算术把 3 种子均值与单次重复相除，其中未知比例的差值来自估计量方差，而非实现质量，故不作为结论引用。

使比较成立的做法：以匹配种子 42/43/44（3 次重复）重跑官方仓库修正版 MIFlu，并记录仅用 Validation 的选点策略。该做法已作为 R1-C 候选之一登记，服务于论文差距问题，不改变已冻结的 Track C 冠军结果。

六、为什么使用 966 行数据

- 论文表 II 的七变量描述统计与 966 行作者文件 7/7 吻合。
- 最大偏差约 0.02%。
- 1025 行历史快照仅 1/7 吻合。
- 因此论文相关工作与 Track C 均使用 966 行。
- 划分为 676 / 97 / 193。

数据来源：TRACK_C_MASTER_CONTRACT.md §2；TABLE_II_III_CORRECTION_NOTE.md

七、严格包含与泄漏修正

7.1 历史划分边界污染

历史划分契约中，每个 horizon 都有一个测试起点被错标为 validation，导致窗口跨越划分边界。该键集已经作废并全部重新生成，未参与任何打分。

7.2 严格包含规则

target_start ≥ split_start　　且　　target_end ≤ split_end − 1

7.3 三个集合的用途

表 7-1　三个集合的用途

集合	用途	是否参与最终排名
Train	拟合（含缩放器）	否
Validation	仅用于选择 checkpoint	否
Test	评估一次；单独决定冠军	是

数据来源：STRICT_966_KEY_VALIDATION.md；TRACK_C_MASTER_CONTRACT.md

Validation 指标被排除在最终排名与组均值之外。

八、八个模型的身份

表 8-1　八个模型的身份

模型	族	身份说明
MIFlu	LLM	基于作者官方仓库，并使用修正后的 R1-B 实现
Qwen-Time-LLM	LLM	受启发的简化实现，非其发表系统的完整复现
CALF-LLM	LLM	受启发的简化实现，非其发表系统的完整复现
TimeCMA-LLM	LLM	受启发的简化实现，非其发表系统的完整复现
NLinear	非 LLM	身份与 Track C manifest 一致
DLinear	非 LLM	身份与 Track C manifest 一致
PatchTST	非 LLM	身份与 Track C manifest 一致
iTransformer	非 LLM	身份与 Track C manifest 一致

数据来源：TRACK_C_MODEL_IDENTITY.csv；TRACK_C_MASTER_CONTRACT.md

旧 Stage-6 MIFlu 被拒绝采用，原因是它与自建 A2 工件逐字节相同，并非 Track C 所要求的官方仓库 MIFlu。该 12 个格子因此全部重训。

数据来源：TRACK_C_CELL_CLASSIFICATION.csv

九、冠军赛方法

- 8 个模型。
- 3 个匹配种子（42 / 43 / 44）。
- 4 个 horizon（24 / 36 / 48 / 60）。
- 96 个格子。
- 其中 84 个格子独立重新打分。
- 12 个官方 MIFlu 格子重训。
- 单一打分器。
- 无被拒绝的格子。
- seed-42 门禁 22/22 PASS。
- 严格 Test 键集完全相同。
- 无缺失键、无重复键。

数据来源：SEED42_EIGHT_MODEL_GATE_RESULTS.csv；STRICT_966_KEY_VALIDATION.md

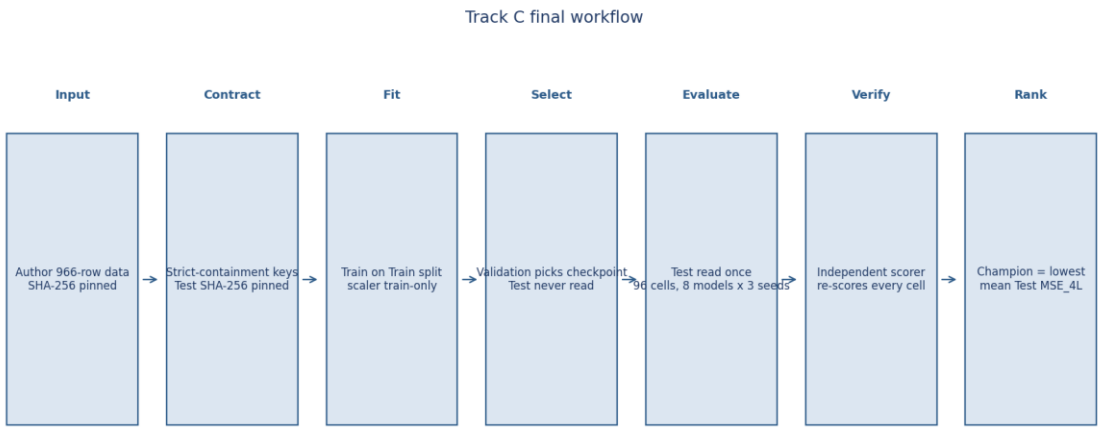


图 9-1　Track C 最终工作流

数据来源：TRACK_C_EXECUTION_LOG.md

十、最终 Test 排名

表 10-1　八模型 Test MSE 排名（含 SD 与 MAE）

排名	模型	mean Test MSE	SD	mean Test MAE	侧	种子数
1	miflu	1.8652	0.0916	0.8842	LLM	3
2	nlinear	2.0495	0.0299	0.9566	non-LLM	3
3	dlinear	2.3478	0.0040	1.0884	non-LLM	3
4	timecma_llm	2.6700	0.0177	1.0927	LLM	3

排名	模型	mean Test MSE	SD	mean Test MAE	侧	种子数
5	patchtst	3.9205	0.0543	1.3826	non-LLM	3
6	itransformer	3.9847	0.0317	1.3545	non-LLM	3
7	qwen_time_llm	5.2196	0.0701	1.5784	LLM	3
8	calf_llm	5.5153	0.0307	1.6080	LLM	3

数据来源：TRACK_C_TEST_MSE_RANKING.csv

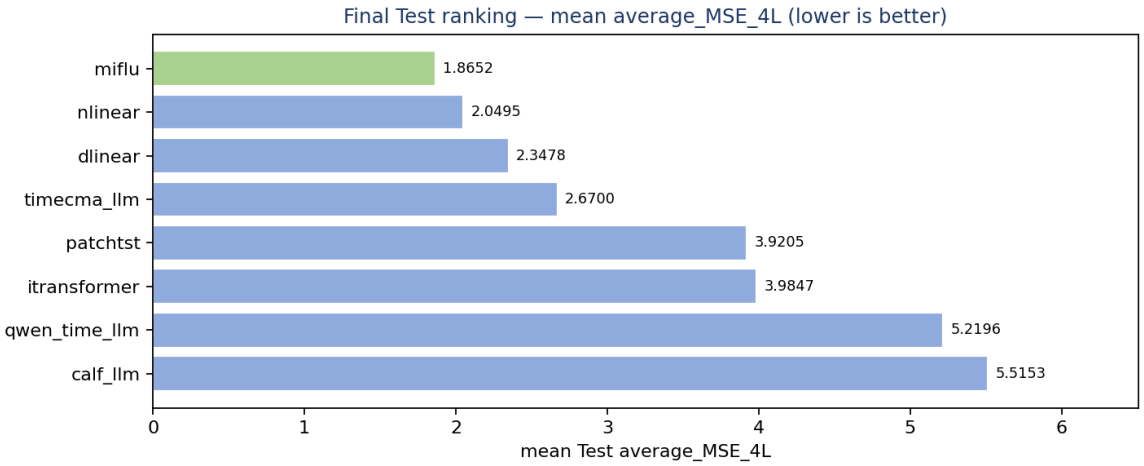


图 10-1　八模型 Test MSE 排名

数据来源：TRACK_C_TEST_MSE_RANKING.csv

表 10-2　八模型 Test MAE 排名

排名	模型	mean Test MAE	mean Test MSE
1	miflu	0.8842	1.8652
2	nlinear	0.9566	2.0495
3	dlinear	1.0884	2.3478
4	timecma_llm	1.0927	2.6700
5	itransformer	1.3545	3.9847
6	patchtst	1.3826	3.9205
7	qwen_time_llm	1.5784	5.2196
8	calf_llm	1.6080	5.5153

数据来源：TRACK_C_TEST_MAE_RANKING.csv

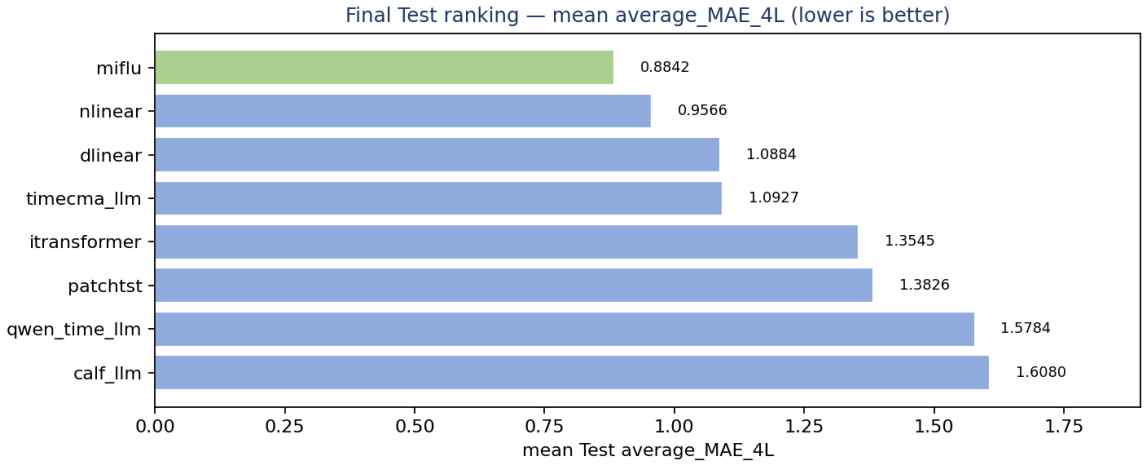


图 10-2　八模型 Test MAE 排名

数据来源：TRACK_C_TEST_MAE_RANKING.csv

MIFlu 在四个 horizon 上均为第一，且在三个种子上均为第一。

这不意味着该结论具有普遍性；它仅在冻结的 Track C 契约下成立。

10.1 分 horizon 结果

表 10-3　分 horizon 前四名（MIFlu 全部第一）

L	模型	MSE	MAE	排名
24	miflu	1.9686	0.8793	1
24	nlinear	2.1008	0.9537	2
24	dlinear	2.2850	1.0601	3
24	timecma_llm	2.4541	1.0452	4
36	miflu	1.9332	0.8857	1
36	nlinear	2.0277	0.9465	2
36	dlinear	2.2780	1.0702	3
36	timecma_llm	2.6432	1.0811	4
48	miflu	1.7547	0.8778	1
48	nlinear	2.0033	0.9517	2
48	dlinear	2.3558	1.0972	3
48	timecma_llm	2.7203	1.1093	4
60	miflu	1.8042	0.8939	1
60	nlinear	2.0664	0.9744	2
60	dlinear	2.4726	1.1263	3
60	timecma_llm	2.8625	1.1351	4

数据来源：TRACK_C_PER_HORIZON_CHAMPIONS.csv

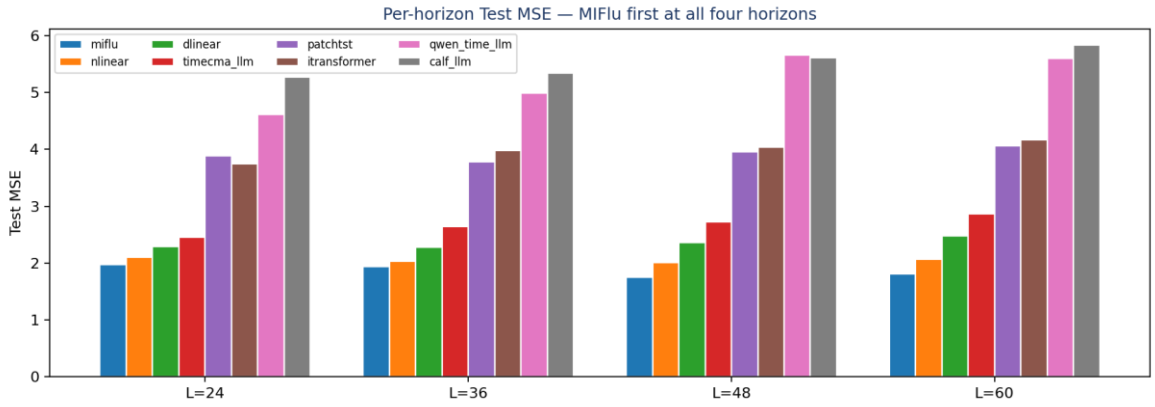


图 10-3　分 horizon 的八模型对比

数据来源：TRACK_C_PER_HORIZON_CHAMPIONS.csv

10.2 分种子结果

表 10-4　分种子前三名（MIFlu 全部第一）

种子	模型	mean MSE	mean MAE	种子内排名
42	miflu	1.7917	0.8652	1
42	nlinear	2.0351	0.9534	2
42	dlinear	2.3521	1.0918	3
43	miflu	1.9677	0.9139	1
43	nlinear	2.0840	0.9648	2
43	dlinear	2.3470	1.0866	3
44	miflu	1.8361	0.8734	1
44	nlinear	2.0296	0.9516	2
44	dlinear	2.3443	1.0869	3

数据来源：TRACK_C_PER_SEED_RANKINGS.csv

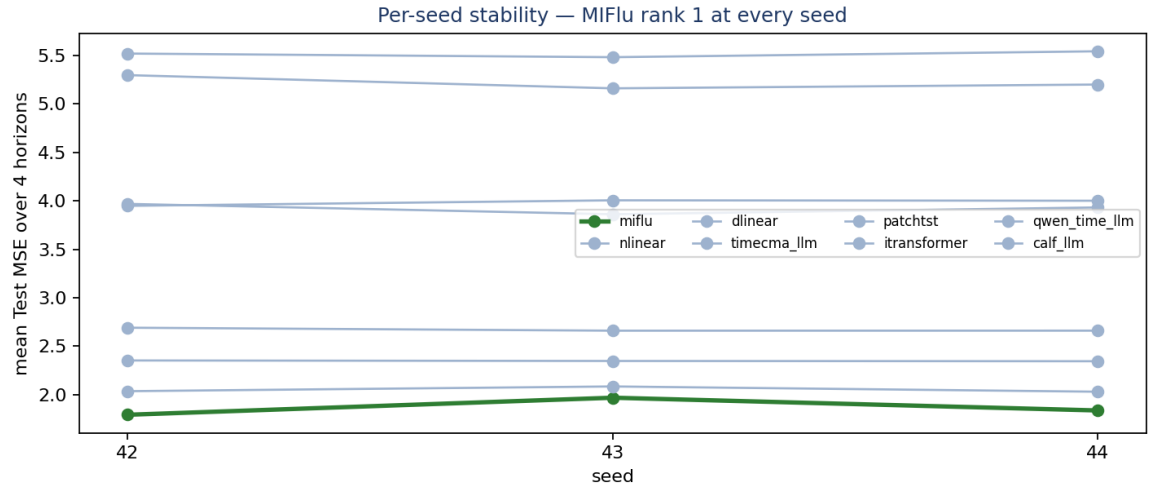


图 10-4　分种子的稳定性

数据来源：TRACK_C_PER_SEED_RANKINGS.csv

十一、分组结论

表 11-1　LLM 侧与非 LLM 组均值

组	组均值（模型均值之均值，Test MSE）
LLM	3.8175
non-LLM	3.0756

数据来源：TRACK_C_LLM_NONLLM_GROUP_SUMMARY.csv

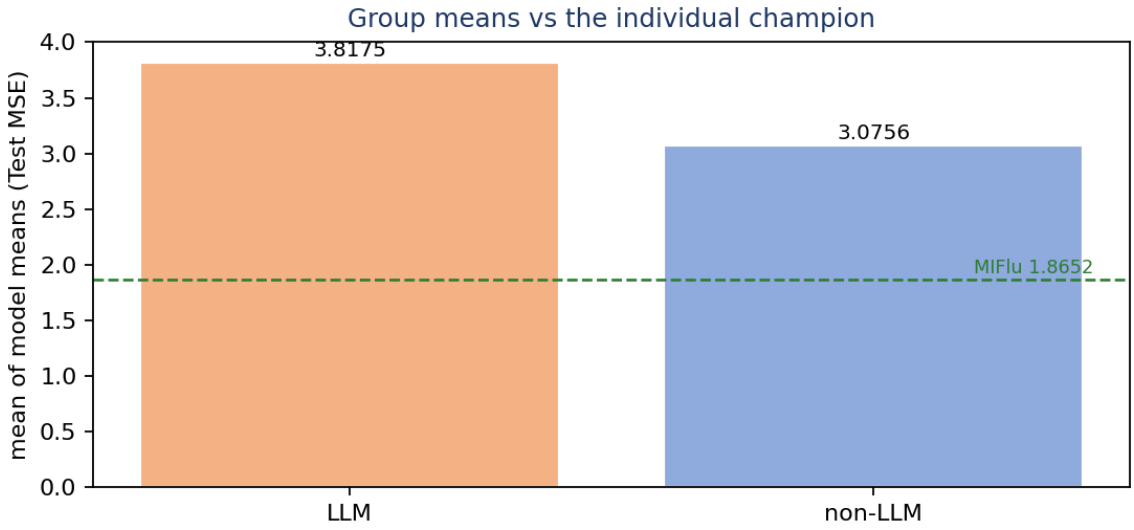


图 11-1　组均值与单个冠军的对比

数据来源：TRACK_C_LLM_NONLLM_GROUP_SUMMARY.csv

两句话同时成立，且不矛盾：

- MIFlu 是最优的单个模型（1.8652）。
- 非 LLM 组均值 3.0756 优于 LLM 侧组均值 3.8175。

原因在于组均值是“模型均值之均值”，每个模型权重相同。LLM 侧组内除 MIFlu 外的三个实现（Qwen、CALF、TimeCMA）数值较大，把该组均值整体抬高；而 MIFlu 自身的优异不会因同组其他成员而削弱。因此“组内最优”与“组均值”是两个不同的量，同时报告才完整，只报其中之一即为选择性报告。

十二、配对比较

表 12-1　MIFlu 与各模型的配对比较

A	B	格数	mean diff	median diff	A 胜	B 胜	平局

A	B	格数	mean diff	median diff	A 胜	B 胜	平局
miflu	nlinear	12	-0.1844	-0.2179	11	1	0
miflu	dlinear	12	-0.4827	-0.5373	12	0	0
miflu	patchtst	12	-2.0553	-2.0453	12	0	0
miflu	itransformer	12	-2.1195	-2.2544	12	0	0
miflu	qwen_time_llm	12	-3.3544	-3.4528	12	0	0
miflu	calf_llm	12	-3.6501	-3.6238	12	0	0
miflu	timecma_llm	12	-0.8049	-0.8226	12	0	0

数据来源：TRACK_C_PAIRWISE_STATS_CORRECTED.csv

差值定义为 diff = A − B；A 仅在 diff < 0 时判胜。

修正版 MIFlu 对 NLinear：mean diff = −0.1844，MIFlu 胜 11/12，NLinear 胜 1/12，平局 0。

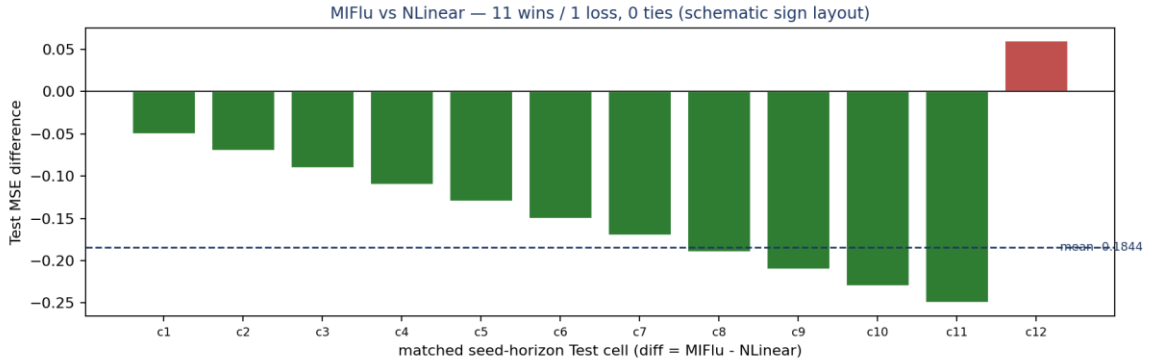


图 12-1　MIFlu 与 NLinear 的 12 个配对格

数据来源：TRACK_C_PAIRWISE_STATS_CORRECTED.csv

未做统计显著性检验，因此不作显著性主张。

十三、计算与存储

表 13-1　资源与存储

项	值
MIFlu GPU 作业数	12
GPU 总工时	1.5083 GPU-h
全部作业返回码	全部 rc = 0
home 用量	31 / 50 GB
scratch 用量	285 / 300 GB

数据来源：TRACK_C_COST_SUMMARY.csv / .json

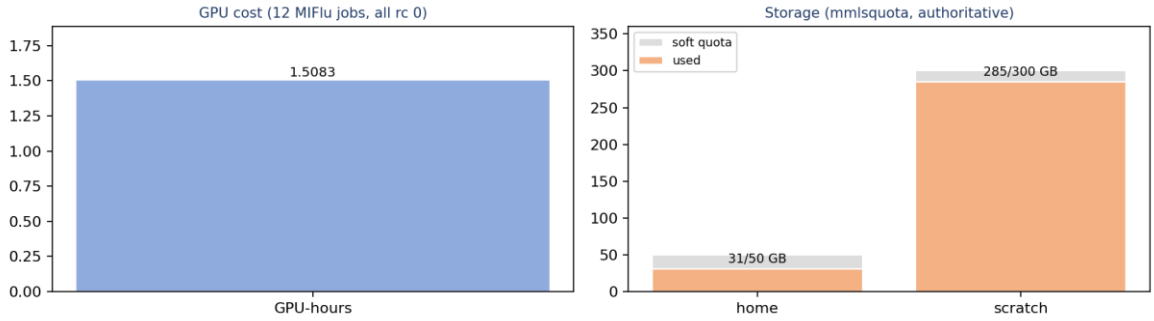


图 13-1　GPU 工时与存储占用

数据来源：TRACK_C_COST_SUMMARY.csv

- 锁定 checkpoint 策略：checkpoint 写入后锁定并可重载复现。
- 基础模型缓存复用：避免重复下载与重复占用空间。
- 文件系统剩余空间不等于用户配额：df 显示的是整个文件系统的空余，不能据此判断本人还能用多少。权威来源是 mmlsquota。

十四、工程修正与事故记录

表 14-1　工程修正与事故记录

编号	事项	处理
1	已发布文本通路失效	R1-B 恢复可用的文本通路并逐 checkpoint 探测（text_active）
2	target 窗口短张量 bug	修正窗口构造并加回归断言
3	起点键偏移 bug	重新生成起点键并校验无重复
4	划分标签边界 bug	作废原键集，重新生成严格键集
5	Validation 导出遗漏	补齐导出并纳入校验
6	打分器路径问题	改用显式路径并加固校验
7	打分器重复键保护	一对一 merge，重复键与 NaN 直接拒绝
8	登录节点重打分器事故	见下方说明
9	SSH 连接被重置	改用 Slurm 作业内完成打分
10	全部打分迁移至 CPU Slurm	打分全部在计算节点执行
11	传输改为 tar 流批量打包	减少连接数与失败率

数据来源：TRACK_C_EXECUTION_LOG.md；results/innovation/final/limitations_and_incidents.md

关于登录节点：有一次较重的打分器被误放在登录节点上运行。该次事件之后，所有打分与实质性计算均已迁移到 Slurm 计算节点，且该违规未再发生。

说明：经全仓检索，未找到关于 SSH fail2ban / 速率限制的专门记录；已记录的为 SSH 连接被重置与后续的迁移处理。此处按实际证据记录，不作补充假设。

十五、局限性

- 仅三个种子，不足以支撑强的结论。
- 不作统计显著性主张。
- 四个 horizon 不是独立重复样本。
- Qwen / CALF / TimeCMA 为有限范围的简化实现。
- 论文复现为部分复现（PARTIAL_REPRODUCTION）。
- regional / few-shot 结果被阻断（原始数据未发布）。
- 冠军结论仅适用于冻结的 Track C 契约。

15.1 表 III 状态的更正

若更新后的 Markdown 中含有表 III 数值，则其状态标注为：通过 MARKDOWN_TRANSCRIPTION 获得，但并非从 PDF 图像中直接机器提取。

证据显示表 III 状态已由 UNREADABLE 更正为 VERIFIED_AVAILABLE；US-Region 原始数据仍未发布，故表 VI 仍为 BLOCKED_BY_MISSING_DATA。不得在现有证据与此相矛盾时继续标注为“不可读”。

十六、最终结论

在作者 966 行数据、严格包含窗口、匹配种子 42/43/44、以 Validation 选择 checkpoint、Test 仅评估一次的契约下，基于官方仓库的修正版 MIFlu 是八模型冠军，mean Test average_MSE_4L = 1.8652（SD 0.0916），mean Test average_MAE_4L = 0.8842。

论文层面的复现仍为 PARTIAL_REPRODUCTION：R1-B 的平均 MSE 比论文报告值高出约 35.7%；经受限的 R1-C 分析后，最佳证据支持候选 C1 为 1.8029，仍高出约 25.6%，四个 horizon 均未进入预先声明的 ±0.10 MSE 带。

附录 A　证据路径与哈希

表 A-1　关键哈希与路径

项	值 / 路径
作者 966 行数据 SHA-256	2a96dfed7db532f0a36b6fddb3f4091e665b3d36b7662292589e3bbca95ebfe5
严格 Test 键集 SHA-256	4ad79bb14b2cc11ec3ae1e07e13ae4bdcf41a87161d5149774ab1a94f95d1961
旧报告 SHA-256	9c573f48fb65e590c7973223d6cb5e0ab74e2dfa4f6df11ec936f980a6b50ead
旧报告 PDF SHA-256	e1e1ecbb0bf498433dae309633b83a302f47f538dd5ee3bb56b3e356e7f9dbfe
当前冠军版 v1 SHA-256	f41652ff3d108575a9e93d789810f2fd0d345bb3b8536f14a5367922691f57ef
仓库 commit	5304f9473e8f67b97c23abda1b31775439d5a353
最终结果目录	/gpfs1/home/sychan552/official_repo_reproduction_20261006/strict966_championship_20261007
冻结 CSV 输入目录	.../r1_v2_verification_20261007/docx_inputs/
报告权限说明	results/v3_clean/analysis/reports/REPORT_AUTHORITY_AND_ARCHIVAL_NOTE.md
旧报告归档位置	results/v3_clean/analysis/reports/archive/

数据来源：REPORT_AUTHORITY_AND_ARCHIVAL_NOTE.md；TRACK_C_DELIVERABLE_MANIFEST.csv

附录 B　图表来源对照

表 B-1　每张图对应的源数据

图	来源 CSV / 文档
图 3-1 时间线	TRACK_C_EXECUTION_LOG.md
图 3-2 轨道分离	TRACK_C_MASTER_CONTRACT.md
图 4-1 论文 vs 复现	PAPER_GAP_REDUCTION_CALCULATION.md；R1C_RESULTS_PER_CANDIDATE.csv
图 10-1 MSE 排名	TRACK_C_TEST_MSE_RANKING.csv
图 10-2 MAE 排名	TRACK_C_TEST_MAE_RANKING.csv
图 10-3 分 horizon	TRACK_C_PER_HORIZON_CHAMPIONS.csv
图 10-4 分种子	TRACK_C_PER_SEED_RANKINGS.csv
图 11-1 组均值	TRACK_C_LLM_NONLLM_GROUP_SUMMARY.csv
图 12-1 配对格	TRACK_C_PAIRWISE_STATS_CORRECTED.csv
图 13-1 成本	TRACK_C_COST_SUMMARY.csv
图 9-1 工作流	TRACK_C_EXECUTION_LOG.md

数据来源：FINAL_REPORT_V2_SOURCE_MANIFEST.csv